

# Theoretical Foundations of GWR with GNN-Based Adaptive Kernels

---

## 1. Model (Intuition and Formal Definition)

### 1.1 Intuisi Model (dengan GNN sejak awal)

Kita mempelajari hubungan antara variabel respon dan kovariat yang **bervariasi secara spasial**. Namun, kita **tidak ingin**:

- memaksakan bentuk kernel spasial tertentu (Gaussian, bisquare, dsb),
- karena struktur spasial **bisa kompleks** (barrier, anisotropi, klaster).

Sebagai gantinya:

**Kita membiarkan bobot spasial dipelajari dari data, tetapi tetap menjaga lokalitas spasial** agar inferensi sah.

Dengan kata lain:

- **GWR tetap model inferensi utama,**
- **GNN hanya berperan sebagai *estimator kernel adaptif*.**

### 1.2 Data dan Notasi

Kita mengamati  $n$  observasi independen:

$$\{(Y_i, X_i, U_i)\}_{i=1}^n$$

dengan:

- $Y_i \in \mathbb{R}$  – variabel respon (skalar)
- $X_i \in \mathbb{R}^p$  – vektor kovariat berdimensi  $p$
- $U_i \in \mathbb{R}^d$  – lokasi spasial berdimensi  $d$

### 1.3 Model Struktural (*data-generating process*)

Model sebenarnya diasumsikan:

$$Y_i = X_i^\top \beta(U_i) + \varepsilon_i$$

Penjelasan:

- $\beta(\cdot) : \mathbb{R}^d \rightarrow \mathbb{R}^p$  – fungsi koefisien spasial yang **halus**
- $\beta(U_i)$  – koefisien lokal sebenarnya di lokasi  $U_i$
- $\varepsilon_i$  – error acak dengan mean nol

Target inferensi **tetap**:

$$\beta(u_0)$$

untuk satu lokasi target tetap  $u_0 \in \mathbb{R}^d$ .

---

#### 1.4 Prinsip Lokalitas (belum pakai kernel)

Agar  $\beta(u_0)$  dapat diestimasi, kita perlu:

- hanya menggunakan observasi **cukup dekat** dengan  $u_0$ ,
- tetapi **jumlahnya bertambah** saat  $n$  membesar.

Untuk itu, diperkenalkan **bandwidth**  $h = h_n > 0$  dan neighborhood:

$$\mathcal{N}_h(u_0) = \{i : |U_i - u_0| \leq h\}$$

Dengan syarat asimtotik:

$$h \rightarrow 0, \quad nh^d \rightarrow \infty$$

✳ **Sampai titik ini: belum ada kernel, belum ada GNN.** Ini murni struktur nonparametrik lokal.

---

## 2. Asumsi Klasik yang Digunakan

Asumsi berikut **bukan** CLM global, melainkan **versi lokal untuk GWR dengan kernel adaptif**.

#### (A1) Independensi

$$\{(X_i, U_i, \varepsilon_i)\}_{i=1}^n \quad \text{i.i.d.}$$

#### (A2) Eksogenitas Lokal

$$\boxed{\mathbb{E}[\varepsilon_i \mid X_i, U_i] = 0}$$

Ini menjamin bahwa **ketidakpastian hanya berasal dari error**, bukan dari desain pembobotan.

#### (A3) Variansi Terbatas

$$\mathbb{E}[\varepsilon_i^2 \mid X_i, U_i] = \sigma^2 < \infty$$

#### (A4) Momen Kovariat Terbatas

$$\mathbb{E}[|X_i|^2] < \infty$$

#### (A5) Kehalusan Koefisien Spasial

Fungsi  $\beta(u)$  memiliki turunan kedua kontinu di sekitar  $u_0$ . Ini memungkinkan **ekspansi Taylor lokal**.

✳ **Perhatikan:** Belum ada satu pun asumsi tentang **kernel atau GNN**. Itu sengaja.

---

### 3. Estimator: Kernel sebagai Fungsi yang Diestimasi oleh GNN

Di sinilah perbedaan fundamental dengan GWR klasik dimulai.

#### 3.1 Masalah yang Harus Diselesaikan

Dalam GWR klasik, bobot berbentuk:

$$w_i(u_0) = \frac{K\left(\frac{U_i - u_0}{h}\right)}{\sum_j K\left(\frac{U_j - u_0}{h}\right)}$$

Namun di sini:

- kita **tidak ingin menetapkan**  $K(\cdot)$  secara eksplisit,
- kita ingin **mempelajari bentuk kernel dari data**.

Maka kita perlukan:

suatu **fungsi pembobotan adaptif** yang **menggantikan kernel**, tetapi **tidak merusak struktur GWR**.

#### 3.2 Objek yang Ingin Kita Estimasi (kernel adaptif)

Kita ingin bobot berbentuk:

$$w_i(u_0) = \frac{\exp(s(U_i, X_i, u_0)) \cdot \mathbf{1}\{|U_i - u_0| \leq h\}}{\sum_{j: |U_j - u_0| \leq h} \exp(s(U_j, X_j, u_0))}$$

Penjelasan:

- $s(\cdot)$  adalah **fungsi skor**, belum ditentukan bentuknya
- indikator memastikan **lokalitas keras**
- softmax memastikan:
  - bobot positif
  - jumlah bobot = 1

#### 3.3 Mengapa Fungsi Skor $s(\cdot)$ Harus Dipelajari?

Karena:

- hubungan spasial bisa **anisotropik**,
- jarak Euclidean saja tidak cukup,
- informasi graf (keterhubungan wilayah) penting.

Maka:

$s(\cdot)$  harus mampu memproses struktur graf

Di sinilah GNN menjadi pilihan natural.

### 3.4 Definisi Formal: GNN sebagai Estimator Kernel

Kita definisikan sebuah fungsi parametrik:

$$s_{\theta}(i, u_0) = \text{GNN}_{\theta} \left( \mathcal{G}_h(u_0), \mathbf{f}_i(u_0) \right)$$

dengan:

- $\mathcal{G}_h(u_0)$ : graf lokal dengan node  $i \in \mathcal{N}_h(u_0)$
- $\mathbf{f}_i(u_0)$ : fitur node, **minimal** berisi

$$\mathbf{f}_i(u_0) = (X_i, U_i - u_0)$$

✦ **Belum ada embedding atau layer disebutkan.** Kita hanya butuh: GNN = fungsi kontinu, terbatas, dan invariant terhadap permutasi node.

### 3.5 Bobot Akhir (kernel hasil estimasi GNN)

Bobot lokal didefinisikan sebagai:

$$w_i(u_0) = \frac{\exp(s_{\theta}(i, u_0))}{\sum_{j \in \mathcal{N}_h(u_0)} \exp(s_{\theta}(j, u_0))}$$

Inilah **kernel adaptif yang diestimasi dari data**.

### 3.6 Estimator GWR dengan Kernel Hasil GNN

Definisikan matriks bobot:

$$W_{\theta}(u_0) = \text{diag}(w_1(u_0), \dots, w_n(u_0))$$

Estimator koefisien lokal:

$$\hat{\beta}(u_0) = (X^{\top} W_{\theta}(u_0) X)^{-1} X^{\top} W_{\theta}(u_0) Y$$

✦ **Inilah estimator yang akan kita analisis.**

---

## 4. Penurunan Konsistensi Koefisien Lokal

(dengan kernel yang diestimasi oleh GNN)

### 4.1 Tujuan Formal

Yang ingin kita buktikan adalah:

$$\hat{\beta}(u_0) \xrightarrow{p} \beta(u_0)$$

artinya: estimator koefisien lokal berbasis GWR dengan **kernel hasil GNN** adalah **konsisten** untuk koefisien lokal sebenarnya.

### 4.2 Mulai dari Definisi Estimator

Estimator didefinisikan sebagai:

$$\hat{\beta}(u_0) = (X^\top W_\theta(u_0)X)^{-1} X^\top W_\theta(u_0)Y$$

dengan:

- $W_\theta(u_0)$  matriks diagonal berisi bobot
- bobot:

$$w_i(u_0) = \frac{\exp(s_\theta(i, u_0))}{\sum_{j \in \mathcal{N}_h(u_0)} \exp(s_\theta(j, u_0))}$$

#### 4.3 Substitusi Model Struktural

Ingat model sebenarnya:

$$Y = X\beta(U) + \varepsilon$$

Substitusi ke estimator:

$$\hat{\beta}(u_0) = (X^\top W X)^{-1} X^\top W (X\beta(U) + \varepsilon)$$

Pisahkan:

$$= (X^\top W X)^{-1} X^\top W X \beta(U) + (X^\top W X)^{-1} X^\top W \varepsilon$$

Sampai sini **belum ada probabilitas**. Ini **identitas aljabar murni**.

#### 4.4 Trik Fundamental: Tambah–Kurang $\beta(u_0)$

Tuliskan untuk setiap observasi:

$$\beta(U_i) = \beta(u_0) + (\beta(U_i) - \beta(u_0))$$

Maka:

$$X^\top W X \beta(U) = X^\top W X \beta(u_0) + X^\top W X (\beta(U) - \beta(u_0))$$

Substitusi kembali:

$$\hat{\beta}(u_0) = \beta(u_0) + \underbrace{(X^\top W X)^{-1} X^\top W X (\beta(U) - \beta(u_0))}_{\text{Bias term}} + \underbrace{(X^\top W X)^{-1} X^\top W \varepsilon}_{\text{Noise term}}$$

✳ **Inilah dekomposisi utama.** Semua analisis konsistensi bergantung pada dua suku ini.

#### 4.5 Strategi Pembuktian Konsistensi

Untuk menunjukkan:

$$\hat{\beta}(u_0) \xrightarrow{p} \beta(u_0)$$

cukup menunjukkan bahwa:

##### 1. Bias term

$$(X^\top W X)^{-1} X^\top W X (\beta(U) - \beta(u_0)) \xrightarrow{p} 0$$

## 2. Noise term

$$(X^\top W X)^{-1} X^\top W \varepsilon \xrightarrow{p} 0$$

### 4.6 Analisis Bias Term (bagian deterministik)

#### 4.6.1 Gunakan Kehalusan $\beta(\cdot)$

Dari Asumsi (A5),  $\beta(\cdot)$  dua kali terdiferensiasi. Maka, untuk  $U_i$  dekat  $u_0$ :

$$\beta(U_i) = \beta(u_0) + \nabla \beta(u_0)^\top (U_i - u_0) + R_i$$

dengan remainder:

$$|R_i| \leq C |U_i - u_0|^2$$

#### 4.6.2 Substitusi ke Bias Term

Bias term menjadi:

$$(X^\top W X)^{-1} \sum_{i=1}^n w_i X_i X_i^\top \left[ \nabla \beta(u_0)^\top (U_i - u_0) + R_i \right]$$

Pisahkan dua bagian: 1. **Suku linear** 2. **Suku remainder kuadrat**

#### 4.6.3 Kenapa Suku Linear Hilang?

Kita ingin:

$$\sum_i w_i (U_i - u_0) \approx 0$$

Agar ini benar, **kita mentok** dan harus membuat **asumsi/desain**.

#### ● TITIK KEBUNTUAN PERTAMA

Jika bobot **tidak simetris** terhadap  $u_0$ , maka:

$$\sum_i w_i (U_i - u_0) \neq 0$$

➡ Bias menjadi orde  $h$ , konsistensi tetap bisa, tapi sangat buruk.

**Maka kita BUTUH:**

**Asumsi (K1) – Local symmetry (implisit)**

Secara formal:

$$\sum_{i \in \mathcal{N}_h(u_0)} w_i (U_i - u_0) \xrightarrow{p} 0$$

**Bagaimana ini DICAPAI dengan GNN?**

➡ **Desain, bukan asumsi kosong:**

- input GNN memakai  $(U_i - u_0)$  (koordinat relatif)
- graf dibangun simetris di sekitar  $u_0$
- output di-softmax  $\rightarrow$  bobot ter-normalisasi

Ini membuat **ekspektasi bobot simetris** meskipun bentuk kernel fleksibel.

✳ **Catatan penting:** Kita TIDAK mengasumsikan GNN simetris sempurna, hanya bahwa **dalam limit**, bobot tidak bias arah.

#### 4.6.4 Remainder Term

Karena:  $|U_i - u_0| \leq h$ ,  $|R_i| \leq Ch^2$ ,

maka:

$$\left| (X^\top W X)^{-1} \sum_i w_i X_i X_i^\top R_i \right| = O_p(h^2)$$

Dan karena  $h \rightarrow 0$ :

$$O_p(h^2) \rightarrow 0$$

#### 4.6.5 Kesimpulan Bias Term

$$\boxed{\text{Bias term} \xrightarrow{p} 0}$$

#### 4.7 Analisis Noise Term (bagian stokastik)

Sekarang bagian **paling berbahaya**:

$$(X^\top W X)^{-1} X^\top W \varepsilon$$

##### 4.7.1 Masalah Utama

Bobot  $W$  dihasilkan oleh GNN dari data. Maka secara umum:

$$\mathbb{E}[X^\top W \varepsilon] \neq 0$$

➡ LLN gagal, konsistensi gagal.

#### ● TITIK KEBUNTUAN KEDUA

Tanpa intervensi, estimator **TIDAK konsisten**.

##### 4.7.2 Solusi: Cross-fitting (desain, bukan asumsi)

**Konstruksi**

Bagi data:

$$\{1, \dots, n\} = I_1 \cup I_2$$

- Gunakan  $I_1$  untuk **melatih** GNN

- Gunakan  $I_2$  untuk **menghitung**  $\hat{\beta}(u_0)$

Bobot menjadi:

$$W_{\theta}^{(1)}(u_0) \text{ independen dari } \varepsilon_i, i \in I_2$$

### Konsekuensi kunci

Kondisional pada  $W^{(1)}$ :

$$\mathbb{E} [ X_i w_i \varepsilon_i \mid W^{(1)} ] = 0$$

→ LLN berlaku kembali

### 4.7.3 Konvergensi Noise Term

Karena: \*  $w_i$  bounded dan ter-normalisasi, \*  $X_i \varepsilon_i$  punya mean nol dan variansi terbatas, maka:

$$X^{\top} W \varepsilon = O_p ( \sqrt{nh^d} )$$

dan:

$$(X^{\top} W X)^{-1} = O_p ( (nh^d)^{-1} )$$

Sehingga:

$$(X^{\top} W X)^{-1} X^{\top} W \varepsilon = O_p ( (nh^d)^{-1/2} ) \xrightarrow{p} 0$$

karena  $nh^d \rightarrow \infty$ .

### 4.8 Kesimpulan Konsistensi

Gabungkan: \* bias term  $\rightarrow 0$  \* noise term  $\rightarrow 0$

maka:

$$\boxed{\hat{\beta}(u_0) \xrightarrow{p} \beta(u_0)}$$

### 4.9 Ringkasan Logika Konsistensi

Konsistensi koefisien lokal tercapai karena neighborhood menyempit, fungsi koefisien halus, bobot GNN bersifat lokal dan simetris secara limit, serta cross-fitting memulihkan eksogenitas antara bobot dan error.

## 5. Penurunan Variansi Koefisien Lokal

(GWR dengan kernel hasil GNN, cross-fitted)



### 5.1 Tujuan Formal

Kita ingin menghitung (atau membatasi orde dari):

$$\text{Var} \left( \hat{\beta}(u_0) \right)$$

lebih tepatnya, **orde asimtotiknya** sebagai fungsi dari: \* ukuran sampel  $n$ , \* bandwidth  $h$ , \* dimensi spasial  $d$ .

### 5.2 Ingat Kembali Dekomposisi

Dari Part 4, kita punya:

$$\hat{\beta}(u_0) = \beta(u_0) + \underbrace{B_n(u_0)}_{\text{bias}} + \underbrace{(X^\top W X)^{-1} X^\top W \varepsilon}_{\text{noise}}$$

Variansi hanya datang dari **noise term** karena: \*  $\beta(u_0)$  deterministik, \*  $B_n(u_0)$  deterministik bersyarat pada  $U$  (dan kecil).

Jadi:

$$\text{Var} \left( \hat{\beta}(u_0) \right) = \text{Var} \left( (X^\top W X)^{-1} X^\top W \varepsilon \right)$$

### 5.3 Notasi

- $W = W_\theta(u_0)$ : matriks bobot diagonal dengan elemen  $w_i = w_i(u_0)$
- $X$ : matriks desain  $n \times p$
- $\varepsilon = (\varepsilon_1, \dots, \varepsilon_n)^\top$
- Kita bekerja **kondisional pada bobot  $W$**  (ini sah karena cross-fitting)

### 5.4 Variansi Bersyarat

Karena cross-fitting membuat  $W$  **independen dari  $\varepsilon$**  pada fold estimasi, kita boleh menulis:

$$\text{Var} \left( \hat{\beta}(u_0) \right) = \mathbb{E} \left[ \text{Var} \left( (X^\top W X)^{-1} X^\top W \varepsilon \middle| W, X \right) \right]$$

### 5.5 Hitung Variansi Kondisional (aljabar matriks)

Gunakan fakta umum: Jika  $A$  matriks deterministik dan  $\text{Var}(\varepsilon \mid X, U) = \sigma^2 I_n$ , maka:

$$\text{Var}(A\varepsilon) = \sigma^2 A A^\top$$

Di sini:

$$A = (X^\top W X)^{-1} X^\top W$$

Maka:

$$\text{Var} \left( (X^\top W X)^{-1} X^\top W \varepsilon \middle| W, X \right) = \sigma^2 (X^\top W X)^{-1} X^\top W^2 X (X^\top W X)^{-1}$$

✦ **Ini ekspresi variansi eksak** (belum asimtotik).

## 5.6 Orde Asimtotik

### 5.6.1 Orde dari $X^\top W X$

Perhatikan:

$$X^\top W X = \sum_{i=1}^n w_i X_i X_i^\top$$

Karena: \* bobot  $w_i$  hanya non-nol di neighborhood  $\mathcal{N}_h(u_0)$ , \* ukuran neighborhood  $\#\mathcal{N}_h(u_0) \asymp nh^d$ , \* dan bobot **ter-normalisasi** ( $\sum w_i = 1$ ),

maka secara orde:

$$X^\top W X = O_p(nh^d)$$

Lebih tepatnya:

$$\frac{1}{nh^d} X^\top W X \xrightarrow{p} Q(u_0)$$

dengan  $Q(u_0)$  matriks positif definit.

Akibatnya:

$$(X^\top W X)^{-1} = O_p((nh^d)^{-1})$$

### 5.6.2 Orde dari $X^\top W^2 X$

Sekarang:

$$X^\top W^2 X = \sum_{i=1}^n w_i^2 X_i X_i^\top$$

Karena: \*  $w_i = O((nh^d)^{-1})$  secara tipikal (bobot dibagi rata), \* hanya  $nh^d$  observasi yang relevan,

maka:

$$X^\top W^2 X = O_p((nh^d)^{-1})$$

### 5.6.3 Gabungkan Semuanya

Substitusi orde ke ekspresi variansi:

$$\text{Var}(\hat{\beta}(u_0)) = \underbrace{\sigma^2 O_p((nh^d)^{-1})}_{(X^\top W X)^{-1}} \cdot \underbrace{O_p((nh^d)^{-1})}_{X^\top W^2 X} \cdot \underbrace{O_p((nh^d)^{-1})}_{(X^\top W X)^{-1}}$$

Sehingga:

$$\text{Var} ( \hat{\beta}(u_0) ) = O\left(\frac{1}{nh^d}\right)$$

### 5.7 Bentuk Limit Variansi (lebih presisi)

Dengan normalisasi yang tepat, kita bisa tulis:

$$\text{Var} ( \hat{\beta}(u_0) ) \approx \frac{\sigma^2}{nh^d} Q(u_0)^{-1} \Omega(u_0) Q(u_0)^{-1}$$

dengan: \*  $Q(u_0) = \mathbb{E}[X_i X_i^\top \mid U_i \approx u_0]$  \*  $\Omega(u_0) = \mathbb{E}[w_i^2 X_i X_i^\top \mid U_i \approx u_0]$

✦ Bentuk “sandwich” ini akan muncul lagi di CLT.

### 5.8 Interpretasi

#### 5.8.1 Mengapa Muncul $nh^d$ ?

Karena: \* hanya observasi di radius  $h$  yang dipakai, \* jumlahnya  $\asymp nh^d$ .

Ini adalah **effective local sample size**.

#### 5.8.2 Trade-off Inti GWR

- $h$  kecil  $\rightarrow$  bias kecil, tapi variansi besar
- $h$  besar  $\rightarrow$  bias besar, tapi variansi kecil

✦ Variansi memberi **harga statistik** dari pelokalan.

### 5.9 Ringkasan

$$\text{Var} ( \hat{\beta}(u_0) ) = O\left(\frac{1}{nh^d}\right)$$

Ini menyiratkan bahwa **skala fluktuasi alami** dari estimator adalah:

$$\sqrt{nh^d} ( \hat{\beta}(u_0) - \beta(u_0) )$$

➡ Ini tepat skala yang akan kita pakai di CLT.

## 6. Penurunan Distribusi Koefisien Lokal

(GWR dengan kernel hasil GNN, cross-fitted)

### 6.1 Tujuan Formal

Kita ingin mempelajari limit distribusi dari estimator  $\hat{\beta}(u_0)$ . Secara khusus, kita ingin mencari **skala normalisasi**  $a_n$  sedemikian sehingga:

$$a_n ( \hat{\beta}(u_0) - \beta(u_0) ) \xrightarrow{d} \text{distribusi non-degenerate}$$

Dari Part 5, kita sudah tahu:

$$\text{Var} ( \hat{\beta}(u_0) ) = O\left(\frac{1}{nh^d}\right)$$

→ Ini langsung memberi kandidat normalisasi:

$$a_n = \sqrt{nh^d}$$

## 6.2 Kembali ke Dekomposisi Lengkap

Dari Part 4, kita punya:

$$\hat{\beta}(u_0) = \beta(u_0) + B_n(u_0) + V_n(u_0)$$

dengan:

- **Bias term**

$$B_n(u_0) = (X^\top W X)^{-1} X^\top W X ( \beta(U) - \beta(u_0) )$$

- **Noise term**

$$V_n(u_0) = (X^\top W X)^{-1} X^\top W \varepsilon$$

Kalikan seluruh persamaan dengan  $\sqrt{nh^d}$ :

$$\sqrt{nh^d} ( \hat{\beta}(u_0) - \beta(u_0) ) = \underbrace{\sqrt{nh^d} B_n(u_0)}_{\text{bias terstandar}} + \underbrace{\sqrt{nh^d} V_n(u_0)}_{\text{noise terstandar}}$$

Distribusi limit **ditentukan oleh dua suku ini.**

## 6.3 Distribusi Noise Term (CLT inti)

### 6.3.1 Tulis Noise Term sebagai Jumlah Eksplisit

Ingat:

$$V_n(u_0) = (X^\top W X)^{-1} \sum_{i=1}^n w_i X_i \varepsilon_i$$

Kalikan dengan  $\sqrt{nh^d}$ :

$$\sqrt{nh^d} V_n(u_0) = \left( \frac{1}{nh^d} X^\top W X \right)^{-1} \left( \frac{1}{\sqrt{nh^d}} \sum_{i=1}^n w_i X_i \varepsilon_i \right)$$

Perhatikan bahwa ini adalah **produk dua faktor**: 1. satu yang akan konvergen **dalam probabilitas**, 2. satu yang akan konvergen **dalam distribusi**.

### 6.3.2 Limit Faktor Pertama (deterministik secara limit)

Dari Part 5:

$$\frac{1}{nh^d} X^\top W X \xrightarrow{p} Q(u_0)$$

dengan  $Q(u_0)$  matriks positif definit.

Maka:

$$\left( \frac{1}{nh^d} X^\top W X \right)^{-1} \xrightarrow{p} Q(u_0)^{-1}$$

### 6.3.3 Limit Faktor Kedua (CLT sesungguhnya)

Sekarang perhatikan:

$$S_n = \frac{1}{\sqrt{nh^d}} \sum_{i=1}^n w_i X_i \varepsilon_i$$

Ini adalah objek yang akan kita CLT-kan.

Mengapa ini kandidat CLT?

Karena: 1. Berupa **jumlah dari banyak suku kecil** 2. Tiap suku punya **mean nol** 3. Variansi totalnya **tidak nol dan terbatas**

### 6.3.4 Mean Nol (di sinilah cross-fitting KRUSIAL)

Karena cross-fitting: \* bobot  $w_i$  ditentukan dari fold lain, \* sehingga  $w_i$  **independen dari  $\varepsilon_i$**  pada fold estimasi.

Maka:

$$\mathbb{E}[w_i X_i \varepsilon_i \mid X_i, U_i, W] = 0$$

dan:

$$\mathbb{E}[S_n \mid W] = 0$$

### 6.3.5 Variansi Terbatas dan Stabil

Variansi kondisional:

$$\text{Var}(S_n \mid W) = \frac{1}{nh^d} \sum_{i=1}^n w_i^2 \mathbb{E}[X_i X_i^\top \varepsilon_i^2 \mid U_i \approx u_0]$$

Dari Part 5, jumlah ini konvergen ke:

$$\Omega(u_0) = \mathbb{E}[w_i^2 X_i X_i^\top \mid U_i \approx u_0]$$

yang **positif definit** dan terbatas.

### 6.3.6 Aplikasi CLT

Karena: \* suku-suku independen, \* mean nol, \* variansi terbatas,

maka (CLT Lindeberg–Feller):

$$\boxed{S_n \xrightarrow{d} \mathcal{N} ( 0, \Omega(u_0) )}$$

### 6.3.7 Gabungkan Dua Faktor (Slutsky)

Karena satu faktor konvergen dalam probabilitas dan satu dalam distribusi:

$$\sqrt{nh^d} V_n(u_0) \xrightarrow{d} \mathcal{N} ( 0, Q(u_0)^{-1} \Omega(u_0) Q(u_0)^{-1} )$$

### 6.4 Peran Bias Term dalam Distribusi

Sekarang kita analisis:

$$\sqrt{nh^d} B_n(u_0)$$

Dari Part 4, kita tahu:

$$B_n(u_0) = O(h^2)$$

Maka:

$$\sqrt{nh^d} B_n(u_0) = O ( \sqrt{nh^d} h^2 )$$

#### 6.4.1 Dua Kemungkinan Fundamental

##### (i) Bias tidak hilang

Jika:

$$\sqrt{nh^d} h^2 \rightarrow c \neq 0$$

maka:

$$\sqrt{nh^d} ( \hat{\beta}(u_0) - \beta(u_0) ) \xrightarrow{d} \mathcal{N} ( \mu(u_0), Q^{-1} \Omega Q^{-1} )$$

dengan mean **tidak nol**:  $\mu(u_0) \neq 0$

➡ **Distribusi normal, tapi tidak terpusat** ➡ Inferensi Wald standar **tidak valid**

Ini terjadi, misalnya, jika: \* bandwidth dipilih optimal untuk prediksi (CV), \* tidak ada under-smoothing.

##### (ii) Bias dihilangkan (kasus inferensi)

Jika kita memaksakan:

$$\boxed{\sqrt{nh^d} h^2 \rightarrow 0}$$

yang ekuivalen dengan **undersmoothing**, maka:

$$\sqrt{nh^d} B_n(u_0) \xrightarrow{p} 0$$

### 6.5 Distribusi Asimtotik Akhir (kasus inferensi sah)

Di bawah kondisi undersmoothing:

$$\sqrt{nh^d} \left( \hat{\beta}(u_0) - \beta(u_0) \right) \xrightarrow{d} \mathcal{N} \left( 0, Q(u_0)^{-1} \Omega(u_0) Q(u_0)^{-1} \right)$$

Inilah jawaban akhir untuk pertanyaan distribusi.

### 6.6 Interpretasi

1. **Distribusi normal muncul karena CLT lokal**, bukan karena error normal
2. Skala  $\sqrt{nh^d}$  = akar dari **effective local sample size**
3. GNN **tidak mengubah bentuk limit**, hanya memengaruhi:
  - matriks  $Q(u_0)$ ,
  - matriks  $\Omega(u_0)$

### 6.7 Ringkasan Part 6

Setelah dinormalisasi oleh  $\sqrt{nh^d}$ , koefisien lokal GWR dengan kernel yang diestimasi oleh GNN berdistribusi normal asimtotik, asalkan bias dihilangkan melalui undersmoothing dan bobot dipelajari secara cross-fitted.

---

## 7. Ringkasan Asumsi dan Desain Model yang Diperlukan

Bagian ini **sangat penting secara akademis**, karena menunjukkan bahwa asumsi dan desain GNN bukan selera, tapi konsekuensi logis dari inferensi.

### 7.1 Asumsi Data dan Model (tidak bergantung pada GNN)

#### (A1) Independensi

$$\{(Y_i, X_i, U_i)\}_{i=1}^n \text{ i.i.d.}$$

→ Dipakai untuk: LLN, CLT lokal.

#### (A2) Eksogenitas Lokal

$$\mathbb{E}[\varepsilon_i \mid X_i, U_i] = 0$$

→ Dipakai untuk: mean nol noise term, validitas inferensi.

#### (A3) Variansi Error Terbatas

$$\mathbb{E}[\varepsilon_i^2 \mid X_i, U_i] = \sigma^2 < \infty$$

→ Dipakai untuk: variansi terbatas, CLT.

#### (A4) Momen Kovariat Terbatas

$$\mathbb{E}[|X_i|^2] < \infty$$

→ Dipakai untuk: kontrol  $X^\top W X$ , inversibilitas matriks desain lokal.

#### (A5) Kehalusan Fungsi Koefisien

$$\beta(\cdot) \in C^2 \text{ di sekitar } u_0$$

→ Dipakai untuk: Taylor expansion, analisis bias  $O(h^2)$ .

### 7.2 Asumsi Lokalitas (dipaksa oleh konsistensi)

#### (L1) Shrinking Neighborhood

$$h \rightarrow 0$$

→ Dipakai untuk: memastikan  $\beta(U_i) \approx \beta(u_0)$ , menghilangkan bias.

#### (L2) Local Sample Size Diverges

$$nh^d \rightarrow \infty$$

→ Dipakai untuk: LLN lokal, variansi  $\rightarrow 0$ .

✳️ Ini menjelaskan mengapa  $h$  TIDAK bisa dihilangkan, meskipun pakai GNN.

### 7.3 Asumsi Kernel (yang dipenuhi oleh desain GNN)

#### (K1) Non-negativity dan Normalisasi

$$w_i(u_0) \geq 0, \quad \sum_i w_i(u_0) = 1$$

→ Dipakai untuk: stabilitas estimator, interpretasi sebagai rata-rata lokal.

**Dipenuhi oleh:** softmax pada output GNN.

#### (K2) Boundedness

$$\sup_i w_i(u_0) \leq C(nh^d)^{-1}$$

→ Dipakai untuk: mencegah satu observasi mendominasi, CLT Lindeberg.

**Dipenuhi oleh:** softmax + neighborhood terbatas.

#### (K3) Regularity (Kontinuitas)

$$|w_i(u_0; Z) - w_i(u_0; Z')| \leq L|Z - Z'|$$

→ Dipakai untuk: uniform LLN, kontrol remainder.

**Dipenuhi oleh:** arsitektur GNN kontinu (aktivasi halus, tanpa threshold keras).

#### (K4) Simetri Lokal (implisit)

$$\sum_i w_i(u_0)(U_i - u_0) \xrightarrow{p} 0$$

→ Dipakai untuk: menghilangkan bias orde pertama.



**Dipenuhi oleh desain:** \* input relatif ( $U_i - u_0$ ), \* graf lokal simetris, \* normalisasi bobot.

#### 7.4 Asumsi Estimasi Bobot (khusus GNN)

##### (G1) Cross-fitting

Bobot  $w_i$  dipelajari dari data yang **tidak dipakai** untuk estimasi koefisien.

→ Dipakai untuk: memulihkan eksogenitas, memastikan  $\mathbb{E}[w_i \varepsilon_i] = 0$ .

Tanpa ini: konsistensi **gagal total**.

##### (G2) Bounded Complexity

Parameter GNN  $\theta$  berada dalam himpunan kompak.

→ Dipakai untuk: stabilitas limit, mencegah overfitting ekstrem.

#### 7.5 Asumsi Inferensi (untuk CLT terpusat)

##### (I1) Undersmoothing

$$\sqrt{nh^d}h^2 \rightarrow 0$$

→ Dipakai untuk: menghilangkan bias dalam limit, distribusi normal terpusat.

Tanpa ini: distribusi tetap normal, tapi **mean  $\neq 0$**  (inferensi Wald gagal).

---

## 8. Rangkuman Akhir: Model Formal, Asumsi, dan Desain End-to-End

### 8.1 Model Formal

Data:

$$(Y_i, X_i, U_i), \quad i = 1, \dots, n$$

Model:

$$Y_i = X_i^\top \beta(U_i) + \varepsilon_i$$

Target:

$$\beta(u_0)$$

### 8.2 Desain Estimator (end-to-end)

#### Step 1 – Neighborhood

$$\mathcal{N}_h(u_0) = \{i : |U_i - u_0| \leq h\}$$

#### Step 2 – Graph Lokal

Node:  $i \in \mathcal{N}_h(u_0)$

Fitur node:  $(X_i, U_i - u_0)$

### Step 3 – GNN sebagai Estimator Kernel

GNN menghasilkan skor:  $s_\theta(i, u_0)$

Bobot:

$$w_i(u_0) = \frac{\exp(s_\theta(i, u_0))}{\sum_{j \in \mathcal{N}_h(u_0)} \exp(s_\theta(j, u_0))}$$

### Step 4 – Cross-fitting

- GNN dilatih di fold A
- Koefisien dihitung di fold B
- Dirata-ratakan antar fold

### Step 5 – Estimasi Koefisien Lokal

$$\hat{\beta}(u_0) = (X^\top W_\theta X)^{-1} X^\top W_\theta Y$$

## 8.3 Jawaban Eksplisit atas Dua Pertanyaan Utama

### ? Apakah koefisien lokal konsisten?

✓ **YA**, jika: \* neighborhood menyempit, \* fungsi koefisien halus, \* bobot GNN lokal, bounded, dan cross-fitted.

$$\hat{\beta}(u_0) \xrightarrow{p} \beta(u_0)$$

### ? Apa distribusi koefisien lokal?

✓ **Normal asimtotik**, jika additionally: \* undersmoothing dilakukan.

$$\sqrt{nh^d}(\hat{\beta}(u_0) - \beta(u_0)) \xrightarrow{d} \mathcal{N}\left(0, Q(u_0)^{-1} \Omega(u_0) Q(u_0)^{-1}\right)$$

Jika tidak: \* distribusi tetap normal, \* tetapi **mean tidak nol**.

## 8.4 Ringkasan Satu Paragraf (siap pakai di tesis)

*This study establishes the consistency and asymptotic normality of local coefficients in geographically weighted regression with data-adaptive kernels learned via graph neural networks. By preserving shrinking neighborhoods, enforcing kernel regularity through architectural constraints, and employing cross-fitting to restore exogeneity, the proposed estimator achieves valid local inference under standard smoothness and moment conditions.*

---

## 9. Kriteria Arsitektur GNN yang Valid untuk Inferensi

### 9.1 Jawaban Singkat

✗ TIDAK semua backbone GNN bisa digunakan ✓ BANYAK backbone populer harus dimodifikasi ✓ Yang penting BUKAN namanya, tapi properti matematisnya

GNN boleh apa saja selama ia berperilaku seperti kernel yang sah (bounded, smooth, lokal, eksogen secara asimtotik).

### 9.2 Kriteria Matematis yang HARUS Dipenuhi GNN

(C1) Output harus menghasilkan bobot kernel, bukan prediksi

Syarat: GNN tidak boleh memprediksi  $Y$ . Ia harus menghasilkan skor bobot:

$$s_{\theta}(i, u_0) \Rightarrow w_i(u_0) = \text{softmax}(s_{\theta})$$

Kenapa? Kalau GNN memprediksi  $Y$ : \* bobot jadi fungsi langsung dari noise, \*  $\mathbb{E}[w_i \varepsilon_i] \neq 0$ , \* konsistensi gagal total.

Implikasi desain: \* ✓ GNN = kernel learner \* ✗ GNN = regressor

(C2) Boundedness & Normalization

Syarat:

$$0 \leq w_i \leq 1, \quad \sum_i w_i = 1$$

Kenapa? \* Variansi terbatas \* CLT berlaku \* Tidak ada observasi dominan

Implikasi desain: \* ✓ Softmax WAJIB \* ✗ ReLU / linear output langsung

(C3) Kontinuitas / Smoothness terhadap Input

Syarat: Bobot harus berubah halus saat  $U_i$  atau  $X_i$  berubah kecil:

$$|w_i(Z) - w_i(Z')| \leq L|Z - Z'|$$

Kenapa? \* Dipakai di Uniform LLN \* Dipakai di kontrol remainder bias \* Tanpa ini, bukti runtuh diam-diam

Implikasi desain: \* ✓ Aktivasi smooth (tanh, GELU, softplus) \* ✗ Hard attention, threshold, top-k selection

(C4) Locality TIDAK boleh dipelajari oleh GNN

Syarat: Neighborhood ditentukan sebelum GNN:

$$\mathbf{1}\{|U_i - u_0| \leq h\}$$

Kenapa? \* Ini yang menjamin  $h \rightarrow 0$  \* Ini yang mendefinisikan  $\beta(u_0)$

**Implikasi desain:** \* ✓ GNN hanya bekerja *di dalam* neighborhood \* ✗ GNN memilih node global

### (C5) Permutation Invariance

**Syarat:** Urutan node **tidak memengaruhi output**.

**Kenapa?** \* Bobot kernel tidak boleh tergantung indexing \* Ini asumsi implisit semua GWR

**Implikasi desain:** \* ✓ Message passing / aggregation \* ✗ Sequence-based encoder (tanpa simetrisasi)

### (C6) Eksogenitas via Cross-fitting

**Syarat:** Bobot dihitung dari data yang **tidak digunakan** untuk estimasi koefisien.

**Kenapa?** Tanpa ini:  $\mathbb{E}[w_i \varepsilon_i] \neq 0$

**Implikasi desain:** \* ✓ Train GNN di fold A, apply di fold B \* ✗ End-to-end training tanpa sample splitting

## 9.3 Backbone yang Aman vs Berbahaya

✓ **Backbone yang AMAN secara default (dengan desain tepat)**

**Message Passing GNN (GCN-like, GraphSAGE-like)**

Karena: \* aggregation simetris, \* output kontinu, \* mudah dikontrol.

✓ Tambahkan softmax  $\rightarrow$  kernel sah

**Attention-based GNN (GAT-style)**

✓ **BOLEH**, dengan syarat: \* attention score  $\rightarrow$  softmax lokal, \* **tidak hard masking**, \* hanya di neighborhood  $h$ .

⚠ **Backbone yang BERBAHAYA tanpa modifikasi**

**Hard attention / Top-k pooling**

Masalah: \* tidak kontinu, \* melanggar (C3), \* bias sulit dikontrol.

**Deep GNN sangat dalam**

Masalah: \* Lipschitz constant bisa meledak, \* ULLN tidak stabil.

Solusi: \* shallow GNN (1–3 layer), \* weight decay / spectral norm.

**Global Transformer Graph**

Masalah: \* tidak lokal, \* kernel tidak shrink, \* target bukan  $\beta(u_0)$  lagi.

## 9.4 Arsitektur yang “Legal” dari Sudut Pandang Teori

**Input**

Untuk setiap lokasi target  $u_0$ : \* Node features:  $\mathbf{f}_i = (X_i, U_i - u_0)$  \* Graph:  $\mathcal{G}_h(u_0)$

**GNN Body (contoh aman)**

- 1–2 message passing layer
- Aktivasi smooth
- Tidak ada pooling keras

Output:  $e_i = \text{GNN}_\theta(\mathbf{f}_i)$  (ini embedding skalar atau vektor kecil)

### Kernel Head (WAJIB eksplisit)

Mapping embedding  $\rightarrow$  skor:  $s_i = a^\top e_i$

Bobot:

$$w_i(u_0) = \frac{\exp(s_i)}{\sum_{j \in \mathcal{N}_h(u_0)} \exp(s_j)}$$

✦ Inilah kernel hasil estimasi GNN

### Training (cross-fitted)

Loss:

$$\sum_{i \in \text{val}} (Y_i - X_i^\top \hat{\beta}^{(-i)}(U_i))^2$$

Bukan loss prediksi langsung GNN.

### 9.5 Checklist Praktis

Sebelum pakai backbone GNN, tanyakan:

- ? Output GNN jadi **bobot kernel** atau **prediksi Y**?
- ? Ada **softmax lokal**?
- ? Neighborhood ditentukan **sebelum** GNN?
- ? Aktivasi **kontinu**?
- ? Ada **cross-fitting**?
- ? GNN dangkal & stabil?

Kalau satu saja ✗  $\rightarrow$  **inferensi tidak sah**.

### 9.6 Ringkasan

*Not all GNN backbones are suitable for inferential GWR. Only architectures that yield bounded, smooth, locally normalized weights and are trained via cross-fitting preserve the kernel regularity conditions required for consistency and asymptotic normality.*

Secara konsep, GNN di sini bukan “model ML”, tapi:

**alat untuk mengestimasi kernel nonparametrik adaptif.**

## 10. Pemilihan Bandwidth $h$

### 10.1 Prinsip Fundamental

$h$  BUKAN parameter yang harus “optimal” secara numerik.  $h$  adalah parameter yang harus “benar secara asimtotik”.

Artinya: \* tidak mengejar  $h$  terbaik di satu dataset, \* mengejar aturan pemilihan  $h_n$  yang:

$$h_n \rightarrow 0 \quad \text{dan} \quad nh_n^d \rightarrow \infty$$

Inferensi **hidup–mati** di sini.

### 10.2 Ringkasan Rekomendasi

**Dalam praktik inferensial:**

✓ Jangan pilih  $h$  murni dari CV ✓ Tentukan  $h$  dengan **aturan deterministik atau kNN** ✓  
Gunakan CV hanya sebagai **kalibrasi kasar**, bukan penentu akhir ✓ Biarkan GNN mengurus adaptivitas, bukan  $h$

### 10.3 OPSI 1 – Deterministic Bandwidth (PALING AMAN UNTUK TESIS)

**Bentuk:**

$$h_n = C \cdot n^{-\alpha}$$

dengan: \*  $C > 0$  konstanta skala, \*  $\alpha > 0$  laju penyusutan.

**Kenapa ini paling aman?**

Karena dapat **secara eksplisit** menyatakan: \*  $h_n \rightarrow 0$  (karena  $\alpha > 0$ ), \*  $nh_n^d \rightarrow \infty$  (asal  $\alpha < 1/d$ ).

Untuk **inferensi GWR**, kita butuh **undersmoothing**:

$$\sqrt{nh_n^d} h_n^2 \rightarrow 0$$

Untuk data spasial 2D ( $d = 2$ ), pilihan aman:

$$\alpha \in (0.25, 0.4)$$

**Bagaimana memilih  $C$ ?**

Ini **bukan masalah teori**, tapi skala data.

Praktik aman: \* hitung jarak median antar lokasi, \* set  $C$  sebagai proporsi jarak itu (mis. 0.5×).

Yang penting:  $C$  **tetap**, tidak tergantung  $n$ .

## 10.4 OPSI 2 – k-Nearest Neighbors (SANGAT NATURAL UNTUK GNN)

Alih-alih radius  $h$ , dipilih **jumlah tetangga**.

Bentuk:

$$k_n = \lceil n^\gamma \rceil, \quad 0 < \gamma < 1$$

Neighborhood: \* ambil  $k_n$  tetangga terdekat dari  $u_0$ , \*  $h_n(u_0)$  = jarak ke tetangga ke- $k_n$ .

**Kenapa ini sah secara teori?**

Karena:

$$h_n(u_0) \asymp \left( \frac{k_n}{n} \right)^{1/d}$$

Jika: \*  $k_n \rightarrow \infty$ , \*  $k_n/n \rightarrow 0$ ,

maka:

$$h_n \rightarrow 0 \quad \text{dan} \quad nh_n^d \asymp k_n \rightarrow \infty$$

✦ **Semua syarat inferensi terpenuhi.**

**Pilihan  $\gamma$  yang aman (praktis)**

Untuk  $d = 2$ :  $\gamma \in (0.4, 0.7)$

Contoh: \*  $n = 2,000 \rightarrow k \approx 60$  \*  $n = 10,000 \rightarrow k \approx 150$

✦ Ini **sangat cocok** dengan graf GNN: \* graf lokal = kNN graph, \* tidak perlu radius eksplisit.

## 10.5 OPSI 3 – Cross-validation (HANYA SEBAGAI REFERENSI)

**Fakta jujur tentang CV**

CV memilih:

$$h_{CV} \asymp n^{-1/(d+4)}$$

Untuk  $d = 2$ :

$$h_{CV} \asymp n^{-1/6}$$

Masalah:

$$\sqrt{nh_{CV}^d} h_{CV}^2 \rightarrow c \neq 0$$

➡ Bias **tidak hilang** dalam CLT ➡ Inferensi Wald **tidak sah**

**Cara CV masih boleh dipakai**

Sebagai **starting point**, bukan keputusan akhir.

Praktik yang jujur: 1. Hitung  $h_{CV}$  2. Lakukan **undersmoothing**:

$$h = c \cdot h_{CV}, \quad c \in (0.5, 0.8)$$

3. Jelaskan di teks:  $> CV$  digunakan untuk kalibrasi skala, bukan untuk inferensi.

### 10.6 Praktik yang TIDAK Boleh Dilakukan

- ✗ Memilih  $h$  yang meminimalkan MSE dan berhenti di situ
- ✗ Mengklaim “ $h$  kecil” tanpa aturan asimtotik
- ✗ Membiarkan GNN menentukan neighborhood
- ✗ Menggunakan  $k$  tetap (mis. 50) tanpa kaitan ke  $n$

### 10.7 Diagnostic Praktis (sanity check)

#### 1 Effective local sample size

Pastikan:

$$30 \leq nh^d \leq 0.2n$$

Kalau: \* terlalu kecil  $\rightarrow$  variance meledak, \* terlalu besar  $\rightarrow$  tidak lokal.

#### 2 Stabilitas koefisien

Hitung  $\hat{\beta}(u_0)$  untuk:  $h, 0.8h, 0.6h$

Koefisien **harus stabil**, bukan meloncat.

### 10.8 Rekomendasi Akhir

Karena konteks: \* ingin inferensi, \* memakai GNN sebagai kernel adaptif,

maka **pilihan terbaik**:

✓ kNN-based bandwidth dengan  $k_n \propto n^\gamma$  ✓ atau deterministic  $h_n = Cn^{-\alpha}$  ✗ CV murni

Kalimat tesis yang kuat:

*“The bandwidth is chosen to guarantee shrinking neighborhoods and diverging local sample size, while adaptivity is achieved through learned neural weights rather than bandwidth optimization.”*

### 10.9 Ringkasan

**Dalam inferensi GWR–GNN,  $h$  dipilih untuk memenuhi teori, bukan untuk memaksimalkan prediksi.**