

SKRIPSI

**PENGEMBANGAN METODE PEMBOBOTAN BERBASIS JARINGAN
SARAF GRAF PADA REGRESI TERBOBOTI GEOGRAFIS DAN
IMPLIKASINYA TERHADAP INFERENSI**

***DEVELOPMENT OF GRAPH NEURAL NETWORK-BASED
WEIGHTING METHOD FOR GEOGRAPHICALLY WEIGHTED
REGRESSION AND ITS IMPLICATIONS FOR INFERENCE***



Kurniawan Chandra Wijaya
22/497908/PA/21466

**PROGRAM SARJANA PROGRAM STUDI STATISTIKA
DEPARTEMEN MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA**


2025

SKRIPSI

**PENGEMBANGAN METODE PEMBOBOTAN BERBASIS JARINGAN
SARAF GRAF PADA REGRESI TERBOBOTI GEOGRAFIS DAN
IMPLIKASINYA TERHADAP INFERENSI**

***DEVELOPMENT OF GRAPH NEURAL NETWORK-BASED
WEIGHTING METHOD FOR GEOGRAPHICALLY WEIGHTED
REGRESSION AND ITS IMPLICATIONS FOR INFERENCE***

Diajukan untuk memenuhi salah satu syarat memperoleh derajat
Sarjana Program Sarjana Program Studi Statistika



Kurniawan Chandra Wijaya
22/497908/PA/21466

**PROGRAM SARJANA PROGRAM STUDI STATISTIKA
DEPARTEMEN MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA**

2025

HALAMAN PENGESAHAN

SKRIPSI

**PENGEMBANGAN METODE PEMBOBOTAN BERBASIS JARINGAN
SARAF GRAF PADA REGRESI TERBOBOTI GEOGRAFIS DAN
IMPLIKASINYA TERHADAP INFERENSI**

Telah dipersiapkan dan disusun oleh

Kurniawan Chandra Wijaya
22/497908/PA/21466

Telah dipertahankan di depan Tim Penguji
pada tanggal tanggal bulan tahun

Susunan Tim Penguji

Prof. Dr. Abdurakhman, S.Si., M.Si.
Pembimbing Utama

Ketua Penguji
Ketua Tim Penguji

Penguji 1
Penguji

Penguji 2
Penguji

PERNYATAAN BEBAS PLAGIASI

Saya yang bertanda tangan di bawah ini:

Nama : Kurniawan Chandra Wijaya
NIM : 22/497908/PA/21466
Tahun terdaftar : 2025
Program Studi : Program Sarjana Program Studi Statistika
Fakultas : Fakultas Matematika dan Ilmu Pengetahuan Alam

menyatakan bahwa dalam dokumen ilmiah skripsi ini tidak terdapat bagian dari karya ilmiah lain yang telah diajukan untuk memperoleh gelar akademik di suatu lembaga Pendidikan Tinggi, dan juga tidak terdapat karya atau pendapat yang pernah ditulis atau diterbitkan oleh orang/lembaga lain, kecuali yang secara tertulis disitasi dalam dokumen ini dan disebutkan sumbernya secara lengkap dalam daftar pustaka.

Dengan demikian saya menyatakan bahwa dokumen ilmiah ini bebas dari unsur-unsur plagiasi dan apabila dokumen ilmiah skripsi ini di kemudian hari terbukti merupakan plagiasi dari hasil karya penulis lain dan/atau dengan sengaja mengajukan karya atau pendapat yang merupakan hasil karya penulis lain, maka penulis bersedia menerima sanksi akademik dan/atau sanksi hukum yang berlaku.

Yogyakarta, tanggal bulan tahun

Materai Rp10.000,00

Kurniawan Chandra Wijaya
22/497908/PA/21466

Karya sederhana ini dipersembahkan untuk Bapak dan Ibu yang tak lelah mendoakan, serta penulis kecil yang telah berani bermimpi dan berjalan sejauh ini.

“For my part I know nothing with any certainty, but the sight of the stars makes me dream.” – Vincent Van Gogh.

Dum Spiro, Spero.

PRAKATA

Bismillahirrahmanirrahim. Puji syukur penulis panjatkan kehadirat Allah SWT, Dzat Yang Maha Mengetahui segala pola dalam ketidateraturan, atas limpahan berkah dan kekuatan-Nya sehingga penulis dapat menyelesaikan tugas akhir ini. Tugas akhir berjudul "Pengembangan Metode Pembobotan Berbasis Jaringan Saraf Graf pada Regresi Terboboti Geografis dan Implikasinya Terhadap Inferensi" ini disusun sebagai salah satu syarat memperoleh derajat Sarjana di Program Studi Statistika, Universitas Gadjah Mada.

Tugas akhir ini bukan sekadar syarat akademis, melainkan bukti ketahanan penulis dalam menempuh perjalanan panjang selama empat tahun di universitas tercinta ini. Penulis menyadari bahwa penyusunan skripsi ini mustahil terwujud tanpa dukungan, bimbingan, dan doa dari berbagai pihak. Oleh karena itu, dengan segala kerendahan hati, penulis mengucapkan terima kasih kepada:

1. Bapak Prof. Dr.Eng Kuwat Triyana, M.Si., selaku Dekan Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Gadjah Mada;
2. Bapak Dr. Nanang Susyanto, M.Sc., selaku Ketua Departemen Matematika Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Gadjah Mada;
3. Ibu Atina Husnaqilati, S.Si., M.Sc., Ph.D., selaku Ketua Program Studi Statistika Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Gadjah Mada, serta Dosen Pembimbing Akademik penulis;
4. Bapak Prof. Dr. Abdurakhman, S.Si., M.Si., selaku Dosen Pembimbing Utama. Terima kasih Bapak, atas ilmu, kesabaran, dan bimbingannya dalam mengarahkan logika penulis hingga penelitian ini dapat selesai dengan baik;
5. seluruh Dosen dan Staf Program Studi Statistika UGM yang telah membekali penulis dengan ilmu yang sangat berharga selama masa studi;

6. teman-teman seperjuangan Statistika angkatan 2022. Terima kasih telah menjadi penyeimbang akal sehat dan teman diskusi yang menyenangkan di tengah dunia yang terkadang tidak masuk akal;
7. kedua Orang Tua dan Adik tercinta. Terima kasih karena telah bertahan sejauh ini demi pendidikan penulis. Skripsi ini adalah langkah awal dan bakti kecil penulis untuk membasuh setiap tetes keringat dan doa Bapak Ibu;
8. rekan-rekan “Jasa Olah Data DTT”: Fahmi, Banu, Wildan, Hanan, Husni, dan Delan, yang telah menemani dinamika kehidupan penulis selama di Yogyakarta;
9. teman-teman KKN-PPM UGM Periode 3 Tahun 2025 unit “Lendah Melangkah” yang telah membantu penulis menemukan kembali makna-makna kehidupan di tengah masyarakat;
10. Mbak Agnes, Mas Arkan, Mas Reza, dan seluruh rekan tim AI & ML Engineer *Enterprise Data Analytics* (EDA) PT Bank Mandiri (Persero) Tbk. yang telah membimbing penulis selama masa magang; serta
11. pihak-pihak lainnya yang tidak dapat penulis sebutkan satu per satu, terima kasih atas dukungan yang telah diberikan.

Penulis menyadari bahwa tugas akhir ini masih jauh dari kesempurnaan. Oleh karena itu, kritik dan saran yang membangun sangat penulis harapkan. Semoga karya kecil ini dapat memberikan manfaat, sekecil apapun itu, bagi pembaca dan perkembangan ilmu pengetahuan.

Sleman, 20 Januari 2026

Penulis

DAFTAR ISI

HALAMAN JUDUL	i
HALAMAN PENGESAHAN	ii
HALAMAN PERNYATAAN BEBAS PLAGIASI	iii
HALAMAN PERSEMBAHAN	iv
HALAMAN MOTTO	v
PRAKATA	vi
DAFTAR ISI	viii
DAFTAR TABEL	xii
DAFTAR GAMBAR	xiii
INTISARI	xiv
ABSTRACT	xv
I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Pembatasan Masalah	4
1.3 Tujuan dan Manfaat Penelitian	4
1.4 Tinjauan Pustaka	5
1.5 Metodologi Penelitian	5
1.6 Sistematika Penulisan	6
II LANDASAN TEORI	8
2.1 Aljabar Matriks	8
2.1.1 Ruang Vektor dan Matriks	8
2.1.2 Sifat-Sifat Matriks	15
2.1.3 Invers Matriks	24
2.1.4 Determinan dan <i>Rank</i>	33
2.1.5 Nilai Eigen dan Vektor Eigen	42
2.1.6 Perkalian Kronecker dan Operasi Vektorisasi	45
2.1.7 Norma Vektor dan Matriks	47
2.1.8 Diferensial Vektor dan Matriks	50
2.2 Teori Ukuran dan Probabilitas	59
2.2.1 Ruang Ukur dan Ukuran Probabilitas	59
2.2.2 Variabel Acak sebagai Fungsi Terukur	62
2.2.3 Distribusi dan Ekspektasi	64
2.2.4 Momen, Variansi, dan Kovariansi	73

2.2.5	Probabilitas Bersyarat dan Independensi	75
2.2.6	Hukum Probabilitas Total dan Teorema Bayes	78
2.2.7	Hukum Ekspektasi Total dan Variansi Total	81
2.3	Konvergensi dan Laju Pertumbuhan	84
2.3.1	Barisan Variabel Acak	85
2.3.2	Konvergensi Barisan Variabel Acak	86
2.3.3	Hubungan Antarmode Konvergensi	88
2.4	Teori Probabilitas Asimtotik	92
2.4.1	Hukum Bilangan Besar	92
2.4.2	Konsistensi Estimator	93
2.4.3	Fungsi Karakteristik	93
2.4.4	Teorema Pemetaan Kontinu dan Teorema Slutsky	97
2.4.5	Notasi <i>Big-O</i> dan <i>Little-o</i> (Deterministik)	103
2.4.6	Notasi <i>Big-O</i> dan <i>Little-o</i> dalam Probabilitas	106
2.4.7	Teorema Limit Pusat	113
2.4.8	Metode Delta	120
2.5	Analisis Regresi Linear	122
2.5.1	Regresi Linear Biasa atau <i>Ordinary Least Squares</i> (OLS)	122
2.5.2	Teori Asimtotik untuk OLS	128
2.5.3	Regresi Terboboti	133
2.5.4	Teori Asimtotik untuk GLS/WLS	137
2.6	Pemodelan Polinomial Lokal	139
2.6.1	Asumsi Model Polinomial Lokal	141
2.6.2	Estimasi Model Polinomial Lokal	142
2.7	Analisis Regresi Spasial	144
2.7.1	Regresi dengan Dependensi Spasial	145
2.7.2	Regresi dengan Keragaman Spasial	147
2.8	Jaringan Saraf Tiruan	167
2.8.1	Model Dasar dan Notasi	167
2.8.2	Fungsi Aktivasi	168
2.8.3	Fungsi Kerugian dan Kriteria Pembelajaran	171
2.8.4	Pembelajaran dengan Propagasi Mundur	172
2.8.5	Optimisasi Parameter	174
2.8.6	Jaringan Saraf Tiruan sebagai Aproksimasi Universal	180
2.9	Jaringan Saraf Graf	183
2.9.1	Dasar Graf dan Laplacian	183

2.9.2	Kerangka Penyampaian Pesan pada Jaringan Saraf	185
2.9.3	Arsitektur Umum dalam GNN	186
2.9.4	Sifat Simetri dan Invariansi Permutasi	188
2.9.5	Daya Aproksimasi Jaringan Saraf Graf	188
III KERANGKA METODOLOGIS DAN ANALISIS ASIMTOTIK GRAPH ATTENTION-BASED GEOGRAPHICALLY WEIGHTED REGRESSION		190
3.1	Keterbatasan Pembobotan Spasial Berbasis <i>Kernel</i> Konvensional . .	190
3.1.1	Prinsip Pembobotan Spasial dalam GWR	190
3.1.2	Bias Induktif pada <i>Kernel</i> Tetap	191
3.2	Pembelajaran <i>Kernel</i> Spasial dengan Jaringan Saraf Graf	193
3.2.1	Representasi Graf untuk Data Spasial	193
3.2.2	Fleksibilitas Metrik Jarak dalam Konstruksi Representasi . .	195
3.2.3	Fungsi Skor Spasial dan Jaringan Saraf Graf	198
3.2.4	Konstruksi <i>Kernel</i> Spasial Berbasis GNN	199
3.3	Integrasi <i>Kernel</i> Terestimasi ke dalam Kerangka GWR	204
3.3.1	Definisi Model <i>Graph Attention-based</i> GWR (GA-GWR) .	204
3.3.2	<i>Kernel</i> Terestimasi sebagai <i>Nuisance Parameter</i>	205
3.3.3	Permasalahan Endogenitas dan Ketergantungan Data	205
3.3.4	Skema <i>Cross-Fitting</i> untuk Inferensi Valid	208
3.4	Analisis Asimtotik Koefisien Lokal pada GA-GWR	214
3.4.1	Asumsi-Asumsi Regularitas	214
3.4.2	Analisis Bias Asimtotik Koefisien Lokal	218
3.4.3	Analisis Bias Asimtotik Variansi Galat	222
3.4.4	Konsistensi Koefisien Lokal	227
3.4.5	Konsistensi Variansi Koefisien Lokal	230
3.4.6	Distribusi Asimtotik Koefisien Lokal	235
3.4.7	Distribusi Asimtotik Uji Statistik	240
3.5	Analisis Komputasional GA-GWR	244
3.5.1	Graf Komputasional dan Diferensiabilitas	245
3.5.2	Analisis <i>Vanishing</i> dan <i>Exploding Gradient</i>	248
3.5.3	Konstanta Lipschitz dan Stabilitas <i>Pipeline</i>	251
3.5.4	Algoritma Pelatihan dan Kompleksitas Komputasional . . .	253
3.5.5	Diagnostik Model dan Validasi Inferensi	256
IV STUDI KASUS		261
4.1	Studi Simulasi	261

4.1.1	Desain Eksperimen Simulasi	262
4.1.2	Evaluasi Akurasi Estimasi Titik	267
4.1.3	Analisis Diagnostik Residual	272
4.1.4	Validasi Inferensi Statistik	274
4.1.5	Analisis Bias Estimator Cross-Fitted	277
4.1.6	Pengujian Hipotesis dan Kualitas Estimasi Variance	278
4.2	Studi Kasus pada Data Kredit UMKM dan Harga Pangan Indonesia	281
4.2.1	Deskripsi Data dan Variabel	281
4.2.2	Analisis Multikolinearitas	283
4.2.3	Pemodelan dan Perbandingan Kinerja Prediksi	286
4.2.4	Estimasi Koefisien Spasial GWR	288
4.2.5	Uji Signifikansi Koefisien Lokal	288
4.2.6	Uji Diagnostik Residual dan Validasi Model	290
4.2.7	Pembahasan Hasil dan Implikasi untuk Kebijakan	291
4.2.8	Estimasi T-Statistics Lokal dengan Sandwich Estimator . . .	293
4.2.9	Tipologi Spasial melalui Analisis Clustering	294
4.2.10	Validasi Diagnostik Model GA-GWR dengan Backbone GAT	296
V	PENUTUP	298
5.1	Kesimpulan	298
5.2	Saran	298
	DAFTAR PUSTAKA	299
A	Data	303
B	Syntax R	304

DAFTAR TABEL

4.1	Perbandingan Kernel GWR Gaussian dan Exponential	264
4.2	Konfigurasi Hyperparameter Model GA-GWR	266
4.3	Perbandingan Performa Prediksi Model ($n = 3.600, \sigma = 0.5$)	268
4.4	RMSE Estimasi Koefisien Spasial	269
4.5	Perbandingan Arsitektur GNN sebagai <i>Backbone</i> GA-GWR	269
4.6	Analisis Sensitivitas GA-GWR terhadap Ukuran Sampel dan Ting- kat Noise	271
4.7	Hasil Uji Normalitas Residual GA-GWR	273
4.8	<i>Coverage Probability</i> GA-GWR pada Berbagai Tingkat Kepercayaan	276
4.9	Analisis Bias Estimator GA-GWR vs GWR - Skenario Baseline ($n = 3600, \sigma = 0,5$)	278
4.10	<i>Coverage Probability Hypothesis Test</i> : $\hat{\beta}^{CF}(\mathbf{u}) = \beta^*(\mathbf{u})$	280
4.11	Analisis Estimasi Variance: $\hat{\sigma}^2$ vs $\sigma_{\text{true}}^2 = 0,25$	280
4.12	Statistik Deskriptif Variabel Studi Kasus Data BI dan SEKDA . . .	283
4.13	Variance Inflation Factor (VIF) dan Korelasi Variabel Prediktor . . .	285
4.14	Ringkasan Kondisi Angka Lokal GWR	285
4.15	Spesifikasi Konfigurasi GA-GWR pada Data BI-SEKDA	287
4.16	Perbandingan Performa Prediksi Model pada Data BI-SEKDA . . .	287
4.17	Statistik Koefisien Spasial GWR (Kernel Exponential) pada Data BI-SEKDA	289
4.18	Ringkasan Signifikansi Koefisien Lokal GWR ($\alpha = 0,05$)	290
4.19	Hasil Uji Diagnostik Residual GWR pada Data BI-SEKDA	290
4.20	Ringkasan T-Statistics Lokal dengan Sandwich Estimator	293
4.21	Karakterisasi Cluster Koefisien Elastisitas Harga	294

DAFTAR GAMBAR

2.1	Ilustrasi transformasi linear $f : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ dengan $f(x, y) = (2x, y)$.	34
2.2	Ilustrasi bentuk bilinear anti-simetri $\omega(v_1, v_2) = x_1y_2 - x_2y_1$ pada \mathbb{R}^2 .	38
2.3	Perbandingan luas paralelogram sebelum dan sesudah transformasi A .	40
2.4	Ilustrasi vektor eigen dan nilai eigen untuk transformasi $T(x, y) = (2x, 3y)$.	43
2.5	Diagram hubungan antarmode konvergensi.	89
4.1	Perbandingan koefisien spasial sejati (baris atas), estimasi GWR klasik (baris tengah), dan estimasi GA-GWR (baris bawah) untuk β_0 (kolom kiri), β_1 (kolom tengah), dan β_2 (kolom kanan). GA-GWR menangkap pola spasial dengan lebih akurat termasuk diskontinuitas tajam pada β_1 .	270
4.2	<i>Heatmap</i> analisis sensitivitas GA-GWR.	272
4.3	Analisis diagnostik residual GA-GWR (GraphSAGE backbone): (kiri atas) histogram residual standarisasi dengan overlay kurva normal, (kanan atas) Q-Q plot, (kiri bawah) residual vs fitted values, (tengah bawah) scale-location plot, (bawah kiri) residual autocorrelation, (bawah kanan) peta sebaran spasial residual.	275
4.4	Evaluasi <i>coverage probability</i> GA-GWR.	276
4.5	Kurva konvergensi pelatihan GA-GWR, kerugian tiap <i>epoch</i> untuk setiap <i>fold</i> dalam 3-fold temporal cross-fitting.	277
4.6	Distribusi spasial bias koefisien: (atas) GA-GWR dengan backbone GAT, (bawah) GWR kernel Gaussian. Warna merah menunjukkan bias positif, biru menunjukkan bias negatif, intensitas warna menunjukkan magnitude bias.	279
4.7	Peta clustering elastisitas harga koefisien lokal GWR yang menunjukkan 3 cluster sensitivitas: Tinggi (merah), Moderat (hijau), dan Rendah (biru) di 34 provinsi Indonesia.	295

INTISARI

PENGEMBANGAN METODE PEMBOBOTAN BERBASIS JARINGAN SARAF GRAF PADA REGRESI TERBOBOTI GEOGRAFIS DAN IMPLIKASINYA TERHADAP INFERENSI

Oleh

Kurniawan Chandra Wijaya

22/497908/PA/21466

TULIS ABSTRAK,

Kata Kunci: kata kunci.

ABSTRACT

DEVELOPMENT OF GRAPH NEURAL NETWORK-BASED WEIGHTING METHOD FOR GEOGRAPHICALLY WEIGHTED REGRESSION AND ITS IMPLICATIONS FOR INFERENCE

By

Kurniawan Chandra Wijaya

22/497908/PA/21466

TULIS ABSTRAK ENGGRES,

Keyword: keywordsssss

BAB I

PENDAHULUAN

1.1 Latar Belakang

Dalam ranah statistika spasial dan ekonometrika, tantangan fundamental yang terus dihadapi adalah pemodelan ketidakstasioneran spasial, yaitu suatu kondisi ketika parameter hubungan antarvariabel tidak bersifat konstan melainkan bervariasi melintasi ruang geografis. Pendekatan konvensional yang dominan selama dua dekade terakhir, yaitu *Geographically Weighted Regression* (GWR), beroperasi di atas asumsi dasar bahwa heterogenitas spasial dapat ditangkap melalui fungsi pembobot (*kernel*) yang bersifat tetap dan deterministik. Asumsi ini, yang berakar pada Hukum Pertama Geografi Tobler, menyatakan bahwa “segala sesuatu saling berhubungan, tetapi hal-hal yang dekat lebih berhubungan daripada hal-hal yang jauh” (Fotheringham, Brunsdon, dan Charlton, 2002). Namun, dalam kenyataannya, data modern semakin kompleks sehingga asumsi kaku mengenai peluruhan jarak (*distance decay*) yang monotonik dan isotropik ini menjadi batasan metodologis yang serius.

Penelitian ini tidak hanya berangkat dari fenomena empiris, melainkan dari kebutuhan mendesak untuk merevisi arsitektur matematis dari mekanisme pembobotan itu sendiri. GWR klasik, meskipun elegan dalam kesederhanaannya, mengalami apa yang disebut sebagai bias induktif (*inductive bias*) yang sempit. Metode ini memaksakan struktur lingkungan Euclidean pada data yang seringkali berada pada Manifold non-Euclidean, seperti jaringan transportasi perkotaan, kepulauan yang terpisah laut, atau interaksi sosial-ekonomi yang tidak terikat jarak fisik semata. Ketergantungan pada kernel tetap (seperti *Gaussian* atau *exponential*) dengan bandwidth yang seringkali global atau adaptif secara terbatas, gagal menangkap dinamika dependensi spasial yang bersifat asimetris dan multi-skala. (?)

Oleh karena itu, penelitian ini mengajukan konsepsi metodologis bahwa va-

liditas inferensi dalam regresi spasial tidak lagi cukup hanya dengan mengkalibrasi *bandwidth* pada kernel tetap. Diperlukan transisi menuju *adaptive spatial weighting* yang dipelajari secara *end-to-end* dari data itu sendiri. Di sinilah *Graph Neural Networks* (GNN), dan secara spesifik *Graph Attention Networks* (GAT), menawarkan solusi teoretis yang *robust*. Dengan merepresentasikan unit spasial sebagai simpul (*nodes*) dalam sebuah graf dan interaksi spasial sebagai sisi (*edges*), GAT memungkinkan model untuk mempelajari bobot interaksi (w_{ij}) berdasarkan kesamaan fitur dan konteks topologi, bukan sekadar jarak geometris. (Veličković dkk., 2018) Sistemika pembobotan ini bersifat dinamis, kontekstual, dan mampu menangkap pola non-monotonik yang lebih realistis dalam hubungan spasial. Model GNN menghasilkan keluaran berupa skor perhatian (*attention scores*) yang akan menjadi bobot spasial adaptif dalam kerangka GWR melalui fungsi aktivasi *softmax*. Oleh karena itu, arsitektur ini diberi nama *Graph Attention-based Geographically Weighted Regression* (GA-GWR) karena kemiripannya dengan GAT dalam hal mekanisme pembobotan adaptif.

Perkembangan terkini di bidang *geospatial artificial intelligence* (GeoAI) menghadirkan pendekatan *machine learning* yang dapat mempelajari pola nonlinear secara adaptif. Salah satunya adalah *Geographically Weighted Artificial Neural Network* (GWANN) yang dikembangkan oleh Hagenauer dan Helbich (2022) serta *Spatial and Attribute Neural Network Weighted Regression* (SANNWR) oleh Ni, Wu, dan Zhang (2022). Keduanya berupaya memanfaatkan jaringan saraf tiruan untuk mengestimasi fungsi pembobot spasial yang kompleks. Lebih lanjut, Yin, Huang, Du, Wu, dkk. (2024) memperkenalkan model *Geographically Neural Network Weighted Regression* (GNNWR) dan *Geographically and Temporally Neural Network Weighted Regression* (GTNNWR), yang memadukan kerangka *varying coefficient* dengan kemampuan pembelajaran representasi nonlinear dari *neural networks*. Model tersebut menunjukkan peningkatan akurasi yang signifikan dalam memetakan hubungan spasial-temporal pada data lingkungan dan sosial.

Di sisi lain, Zhu, Liu, Yao, dan Fischer (2022) mengusulkan *Spatial Regression Graph Convolutional Neural Networks* (SRGCNN) yang mengintegrasik-

an *graph convolutional neural network* (GCN) ke dalam paradigma regresi spasial. Pendekatan ini memperlakukan data spasial sebagai graf, dengan simpul merepresentasikan lokasi dan sisi (*edges*) merepresentasikan keterhubungan spasial antar-unit observasi. Dengan mekanisme *message passing* yang mengagregasi informasi dari tetangga terdekat, SRGCNN tidak hanya mampu menangani struktur data non-Euclidean, tetapi juga mendukung pembelajaran semi-terawasi (*semi-supervised learning*) yang memungkinkan model belajar dari data yang sebagian tidak teramati. Pendekatan ini membuka peluang besar untuk memperkuat model regresi spasial konvensional melalui pembobotan berbasis graf.

Berdasarkan keterbatasan fungsi *kernel* klasik dan juga perkembangan tersebut, penelitian ini berupaya mengintegrasikan prinsip pembobotan adaptif berbasis GNN ke dalam kerangka GWR. Namun, penggunaan *kernel* terestimasi dengan GNN dapat menyebabkan suatu permasalahan yang dinamakan sebagai endogenitas. Endogenitas terjadi ketika

$$\text{Cov}(w_{ij}, \varepsilon_i) \neq 0, \quad (1.1.1)$$

dengan w_{ij} adalah bobot spasial dan ε_i adalah istilah kesalahan pada lokasi i . Kondisi ini melanggar asumsi klasik bahwa bobot spasial harus eksogen terhadap kesalahan, yang dapat mengakibatkan estimasi parameter yang bias dan tidak konsisten. Dengan demikian, model yang diusulkan tidak hanya mengakomodasi ketidakstasioneran spasial-temporal, tetapi juga memperbaiki validitas inferensi statistik dengan analisis asimtotik. Dalam konteks empiris, model ini akan diterapkan pada analisis spasial Umur Harapan Hidup (UHH) antarkabupaten/kota di Indonesia periode 2023–2025, guna mengidentifikasi faktor-faktor sosial-ekonomi yang mempengaruhi disparitas UHH secara spasial-temporal. Dengan demikian, penelitian ini diharapkan dapat memberikan kontribusi signifikan baik dari segi metodologis maupun aplikatif dalam bidang statistika spasial dan ekonometrika.

1.2 Pembatasan Masalah

Penelitian ini berfokus pada pengembangan, validitas inferensial, dan penerapan model GA-GWR pada kasus Umur Harapan Hidup (UHH) antarkabupaten/kota di Indonesia periode 2023–2025. Adapun pembatasan masalah dalam penelitian ini adalah sebagai berikut.

- (a) Model GA-GWR yang dikembangkan hanya mengakomodasi ketidakstasioneran spasial dan temporal melalui pembobotan adaptif berbasis GNN, tanpa mempertimbangkan aspek multikolinearitas spasial atau heteroskedastisitas spasial.
- (b) Validitas inferensial model GA-GWR dianalisis melalui pendekatan asimtotik, dengan asumsi bahwa data yang digunakan memenuhi kondisi stasioneritas temporal dan independensi spasial.
- (c) Studi kasus difokuskan pada analisis UHH antarkabupaten/kota di Indonesia periode 2023–2025, dengan menggunakan data sekunder dari BPS.
- (d) Analisis dan komputasi dilakukan menggunakan bahasa pemrograman Python dengan pustaka *PyTorch Geometric* untuk implementasi jaringan saraf graf.

1.3 Tujuan dan Manfaat Penelitian

Tujuan utama penelitian ini adalah mengembangkan model pembelajaran spasial-temporal berbasis graf untuk menganalisis variasi Umur Harapan Hidup (UHH) antarkabupaten/kota di Indonesia. Secara khusus, penelitian ini bertujuan untuk:

1. mengonstruksi model *Graph Attention-based Geographically Weighted Regression* (GA-GWR) sebagai perluasan dari model GWR yang mampu menangkap ketidakstasioneran spasial melalui pembobotan adaptif berbasis Graph Attention Networks;
2. mengevaluasi validitas inferensial model melalui analisis asimtotik dan membandingkan kinerja model terhadap model konvensional (GWR dan regresi

klasik) dalam hal ketepatan estimasi, stabilitas, dan interpretabilitas koefisien lokal; serta

3. menerapkan model yang dikembangkan pada studi kasus UHH antarkabupaten/kota di Indonesia periode 2023–2025 untuk mengidentifikasi pola spasial dan faktor-faktor sosial-ekonomi yang berpengaruh.

Secara praktis, hasil penelitian ini diharapkan dapat memberikan kontribusi bagi lembaga perencana kebijakan, khususnya Kementerian Kesehatan dan Badan Pusat Statistik, dalam memahami disparitas UHH regional dan merancang kebijakan pembangunan kesehatan yang adaptif terhadap kondisi spasial antarkabupaten/kota di Indonesia.

1.4 Tinjauan Pustaka

Penelitian mengenai regresi spasial dan spasial-temporal telah berkembang pesat dalam dua dekade terakhir. Model klasik seperti GWR (Fotheringham dkk., 2002) dan GTWR (Huang, Wu, dan Barry, 2010) menjadi dasar utama dalam analisis hubungan spasial yang tidak stasioner. Namun, keterbatasannya pada asumsi linearitas dan bentuk kernel mendorong munculnya model berbasis kecerdasan buatan seperti GWANN (Hagenauer dan Helbich, 2022), SANNWR (Ni dkk., 2022), dan GNNWR (Yin dkk., 2024). Di sisi lain, pendekatan *graph-based learning* seperti SRGCNN (Zhu dkk., 2022) memperlihatkan potensi besar dalam memodelkan struktur dependensi spasial-temporal yang kompleks melalui pembelajaran representasi graf. Berangkat dari temuan tersebut, penelitian ini berupaya menggabungkan kekuatan metodologis antara regresi terboboti spasial-temporal dan pembelajaran berbasis graf guna mengembangkan model yang lebih adaptif, akurat, dan interpretatif.

1.5 Metodologi Penelitian

Metodologi yang digunakan dalam penelitian ini meliputi *stress test* dan studi kasus. *Stress test* adalah serangkaian eksperimen simulasi yang dirancang untuk menguji kinerja model GA-GWR di bawah berbagai kondisi data sintetis. Eksperi-

men ini mencakup variasi ukuran sampel, tingkat kebisingan, pola ketidakstasioneran spasial-temporal, dan struktur dependensi antarunit observasi. Tujuannya adalah untuk mengevaluasi ketepatan estimasi, stabilitas koefisien lokal, serta sensitivitas model terhadap parameter hiper seperti arsitektur GNN dan fungsi aktivasi. Hasil dari *stress test* akan dibandingkan dengan model GWR klasik dan GTWR untuk menilai keunggulan relatif dari pendekatan yang diusulkan. Selain itu, analisis asimtotik akan dilakukan untuk memastikan validitas inferensial dari estimasi parameter dalam model GA-GWR.

Studi kasus akan diterapkan pada data Umur Harapan Hidup (UHH) antar-kabupaten/kota di Indonesia periode 2023–2025. Data sekunder akan diperoleh dari Badan Pusat Statistik (BPS) dan Kementerian Kesehatan. Analisis akan melibatkan pemodelan hubungan antara UHH dengan variabel sosial-ekonomi seperti pendapatan per kapita, tingkat pendidikan, akses layanan kesehatan, dan faktor lingkungan. Model GA-GWR akan diimplementasikan menggunakan bahasa pemrograman Python dengan pustaka *PyTorch Geometric* untuk membangun dan melatih jaringan saraf graf. Hasil analisis akan mencakup peta koefisien lokal, evaluasi kinerja model, serta interpretasi hasil dalam konteks kebijakan kesehatan regional.

1.6 Sistematika Penulisan

Pada penyusunan skripsi ini, penulis mengacu pada sistematika penulisan sebagai berikut.

BAB I PENDAHULUAN

Bab ini berisi tentang latar belakang, pembatasan masalah, tujuan dan manfaat penelitian, tinjauan pustaka, metodologi penelitian, dan sistematika penulisan.

BAB II LANDASAN TEORI

Bab ini membahas dasar-dasar teori yang digunakan, termasuk teori regresi spasial-temporal, jaringan saraf graf, dan pembelajaran semi-terawasi.

BAB III KERANGKA METODOLOGIS DAN ANALISIS ASIMTOTIK *GRAPH ATTENTION-BASED GEOGRAPHICALLY WEIGHTED REGRESSION*

Bab ini menjelaskan rancangan model GA-GWR, formulasi matematis, analisis asimtotik, dan analisis komputasi.

BAB IV STUDI KASUS

Bab ini berisi studi simulasi untuk *stress test* dan hasil implementasi model pada data Umur Harapan Hidup (UHH) antarkabupaten/kota di Indonesia periode 2023–2025 serta perbandingan kinerja model.

BAB V PENUTUP

Bab ini menyajikan kesimpulan yang diperoleh dari hasil penelitian dan memberikan saran untuk penelitian selanjutnya.

BAB II

LANDASAN TEORI

Pada bab ini akan dibahas mengenai konsep, teori, dan referensi yang menjadi dasar dalam melakukan analisis suatu metode statistik. Konsep dasar yang dibahas pada bab ini adalah aljabar matriks, teori ukuran dan probabilitas, konvergensi dan laju pertumbuhan, teori probabilitas asimtotik, statistika inferensial, analisis regresi linear, analisis regresi spasial, jaringan saraf tiruan, dan jaringan saraf graf.

2.1 Aljabar Matriks

Aljabar linear merupakan salah satu fondasi matematis terpenting dalam statistika, ekonometrika, serta pembelajaran mesin. Banyak metode statistika tradisional maupun modern dapat direpresentasikan dalam aljabar matriks, seperti jaringan saraf graf atau *graph neural networks* (GNN). Oleh karena itu, pemahaman yang kuat mengenai struktur vektor dan matriks serta sifat-sifat aljabarnya diperlukan sebelum membahas metode regresi terboboti geografis.

2.1.1 Ruang Vektor dan Matriks

Pembahasan aljabar linear umumnya berangkat dari konsep lapangan atau *field* sebagai struktur aljabar dasar tempat bilangan berlaku. Dari lapangan, dibangun ruang vektor, kemudian matriks sebagai representasi transformasi linear, dan tensor sebagai generalisasi multidimensi.

Definisi 2.1.1 (Lapangan, Lang 1987) Misalkan \mathcal{F} adalah subhimpunan dari bilangan kompleks \mathbb{C} , \mathcal{F} disebut sebagai lapangan apabila memenuhi kondisi berikut.

- (a) Apabila x, y adalah elemen dari \mathcal{F} , maka $x + y$ dan xy juga merupakan elemen dari \mathcal{F} .
- (b) Apabila $x \in \mathcal{F}$, maka $-x$ juga merupakan elemen dari \mathcal{F} . Lebih lanjut, jika

$x \neq 0$, maka x^{-1} merupakan elemen dari \mathcal{F} .

(c) 0 dan 1 merupakan elemen dari \mathcal{F} .

Berdasarkan definisi di atas, dapat diperhatikan bahwa \mathbb{R} dan \mathbb{C} merupakan lapangan.

Contoh 2.1.2 Apabila dinotasikan \mathbb{Q} sebagai himpunan bilangan rasional, yaitu

$$\mathbb{Q} = \left\{ \frac{m}{n} : m, n \in \mathbb{Z}, n \neq 0 \right\}, \quad (2.1.1)$$

maka dapat dinyatakan bahwa \mathbb{Q} membentuk suatu lapangan. Misalkan $\frac{a}{b}, \frac{c}{d} \in \mathbb{Q}$ dengan $a, b, c, d \in \mathbb{Z}$ dan $b, d \neq 0$. Jelas bahwa

$$\frac{a}{b} + \frac{c}{d} = \frac{ad + bc}{bd} \in \mathbb{Q}, \quad (2.1.2)$$

sehingga sifat tertutup terhadap penjumlahan, sebagai salah satu aksioma lapangan, terpenuhi. Lebih lanjut, untuk setiap $\frac{a}{b} \in \mathbb{Q}$ berlaku pula bahwa $-\frac{a}{b} \in \mathbb{Q}$. Selain itu, jika $a \neq 0$, maka invers perkalian $\frac{a}{b}$ diberikan oleh

$$\left(\frac{a}{b} \right)^{-1} = \frac{b}{a} \in \mathbb{Q}. \quad (2.1.3)$$

Dengan demikian, keberadaan invers aditif dan invers perkalian juga terjamin. Akhirnya, apabila dipilih $\frac{a}{b} = \frac{0}{1}$ dan $\frac{a}{b} = \frac{1}{1}$, diperoleh bahwa elemen identitas penjumlahan 0 dan identitas perkalian 1 termasuk dalam \mathbb{Q} . Di sisi lain, dapat dengan mudah diperiksa bahwa \mathbb{Z} bukan merupakan lapangan, karena apabila $n \in \mathbb{Z}$ dan $n \neq 0$, jelas bahwa $n^{-1} \notin \mathbb{Z}$, kecuali untuk kasus $n = 1$ atau $n = -1$.

Dalam ruang vektor dan matriks, dikenal juga istilah sublapangan. Apabila \mathcal{F} dan \mathcal{G} keduanya merupakan lapangan, serta dimisalkan bahwa $\mathcal{F} \subseteq \mathcal{G}$, maka \mathcal{F} dapat disebut sebagai sublapangan atau *subfield* dari \mathcal{G} . Elemen-elemen dari lapangan disebut sebagai bilangan atau skalar (Lang, 1987).

Definisi terkait lapangan atau *field* juga dirumuskan oleh Billingsley (1995)

yang digunakan dalam konteks teori ukuran dan probabilitas.

Definisi 2.1.3 (Lapangan, Billingsley 1995) Suatu keluarga \mathcal{F} dari kejadian-kejadian dalam ruang sampel Ω disebut sebagai lapangan (field) apabila

- (a) $\Omega \in \mathcal{F}$;
- (b) jika $A \in \mathcal{F}$, maka $A^c \in \mathcal{F}$; dan
- (c) jika $A, B \in \mathcal{F}$, maka $A \cup B \in \mathcal{F}$.

Konsekuensi dari definisi di atas adalah bahwa himpunan kosong (\emptyset) dan himpunan dari seluruh ruang sampel (Ω) selalu merupakan elemen dari lapangan \mathcal{F} . Selain itu, lapangan juga tertutup terhadap operasi irisan, yaitu jika $A, B \in \mathcal{F}$, maka $A \cap B \in \mathcal{F}$.

Contoh 2.1.4 Diberikan ruang sampel atau semesta $\Omega = \{1, 2, 3\}$ dan himpunan $\mathcal{F}_1, \mathcal{F}_2$ berikut.

$$\begin{aligned}\mathcal{F}_1 &= \{\emptyset, \Omega, \{1\}, \{2\}, \{2, 3\}\}, \\ \mathcal{F}_2 &= \{\emptyset, \Omega, \{2\}, \{1, 3\}\}.\end{aligned}$$

Dapat diperiksa bahwa \mathcal{F}_1 bukan merupakan lapangan karena meskipun $\{2\} \in \mathcal{F}_1$, tetapi komplementnya $\{1, 3\} \notin \mathcal{F}_1$. Sebaliknya, \mathcal{F}_2 adalah lapangan karena memenuhi ketiga aksioma di atas.

Definisi 2.1.5 (Ruang vektor, Lang 1987) Suatu ruang vektor \mathcal{V} atas suatu lapangan \mathcal{F} adalah sebuah himpunan objek yang dapat dijumlahkan dan dikalikan dengan elemen-elemen dari \mathcal{F} , sedemikian rupa sehingga hasil penjumlahan dua elemen dari \mathcal{V} merupakan elemen \mathcal{V} kembali, dan hasil perkalian sebuah elemen \mathcal{V} dengan sebuah elemen dari \mathcal{F} juga merupakan elemen dari \mathcal{V} . Selain itu, sifat-sifat berikut dipenuhi:

- (a) $\forall \mathbf{u}, \mathbf{v}, \mathbf{w} \in \mathcal{V}$ berlaku $(\mathbf{u} + \mathbf{v}) + \mathbf{w} = \mathbf{u} + (\mathbf{v} + \mathbf{w})$.
- (b) $\exists \mathbf{0} \in \mathcal{V}$ sedemikian sehingga $\forall \mathbf{u} \in \mathcal{V}$ berlaku $\mathbf{u} + \mathbf{0} = \mathbf{u}$.

- (c) $\forall \mathbf{u} \in \mathcal{V}, \exists -\mathbf{u} \in \mathcal{V}$ sedemikian sehingga $\mathbf{u} + (-\mathbf{u}) = \mathbf{0}$.
- (d) $\forall \mathbf{u}, \mathbf{v} \in \mathcal{V}$ berlaku $\mathbf{u} + \mathbf{v} = \mathbf{v} + \mathbf{u}$.
- (e) $\forall c \in \mathcal{F}$ dan $\forall \mathbf{u}, \mathbf{v} \in \mathcal{V}$ berlaku $c(\mathbf{u} + \mathbf{v}) = c\mathbf{u} + c\mathbf{v}$.
- (f) $\forall a, b \in \mathcal{F}$ dan $\forall \mathbf{v} \in \mathcal{V}$ berlaku $(a + b)\mathbf{v} = a\mathbf{v} + b\mathbf{v}$.
- (g) $\forall a, b \in \mathcal{F}$ dan $\forall \mathbf{v} \in \mathcal{V}$ berlaku $(ab)\mathbf{v} = a(b\mathbf{v})$.
- (h) $\forall \mathbf{u} \in \mathcal{V}$ berlaku $1 \cdot \mathbf{u} = \mathbf{u}$, dengan 1 adalah elemen identitas pada \mathcal{F} .

Dalam mendefinisikan ruang vektor, lapangan tempat ruang vektor berada harus didefinisikan dengan spesifik, misalnya \mathbb{C}^n merupakan ruang vektor atas \mathbb{C} , tetapi \mathbb{R}^n bukan ruang vektor atas \mathbb{C} . \mathbb{R}^n merupakan ruang vektor atas \mathbb{R} .

Definisi 2.1.6 (Matriks, Lang 1987) Misalkan \mathcal{F} merupakan lapangan dan $m, n \geq 1 \in \mathbb{Z}$. Matriks adalah suatu larik atau array dari bilangan-bilangan dalam \mathcal{F} yang dinotasikan sebagai

$$\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix}.$$

Notasi matriks pada definisi di atas dapat dipersingkat dengan menulis (a_{ij}) , $i = 1, 2, \dots, m$ dan $j = 1, 2, \dots, n$. Matriks tersebut merupakan matriks $m \times n$ yang berarti bahwa matriks tersebut memiliki m -baris dan n -kolom. Sebagai contoh, kolom pertama dari matriks tersebut adalah

$$\begin{pmatrix} a_{11} \\ a_{21} \\ \vdots \\ a_{m1} \end{pmatrix}$$

dan baris pertamanya adalah $(a_{11}, a_{12}, \dots, a_{1n})$. Nilai a_{ij} disebut sebagai komponen dari matriks.

Dua buah matriks dikatakan sama apabila keduanya memiliki ukuran yang sama dan elemen-elemen pada posisi yang bersesuaian juga sama. Oleh karena itu, jika $\mathbf{A} = (a_{ij})$ dan $\mathbf{B} = (b_{ij})$, maka $\mathbf{A} = \mathbf{B}$ apabila $a_{ij} = b_{ij}$, untuk setiap i, j .

Definisi 2.1.7 (Kebebasan linear, Lang 1987) Misalkan \mathcal{V} ruang vektor atas lapangan \mathcal{F} dan misalkan pula $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ elemen-elemen dari \mathcal{V} , maka $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ dikatakan bebas linear jika dan hanya jika a_1, a_2, \dots, a_n merupakan bilangan sehingga

$$a_1\mathbf{v}_1 + a_2\mathbf{v}_2 + \dots + a_n\mathbf{v}_n = \mathbf{0}, \quad (2.1.4)$$

maka $a_i = 0, \forall i = 1, 2, \dots, n$.

Vektor $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ dikatakan bergantung linear terhadap \mathcal{F} apabila terdapat elemen-elemen a_1, a_2, \dots, a_n di \mathcal{F} yang semuanya tidak sama dengan nol, sedemikian sehingga Persamaan (2.1.4) terpenuhi.

Contoh 2.1.8 Misalkan $\mathcal{V} = \mathcal{F}^n$ dan vektor $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ didefinisikan sebagai berikut.

$$\mathbf{v}_1 = (1, 0, \dots, 0)$$

$$\vdots$$

$$\mathbf{v}_n = (0, 0, \dots, 1).$$

Vektor-vektor $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ dikatakan bebas linear. Misalkan a_1, a_2, \dots, a_n merupakan bilangan-bilangan sedemikian sehingga Persamaan (2.1.4) terpenuhi. Sebab

$$a_1\mathbf{v}_1 + a_2\mathbf{v}_2 + \dots + a_n\mathbf{v}_n = (a_1, a_2, \dots, a_n), \quad (2.1.5)$$

dapat disimpulkan bahwa $a_i = 0, \forall i = 1, 2, \dots, n$.

Definisi 2.1.9 (Span atau jangkauan linear, Axler 2024) Misalkan \mathcal{V} ruang vektor atas lapangan \mathcal{F} dan $S = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_m\} \subseteq \mathcal{V}$. Span dari S , ditulis $\text{span}(S)$,

adalah himpunan semua kombinasi linear dari elemen-elemen S , yaitu

$$\text{span}(S) = \left\{ \sum_{i=1}^m a_i \mathbf{v}_i : a_i \in \mathcal{F} \right\}. \quad (2.1.6)$$

Dengan kata lain, $\text{span}(S)$ adalah subruang terkecil dari \mathcal{V} yang memuat S . Di sisi lain, span dari himpunan kosong $\{\}$ didefinisikan sebagai $\{0\}$.

Contoh 2.1.10 Pada \mathbb{R}^2 , ambil $S = \{(1, 0), (0, 1)\}$, maka

$$\text{span}(S) = \{a(1, 0) + b(0, 1) : a, b \in \mathbb{R}\} = \mathbb{R}^2. \quad (2.1.7)$$

Hal ini berarti dua vektor standar membentang atau menjangkau (*spanning*) seluruh bidang \mathbb{R}^2 . Pada \mathbb{R}^3 , ambil $S = \{(1, 0, 0), (0, 1, 0)\}$, maka

$$\text{span}(S) = \{a(1, 0, 0) + b(0, 1, 0) : a, b \in \mathbb{R}\} = \{(x, y, 0) : x, y \in \mathbb{R}\}, \quad (2.1.8)$$

yaitu bidang xy dalam \mathbb{R}^3 .

Definisi 2.1.11 (Basis, Axler 2024) Suatu basis \mathcal{V} adalah himpunan vektor-vektor di \mathcal{V} yang bebas linear dan menjangkau (*spanning*) \mathcal{V} .

Contoh 2.1.12 Perhatikan vektor-vektor $\mathbf{v}_1 = (1, 2, -4)$ dan $\mathbf{v}_2 = (7, -5, 6)$ di dalam \mathbb{R}^3 . Jelas bahwa \mathbf{v}_1 dan \mathbf{v}_2 bebas linear, sebab tidak terdapat skalar $c \in \mathbb{R}$ sehingga $\mathbf{v}_2 = c\mathbf{v}_1$. Namun, himpunan $\{\mathbf{v}_1, \mathbf{v}_2\}$ hanya terdiri dari dua vektor, sehingga $\text{span}\{\mathbf{v}_1, \mathbf{v}_2\}$ paling jauh merupakan subruang berdimensi 2, yaitu sebuah bidang melalui titik asal di \mathbb{R}^3 . Sebab $\text{span}\{\mathbf{v}_1, \mathbf{v}_2\} \subsetneq \mathbb{R}^3$, maka himpunan ini tidak dapat dijadikan basis dari \mathbb{R}^3 .

Teorema 2.1.13 (Axler, 2024) Sebuah list dari vektor-vektor $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ merupakan basis dari \mathcal{V} jika dan hanya jika $\forall \mathbf{v} \in \mathcal{V}$ dapat dituliskan secara unik dalam bentuk

$$\mathbf{v} = a_1 \mathbf{v}_1 + a_2 \mathbf{v}_2 + \dots + a_n \mathbf{v}_n, \quad (2.1.9)$$

dengan $a_1, a_2, \dots, a_n \in \mathcal{F}$, dengan \mathcal{F} dapat berupa \mathbb{R} ataupun \mathbb{C} .

Bukti. (\Rightarrow) Pertama andaikan bahwa $\mathbf{v}_1, \dots, \mathbf{v}_n$ adalah basis dari \mathcal{V} . Sebab $\{\mathbf{v}_1, \dots, \mathbf{v}_n\}$ menjangkau \mathcal{V} , maka untuk setiap $\mathbf{v} \in \mathcal{V}$ terdapat skalar $a_1, \dots, a_n \in \mathcal{F}$ sehingga Persamaan (2.1.9) terpenuhi. Untuk menunjukkan bahwa representasi tersebut unik, misalkan terdapat skalar $c_1, \dots, c_n \in \mathcal{F}$ dengan

$$\mathbf{v} = c_1 \mathbf{v}_1 + \dots + c_n \mathbf{v}_n. \quad (2.1.10)$$

Dengan mengurangkan Persamaan (2.1.10) dari Persamaan (2.1.9) akan diperoleh

$$0 = (a_1 - c_1) \mathbf{v}_1 + \dots + (a_n - c_n) \mathbf{v}_n. \quad (2.1.11)$$

Sebab $\mathbf{v}_1, \dots, \mathbf{v}_n$ bebas linear, maka setiap koefisien harus nol, yaitu $a_k - c_k = 0$ untuk $k = 1, \dots, n$. Dengan demikian $a_1 = c_1, \dots, a_n = c_n$, sehingga representasi (2.1.9) bersifat unik. Hal ini menyelesaikan pembuktian arah pertama.

(\Leftarrow) Sebaliknya, andaikan setiap $\mathbf{v} \in \mathcal{V}$ dapat dituliskan secara unik dalam bentuk

$$\mathbf{v} = a_1 \mathbf{v}_1 + \dots + a_n \mathbf{v}_n, \quad (2.1.12)$$

maka jelas $\{\mathbf{v}_1, \dots, \mathbf{v}_n\}$ menjangkau \mathcal{V} . Untuk membuktikan bahwa $\{\mathbf{v}_1, \dots, \mathbf{v}_n\}$ bebas linear, andaikan terdapat $a_1, \dots, a_n \in \mathcal{F}$ sehingga

$$0 = a_1 \mathbf{v}_1 + \dots + a_n \mathbf{v}_n. \quad (2.1.13)$$

Sebab representasi (2.1.12) bersifat unik, khususnya untuk $\mathbf{v} = 0$, maka harus berlaku $a_1 = \dots = a_n = 0$. Jadi $\mathbf{v}_1, \dots, \mathbf{v}_n$ bebas linear. Dengan demikian $\{\mathbf{v}_1, \dots, \mathbf{v}_n\}$ adalah basis \mathcal{V} . ■

Definisi 2.1.14 (Ruang vektor berdimensi-hingga, Axler 2024) Suatu ruang vektor \mathcal{V} atas lapangan \mathcal{F} dikatakan berdimensi-hingga apabila terdapat suatu basis $\{v_1, \dots, v_n\}$ dari \mathcal{V} yang terdiri atas sejumlah hingga (n buah) vektor. Dengan kata lain, \mathcal{V} berdimensi-hingga jika \mathcal{V} dapat dijangkau oleh suatu himpunan vektor berukuran hingga.

Definisi 2.1.15 (Dimensi, Axler 2024) *Dimensi dari suatu ruang vektor berdimensi-hingga \mathcal{V} adalah banyaknya elemen dalam setiap basis \mathcal{V} . Sebab semua basis dari \mathcal{V} memiliki panjang yang sama, maka bilangan ini terdefinisi dengan baik. Dimensi \mathcal{V} dilambangkan dengan $\dim \mathcal{V}$.*

Contoh 2.1.16 Jika $U = \{(x, x, y) \in \mathbb{R}^3 : x, y \in \mathbb{R}\}$, maka $\dim U = 2$ karena $(1, 1, 0), (0, 0, 1)$ merupakan basis dari U .

2.1.2 Sifat-Sifat Matriks

Seluruh bagian ini bekerja di atas suatu lapangan \mathcal{F} (umumnya $\mathcal{F} = \mathbb{R}$ atau $\mathcal{F} = \mathbb{C}$). Untuk $m, n \geq 1$, himpunan seluruh matriks $m \times n$ berelemen di \mathcal{F} dilambangkan dengan $\text{Mat}_{m \times n}(\mathcal{F})$. Dengan penjumlahan dan perkalian skalar yang didefinisikan komponen-demi-komponen, $\text{Mat}_{m \times n}(\mathcal{F})$ membentuk ruang vektor atas lapangan \mathcal{F} (Axler, 2024).

Definisi 2.1.17 Untuk $\mathbf{A} = (a_{ij}), \mathbf{B} = (b_{ij}) \in \text{Mat}_{m \times n}(\mathcal{F})$ dan $c \in \mathcal{F}$, berlaku beberapa hal berikut.

- (a) $\mathbf{A} = \mathbf{B}$ jika dan hanya jika $a_{ij} = b_{ij}$ untuk semua i, j .
- (b) $(\mathbf{A} + \mathbf{B})_{ij} = a_{ij} + b_{ij}$ (didefinisikan hanya bila ukuran sama).
- (c) $(c\mathbf{A})_{ij} = c a_{ij}$.

Definisi 2.1.18 (Perkalian matriks, Axler 2024) Jika $\mathbf{A} \in \text{Mat}_{m \times n}(\mathcal{F})$ dan $\mathbf{B} \in \text{Mat}_{n \times p}(\mathcal{F})$, maka hasil kali $\mathbf{AB} \in \text{Mat}_{m \times p}(\mathcal{F})$ didefinisikan oleh

$$(\mathbf{AB})_{ik} = \sum_{j=1}^n a_{ij} b_{jk} \quad (1 \leq i \leq m, 1 \leq k \leq p). \quad (2.1.14)$$

Contoh 2.1.19 Perkalian matriks berukuran 3×2 dan 2×4 :

$$\underbrace{\begin{pmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{pmatrix}}_{3 \times 2} \underbrace{\begin{pmatrix} 6 & 5 & 4 & 3 \\ 2 & 1 & 0 & -1 \end{pmatrix}}_{2 \times 4} = \underbrace{\begin{pmatrix} 10 & 7 & 4 & 1 \\ 26 & 19 & 12 & 5 \\ 42 & 31 & 20 & 9 \end{pmatrix}}_{3 \times 4}. \quad (2.1.15)$$

Proposisi 2.1.20 (Axler, 2024) Untuk ukuran yang sesuai, berlaku:

- (a) sifat asosiatif, yaitu $(\mathbf{AB})\mathbf{C} = \mathbf{A}(\mathbf{BC})$;
- (b) sifat distributif, yaitu $\mathbf{A}(\mathbf{B} + \mathbf{C}) = \mathbf{AB} + \mathbf{AC}$ dan $(\mathbf{A} + \mathbf{B})\mathbf{C} = \mathbf{AC} + \mathbf{BC}$;
- (c) sifat identitas, yaitu $\mathbf{I}_m \mathbf{A} = \mathbf{A}$ dan $\mathbf{A} \mathbf{I}_n = \mathbf{A}$ untuk $\mathbf{A} \in \text{Mat}_{m \times n}(\mathcal{F})$; dan
- (d) dapat terjadi $\mathbf{AB} \neq \mathbf{BA}$.

Bukti. Di bawah ini adalah pembuktian untuk keempat sifat elementer perkalian matriks.

- (a) Untuk $(\mathbf{AB})\mathbf{C}$, berlaku

$$\begin{aligned}
 ((\mathbf{AB})\mathbf{C})_{ik} &= \sum_{\ell=1}^p (\mathbf{AB})_{i\ell} c_{\ell k} \\
 &= \sum_{\ell=1}^p \left(\sum_{j=1}^n a_{ij} b_{j\ell} \right) c_{\ell k} \\
 &= \sum_{j=1}^n \sum_{\ell=1}^p a_{ij} b_{j\ell} c_{\ell k}.
 \end{aligned} \tag{2.1.16}$$

Di sisi lain, untuk $\mathbf{A}(\mathbf{BC})$ berlaku

$$\begin{aligned}
 (\mathbf{A}(\mathbf{BC}))_{ik} &= \sum_{j=1}^n a_{ij} (\mathbf{BC})_{jk} \\
 &= \sum_{j=1}^n a_{ij} \left(\sum_{\ell=1}^p b_{j\ell} c_{\ell k} \right) \\
 &= \sum_{j=1}^n \sum_{\ell=1}^p a_{ij} b_{j\ell} c_{\ell k}.
 \end{aligned} \tag{2.1.17}$$

Keduanya merupakan matriks yang sama.

(b) Untuk $\mathbf{A}(\mathbf{B} + \mathbf{C})$, berlaku

$$\begin{aligned} (\mathbf{A}(\mathbf{B} + \mathbf{C}))_{ik} &= \sum_{j=1}^n a_{ij}(b_{jk} + c_{jk}) \\ &= \sum_{j=1}^n a_{ij}b_{jk} + \sum_{j=1}^n a_{ij}c_{jk} \\ &= (\mathbf{AB})_{ik} + (\mathbf{AC})_{ik}. \end{aligned} \quad (2.1.18)$$

Kasus $(\mathbf{A} + \mathbf{B})\mathbf{C}$ serupa.

(c) Untuk \mathbf{I}_m merupakan matriks identitas berukuran $m \times m$, berlaku

$$(\mathbf{I}_m \mathbf{A})_{ik} = \sum_{j=1}^m (\mathbf{I}_m)_{ij} a_{jk} = \sum_{j=1}^m \delta_{ij} a_{jk} = a_{ik}, \quad (2.1.19)$$

dan

$$(\mathbf{A} \mathbf{I}_n)_{ik} = \sum_{j=1}^n a_{ij} (\mathbf{I}_n)_{jk} = \sum_{j=1}^n a_{ij} \delta_{jk} = a_{ik}, \quad (2.1.20)$$

dengan

$$\delta_{ij} = \begin{cases} 1, & \text{jika } i = j, \\ 0, & \text{jika } i \neq j. \end{cases} \quad (2.1.21)$$

Dapat disimpulkan bahwa $\mathbf{IA} = \mathbf{A}$.

(d) Sifat ini akan dibuktikan dengan *counterexample*. Pertimbangkan perkalian matriks berikut.

$$\begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}. \quad (2.1.22)$$

Apabila urutan dibalik, akan memberikan matriks $\begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}$, sehingga kontradiksi apabila $\mathbf{AB} = \mathbf{BA}$ untuk semua \mathbf{A} dan \mathbf{B} .

■

Definisi 2.1.21 (Perkalian Hadamard, Horn dan Johnson 2012) Jika diberikan

$\mathbf{A} = (a_{ij}) \in \text{Mat}_{m \times n}(\mathcal{F})$ dan $\mathbf{B} = (b_{ij}) \in \text{Mat}_{m \times n}(\mathcal{F})$, maka perkalian Hadamard atau perkalian Schur dari \mathbf{A} dan \mathbf{B} merupakan perkalian elemen per elemen dari matriks tersebut atau dapat dituliskan sebagai berikut.

$$\mathbf{A} \odot \mathbf{B} = (a_{ij}b_{ij}) \in \text{Mat}_{m \times n}(\mathcal{F}). \quad (2.1.23)$$

Notasi perkalian Hadamard \odot dalam beberapa literatur dapat dituliskan juga dengan \circ .

Contoh 2.1.22 Misalkan

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 7 & 8 & 9 \\ 10 & 11 & 12 \end{bmatrix}.$$

Maka hasil perkalian Hadamard adalah

$$\mathbf{A} \odot \mathbf{B} = \begin{bmatrix} 1 \cdot 7 & 2 \cdot 8 & 3 \cdot 9 \\ 4 \cdot 10 & 5 \cdot 11 & 6 \cdot 12 \end{bmatrix} = \begin{bmatrix} 7 & 16 & 27 \\ 40 & 55 & 72 \end{bmatrix}.$$

Definisi 2.1.23 (Transpose) Jika $\mathbf{A} \in \text{Mat}_{m \times n}(\mathcal{F})$, maka transpose dari \mathbf{A} , dilambangkan sebagai \mathbf{A}^\top , dengan $\mathbf{A}^\top \in \text{Mat}_{n \times m}(\mathcal{F})$ didefinisikan oleh $(\mathbf{A}^\top)_{ji} = a_{ij}$.

Contoh 2.1.24 Salah satu contoh *transpose* dari matriks adalah

$$\mathbf{A} = \begin{pmatrix} -5 & 2 & 4 \\ 3 & 6 & -2 \end{pmatrix} \iff \mathbf{A}^\top = \begin{pmatrix} -5 & 3 \\ 2 & 6 \\ 4 & -2 \end{pmatrix}, \quad (2.1.24)$$

sedangkan untuk vektor adalah

$$\mathbf{a} = \begin{pmatrix} 2 \\ -3 \\ 1 \end{pmatrix} \iff \mathbf{a}^\top = (2, -3, 1). \quad (2.1.25)$$

Notasi untuk *transpose* pada vektor \mathbf{a} dapat juga dinotasikan dengan \mathbf{a}' . Di sisi lain,

untuk skalar di lapangan \mathcal{F} atau $c \in \mathcal{F}$, $c^\top = c$.

Teorema 2.1.25 Untuk \mathbf{A}, \mathbf{B} berukuran sesuai dan $c \in \mathcal{F}$, berlaku:

- (a) $(\mathbf{A}^\top)^\top = \mathbf{A}$;
- (b) $(\mathbf{A} + \mathbf{B})^\top = \mathbf{A}^\top + \mathbf{B}^\top$;
- (c) $(c\mathbf{A})^\top = c\mathbf{A}^\top$; dan
- (d) $(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top$.

Bukti. Berikut ini adalah bukti dari keempat sifat *transpose* tersebut.

- (a) Elemen-elemen dari $(\mathbf{A}^\top)^\top$ akan sama dengan elemen-elemen dari \mathbf{A} , karena

$$((\mathbf{A}^\top)^\top)_{ij} = a_{ij} = (\mathbf{A})_{ij}. \quad (2.1.26)$$

- (b) Elemen-elemen dari $(\mathbf{A} + \mathbf{B})^\top$ adalah $((\mathbf{A} + \mathbf{B})^\top)_{ij} = a_{ji} + b_{ji}$ yang merupakan elemen-elemen dari $\mathbf{A}^\top + \mathbf{B}^\top$.

- (c) Elemen-elemen dari $(c\mathbf{A})^\top$ adalah ca_{ji} yang merupakan elemen-elemen dari $c\mathbf{A}^\top$.

- (d) Dengan menuliskan $c_{ik} = (\mathbf{AB})_{ik} = \sum_j a_{ij}b_{jk}$ akan didapatkan

$$\begin{aligned} ((\mathbf{AB})^\top)_{ki} &= c_{ik} \\ &= \sum_j a_{ij}b_{jk} \\ &= \sum_j (\mathbf{B}^\top)_{kj}(\mathbf{A}^\top)_{ji} \\ &= (\mathbf{B}^\top \mathbf{A}^\top)_{ki}. \end{aligned} \quad (2.1.27)$$

■

Definisi 2.1.26 (Matriks simetris, diagonal, dan identitas) Berikut ini adalah beberapa definisi terkait matriks simetris, diagonal, dan identitas.

- (a) $\mathbf{A} \in \text{Mat}_{n \times n}(\mathcal{F})$ disebut simetris jika $\mathbf{A}^\top = \mathbf{A}$.
- (b) \mathbf{A} disebut diagonal jika $a_{ij} = 0$ untuk $i \neq j$.
- (c) \mathbf{I}_n adalah matriks identitas berukuran n , dengan elemen diagonal 1 dan selainnya 0.

Contoh 2.1.27 Matriks $\mathbf{A} = \begin{pmatrix} 3 & -2 & 4 \\ -2 & 10 & -7 \\ 4 & -7 & 9 \end{pmatrix}$ adalah matriks simetris karena $\mathbf{A}^\top = \mathbf{A}$.

Definisi 2.1.28 (Matriks ortogonal, Dhrymes 2013) Misalkan \mathbf{a} dan \mathbf{b} adalah vektor-vektor di \mathbb{R}^n . Vektor-vektor tersebut dikatakan ortogonal jika dan hanya jika

$$\mathbf{a}^\top \mathbf{b} = 0. \quad (2.1.28)$$

Sebuah matriks persegi \mathbf{A} dikatakan ortogonal jika dan hanya jika

$$\mathbf{A}^\top \mathbf{A} = \mathbf{A} \mathbf{A}^\top = \mathbf{I}_n. \quad (2.1.29)$$

Contoh 2.1.29 Misalkan

$$\mathbf{A} = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}.$$

Dapat diverifikasi bahwa \mathbf{A} adalah matriks ortogonal karena

$$\mathbf{A}^\top \mathbf{A} = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = \mathbf{I}_2.$$

Definisi 2.1.30 (Matriks idempoten, Dhrymes 2013) Suatu matriks persegi \mathbf{A} dikatakan idempoten jika dan hanya jika

$$\mathbf{A} \mathbf{A} = \mathbf{A}^2 = \mathbf{A}. \quad (2.1.30)$$

Contoh 2.1.31 Matriks proyeksi merupakan contoh klasik dari matriks idempoten.

Misalkan

$$\mathbf{P} = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}.$$

Dapat diverifikasi bahwa \mathbf{P} adalah matriks idempoten karena

$$\mathbf{P}^2 = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} = \mathbf{P}.$$

Contoh lain adalah matriks proyeksi ortogonal ke subruang yang direntang oleh vektor $\mathbf{u} = (1, 1)^\top$, yaitu

$$\mathbf{P}_u = \frac{\mathbf{u}\mathbf{u}^\top}{\mathbf{u}^\top\mathbf{u}} = \frac{1}{2} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}.$$

Dapat diperiksa bahwa $\mathbf{P}_u^2 = \mathbf{P}_u$, sehingga \mathbf{P}_u juga idempoten.

Definisi 2.1.32 (Jejak atau *trace*, Dhrymes 2013) Untuk suatu matriks persegi \mathbf{A} berukuran $n \times n$ atau $\mathbf{A} = (a_{ij}) \in \text{Mat}_{n \times n}(\mathcal{F})$, jejak atau *trace* didefinisikan sebagai

$$\text{tr}(\mathbf{A}) = \sum_{i=1}^n a_{ii}. \quad (2.1.31)$$

Contoh 2.1.33 Misalkan

$$\mathbf{A} = \begin{pmatrix} 3 & 1 & 4 \\ 1 & 5 & 9 \\ 2 & 6 & 5 \end{pmatrix}.$$

Jejak dari matriks \mathbf{A} adalah jumlah elemen-elemen pada diagonal utamanya, yaitu

$$\text{tr}(\mathbf{A}) = a_{11} + a_{22} + a_{33} = 3 + 5 + 5 = 13.$$

Perhatikan bahwa untuk matriks identitas \mathbf{I}_n berukuran $n \times n$, berlaku $\text{tr}(\mathbf{I}_n) = n$ karena setiap elemen diagonal bernilai 1.

Teorema 2.1.34 (Sifat-Sifat *Trace*, Axler 2024) Untuk ukuran yang sesuai, berla-

ku:

$$(a) \operatorname{tr}(\alpha \mathbf{A} + \beta \mathbf{B}) = \alpha \operatorname{tr}(\mathbf{A}) + \beta \operatorname{tr}(\mathbf{B});$$

$$(b) \operatorname{tr}(\mathbf{AB}) = \operatorname{tr}(\mathbf{BA}), \text{ lebih umum } \operatorname{tr}(\mathbf{ABC}) = \operatorname{tr}(\mathbf{BCA}); \text{ dan}$$

$$(c) \text{ jika } \mathbf{B} \text{ invertibel, maka } \operatorname{tr}(\mathbf{B}^{-1}\mathbf{AB}) = \operatorname{tr}(\mathbf{A}).$$

Bukti. Berikut ini adalah bukti-bukti untuk ketiga sifat di atas.

(a)

$$\begin{aligned} \operatorname{tr}(\alpha \mathbf{A} + \beta \mathbf{B}) &= \sum_i (\alpha a_{ii} + \beta b_{ii}) \\ &= \alpha \sum_i a_{ii} + \beta \sum_i b_{ii} \\ &= \alpha \operatorname{tr}(\mathbf{A}) + \beta \operatorname{tr}(\mathbf{B}). \end{aligned} \tag{2.1.32}$$

(b) Untuk dua faktor,

$$\begin{aligned} \operatorname{tr}(\mathbf{AB}) &= \sum_i (\mathbf{AB})_{ii} \\ &= \sum_i \sum_j a_{ij} b_{ji} \\ &= \sum_j \sum_i b_{ji} a_{ij} \\ &= \sum_j (\mathbf{BA})_{jj} \\ &= \operatorname{tr}(\mathbf{BA}). \end{aligned} \tag{2.1.33}$$

Untuk tiga faktor,

$$\begin{aligned}
 \text{tr}(\mathbf{ABC}) &= \sum_i (\mathbf{ABC})_{ii} \\
 &= \sum_i \sum_j \sum_k a_{ij} b_{jk} c_{ki} \\
 &= \sum_j \sum_k \sum_i b_{jk} c_{ki} a_{ij} \\
 &= \text{tr}(\mathbf{BCA}).
 \end{aligned} \tag{2.1.34}$$

(c) Dengan sifat (b), dapat diketahui bahwa

$$\begin{aligned}
 \text{tr}(\mathbf{B}^{-1}\mathbf{AB}) &= \text{tr}(\mathbf{ABB}^{-1}) \\
 &= \text{tr}(\mathbf{AI}) \\
 &= \text{tr}(\mathbf{A}).
 \end{aligned} \tag{2.1.35}$$

■

Definisi 2.1.35 (Matriks semi-definit positif, Horn dan Johnson 2012) Suatu matriks simetris $\mathbf{A} \in \text{Mat}_{n \times n}(\mathbb{R})$ dikatakan semi-definit positif jika untuk setiap vektor tak nol $\mathbf{x} \in \mathbb{R}^n$ berlaku

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} \geq 0. \tag{2.1.36}$$

Matriks \mathbf{A} dikatakan definit positif jika dan hanya jika untuk setiap vektor tak nol $\mathbf{x} \in \mathbb{R}^n$ berlaku

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0. \tag{2.1.37}$$

Contoh 2.1.36 Pertimbangkan matriks

$$\mathbf{A} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}.$$

Untuk sembarang vektor $\mathbf{x} = (x_1, x_2)^\top$, berlaku

$$\begin{aligned}\mathbf{x}^\top \mathbf{A} \mathbf{x} &= \begin{pmatrix} x_1 & x_2 \end{pmatrix} \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \\ &= 2x_1^2 + 2x_1x_2 + 2x_2^2 \\ &= x_1^2 + (x_1 + x_2)^2 + x_2^2 \geq 0.\end{aligned}\tag{2.1.38}$$

Lebih lanjut, jika $\mathbf{x} \neq \mathbf{0}$, maka $\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0$. Oleh karena itu, \mathbf{A} adalah matriks definit positif. Sebagai contoh lain, matriks identitas \mathbf{I}_n selalu definit positif karena $\mathbf{x}^\top \mathbf{I}_n \mathbf{x} = \|\mathbf{x}\|^2 > 0$ untuk setiap $\mathbf{x} \neq \mathbf{0}$.

Beberapa literatur menggunakan notasi \succeq untuk menunjukkan matriks semidefinit positif, seperti $\mathbf{A} \succeq 0$ berarti $\mathbf{x}^\top \mathbf{A} \mathbf{x} \geq 0, \forall \mathbf{x}$.

2.1.3 Invers Matriks

Sesuai kerangka Axler, konsep invers dipahami melalui operator linear dan representasinya dalam suatu basis. Sebuah matriks bujur sangkar merepresentasikan operator linear $T : \mathcal{F}^n \rightarrow \mathcal{F}^n$, dan invers matriks berkorespondensi dengan invers operator linear T^{-1} ketika T bijektif.

Definisi 2.1.37 (Invers matriks, Axler 2024) Misalkan $\mathbf{A} \in \text{Mat}_{n \times n}(\mathcal{F})$. Matriks \mathbf{A} disebut invertibel (atau non-singular) apabila terdapat matriks $\mathbf{B} \in \text{Mat}_{n \times n}(\mathcal{F})$ sedemikian sehingga

$$\mathbf{AB} = \mathbf{BA} = \mathbf{I}_n,\tag{2.1.39}$$

dengan \mathbf{I}_n matriks identitas berukuran $n \times n$. Matriks \mathbf{B} disebut invers dari \mathbf{A} dan dinotasikan \mathbf{A}^{-1} .

Contoh 2.1.38 Pertimbangkan matriks

$$\mathbf{A} = \begin{pmatrix} 2 & 1 \\ 5 & 3 \end{pmatrix}.$$

Untuk menunjukkan bahwa \mathbf{A} invertibel, perlu dicari matriks \mathbf{B} sehingga $\mathbf{AB} = \mathbf{BA} = \mathbf{I}_2$. Dengan menggunakan rumus invers matriks 2×2 , diperoleh

$$\mathbf{B} = \mathbf{A}^{-1} = \frac{1}{2 \cdot 3 - 1 \cdot 5} \begin{pmatrix} 3 & -1 \\ -5 & 2 \end{pmatrix} = \begin{pmatrix} 3 & -1 \\ -5 & 2 \end{pmatrix}.$$

Dapat diverifikasi bahwa

$$\mathbf{AB} = \begin{pmatrix} 2 & 1 \\ 5 & 3 \end{pmatrix} \begin{pmatrix} 3 & -1 \\ -5 & 2 \end{pmatrix} = \begin{pmatrix} 6 - 5 & -2 + 2 \\ 15 - 15 & -5 + 6 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = \mathbf{I}_2.$$

Dengan demikian, \mathbf{A} adalah matriks invertibel dengan invers $\mathbf{A}^{-1} = \begin{pmatrix} 3 & -1 \\ -5 & 2 \end{pmatrix}$.

Teorema 2.1.39 *Jika \mathbf{A} invertibel, maka \mathbf{A}^{-1} tunggal (unik).*

Bukti. Jika \mathbf{B} dan \mathbf{C} keduanya memenuhi $\mathbf{AB} = \mathbf{BA} = \mathbf{I}_n$ dan $\mathbf{AC} = \mathbf{CA} = \mathbf{I}_n$, maka

$$\mathbf{B} = \mathbf{BI}_n = \mathbf{B}(\mathbf{AC}) = (\mathbf{BA})\mathbf{C} = \mathbf{I}_n\mathbf{C} = \mathbf{C}. \quad (2.1.40)$$

Oleh karena itu, invers matriks adalah unik. ■

Proposisi 2.1.40 *Misalkan $\mathbf{A}, \mathbf{B} \in \text{Mat}_{n \times n}(\mathcal{F})$ invertibel dan $\alpha \in \mathcal{F}$. Berlaku:*

- (a) $(\mathbf{A}^{-1})^{-1} = \mathbf{A}$;
- (b) $(\mathbf{A}^\top)^{-1} = (\mathbf{A}^{-1})^\top$;
- (c) $(\mathbf{AB})^{-1} = \mathbf{B}^{-1}\mathbf{A}^{-1}$; dan
- (d) jika $\mathbf{A} = \text{diag}(\mathbf{B}_1, \dots, \mathbf{B}_k)$ dengan setiap \mathbf{B}_i invertibel (ukuran mungkin berbeda), maka

$$\mathbf{A}^{-1} = \text{diag}(\mathbf{B}_1^{-1}, \dots, \mathbf{B}_k^{-1}).$$

Bukti. Berikut adalah bukti untuk keempat sifat invers matriks.

- (a) Berdasarkan definisi invers, \mathbf{A}^{-1} adalah matriks yang memenuhi $\mathbf{AA}^{-1} = \mathbf{A}^{-1}\mathbf{A} = \mathbf{I}_n$. Oleh karena itu, $(\mathbf{A}^{-1})^{-1} = \mathbf{A}$.

(b) Akan ditunjukkan bahwa $(\mathbf{A}^{-1})^\top$ adalah invers dari \mathbf{A}^\top . Perhatikan bahwa

$$\begin{aligned}\mathbf{A}^\top (\mathbf{A}^{-1})^\top &= (\mathbf{A}^{-1} \mathbf{A})^\top \quad (\text{sifat transpose perkalian}) \\ &= \mathbf{I}_n^\top \\ &= \mathbf{I}_n.\end{aligned}\tag{2.1.41}$$

Demikian pula,

$$\begin{aligned}(\mathbf{A}^{-1})^\top \mathbf{A}^\top &= (\mathbf{A} \mathbf{A}^{-1})^\top \\ &= \mathbf{I}_n^\top \\ &= \mathbf{I}_n.\end{aligned}\tag{2.1.42}$$

Sebab $(\mathbf{A}^{-1})^\top$ memenuhi $\mathbf{A}^\top (\mathbf{A}^{-1})^\top = (\mathbf{A}^{-1})^\top \mathbf{A}^\top = \mathbf{I}_n$, berdasarkan definisi invers, $(\mathbf{A}^{-1})^\top = (\mathbf{A}^\top)^{-1}$.

(c) Akan ditunjukkan bahwa $\mathbf{B}^{-1} \mathbf{A}^{-1}$ adalah invers dari $\mathbf{A} \mathbf{B}$. Perhatikan bahwa

$$\begin{aligned}(\mathbf{A} \mathbf{B})(\mathbf{B}^{-1} \mathbf{A}^{-1}) &= \mathbf{A}(\mathbf{B} \mathbf{B}^{-1}) \mathbf{A}^{-1} \quad (\text{sifat asosiatif}) \\ &= \mathbf{A} \mathbf{I}_n \mathbf{A}^{-1} \\ &= \mathbf{A} \mathbf{A}^{-1} \\ &= \mathbf{I}_n.\end{aligned}\tag{2.1.43}$$

Demikian pula,

$$\begin{aligned}(\mathbf{B}^{-1} \mathbf{A}^{-1})(\mathbf{A} \mathbf{B}) &= \mathbf{B}^{-1}(\mathbf{A}^{-1} \mathbf{A}) \mathbf{B} \\ &= \mathbf{B}^{-1} \mathbf{I}_n \mathbf{B} \\ &= \mathbf{B}^{-1} \mathbf{B} \\ &= \mathbf{I}_n.\end{aligned}\tag{2.1.44}$$

Sebab $\mathbf{B}^{-1} \mathbf{A}^{-1}$ memenuhi $(\mathbf{A} \mathbf{B})(\mathbf{B}^{-1} \mathbf{A}^{-1}) = (\mathbf{B}^{-1} \mathbf{A}^{-1})(\mathbf{A} \mathbf{B}) = \mathbf{I}_n$, berdasarkan definisi invers, $\mathbf{B}^{-1} \mathbf{A}^{-1} = (\mathbf{A} \mathbf{B})^{-1}$.

(d) Misalkan $\mathbf{A} = \text{diag}(\mathbf{B}_1, \dots, \mathbf{B}_k)$ adalah matriks blok diagonal dengan setiap \mathbf{B}_i berukuran $n_i \times n_i$ dan invertibel. Akan ditunjukkan bahwa $\mathbf{A}^{-1} = \text{diag}(\mathbf{B}_1^{-1}, \dots, \mathbf{B}_k^{-1})$.

Perhatikan struktur perkalian matriks blok diagonal:

$$\begin{aligned} \mathbf{A} \cdot \text{diag}(\mathbf{B}_1^{-1}, \dots, \mathbf{B}_k^{-1}) &= \text{diag}(\mathbf{B}_1, \dots, \mathbf{B}_k) \cdot \text{diag}(\mathbf{B}_1^{-1}, \dots, \mathbf{B}_k^{-1}) \\ &= \text{diag}(\mathbf{B}_1 \mathbf{B}_1^{-1}, \dots, \mathbf{B}_k \mathbf{B}_k^{-1}) \\ &= \text{diag}(\mathbf{I}_{n_1}, \dots, \mathbf{I}_{n_k}) \\ &= \mathbf{I}_n, \end{aligned} \tag{2.1.45}$$

dengan $n = n_1 + n_2 + \dots + n_k$. Kesamaan kedua berlaku karena perkalian matriks blok diagonal bersifat *block-wise*, yaitu blok ke- i dari hasil kali adalah $\mathbf{B}_i \mathbf{B}_i^{-1}$. Analog, $\text{diag}(\mathbf{B}_1^{-1}, \dots, \mathbf{B}_k^{-1}) \cdot \mathbf{A} = \mathbf{I}_n$. Dengan demikian, $\mathbf{A}^{-1} = \text{diag}(\mathbf{B}_1^{-1}, \dots, \mathbf{B}_k^{-1})$. ■

Salah satu cara atau algoritma perhitungan invers matriks adalah dengan invers Gauss-Jordan. Jika \mathbf{A} invertibel, maka terdapat barisan operasi baris elementer (matriks elementer $\mathbf{E}_k \cdots \mathbf{E}_1$, yaitu matriks yang diperoleh dari matriks identitas dengan melakukan satu operasi baris elementer) sehingga $\mathbf{E}_k \cdots \mathbf{E}_1 \mathbf{A} = \mathbf{I}$. Dengan demikian,

$$\mathbf{A}^{-1} = \mathbf{E}_k \cdots \mathbf{E}_1. \tag{2.1.46}$$

Secara praktis, dapat dilakukan reduksi baris teraugmentasi, yaitu reduksi baris pada matriks yang diperoleh dengan menggabungkan \mathbf{A} dan \mathbf{I} secara horizontal, sehingga

$$[\mathbf{A} \mid \mathbf{I}] \xrightarrow{\text{operasi baris}} [\mathbf{I} \mid \mathbf{A}^{-1}].$$

Contoh 2.1.41 Ambil

$$\mathbf{A} = \begin{pmatrix} 2 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 2 \end{pmatrix}.$$

Dengan melakukan eliminasi Gauss–Jordan pada $[A \mid I]$ diperoleh

$$\left[\begin{array}{ccc|ccc} 2 & 1 & 0 & 1 & 0 & 0 \\ 1 & 2 & 1 & 0 & 1 & 0 \\ 0 & 1 & 2 & 0 & 0 & 1 \end{array} \right] \xrightarrow{R_1 \leftarrow R_1 - \frac{1}{2}R_2} \left[\begin{array}{ccc|ccc} \frac{3}{2} & 0 & -\frac{1}{2} & 1 & -\frac{1}{2} & 0 \\ 1 & 2 & 1 & 0 & 1 & 0 \\ 0 & 1 & 2 & 0 & 0 & 1 \end{array} \right]$$

$$\xrightarrow{R_2 \leftarrow R_2 - R_3} \left[\begin{array}{ccc|ccc} \frac{3}{2} & 0 & -\frac{1}{2} & 1 & -\frac{1}{2} & 0 \\ 1 & 1 & -1 & 0 & 1 & -1 \\ 0 & 1 & 2 & 0 & 0 & 1 \end{array} \right]$$

$$\xrightarrow{R_3 \leftarrow R_3 - R_2} \left[\begin{array}{ccc|ccc} \frac{3}{2} & 0 & -\frac{1}{2} & 1 & -\frac{1}{2} & 0 \\ 1 & 1 & -1 & 0 & 1 & -1 \\ -1 & 0 & 3 & 0 & -1 & 2 \end{array} \right]$$

$$\xrightarrow{R_1 \leftarrow R_1 + \frac{1}{2}R_3} \left[\begin{array}{ccc|ccc} 1 & 0 & 1 & 1 & -1 & 1 \\ 1 & 1 & -1 & 0 & 1 & -1 \\ -1 & 0 & 3 & 0 & -1 & 2 \end{array} \right]$$

$$\xrightarrow{R_2 \leftarrow R_2 - R_1} \left[\begin{array}{ccc|ccc} 1 & 0 & 1 & 1 & -1 & 1 \\ 0 & 1 & -2 & -1 & 2 & -2 \\ -1 & 0 & 3 & 0 & -1 & 2 \end{array} \right]$$

$$\xrightarrow{R_3 \leftarrow R_3 + R_1} \left[\begin{array}{ccc|ccc} 1 & 0 & 1 & 1 & -1 & 1 \\ 0 & 1 & -2 & -1 & 2 & -2 \\ 0 & 0 & 4 & 1 & -2 & 3 \end{array} \right]$$

$$\xrightarrow{R_3 \leftarrow \frac{1}{4}R_3} \left[\begin{array}{ccc|ccc} 1 & 0 & 1 & 1 & -1 & 1 \\ 0 & 1 & -2 & -1 & 2 & -2 \\ 0 & 0 & 1 & \frac{1}{4} & -\frac{1}{2} & \frac{3}{4} \end{array} \right]$$

$$\begin{aligned}
& \xrightarrow{R_1 \leftarrow R_1 - R_3} \left[\begin{array}{ccc|ccc} 1 & 0 & 0 & \frac{3}{4} & -\frac{1}{2} & \frac{1}{4} \\ 0 & 1 & -2 & -1 & 2 & -2 \\ 0 & 0 & 1 & \frac{1}{4} & -\frac{1}{2} & \frac{3}{4} \end{array} \right] \\
& \xrightarrow{R_2 \leftarrow R_2 + 2R_3} \left[\begin{array}{ccc|ccc} 1 & 0 & 0 & \frac{3}{4} & -\frac{1}{2} & \frac{1}{4} \\ 0 & 1 & 0 & -\frac{1}{2} & 1 & -\frac{1}{2} \\ 0 & 0 & 1 & \frac{1}{4} & -\frac{1}{2} & \frac{3}{4} \end{array} \right].
\end{aligned}$$

Maka

$$\mathbf{A}^{-1} = \begin{pmatrix} \frac{3}{4} & -\frac{1}{2} & \frac{1}{4} \\ -\frac{1}{2} & 1 & -\frac{1}{2} \\ \frac{1}{4} & -\frac{1}{2} & \frac{3}{4} \end{pmatrix}.$$

Definisi 2.1.42 (Kofaktor dan matriks adjoin, Dhrymes, 2013) Misalkan $\mathbf{A} = (a_{ij}) \in \text{Mat}_{n \times n}(\mathcal{F})$. Minor dari elemen a_{ij} , dinotasikan M_{ij} , adalah determinan submatriks berukuran $(n-1) \times (n-1)$ yang diperoleh dengan menghapus baris ke- i dan kolom ke- j dari \mathbf{A} . Kofaktor dari a_{ij} didefinisikan sebagai

$$C_{ij} = (-1)^{i+j} M_{ij}. \quad (2.1.47)$$

Matriks kofaktor adalah $\mathbf{C} = (C_{ij})$. Matriks adjoin (atau adjugate) dari \mathbf{A} , dinotasikan $\text{adj}(\mathbf{A})$, adalah transpose dari matriks kofaktor:

$$\text{adj}(\mathbf{A}) = \mathbf{C}^\top. \quad (2.1.48)$$

Teorema 2.1.43 Jika $\mathbf{A} \in \mathcal{F}^{n \times n}$ dengan $\det(\mathbf{A}) \neq 0$, maka

$$\mathbf{A}^{-1} = \frac{1}{\det(\mathbf{A})} \text{adj}(\mathbf{A}). \quad (2.1.49)$$

Bukti. Akan ditunjukkan bahwa $\mathbf{A} \cdot \text{adj}(\mathbf{A}) = \det(\mathbf{A}) \cdot \mathbf{I}_n$. Elemen (i, j) dari

matriks $\mathbf{A} \cdot \text{adj}(\mathbf{A})$ adalah

$$(\mathbf{A} \cdot \text{adj}(\mathbf{A}))_{ij} = \sum_{k=1}^n a_{ik} \cdot (\text{adj}(\mathbf{A}))_{kj} = \sum_{k=1}^n a_{ik} C_{jk}, \quad (2.1.50)$$

dengan C_{jk} adalah kofaktor dari elemen a_{jk} pada matriks \mathbf{A} .

Teorema ekspansi Laplace menyatakan bahwa determinan matriks dapat dihitung dengan ekspansi kofaktor sepanjang baris ke- i :

$$\det(\mathbf{A}) = \sum_{k=1}^n a_{ik} C_{ik}. \quad (2.1.51)$$

Oleh karena itu, $(\mathbf{A} \cdot \text{adj}(\mathbf{A}))_{ii} = \det(\mathbf{A})$.

Sifat ekspansi kofaktor asing menyatakan bahwa jumlah $\sum_{k=1}^n a_{ik} C_{jk}$ dengan $i \neq j$ sama dengan determinan matriks yang memiliki dua baris identik (baris ke- i dan baris ke- j), sehingga bernilai nol:

$$\sum_{k=1}^n a_{ik} C_{jk} = 0 \quad \text{untuk } i \neq j. \quad (2.1.52)$$

Dengan menggabungkan kedua kasus, diperoleh

$$(\mathbf{A} \cdot \text{adj}(\mathbf{A}))_{ij} = \delta_{ij} \det(\mathbf{A}), \quad (2.1.53)$$

dengan δ_{ij} adalah delta Kronecker, yaitu fungsi yang bernilai 1 jika $i = j$ dan 0 jika $i \neq j$. Ini berarti $\mathbf{A} \cdot \text{adj}(\mathbf{A}) = \det(\mathbf{A}) \cdot \mathbf{I}_n$. Sebab $\det(\mathbf{A}) \neq 0$, dapat dibagi kedua ruas dengan $\det(\mathbf{A})$ sehingga

$$\mathbf{A} \cdot \frac{1}{\det(\mathbf{A})} \text{adj}(\mathbf{A}) = \mathbf{I}_n. \quad (2.1.54)$$

Dengan demikian, $\mathbf{A}^{-1} = \frac{1}{\det(\mathbf{A})} \text{adj}(\mathbf{A})$. ■

Contoh 2.1.44 Untuk matriks $\mathbf{A} = \begin{pmatrix} 1 & 2 & 3 \\ 0 & 1 & 4 \\ 5 & 6 & 0 \end{pmatrix}$, akan dihitung inversnya menggunakan rumus adjoin. Pertama, dihitung kofaktor-kofaktor dari setiap elemen matriks:

$$C_{11} = (-1)^{1+1} \det \begin{pmatrix} 1 & 4 \\ 6 & 0 \end{pmatrix} = 1 \cdot (1 \cdot 0 - 4 \cdot 6) = -24,$$

$$C_{12} = (-1)^{1+2} \det \begin{pmatrix} 0 & 4 \\ 5 & 0 \end{pmatrix} = -1 \cdot (0 \cdot 0 - 4 \cdot 5) = 20,$$

$$C_{13} = (-1)^{1+3} \det \begin{pmatrix} 0 & 1 \\ 5 & 6 \end{pmatrix} = 1 \cdot (0 \cdot 6 - 1 \cdot 5) = -5,$$

$$C_{21} = (-1)^{2+1} \det \begin{pmatrix} 2 & 3 \\ 6 & 0 \end{pmatrix} = -1 \cdot (2 \cdot 0 - 3 \cdot 6) = 18,$$

$$C_{22} = (-1)^{2+2} \det \begin{pmatrix} 1 & 3 \\ 5 & 0 \end{pmatrix} = 1 \cdot (1 \cdot 0 - 3 \cdot 5) = -15,$$

$$C_{23} = (-1)^{2+3} \det \begin{pmatrix} 1 & 2 \\ 5 & 6 \end{pmatrix} = -1 \cdot (1 \cdot 6 - 2 \cdot 5) = 4,$$

$$C_{31} = (-1)^{3+1} \det \begin{pmatrix} 2 & 3 \\ 1 & 4 \end{pmatrix} = 1 \cdot (2 \cdot 4 - 3 \cdot 1) = 5,$$

$$C_{32} = (-1)^{3+2} \det \begin{pmatrix} 1 & 3 \\ 0 & 4 \end{pmatrix} = -1 \cdot (1 \cdot 4 - 3 \cdot 0) = -4,$$

$$C_{33} = (-1)^{3+3} \det \begin{pmatrix} 1 & 2 \\ 0 & 1 \end{pmatrix} = 1 \cdot (1 \cdot 1 - 2 \cdot 0) = 1.$$

Matriks kofaktor adalah

$$\mathbf{C} = \begin{pmatrix} -24 & 20 & -5 \\ 18 & -15 & 4 \\ 5 & -4 & 1 \end{pmatrix},$$

sehingga matriks adjoin (transpose dari matriks kofaktor) adalah

$$\text{adj}(\mathbf{A}) = \mathbf{C}^T = \begin{pmatrix} -24 & 18 & 5 \\ 20 & -15 & -4 \\ -5 & 4 & 1 \end{pmatrix}.$$

Selanjutnya, determinan \mathbf{A} dihitung menggunakan ekspansi kofaktor sepanjang baris pertama:

$$\det(\mathbf{A}) = a_{11}C_{11} + a_{12}C_{12} + a_{13}C_{13} = -24 + 40 - 15 = 1.$$

Sebab $\det(\mathbf{A}) = 1 \neq 0$, maka \mathbf{A} invertibel dan

$$\mathbf{A}^{-1} = \frac{1}{\det(\mathbf{A})} \text{adj}(\mathbf{A}) = \frac{1}{1} \begin{pmatrix} -24 & 18 & 5 \\ 20 & -15 & -4 \\ -5 & 4 & 1 \end{pmatrix} = \begin{pmatrix} -24 & 18 & 5 \\ 20 & -15 & -4 \\ -5 & 4 & 1 \end{pmatrix}.$$

Untuk memverifikasi hasil, dapat diperiksa bahwa $\mathbf{A}\mathbf{A}^{-1} = \mathbf{I}_3$:

$$\begin{aligned} \mathbf{A}\mathbf{A}^{-1} &= \begin{pmatrix} 1 & 2 & 3 \\ 0 & 1 & 4 \\ 5 & 6 & 0 \end{pmatrix} \begin{pmatrix} -24 & 18 & 5 \\ 20 & -15 & -4 \\ -5 & 4 & 1 \end{pmatrix} \\ &= \begin{pmatrix} -24 + 40 - 15 & 18 - 30 + 12 & 5 - 8 + 3 \\ 0 + 20 - 20 & 0 - 15 + 16 & 0 - 4 + 4 \\ -120 + 120 + 0 & 90 - 90 + 0 & 25 - 24 + 0 \end{pmatrix} \\ &= \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} = \mathbf{I}_3. \end{aligned}$$

Dengan demikian, hasil perhitungan invers terverifikasi benar.

Contoh 2.1.45 Untuk $\mathbf{A} = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$ dengan $ad - bc \neq 0$, matriks adjoin adalah

$$\text{adj}(\mathbf{A}) = \begin{pmatrix} d & -b \\ -c & a \end{pmatrix},$$

sehingga

$$\mathbf{A}^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}. \quad (2.1.55)$$

Rumus ini konsisten dengan Gauss–Jordan dan merupakan kasus khusus dari rumus adjoin ketika $n = 2$.

2.1.4 Determinan dan Rank

Pada seluruh bagian ini, \mathcal{V} menyatakan ruang vektor berdimensi hingga atas suatu lapangan \mathcal{F} dan $\mathcal{L}(\mathcal{V}, \mathcal{W})$ himpunan semua pemetaan linear $\mathcal{V} \rightarrow \mathcal{W}$.

Definisi 2.1.46 (Pemetaan linear, Axler 2024) Misalkan \mathcal{V}, \mathcal{W} ruang vektor atas suatu lapangan \mathcal{F} . Suatu pemetaan $T : \mathcal{V} \rightarrow \mathcal{W}$ disebut pemetaan linear jika untuk semua $\mathbf{u}, \mathbf{v} \in \mathcal{V}$ dan $\lambda \in \mathcal{F}$ berlaku

$$T(\mathbf{u} + \mathbf{v}) = T(\mathbf{u}) + T(\mathbf{v}), \quad T(\lambda \mathbf{v}) = \lambda T(\mathbf{v}). \quad (2.1.56)$$

Notasi $\mathcal{L}(\mathcal{V}, \mathcal{W})$ menyatakan himpunan semua pemetaan linear dari \mathcal{V} ke \mathcal{W} . Jika $\mathcal{V} = \mathcal{W}$, maka $\mathcal{L}(\mathcal{V}) = \mathcal{L}(\mathcal{V}, \mathcal{V})$ adalah himpunan semua operator linear pada \mathcal{V} .

Contoh 2.1.47 Berikut ini adalah beberapa contoh pemetaan linear.

(a) Jika $\mathcal{V} = \mathcal{W} = \mathbb{R}^2$, maka pemetaan

$$T(\mathbf{x}, \mathbf{y}) = (\mathbf{x} + 2\mathbf{y}, 3\mathbf{x} - \mathbf{y}) \quad (2.1.57)$$


adalah elemen $\mathcal{L}(\mathbb{R}^2, \mathbb{R}^2)$.

(b) Jika $\mathcal{V} = \mathbb{R}^3$ dan $\mathcal{W} = \mathbb{R}^2$, maka setiap $T \in \mathcal{L}(\mathbb{R}^3, \mathbb{R}^2)$ dapat direpresenta-

sikan oleh matriks 2×3 , misalnya

$$T(x_1, x_2, x_3) = \begin{pmatrix} 1 & 2 & 0 \\ 0 & 1 & -1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}. \quad (2.1.58)$$

Transformasi linear dapat divisualisasikan sebagai pemetaan yang membawa suatu vektor ke vektor lain dengan cara yang teratur (tanpa membengkokkan ruang). Sebagai contoh, Gambar 2.1 berikut memperlihatkan fungsi linear $f : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ dengan $f(x, y) = (2x, y)$ yang meregangkan komponen x dari setiap vektor dengan faktor 2. Vektor \mathbf{a} (biru) dipetakan ke $f(\mathbf{a})$ (merah).



Gambar 2.1 Ilustrasi transformasi linear $f : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ dengan $f(x, y) = (2x, y)$.

Definisi 2.1.48 (*Null space, range, dan rank, Axler 2024*) Untuk $T \in \mathcal{L}(\mathcal{V}, \mathcal{W})$, null space dan range didefinisikan sebagai

$$\text{null } T := \{\mathbf{v} \in \mathcal{V} : T\mathbf{v} = 0\}, \quad \text{range } T := \{T\mathbf{v} : \mathbf{v} \in \mathcal{V}\} \subseteq \mathcal{W}.$$

Jika \mathcal{V} berdimensi-hingga, rank T didefinisikan oleh $\text{rank } T := \dim(\text{range } T)$. Dalam notasi matriks, untuk $\mathbf{A} \in \mathcal{F}^{m \times n}$ yang merepresentasikan T relatif terhadap basis yang dipilih, $\text{rank}(\mathbf{A}) := \text{rank}(T) = \dim(\text{range } T)$.

Contoh 2.1.49 Misalkan

$$\mathbf{A} = \begin{pmatrix} 1 & 2 & 3 \\ 0 & 1 & 4 \end{pmatrix} \in \mathbb{R}^{2 \times 3}, \quad T : \mathbb{R}^3 \rightarrow \mathbb{R}^2, \text{ dan } T(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

(a) Sistem homogen $\mathbf{A}\mathbf{x} = 0$ memberi

$$x_2 = -4t, \quad x_1 = 5t, \quad x_3 = t, \quad (t \in \mathbb{R}),$$

sehingga

$$\text{null } T = \text{span}\{(5, -4, 1)^\top\} \quad \text{dan} \quad \dim(\text{null } T) = 1. \quad (2.1.59)$$

(b) Kolom pertama dan kedua bebas linear, maka

$$\text{range } T = \text{span}\{(1, 0)^\top, (2, 1)^\top\} \quad (2.1.60)$$

sehingga $\dim(\text{range } T) = 2$.

Contoh sebelumnya menyebutkan tentang Teorema Rank-Nulitas yang merupakan teorema fundamental dalam pemetaan linear. Lebih lanjut, secara formal, teorema tersebut dirumuskan sebagai berikut.

Teorema 2.1.50 (Teorema Rank–Nulitas, Axler 2024) *Jika \mathcal{V} berdimensi-hingga dan $T \in \mathcal{L}(\mathcal{V}, \mathcal{W})$, maka*

$$\dim \mathcal{V} = \dim(\text{null } T) + \dim(\text{range } T). \quad (2.1.61)$$

Bukti. Misalkan $\dim(\text{null } T) = k$ dan pilih basis $\{\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_k\}$ untuk $\text{null } T$. Sebab $\text{null } T$ adalah subruang dari \mathcal{V} , basis ini dapat diperluas menjadi basis \mathcal{V} , misalkan $\{\mathbf{u}_1, \dots, \mathbf{u}_k, \mathbf{v}_1, \dots, \mathbf{v}_m\}$ dengan $k + m = \dim \mathcal{V}$.

Akan ditunjukkan bahwa $\{T\mathbf{v}_1, T\mathbf{v}_2, \dots, T\mathbf{v}_m\}$ adalah basis untuk $\text{range } T$. Ambil sembarang $\mathbf{w} \in \text{range } T$. Maka terdapat $\mathbf{v} \in \mathcal{V}$ sehingga $T\mathbf{v} = \mathbf{w}$. Sebab

$\{\mathbf{u}_1, \dots, \mathbf{u}_k, \mathbf{v}_1, \dots, \mathbf{v}_m\}$ adalah basis \mathcal{V} , maka

$$\mathbf{v} = a_1\mathbf{u}_1 + \dots + a_k\mathbf{u}_k + b_1\mathbf{v}_1 + \dots + b_m\mathbf{v}_m \quad (2.1.62)$$

untuk suatu skalar $a_1, \dots, a_k, b_1, \dots, b_m$. Dengan menerapkan T pada kedua ruas, diperoleh

$$\begin{aligned} \mathbf{w} = T\mathbf{v} &= a_1T\mathbf{u}_1 + \dots + a_kT\mathbf{u}_k + b_1T\mathbf{v}_1 + \dots + b_mT\mathbf{v}_m \\ &= a_1 \cdot \mathbf{0} + \dots + a_k \cdot \mathbf{0} + b_1T\mathbf{v}_1 + \dots + b_mT\mathbf{v}_m \\ &= b_1T\mathbf{v}_1 + \dots + b_mT\mathbf{v}_m, \end{aligned} \quad (2.1.63)$$

sebab $\mathbf{u}_1, \dots, \mathbf{u}_k \in \text{null } T$ sehingga $T\mathbf{u}_i = \mathbf{0}$. Jadi, \mathbf{w} dapat ditulis sebagai kombinasi linear dari $\{T\mathbf{v}_1, \dots, T\mathbf{v}_m\}$.

Andaikan terdapat skalar c_1, \dots, c_m sehingga

$$c_1T\mathbf{v}_1 + c_2T\mathbf{v}_2 + \dots + c_mT\mathbf{v}_m = \mathbf{0}. \quad (2.1.64)$$

Sebab T linear, hal ini ekuivalen dengan

$$T(c_1\mathbf{v}_1 + c_2\mathbf{v}_2 + \dots + c_m\mathbf{v}_m) = \mathbf{0}, \quad (2.1.65)$$

yang berarti $c_1\mathbf{v}_1 + c_2\mathbf{v}_2 + \dots + c_m\mathbf{v}_m \in \text{null } T$. Sebab $\{\mathbf{u}_1, \dots, \mathbf{u}_k\}$ adalah basis untuk $\text{null } T$, terdapat skalar d_1, \dots, d_k sehingga

$$c_1\mathbf{v}_1 + c_2\mathbf{v}_2 + \dots + c_m\mathbf{v}_m = d_1\mathbf{u}_1 + d_2\mathbf{u}_2 + \dots + d_k\mathbf{u}_k. \quad (2.1.66)$$

Dengan menyusun ulang, diperoleh

$$(-d_1)\mathbf{u}_1 + \dots + (-d_k)\mathbf{u}_k + c_1\mathbf{v}_1 + \dots + c_m\mathbf{v}_m = \mathbf{0}. \quad (2.1.67)$$

Sebab $\{\mathbf{u}_1, \dots, \mathbf{u}_k, \mathbf{v}_1, \dots, \mathbf{v}_m\}$ adalah basis \mathcal{V} (bebas linear), semua koefisien ha-

rus nol:

$$d_1 = \cdots = d_k = 0 \quad \text{dan} \quad c_1 = \cdots = c_m = 0. \quad (2.1.68)$$

Dengan demikian, $\{T\mathbf{v}_1, \dots, T\mathbf{v}_m\}$ bebas linear.

Sebab $\{T\mathbf{v}_1, \dots, T\mathbf{v}_m\}$ menjangkau $\text{range } T$ dan bebas linear, maka himpunan ini adalah basis untuk $\text{range } T$. Oleh karena itu,

$$\dim(\text{range } T) = m. \quad (2.1.69)$$

Dengan demikian,

$$\dim V = k + m = \dim(\text{null } T) + \dim(\text{range } T). \quad (2.1.70)$$

■

Contoh 2.1.51 Berdasarkan Contoh 2.1.49, diketahui bahwa $\dim(\text{null } T) = 1$ dan $\dim(\text{range } T) = 2$. Konsisten dengan Rank–Nulitas, $1 + 2 = 3 = \dim \mathbb{R}^3$.

Definisi 2.1.52 (Bentuk multilinear anti-simetri, Axler 2024) Misalkan \mathcal{V} ruang vektor atas lapangan \mathcal{F} . Suatu fungsi $\omega : \mathcal{V}^n \rightarrow \mathcal{F}$ disebut bentuk n -linear jika linear pada setiap argumennya. Bentuk n -linear ω disebut anti-simetri atau alternating jika

$$\omega(\mathbf{v}_1, \dots, \mathbf{v}_i, \dots, \mathbf{v}_j, \dots, \mathbf{v}_n) = -\omega(\mathbf{v}_1, \dots, \mathbf{v}_j, \dots, \mathbf{v}_i, \dots, \mathbf{v}_n) \quad (2.1.71)$$

untuk setiap pertukaran dua argumen $\mathbf{v}_i, \mathbf{v}_j \in \mathcal{V}$. Konsekuensinya, jika ada dua argumen sama, maka $\omega(\mathbf{v}_1, \dots, \mathbf{v}_i, \dots, \mathbf{v}_i, \dots, \mathbf{v}_n) = 0$.


Contoh 2.1.53 Pada $\mathcal{V} = \mathbb{R}^2$, fungsi

$$\omega((x_1, y_1), (x_2, y_2)) = x_1 y_2 - x_2 y_1 \quad (2.1.72)$$

adalah bentuk bilinear anti-simetri, karena

$$\omega((x_2, y_2), (x_1, y_1)) = x_2y_1 - x_1y_2 = -\omega((x_1, y_1), (x_2, y_2)). \quad (2.1.73)$$

Nilainya sama dengan luas terorientasi jajaran genjang yang dibentuk oleh kedua vektor.



Gambar 2.2 Ilustrasi bentuk bilinear anti-simetri $\omega(v_1, v_2) = x_1y_2 - x_2y_1$ pada \mathbb{R}^2 .

Luas dari jajar genjang pada Gambar 2.2 adalah

$$|\mathbf{v}_1||\mathbf{v}_2| \cdot \sin(\theta),$$

dengan $\cos(\theta) = \frac{\mathbf{v}_1 \mathbf{v}_2}{|\mathbf{v}_1||\mathbf{v}_2|}$. Perhatikan bahwa $\sin(\theta) = \sqrt{1 - \cos^2(\theta)}$, maka

$$\begin{aligned} |\mathbf{v}_1||\mathbf{v}_2| \sin(\theta) &= \sqrt{|\mathbf{v}_1|^2|\mathbf{v}_2|^2 - (x_1x_2 + y_1y_2)^2} \\ &= \sqrt{x_1^2x_2^2 + x_1^2y_2^2 + y_1^2x_2^2 + y_1^2y_2^2 - (x_1^2x_2^2 + 2x_1x_2y_1y_2 + y_1^2y_2^2)} \\ &= \sqrt{x_1^2y_2^2 + y_1^2x_2^2 - 2x_1x_2y_1y_2} \\ &= \sqrt{(x_1y_2 - x_2y_1)^2} \\ &= |x_1y_2 - x_2y_1|. \end{aligned} \quad (2.1.74)$$

Persamaan terakhir menunjukkan bahwa luas jajar genjang pada Gambar 2.2 adalah $|x_1y_2 - x_2y_1| = |\omega(v_1, v_2)|$.

Contoh 2.1.53 memberikan intuisi penting tentang determinan. Fungsi bilinear anti-simetri $\omega(v_1, v_2) = x_1y_2 - x_2y_1$ tidak lain adalah determinannya pada

\mathbb{R}^2 . Secara geometri, determinan mengukur luas terorientasi dari jajar genjang yang dibentang oleh dua vektor. Nilai absolut $|\det|$ memberikan ukuran luas (atau volume pada dimensi lebih tinggi), sedangkan tanda determinan membedakan orientasi. Jika \mathbf{v}_1 ke \mathbf{v}_2 berputar berlawanan arah jarum jam, maka $\det(\cdot) > 0$ dan sebaliknya jika searah jarum jam, maka $\det(\cdot) < 0$.

Definisi 2.1.54 (Determinan, Axler 2024) Misalkan \mathcal{V} berdimensi $n \geq 1$. Ruang semua bentuk n -linear beranti-simetri pada \mathcal{V} memiliki dimensi 1. Untuk setiap $T \in \mathcal{L}(\mathcal{V})$, determinan T , ditulis $\det T$, adalah satu-satunya skalar di \mathcal{F} dengan sifat

$$\omega(T\mathbf{v}_1, \dots, T\mathbf{v}_n) = (\det T) \omega(\mathbf{v}_1, \dots, \mathbf{v}_n), \quad (2.1.75)$$

untuk setiap bentuk n -linear beranti-simetri ω pada \mathcal{V} . Jika \mathbf{A} adalah matriks $n \times n$ yang merepresentasikan T pada suatu basis \mathcal{V} , maka determinan matriks didefinisikan oleh $\det(\mathbf{A}) := \det(T)$.

Contoh 2.1.55 Ambil $\mathcal{V} = \mathbb{R}^2$ dan operator linear $T : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ yang direpresentasikan oleh matriks

$$\mathbf{A} = \begin{pmatrix} 3 & 5 \\ 7 & 2 \end{pmatrix}.$$

Untuk dua vektor $\mathbf{v}_1 = (2, 1)^\top$ dan $\mathbf{v}_2 = (1, 2)^\top$, bentuk bilinear anti-simetri standar di \mathbb{R}^2 adalah

$$\omega(\mathbf{v}_1, \mathbf{v}_2) = \det \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} = 3. \quad (2.1.76)$$

Sekarang apabila dilihat bayangan kedua vektor tersebut,

$$T\mathbf{v}_1 = \mathbf{A}\mathbf{v}_1 = (11, 16)^\top, \quad T\mathbf{v}_2 = \mathbf{A}\mathbf{v}_2 = (13, 11)^\top.$$


sehingga

$$\omega(T\mathbf{v}_1, T\mathbf{v}_2) = \det \begin{pmatrix} 11 & 13 \\ 16 & 11 \end{pmatrix} = 11 \cdot 11 - 13 \cdot 16 = -87. \quad (2.1.77)$$

Dengan demikian, sesuai definisi determinan operator,

$$\omega(T\mathbf{v}_1, T\mathbf{v}_2) = (\det T) \omega(\mathbf{v}_1, \mathbf{v}_2) \implies \det T = -87/3 = -29.$$

Sebab $\det(\mathbf{A}) := \det(T)$, diperoleh $\det(\mathbf{A}) = -29$, hasil ini konsisten dengan rumus determinan matriks 2×2 yang sudah dikenal, yaitu $\det \mathbf{A} = 6 - 35 = -29$.



Gambar 2.3 Perbandingan luas parallelogram sebelum dan sesudah transformasi A .

Berdasarkan ilustrasi di atas, terlihat bahwa $\det(\mathbf{A})$ memiliki makna geometris sebagai skala luas jajar genjang hasil transformasi oleh A .

Teorema 2.1.56 (Axler, 2024) Untuk $S, T \in \mathcal{L}(\mathcal{V})$ dan skalar $c \in \mathcal{F}$ berlaku:

- (a) $\det \mathbf{I}_{\mathcal{V}} = 1$;
- (b) $\det(ST) = \det S \cdot \det T$; dan
- (c) T invertibel jika dan hanya jika $\det T \neq 0$.

Jika $\mathbf{A}, \mathbf{B} \in \mathcal{F}^{n \times n}$ merepresentasikan S, T , maka $\det(\mathbf{AB}) = \det(\mathbf{A}) \det(\mathbf{B})$ dan A invertibel jika dan hanya jika $\det(\mathbf{A}) \neq 0$.

Bukti. Berikut ini adalah bukti untuk ketiga sifat dasar determinan.

- (a) Operator identitas $\mathbf{I}_{\mathcal{V}}$ memetakan setiap vektor ke dirinya sendiri, sehingga untuk setiap bentuk n -linear beranti-simetri ω berlaku

$$\omega(\mathbf{I}_{\mathcal{V}}\mathbf{v}_1, \dots, \mathbf{I}_{\mathcal{V}}\mathbf{v}_n) = \omega(\mathbf{v}_1, \dots, \mathbf{v}_n). \quad (2.1.78)$$

Berdasarkan definisi determinan, $(\det \mathbf{I}_{\mathcal{V}}) \omega(\mathbf{v}_1, \dots, \mathbf{v}_n) = \omega(\mathbf{v}_1, \dots, \mathbf{v}_n)$, sehingga $\det \mathbf{I}_{\mathcal{V}} = 1$.

- (b) Untuk $S, T \in \mathcal{L}(\mathcal{V})$ dan bentuk n -linear beranti-simetri ω , berlaku

$$\begin{aligned} \omega((ST)\mathbf{v}_1, \dots, (ST)\mathbf{v}_n) &= \omega(S(T\mathbf{v}_1), \dots, S(T\mathbf{v}_n)) \\ &= (\det S) \omega(T\mathbf{v}_1, \dots, T\mathbf{v}_n) \\ &= (\det S)(\det T) \omega(\mathbf{v}_1, \dots, \mathbf{v}_n). \end{aligned} \quad (2.1.79)$$

Di sisi lain, berdasarkan definisi determinan untuk ST :

$$\omega((ST)\mathbf{v}_1, \dots, (ST)\mathbf{v}_n) = (\det(ST)) \omega(\mathbf{v}_1, \dots, \mathbf{v}_n). \quad (2.1.80)$$

Dengan membandingkan kedua persamaan, diperoleh $\det(ST) = \det S \cdot \det T$.

- (c) (\Rightarrow) Andaikan T invertibel, maka terdapat T^{-1} sehingga $TT^{-1} = \mathbf{I}_{\mathcal{V}}$. Dengan sifat (a) dan (b):

$$1 = \det \mathbf{I}_{\mathcal{V}} = \det(TT^{-1}) = \det T \cdot \det T^{-1}. \quad (2.1.81)$$

Sebab $\det T \cdot \det T^{-1} = 1$, maka $\det T \neq 0$.

(\Leftarrow) Andaikan $\det T \neq 0$. Misalkan T tidak invertibel, maka T tidak bijektif sehingga $\text{null } T \neq \{\mathbf{0}\}$ atau $\text{range } T \neq \mathcal{V}$. Dalam kedua kasus, terdapat vektor-vektor $\mathbf{v}_1, \dots, \mathbf{v}_n$ yang bebas linear sedemikian sehingga $T\mathbf{v}_1, \dots, T\mathbf{v}_n$ bergantung linear. Sebab vektor-vektor hasil transformasi bergantung linear,

maka untuk setiap bentuk n -linear beranti-simetri ω :

$$\omega(T\mathbf{v}_1, \dots, T\mathbf{v}_n) = 0. \quad (2.1.82)$$

Namun, sebab $\mathbf{v}_1, \dots, \mathbf{v}_n$ bebas linear, berlaku $\omega(\mathbf{v}_1, \dots, \mathbf{v}_n) \neq 0$. Dari definisi determinan:

$$0 = \omega(T\mathbf{v}_1, \dots, T\mathbf{v}_n) = (\det T) \omega(\mathbf{v}_1, \dots, \mathbf{v}_n), \quad (2.1.83)$$

sehingga $\det T = 0$, yang berkontradiksi dengan asumsi $\det T \neq 0$. Jadi, T haruslah invertibel.

■

2.1.5 Nilai Eigen dan Vektor Eigen

Dalam aljabar linear, salah satu konsep penting adalah nilai eigen dan vektor eigen yang memberikan wawasan tentang bagaimana suatu operator linear bertindak pada vektor tertentu tanpa mengubah arahnya.

Definisi 2.1.57 (Vektor eigen dan nilai eigen, (Axler 2024, Lang, 1987)) Misalkan $T : \mathcal{V} \rightarrow \mathcal{V}$ adalah operator linear pada ruang vektor \mathcal{V} atas \mathbb{C} .

(a) Suatu vektor $\mathbf{v} \in \mathcal{V}$, $\mathbf{v} \neq \mathbf{0}$, disebut sebagai vektor eigen dari T jika terdapat skalar $\lambda \in \mathbb{C}$ sehingga

$$T(\mathbf{v}) = \lambda\mathbf{v}. \quad (2.1.84)$$


(b) Skalar λ yang memenuhi persamaan di atas disebut nilai eigen dari T .

Secara intuitif, vektor eigen adalah vektor yang tidak berubah arah setelah dikenakan transformasi T , melainkan hanya mengalami skala sebesar λ .

Contoh 2.1.58 Pertimbangkan $T : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ dengan

$$T(x, y) = (2x, 3y). \quad (2.1.85)$$

- (a) Untuk vektor $\mathbf{v} = (1, 0)$, berlaku $T(1, 0) = (2, 0) = 2(1, 0)$, sehingga \mathbf{v} adalah vektor eigen dengan nilai $\lambda = 2$.
- (b) Untuk vektor $\mathbf{w} = (0, 1)$, berlaku $T(0, 1) = (0, 3) = 3(0, 1)$, sehingga \mathbf{w} adalah vektor eigen dengan nilai $\lambda = 3$.



Gambar 2.4 Ilustrasi vektor eigen dan nilai eigen untuk transformasi $T(x, y) = (2x, 3y)$.

Gambar 2.4 mengilustrasikan bahwa vektor eigen \mathbf{v} dan \mathbf{w} tetap searah setelah transformasi T , hanya mengalami penskalaan sebesar nilai eigennya masing-masing. Sebaliknya, vektor $\mathbf{u} = (1, 1)$ yang bukan vektor eigen berubah menjadi $T(\mathbf{u}) = (2, 3)$ yang tidak searah dengan \mathbf{u} .

Contoh 2.1.59 Berikut akan dihitung nilai eigen dan vektor eigen dari matriks

$$\mathbf{A} = \begin{pmatrix} 4 & 1 \\ 2 & 3 \end{pmatrix}.$$

Nilai eigen λ diperoleh dari persamaan karakteristik $\det(\mathbf{A} - \lambda\mathbf{I}) = 0$:

$$\begin{aligned}\det \begin{pmatrix} 4 - \lambda & 1 \\ 2 & 3 - \lambda \end{pmatrix} &= 0 \\ (4 - \lambda)(3 - \lambda) - (1)(2) &= 0 \\ 12 - 4\lambda - 3\lambda + \lambda^2 - 2 &= 0 \\ \lambda^2 - 7\lambda + 10 &= 0 \\ (\lambda - 5)(\lambda - 2) &= 0.\end{aligned}\tag{2.1.86}$$

Dengan demikian, diperoleh nilai eigen $\lambda_1 = 5$ dan $\lambda_2 = 2$. Vektor eigen \mathbf{v}_1 memenuhi $(\mathbf{A} - 5\mathbf{I})\mathbf{v}_1 = \mathbf{0}$:

$$\begin{pmatrix} 4 - 5 & 1 \\ 2 & 3 - 5 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \begin{pmatrix} -1 & 1 \\ 2 & -2 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

Dari baris pertama didapatkan $-v_1 + v_2 = 0$, sehingga $v_2 = v_1$. Dengan memilih $v_1 = 1$, diperoleh vektor eigen

$$\mathbf{v}_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

Vektor eigen \mathbf{v}_2 memenuhi $(\mathbf{A} - 2\mathbf{I})\mathbf{v}_2 = \mathbf{0}$:

$$\begin{pmatrix} 4 - 2 & 1 \\ 2 & 3 - 2 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \begin{pmatrix} 2 & 1 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

Dari baris pertama didapatkan $2v_1 + v_2 = 0$, sehingga $v_2 = -2v_1$. Dengan memilih $v_1 = 1$, diperoleh vektor eigen

$$\mathbf{v}_2 = \begin{pmatrix} 1 \\ -2 \end{pmatrix}.$$

2.1.6 Perkalian Kronecker dan Operasi Vektorisasi

Perkalian Kronecker merupakan operasi matriks yang menghasilkan matriks blok dengan ukuran yang lebih besar dari kedua matriks operand-nya. Berbeda dengan perkalian matriks biasa yang mensyaratkan kesesuaian dimensi, perkalian Kronecker dapat dilakukan pada dua matriks dengan ukuran sembarang. Operasi ini memiliki peran penting dalam berbagai aplikasi, termasuk pemrosesan sinyal, analisis sistem linear, dan representasi tensor. Dalam konteks pembelajaran mesin dan jaringan saraf graf, perkalian Kronecker sering digunakan untuk mengkonstruksi matriks bobot yang merepresentasikan interaksi antar fitur atau simpul secara efisien.

Definisi 2.1.60 (Perkalian Kronecker, Dhrymes 2013) Untuk $\mathbf{A} \in \text{Mat}_{m \times n}(\mathcal{F})$ dan $\mathbf{B} \in \text{Mat}_{p \times q}(\mathcal{F})$, perkalian Kronecker dari matriks tersebut dituliskan sebagai $\mathbf{A} \otimes \mathbf{B}$, didefinisikan sebagai

$$\mathbf{A} \otimes \mathbf{B} = \begin{bmatrix} a_{11}\mathbf{B} & \cdots & a_{1n}\mathbf{B} \\ \vdots & \ddots & \vdots \\ a_{m1}\mathbf{B} & \cdots & a_{mn}\mathbf{B} \end{bmatrix} \in \text{Mat}_{mp \times nq}(\mathcal{F}). \quad (2.1.87)$$

Contoh 2.1.61 Apabila diambil

$$\mathbf{A} = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} \in \mathbb{R}^{2 \times 2}, \quad \mathbf{B} = \begin{pmatrix} 0 & 5 \\ 6 & 7 \end{pmatrix} \in \mathbb{R}^{2 \times 2}.$$

Perkalian Kronecker $\mathbf{A} \otimes \mathbf{B}$ adalah

$$\mathbf{A} \otimes \mathbf{B} = \begin{pmatrix} 1 \cdot \mathbf{B} & 2 \cdot \mathbf{B} \\ 3 \cdot \mathbf{B} & 4 \cdot \mathbf{B} \end{pmatrix} = \begin{pmatrix} 0 & 5 & 0 & 10 \\ 6 & 7 & 12 & 14 \\ 0 & 15 & 0 & 20 \\ 18 & 21 & 24 & 28 \end{pmatrix}. \quad (2.1.88)$$

Hasilnya adalah matriks berukuran 4×4 karena \mathbf{A} berukuran 2×2 dan \mathbf{B} juga 2×2 , sehingga ukurannya $2 \cdot 2 \times 2 \cdot 2 = 4 \times 4$.

Operasi vektorisasi (vec) adalah teknik yang digunakan untuk mengubah matriks menjadi vektor dengan cara menumpuk kolom-kolom matriks secara vertikal. Operasi ini sangat berguna dalam berbagai aplikasi matematika dan statistik, terutama dalam konteks aljabar linear dan analisis data multivariat. Vektorisasi memungkinkan kita untuk merepresentasikan data matriks dalam bentuk vektor, yang seringkali lebih mudah untuk dianalisis dan diolah menggunakan teknik-teknik statistik dan komputasi.

Definisi 2.1.62 (Vektorisasi, Dhrymes 2013) Untuk matriks berukuran $m \times n$ yaitu $\mathbf{A} = (a_{ij}) \in \text{Mat}_{m \times n}(\mathcal{F})$, operasi vektorisasi, ditulis sebagai $\text{vec}(\mathbf{A})$, didefinisikan sebagai vektor kolom berukuran $mn \times 1$ yang diperoleh dengan menumpuk kolom-kolom matriks \mathbf{A} secara vertikal dengan n elemen pertama berasal dari kolom pertama matriks A , yaitu $a_{.1}$, diikuti oleh n elemen berikutnya dari kolom kedua matriks A , yaitu $a_{.2}$, dan seterusnya, sehingga

$$\text{vec}(\mathbf{A}) = (a_{.1}^\top, a_{.2}^\top, \dots, a_{.n}^\top)^\top, \quad (2.1.89)$$

Sebaliknya, vektorisasi baris, ditulis sebagai $\text{rvec}(\mathbf{A})$, didefinisikan sebagai vektor kolom berukuran $mn \times 1$ yang diperoleh dengan menumpuk baris-baris matriks \mathbf{A} secara vertikal dengan m elemen pertama berasal dari baris pertama matriks A , yaitu $a_{1.}$, diikuti oleh m elemen berikutnya dari baris kedua matriks A , yaitu $a_{2.}$, dan seterusnya, sehingga

$$\text{rvec}(\mathbf{A}) = (a_{1.}, a_{2.}, \dots, a_{m.}). \quad (2.1.90)$$

Contoh 2.1.63 Misalkan

$$\mathbf{A} = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix} \in \mathbb{R}^{2 \times 3}.$$

Vektorisasi dari matriks \mathbf{A} adalah

$$\text{vec}(\mathbf{A}) = \begin{pmatrix} 1 \\ 4 \\ 2 \\ 5 \\ 3 \\ 6 \end{pmatrix} \in \mathbb{R}^{6 \times 1}. \quad (2.1.91)$$

Sedangkan vektorisasi barisnya adalah

$$\text{rvec}(\mathbf{A}) = \begin{pmatrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \\ 6 \end{pmatrix} \in \mathbb{R}^{6 \times 1}. \quad (2.1.92)$$

2.1.7 Norma Vektor dan Matriks

Jarak Euclidean, yaitu jarak yang didefinisikan dengan $d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_2$, adalah salah satu konsep dasar dalam aljabar linear dan analisis vektor. Jarak ini mengukur seberapa jauh dua vektor berada satu sama lain dalam ruang Euclidean, yang merupakan ruang vektor berdimensi n dengan norma Euclidean. Norma dapat didefinisikan sebagai generalisasi dari konsep panjang atau ukuran vektor dalam ruang vektor.

Definisi 2.1.64 (Norma, Horn dan Johnson 2012) Misalkan \mathcal{V} adalah ruang vektor atas lapangan \mathcal{F} (baik \mathbb{R} maupun \mathbb{C}). Fungsi $\|\cdot\| : \mathcal{V} \rightarrow \mathbb{R}$ disebut norma pada \mathcal{V} jika memenuhi sifat-sifat berikut untuk setiap $\mathbf{u}, \mathbf{v} \in \mathcal{V}$ dan skalar $c \in \mathcal{F}$:

- (a) $\|\mathbf{v}\| \geq 0$;
- (b) $\|\mathbf{v}\| = 0$ jika dan hanya jika $\mathbf{v} = \mathbf{0}$;

(c) $\|c\mathbf{v}\| = |c|\|\mathbf{v}\|$; dan

(d) $\|\mathbf{u} + \mathbf{v}\| \leq \|\mathbf{u}\| + \|\mathbf{v}\|$ (ketaksamaan segitiga).

Konsep norma dapat diperluas ke matriks, yang memungkinkan kita untuk mengukur "ukuran" atau "panjang" dari suatu matriks. Norma matriks sering digunakan dalam analisis numerik, optimisasi, dan teori kontrol untuk menilai kestabilan sistem dan konvergensi algoritma.

Dalam konteks norma Euclidean, jarak antara dua vektor \mathbf{x} dan \mathbf{y} dalam ruang Euclidean didefinisikan sebagai norma dari selisih kedua vektor tersebut, yaitu

$$d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_2 = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}. \quad (2.1.93)$$

Norma tersebut sering disebut juga norma L_2 atau norma dua dan merupakan ukuran jarak yang paling umum digunakan dalam berbagai aplikasi matematika dan ilmu komputer.

Di sisi lain, terdapat pula perkalian dalam atau (*inner product*) yang merupakan operasi biner pada ruang vektor yang menghasilkan skalar. Perkalian dalam ini memungkinkan kita untuk mengukur sudut antara dua vektor dan menentukan apakah dua vektor ortogonal (tegak lurus) satu sama lain.

Definisi 2.1.65 (Perkalian dalam, Horn dan Johnson 2012) Misalkan \mathcal{V} adalah ruang vektor atas lapangan \mathcal{F} (baik \mathbb{R} maupun \mathbb{C}). Fungsi $\langle \cdot, \cdot \rangle : \mathcal{V} \times \mathcal{V} \rightarrow \mathcal{F}$ disebut perkalian dalam pada \mathcal{V} jika memenuhi sifat-sifat berikut untuk setiap $\mathbf{u}, \mathbf{v}, \mathbf{w} \in \mathcal{V}$ dan skalar $c \in \mathcal{F}$:

(a) $\langle \mathbf{v}, \mathbf{v} \rangle \geq 0$ dan $\langle \mathbf{v}, \mathbf{v} \rangle = 0$ jika dan hanya jika $\mathbf{v} = \mathbf{0}$;

(b) $\langle \mathbf{u} + \mathbf{v}, \mathbf{w} \rangle = \langle \mathbf{u}, \mathbf{w} \rangle + \langle \mathbf{v}, \mathbf{w} \rangle$;

(c) $\langle c\mathbf{v}, \mathbf{w} \rangle = c\langle \mathbf{v}, \mathbf{w} \rangle$; dan

(d) $\langle \mathbf{v}, \mathbf{w} \rangle = \overline{\langle \mathbf{w}, \mathbf{v} \rangle}$ (simetri Hermitian).

Beberapa contoh norma yang umum digunakan pada vektor dan matriks adalah sebagai berikut:

- (a) **Norma L_1 (Norma Manhattan)**: Untuk vektor $\mathbf{x} \in \mathbb{R}^n$, norma L_1 didefinisikan sebagai

$$\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i|. \quad (2.1.94)$$

- (b) **Norma L_2 (Norma Euclidean)**: Untuk vektor $\mathbf{x} \in \mathbb{R}^n$, norma L_2 didefinisikan sebagai

$$\|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^n x_i^2}. \quad (2.1.95)$$

- (c) **Norma L_p** : Untuk vektor $\mathbf{x} \in \mathbb{R}^n$ dan $p \geq 1$, norma L_p didefinisikan sebagai

$$\|\mathbf{x}\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}. \quad (2.1.96)$$

- (d) **Norma Tak Terbatas (L_∞)**: Untuk vektor $\mathbf{x} \in \mathbb{R}^n$, norma tak terbatas didefinisikan sebagai

$$\|\mathbf{x}\|_\infty = \max_{1 \leq i \leq n} |x_i|. \quad (2.1.97)$$

- (e) **Norma Frobenius**: Untuk matriks $\mathbf{A} \in \mathbb{R}^{m \times n}$, norma Frobenius didefinisikan sebagai

$$\|\mathbf{A}\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n a_{ij}^2}. \quad (2.1.98)$$

Definisi dari norma dan perkalian dalam tidak membutuhkan syarat bahwa ruang vektor harus berdimensi hingga (Horn dan Johnson, 2012). Berikut adalah empat contoh norma pada ruang vektor $\mathcal{V}[a, b]$ dari semua fungsi kontinu atau kompleks pada interval real tertutup $[a, b]$.

- (a) Untuk $f \in \mathcal{V}[a, b]$, didefinisikan $\|f\|_2 = \left(\int_a^b |f(x)|^2 dx \right)^{1/2}$.

- (b) Untuk $f \in \mathcal{V}[a, b]$, didefinisikan $\|f\|_1 = \int_a^b |f(x)| dx$.

(c) Untuk $f \in \mathcal{V}[a, b]$, didefinisikan $\|f\|_p = \left(\int_a^b |f(x)|^p dx \right)^{1/p}$, dengan $1 \leq p < \infty$.

(d) Untuk $f \in \mathcal{V}[a, b]$, didefinisikan $\|f\|_\infty = \sup_{x \in [a, b]} |f(x)| = \max_{x \in [a, b]} |f(x)|$, karena f kontinu pada interval tertutup $[a, b]$ sehingga supremum tercapai.

2.1.8 Diferensial Vektor dan Matriks

Kalkulus matriks adalah perpanjangan dari kalkulus diferensial pada ruang Euclidean ke fungsi yang melibatkan vektor dan matriks sebagai argumen maupun hasil.

Definisi 2.1.66 (Dhrymes, 2013) *Misalkan*

$$\mathbf{y} = \psi(\mathbf{x}), \quad (2.1.99)$$

dengan \mathbf{y} dan \mathbf{x} secara berurutan merupakan vektor kolom berukuran m dan n .
Notasi

$$\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \left[\frac{\partial y_i}{\partial x_j} \right], \quad i = 1, 2, \dots, m, \quad j = 1, 2, \dots, n \quad (2.1.100)$$

merupakan notasi dari matriks derivatif parsial orde pertama (atau matriks Jacobian) dari transformasi \mathbf{x} ke \mathbf{y} sedemikian sehingga baris ke- i berisi turunan parsial dari y_i terhadap elemen dari \mathbf{x} , yaitu

$$\frac{\partial y_i}{\partial x_1}, \frac{\partial y_i}{\partial x_2}, \dots, \frac{\partial y_i}{\partial x_n}. \quad (2.1.101)$$

Proposisi 2.1.67 *Jika*

$$\mathbf{y} = \mathbf{A}\mathbf{x}, \quad (2.1.102)$$

dengan \mathbf{A} merupakan matriks berukuran $m \times n$ yang tidak bergantung pada \mathbf{x} , maka berlaku

$$\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \mathbf{A}. \quad (2.1.103)$$

Bukti. Matriks Jacobian $\frac{\partial \mathbf{y}}{\partial \mathbf{x}}$ didefinisikan sebagai matriks dengan elemen (i, j) dari

matriks tersebut adalah $\frac{\partial y_i}{\partial x_j}$. Perhatikan bahwa

$$y_i = \sum_{k=1}^n a_{ik} x_k. \quad (2.1.104)$$

Untuk setiap i dan j , turunan parsialnya adalah

$$\frac{\partial y_i}{\partial x_j} = \frac{\partial}{\partial x_j} \sum_{k=1}^n a_{ik} x_k = \sum_{k=1}^n a_{ik} \frac{\partial x_k}{\partial x_j}. \quad (2.1.105)$$

Sebab $\frac{\partial x_k}{\partial x_j} = \delta_{kj}$ (delta Kronecker), maka

$$\frac{\partial y_i}{\partial x_j} = \sum_{k=1}^n a_{ik} \delta_{kj} = a_{ij}. \quad (2.1.106)$$

Oleh karena itu, elemen (i, j) dari matriks Jacobian adalah a_{ij} , yang berarti

$$\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \mathbf{A}. \quad (2.1.107)$$

■

Proposisi 2.1.68 *Jika*

$$\mathbf{y} = \mathbf{A}\mathbf{x}, \quad (2.1.108)$$

dengan \mathbf{y} berukuran $m \times 1$, \mathbf{A} berukuran $m \times n$, \mathbf{x} berukuran $n \times 1$, serta \mathbf{A} dan \mathbf{x} bergantung pada vektor berukuran r , maka

$$\frac{\partial \mathbf{y}}{\partial \boldsymbol{\alpha}} = (\mathbf{x}^\top \otimes \mathbf{I}_m) \frac{\partial \text{vec}(\mathbf{A})}{\partial \boldsymbol{\alpha}} + \mathbf{A} \frac{\partial \mathbf{x}}{\partial \boldsymbol{\alpha}}. \quad (2.1.109)$$

Bukti. Diferensiasikan kedua ruas persamaan $\mathbf{y} = \mathbf{A}\mathbf{x}$ terhadap parameter skalar α_j , yaitu

$$\frac{\partial \mathbf{y}}{\partial \alpha_j} = \frac{\partial \mathbf{A}}{\partial \alpha_j} \mathbf{x} + \mathbf{A} \frac{\partial \mathbf{x}}{\partial \alpha_j}. \quad (2.1.110)$$

Fokus pada suku pertama $\frac{\partial \mathbf{A}}{\partial \alpha_j} \mathbf{x}$. Elemen ke- i dari vektor ini adalah

$$\left(\frac{\partial \mathbf{A}}{\partial \alpha_j} \mathbf{x} \right)_i = \sum_{k=1}^n \frac{\partial a_{ik}}{\partial \alpha_j} x_k. \quad (2.1.111)$$

Dengan menggunakan identitas vektorisasi $\text{vec}(\mathbf{A}\mathbf{x}) = (\mathbf{x}^\top \otimes \mathbf{I}_m) \text{vec}(\mathbf{A})$, didapatkan

$$\text{vec} \left(\frac{\partial \mathbf{A}}{\partial \alpha_j} \mathbf{x} \right) = (\mathbf{x}^\top \otimes \mathbf{I}_m) \text{vec} \left(\frac{\partial \mathbf{A}}{\partial \alpha_j} \right). \quad (2.1.112)$$

Apabila disusun kolom-kolom $\text{vec} \left(\frac{\partial \mathbf{A}}{\partial \alpha_j} \right)$ untuk $j = 1, \dots, r$ sebagai matriks $mn \times r$:

$$\frac{\partial \text{vec}(\mathbf{A})}{\partial \boldsymbol{\alpha}} = \begin{bmatrix} \text{vec} \left(\frac{\partial \mathbf{A}}{\partial \alpha_1} \right) & \cdots & \text{vec} \left(\frac{\partial \mathbf{A}}{\partial \alpha_r} \right) \end{bmatrix}, \quad (2.1.113)$$

akan diperoleh

$$(\mathbf{x}^\top \otimes \mathbf{I}_m) \frac{\partial \text{vec}(\mathbf{A})}{\partial \boldsymbol{\alpha}} = \begin{bmatrix} \frac{\partial \mathbf{A}}{\partial \alpha_1} \mathbf{x} & \cdots & \frac{\partial \mathbf{A}}{\partial \alpha_r} \mathbf{x} \end{bmatrix} = \frac{\partial \mathbf{A}}{\partial \boldsymbol{\alpha}} \mathbf{x}. \quad (2.1.114)$$

Untuk suku kedua, elemen ke- i dari $\mathbf{A} \frac{\partial \mathbf{x}}{\partial \boldsymbol{\alpha}}$ adalah

$$\left(\mathbf{A} \frac{\partial \mathbf{x}}{\partial \boldsymbol{\alpha}} \right)_i = \sum_{k=1}^n a_{ik} \frac{\partial x_k}{\partial \boldsymbol{\alpha}}. \quad (2.1.115)$$

Dengan menggabungkan kedua suku, diperoleh

$$\frac{\partial \mathbf{y}}{\partial \boldsymbol{\alpha}} = (\mathbf{x}^\top \otimes \mathbf{I}_m) \frac{\partial \text{vec}(\mathbf{A})}{\partial \boldsymbol{\alpha}} + \mathbf{A} \frac{\partial \mathbf{x}}{\partial \boldsymbol{\alpha}}. \quad (2.1.116)$$

■

Proposisi 2.1.69 *Jika*

$$\mathbf{y} = \mathbf{z}^\top \mathbf{A} \mathbf{x}, \quad (2.1.117)$$

dengan \mathbf{z} berukuran $m \times 1$, \mathbf{A} berukuran $m \times n$, \mathbf{x} berukuran $n \times 1$, serta \mathbf{A}

independen dari \mathbf{z} dan \mathbf{x} , maka

$$\frac{\partial \mathbf{y}}{\partial \mathbf{z}} = \mathbf{x}^\top \mathbf{A}^\top, \quad \frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \mathbf{z}^\top \mathbf{A}. \quad (2.1.118)$$

Bukti. Elemen (i, j) dari matriks Jacobian $\frac{\partial \mathbf{y}}{\partial \mathbf{z}}$ adalah $\frac{\partial y}{\partial z_i}$. Perhatikan bahwa y adalah skalar, sehingga

$$y = \mathbf{z}^\top \mathbf{A} \mathbf{x} = \sum_{i=1}^m z_i (\mathbf{A} \mathbf{x})_i = \sum_{i=1}^m z_i \sum_{k=1}^n a_{ik} x_k. \quad (2.1.119)$$

Turunan parsialnya terhadap z_i adalah

$$\frac{\partial y}{\partial z_i} = \sum_{k=1}^n a_{ik} x_k = (\mathbf{A} \mathbf{x})_i. \quad (2.1.120)$$

Dalam bentuk vektor (sebagai baris),

$$\frac{\partial \mathbf{y}}{\partial \mathbf{z}} = \mathbf{x}^\top \mathbf{A}^\top. \quad (2.1.121)$$

Untuk turunan terhadap \mathbf{x} , elemen $(j, 1)$ dari matriks Jacobian $\frac{\partial \mathbf{y}}{\partial \mathbf{x}}$ adalah $\frac{\partial y}{\partial x_j}$.

$$\frac{\partial y}{\partial x_j} = \frac{\partial}{\partial x_j} \sum_{i=1}^m z_i \sum_{k=1}^n a_{ik} x_k = \sum_{i=1}^m z_i a_{ij} = (\mathbf{z}^\top \mathbf{A})_j. \quad (2.1.122)$$

Dalam bentuk vektor (sebagai baris),

$$\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \mathbf{z}^\top \mathbf{A}. \quad (2.1.123)$$

■

Proposisi 2.1.70 Jika

$$\mathbf{y} = \mathbf{x}^\top \mathbf{A} \mathbf{x}, \quad (2.1.124)$$

dengan \mathbf{x} berukuran $n \times 1$ serta \mathbf{A} berukuran $n \times n$ dan independen dengan \mathbf{x} ,

maka

$$\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \mathbf{x}^\top (\mathbf{A} + \mathbf{A}^\top). \quad (2.1.125)$$

Jika \mathbf{A} adalah matriks simetri, maka

$$\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = 2\mathbf{x}^\top \mathbf{A}. \quad (2.1.126)$$

Bukti. Elemen $(j, 1)$ dari matriks Jacobian $\frac{\partial \mathbf{y}}{\partial \mathbf{x}}$ adalah $\frac{\partial y}{\partial x_j}$. Perhatikan bahwa

$$y = \mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{i=1}^n \sum_{k=1}^n x_i a_{ik} x_k. \quad (2.1.127)$$

Turunan parsial terhadap x_j adalah

$$\begin{aligned} \frac{\partial y}{\partial x_j} &= \frac{\partial}{\partial x_j} \sum_{i=1}^n \sum_{k=1}^n x_i a_{ik} x_k \\ &= \sum_{i=1}^n a_{ij} x_i + \sum_{k=1}^n a_{jk} x_k \\ &= \sum_{i=1}^n a_{ji} x_i + \sum_{k=1}^n a_{jk} x_k \\ &= (\mathbf{A}^\top \mathbf{x})_j + (\mathbf{A} \mathbf{x})_j. \end{aligned} \quad (2.1.128)$$

Dalam bentuk vektor (sebagai baris), ini adalah

$$\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \mathbf{x}^\top \mathbf{A}^\top + \mathbf{x}^\top \mathbf{A} = \mathbf{x}^\top (\mathbf{A} + \mathbf{A}^\top). \quad (2.1.129)$$

Jika \mathbf{A} simetri, maka $\mathbf{A}^\top = \mathbf{A}$, sehingga

$$\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \mathbf{x}^\top \mathbf{A} + \mathbf{x}^\top \mathbf{A} = 2\mathbf{x}^\top \mathbf{A}. \quad (2.1.130)$$

■

Proposisi 2.1.71 Misalkan matriks \mathbf{A} nonsingular yang berukuran $m \times m$ dan ber-

gantung dengan parameter skalar α , maka

$$\frac{\partial \mathbf{A}^{-1}}{\partial \alpha} = -\mathbf{A}^{-1} \frac{\partial \mathbf{A}}{\partial \alpha} \mathbf{A}^{-1}. \quad (2.1.131)$$

Bukti. Dari identitas $\mathbf{A} \mathbf{A}^{-1} = \mathbf{I}_m$, diferensiasikan kedua ruas terhadap parameter α :

$$\frac{\partial}{\partial \alpha} (\mathbf{A} \mathbf{A}^{-1}) = \frac{\partial \mathbf{I}_m}{\partial \alpha} = \mathbf{0}. \quad (2.1.132)$$

Dengan aturan hasil kali untuk matriks, diperoleh

$$\frac{\partial \mathbf{A}}{\partial \alpha} \mathbf{A}^{-1} + \mathbf{A} \frac{\partial \mathbf{A}^{-1}}{\partial \alpha} = \mathbf{0}. \quad (2.1.133)$$

Analisis per elemen (i, j) dari identitas di atas:

$$\sum_k \frac{\partial a_{ik}}{\partial \alpha} (\mathbf{A}^{-1})_{kj} + \sum_k a_{ik} \frac{\partial (\mathbf{A}^{-1})_{kj}}{\partial \alpha} = 0. \quad (2.1.134)$$

Pindahkan suku kedua ke ruas kanan:

$$\mathbf{A} \frac{\partial \mathbf{A}^{-1}}{\partial \alpha} = -\frac{\partial \mathbf{A}}{\partial \alpha} \mathbf{A}^{-1}. \quad (2.1.135)$$

Kalikan kedua ruas dari kiri dengan \mathbf{A}^{-1} :

$$\frac{\partial \mathbf{A}^{-1}}{\partial \alpha} = -\mathbf{A}^{-1} \frac{\partial \mathbf{A}}{\partial \alpha} \mathbf{A}^{-1}. \quad (2.1.136)$$

Verifikasi per elemen (i, j) :

$$\frac{\partial (\mathbf{A}^{-1})_{ij}}{\partial \alpha} = -\sum_k \sum_\ell (\mathbf{A}^{-1})_{ik} \frac{\partial a_{k\ell}}{\partial \alpha} (\mathbf{A}^{-1})_{\ell j}. \quad (2.1.137)$$

■

Teorema 2.1.72 (Dhrymes, 2013) Untuk matriks dengan ukuran yang sesuai berlaku:

$$\frac{\partial}{\partial \mathbf{X}} \text{tr}(\mathbf{A} \mathbf{X}) = \mathbf{A}^\top, \quad \frac{\partial}{\partial \mathbf{X}} \text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X}) = (\mathbf{A} + \mathbf{A}^\top) \mathbf{X}.$$

Bukti. Berikut ini adalah bukti untuk kedua aturan jejak tersebut.

(a) Untuk $\text{tr}(\mathbf{A}\mathbf{X})$, perhatikan bahwa

$$\text{tr}(\mathbf{A}\mathbf{X}) = \sum_{i=1}^m (\mathbf{A}\mathbf{X})_{ii} = \sum_{i=1}^m \sum_{j=1}^n a_{ij} x_{ji}. \quad (2.1.138)$$

Turunan parsial terhadap x_{kl} adalah

$$\frac{\partial}{\partial x_{kl}} \text{tr}(\mathbf{A}\mathbf{X}) = \frac{\partial}{\partial x_{kl}} \sum_{i=1}^m \sum_{j=1}^n a_{ij} x_{ji} = a_{lk}, \quad (2.1.139)$$

karena satu-satunya suku yang mengandung x_{kl} adalah ketika $j = k$ dan $i = l$. Dengan demikian,

$$\left(\frac{\partial}{\partial \mathbf{X}} \text{tr}(\mathbf{A}\mathbf{X}) \right)_{kl} = a_{lk} = (\mathbf{A}^\top)_{kl}, \quad (2.1.140)$$

sehingga $\frac{\partial}{\partial \mathbf{X}} \text{tr}(\mathbf{A}\mathbf{X}) = \mathbf{A}^\top$.

(b) Untuk $\text{tr}(\mathbf{X}^\top \mathbf{A}\mathbf{X})$, perhatikan bahwa

$$\text{tr}(\mathbf{X}^\top \mathbf{A}\mathbf{X}) = \sum_{i,j,k} x_{ji} a_{jk} x_{ki}. \quad (2.1.141)$$

Turunan parsial terhadap x_{pq} adalah

$$\begin{aligned} \frac{\partial}{\partial x_{pq}} \text{tr}(\mathbf{X}^\top \mathbf{A}\mathbf{X}) &= \frac{\partial}{\partial x_{pq}} \sum_{i,j,k} x_{ji} a_{jk} x_{ki} \\ &= \sum_k a_{pk} x_{kq} + \sum_j x_{jq} a_{jp} \\ &= (\mathbf{A}\mathbf{X})_{pq} + (\mathbf{X}^\top \mathbf{A}^\top)_{qp}^\top \\ &= (\mathbf{A}\mathbf{X})_{pq} + (\mathbf{A}^\top \mathbf{X})_{pq}. \end{aligned} \quad (2.1.142)$$

Oleh karena itu,

$$\frac{\partial}{\partial \mathbf{X}} \text{tr}(\mathbf{X}^\top \mathbf{A}\mathbf{X}) = \mathbf{A}\mathbf{X} + \mathbf{A}^\top \mathbf{X} = (\mathbf{A} + \mathbf{A}^\top) \mathbf{X}. \quad (2.1.143)$$



Contoh 2.1.73 Dalam banyak permasalahan estimasi, seringkali ingin dicari vektor parameter β yang meminimumkan suatu fungsi kuadratik. Sebagai ilustrasi, misalkan terdapat n buah observasi yang dikumpulkan dalam vektor $\mathbf{y} \in \mathbb{R}^n$ dan matriks $\mathbf{X} \in \mathbb{R}^{n \times p}$ yang berisi nilai-nilai pengukuran. Tujuannya adalah mencari vektor $\beta \in \mathbb{R}^p$ yang meminimumkan jumlah kuadrat selisih antara \mathbf{y} dan $\mathbf{X}\beta$, atau kuadrat dari norma L_2 dari vektor residual $\mathbf{y} - \mathbf{X}\beta$. Fungsi yang akan diminimumkan adalah

$$S(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|_2^2 = (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta). \quad (2.1.144)$$

Fungsi $S(\beta)$ ini mengukur seberapa jauh vektor $\mathbf{X}\beta$ dari vektor \mathbf{y} . Dengan mengekspansi perkalian dalam, diperoleh

$$\begin{aligned} S(\beta) &= (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta) \\ &= \mathbf{y}^\top \mathbf{y} - \mathbf{y}^\top \mathbf{X}\beta - (\mathbf{X}\beta)^\top \mathbf{y} + (\mathbf{X}\beta)^\top \mathbf{X}\beta \\ &= \mathbf{y}^\top \mathbf{y} - \mathbf{y}^\top \mathbf{X}\beta - \beta^\top \mathbf{X}^\top \mathbf{y} + \beta^\top \mathbf{X}^\top \mathbf{X}\beta. \end{aligned} \quad (2.1.145)$$

Perhatikan bahwa $\mathbf{y}^\top \mathbf{X}\beta$ adalah skalar, sehingga $\mathbf{y}^\top \mathbf{X}\beta = (\mathbf{y}^\top \mathbf{X}\beta)^\top = \beta^\top \mathbf{X}^\top \mathbf{y}$. Dengan demikian,

$$S(\beta) = \mathbf{y}^\top \mathbf{y} - 2\beta^\top \mathbf{X}^\top \mathbf{y} + \beta^\top \mathbf{X}^\top \mathbf{X}\beta. \quad (2.1.146)$$

Untuk meminimumkan $S(\beta)$, dihitung turunan parsialnya terhadap β dan disamakan dengan nol. Menggunakan proposisi-proposisi diferensial matriks:

- Suku $\mathbf{y}^\top \mathbf{y}$ adalah konstanta (tidak bergantung pada β), sehingga turunannya adalah 0.
- Suku $-2\beta^\top \mathbf{X}^\top \mathbf{y}$ berbentuk $\mathbf{c}^\top \beta$ dengan $\mathbf{c} = -2\mathbf{X}^\top \mathbf{y}$. Turunan dari $\mathbf{c}^\top \beta$ terhadap β adalah $\mathbf{c}^\top = -2\mathbf{y}^\top \mathbf{X}$.

- Suku $\beta^\top \mathbf{X}^\top \mathbf{X} \beta$ berbentuk $\beta^\top \mathbf{A} \beta$ dengan $\mathbf{A} = \mathbf{X}^\top \mathbf{X}$ yang simetris. Berdasarkan proposisi sebelumnya, turunannya adalah $2\beta^\top \mathbf{X}^\top \mathbf{X}$.

Dengan demikian, gradien dari $S(\beta)$ adalah

$$\frac{\partial S(\beta)}{\partial \beta} = -2\mathbf{y}^\top \mathbf{X} + 2\beta^\top \mathbf{X}^\top \mathbf{X}. \quad (2.1.147)$$

Untuk menemukan titik stasioner, disamakan gradien dengan nol:

$$\begin{aligned} -2\mathbf{y}^\top \mathbf{X} + 2\hat{\beta}^\top \mathbf{X}^\top \mathbf{X} &= \mathbf{0}^\top \\ \hat{\beta}^\top \mathbf{X}^\top \mathbf{X} &= \mathbf{y}^\top \mathbf{X}. \end{aligned} \quad (2.1.148)$$

Dengan mengambil *transpose* kedua ruas, diperoleh

$$\mathbf{X}^\top \mathbf{X} \hat{\beta} = \mathbf{X}^\top \mathbf{y}. \quad (2.1.149)$$

Jika matriks $\mathbf{X}^\top \mathbf{X}$ bersifat *nonsingular*, maka solusinya adalah

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}. \quad (2.1.150)$$

Untuk memastikan bahwa $\hat{\beta}$ adalah titik minimum (bukan maksimum atau titik pelana), diperiksa turunan kedua (Hessian) dari $S(\beta)$:

$$\frac{\partial^2 S(\beta)}{\partial \beta \partial \beta^\top} = 2\mathbf{X}^\top \mathbf{X}. \quad (2.1.151)$$

Matriks $\mathbf{X}^\top \mathbf{X}$ selalu bersifat semi-definit positif karena untuk sembarang vektor $\mathbf{v} \in \mathbb{R}^p$,

$$\mathbf{v}^\top \mathbf{X}^\top \mathbf{X} \mathbf{v} = (\mathbf{X} \mathbf{v})^\top (\mathbf{X} \mathbf{v}) = \|\mathbf{X} \mathbf{v}\|^2 \geq 0. \quad (2.1.152)$$

Jika \mathbf{X} memiliki *rank* penuh (yaitu $\text{rank}(\mathbf{X}) = p$), maka $\mathbf{X}^\top \mathbf{X}$ bersifat definit positif, sehingga $\hat{\beta}$ adalah peminimum global yang unik.

2.2 Teori Ukuran dan Probabilitas

Teori probabilitas modern dibangun di atas fondasi teori ukuran. Probabilitas dipandang sebagai suatu ukuran terstandarisasi pada kelas himpunan tertentu. Pendekatan ini memungkinkan formulasi yang utuh terhadap variabel acak umum, integrasi ekspektasi, serta analisis limit yang menjadi dasar inferensi statistik asimtotik.

2.2.1 Ruang Ukur dan Ukuran Probabilitas

Definisi 2.2.1 (Aljabar- σ , Ash 1972) Misalkan Ω adalah suatu himpunan tak kosong. Suatu koleksi $\mathcal{F} \subseteq 2^\Omega$ disebut sebagai aljabar- σ apabila memenuhi:

- (a) $\Omega \in \mathcal{F}$;
- (b) jika $A \in \mathcal{F}$, maka $A^c \in \mathcal{F}$; dan
- (c) jika $\{A_n\}_{n=1}^\infty \subseteq \mathcal{F}$, maka $\bigcup_{n=1}^\infty A_n \in \mathcal{F}$.

Contoh 2.2.2 Misalkan $\Omega = \{1, 2, 3\}$ adalah ruang sampel dengan tiga elemen. Berikut adalah beberapa contoh aljabar- σ pada Ω .

- (a) Aljabar- σ trivial: $\mathcal{F}_1 = \{\emptyset, \Omega\} = \{\emptyset, \{1, 2, 3\}\}$. Koleksi ini merupakan aljabar- σ terkecil pada Ω .
- (b) Aljabar- σ power set: $\mathcal{F}_2 = 2^\Omega = \{\emptyset, \{1\}, \{2\}, \{3\}, \{1, 2\}, \{1, 3\}, \{2, 3\}, \{1, 2, 3\}\}$. Koleksi ini merupakan aljabar- σ terbesar pada Ω yang memuat semua subhimpunan.
- (c) Aljabar- σ yang dibangkitkan oleh $\{1\}$: $\mathcal{F}_3 = \{\emptyset, \{1\}, \{2, 3\}, \{1, 2, 3\}\}$. Dapat diperiksa bahwa \mathcal{F}_3 memenuhi ketiga aksioma aljabar- σ , yaitu $\Omega \in \mathcal{F}_3$, tertutup terhadap komplemen (misalnya $\{1\}^c = \{2, 3\} \in \mathcal{F}_3$), dan tertutup terhadap gabungan terhitung.

Di sisi lain, koleksi $\mathcal{G} = \{\emptyset, \{1\}, \{2\}, \Omega\}$ bukan merupakan aljabar- σ karena $\{1\} \cup \{2\} = \{1, 2\} \notin \mathcal{G}$, sehingga tidak tertutup terhadap gabungan.

Kita tahu bahwa aljabar- σ terbesar dari suatu himpunan Ω adalah power set 2^Ω , yang memuat semua subhimpunan dari Ω . Jika \mathcal{G} adalah suatu kelas himpunan, maka aljabar- σ terkecil yang memuat \mathcal{G} dilambangkan dengan $\sigma(\mathcal{G})$ dan disebut sebagai aljabar- σ yang *dibangkitkan* oleh \mathcal{G} .

Definisi 2.2.3 (Himpunan Borel, Ash 1972) Misalkan $\Omega = \mathbb{R}$. Aljabar Borel pada \mathbb{R} , dilambangkan dengan $\mathcal{B}(\mathbb{R})$, adalah aljabar- σ terkecil yang memuat semua interval terbuka $(a, b]$, $a, b \in \mathbb{R}$. Himpunan-himpunan dalam $\mathcal{B}(\mathbb{R})$ disebut sebagai himpunan Borel.

Contoh 2.2.4 Beberapa himpunan yang termasuk dalam $\mathcal{B}(\mathbb{R})$ adalah:

- Interval terbuka: (a, b) untuk sembarang $a, b \in \mathbb{R}$ dengan $a < b$.
- Interval tertutup: $[a, b]$ untuk sembarang $a, b \in \mathbb{R}$ dengan $a < b$.
- Himpunan bilangan rasional: $\mathbb{Q} \subseteq \mathbb{R}$.
- Himpunan bilangan irasional: $\mathbb{R} \setminus \mathbb{Q}$.

Namun, terdapat himpunan-himpunan tertentu yang tidak termasuk dalam $\mathcal{B}(\mathbb{R})$, seperti himpunan Vitali yang dibangun menggunakan aksioma pilihan. Himpunan ini tidak dapat dibentuk melalui operasi hitung pada interval terbuka, sehingga tidak termasuk dalam aljabar Borel.

Definisi 2.2.5 (Ukuran) Diberikan ruang sampel Ω dan aljabar- σ \mathcal{F} relatif terhadap Ω . Suatu fungsi $\mu : \mathcal{F} \rightarrow \mathbb{R}^+$ disebut sebagai ukuran apabila:

- (a) $\mu(F) \geq 0$ untuk semua $F \in \mathcal{F}$;
- (b) $\mu(\emptyset) = 0$; dan
- (c) untuk setiap barisan himpunan saling lepas ($F_i \cap F_j = \emptyset$ untuk $i \neq j$), maka $\{F_n\}_{n=1}^\infty \subseteq \mathcal{F}$ berlaku.

Triple $(\Omega, \mathcal{F}, \mu)$ disebut sebagai ruang ukur.

Definisi 2.2.6 (Ukuran probabilitas, Billingsley 1995) Suatu fungsi $\Pr : \mathcal{F} \rightarrow [0, 1]$ disebut sebagai ukuran probabilitas apabila:

- (a) $\Pr(\Omega) = 1$ dan $\Pr(\emptyset) = 0$;
- (b) $0 \leq \Pr(A) \leq 1$ untuk semua $A \in \mathcal{F}$; dan
- (c) untuk setiap barisan himpunan saling lepas $\{A_n\}_{n=1}^{\infty} \subseteq \mathcal{F}$ berlaku

$$\Pr\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \Pr(A_n). \quad (2.2.1)$$

Triple $(\Omega, \mathcal{F}, \Pr)$ disebut sebagai *ruang probabilitas*. Penyokong atau *support* dari ukuran probabilitas \Pr adalah himpunan terkecil $S \in \mathcal{F}$ sehingga $\Pr(S) = 1$.

Contoh 2.2.7 Misalkan $\Omega = \{1, 2, 3, 4, 5, 6\}$ adalah ruang sampel pelemparan sebuah dadu seimbang, dan $\mathcal{F} = 2^{\Omega}$ adalah aljabar- σ yang memuat semua subhimpunan dari Ω . Didefinisikan fungsi $\Pr : \mathcal{F} \rightarrow [0, 1]$ dengan

$$\Pr(A) = \frac{|A|}{6} \quad (2.2.2)$$

untuk setiap $A \in \mathcal{F}$, dengan $|A|$ menyatakan banyaknya elemen dalam A . Akan diperiksa bahwa \Pr memenuhi aksioma ukuran probabilitas.

- (a) $\Pr(\Omega) = \Pr(\{1, 2, 3, 4, 5, 6\}) = \frac{6}{6} = 1$ dan $\Pr(\emptyset) = \frac{0}{6} = 0$.
- (b) Untuk setiap $A \in \mathcal{F}$, berlaku $0 \leq |A| \leq 6$, sehingga $0 \leq \Pr(A) = \frac{|A|}{6} \leq 1$.
- (c) Untuk himpunan saling lepas $A_1, A_2, \dots \subseteq \mathcal{F}$, berlaku

$$\Pr\left(\bigcup_{n=1}^{\infty} A_n\right) = \frac{|\bigcup_{n=1}^{\infty} A_n|}{6} = \frac{\sum_{n=1}^{\infty} |A_n|}{6} = \sum_{n=1}^{\infty} \frac{|A_n|}{6} = \sum_{n=1}^{\infty} \Pr(A_n). \quad (2.2.3)$$

Dengan demikian, \Pr adalah ukuran probabilitas pada (Ω, \mathcal{F}) . Sebagai contoh perhitungan, probabilitas memperoleh angka genap adalah

$$\Pr(\{2, 4, 6\}) = \frac{3}{6} = \frac{1}{2}. \quad (2.2.4)$$

Definisi 2.2.8 (Ukuran Lebesgue-Stieltjes, Ash 1972) Suatu ukuran Lebesgue-Stieltjes pada \mathbb{R} adalah ukuran μ pada $\mathcal{B}(\mathbb{R})$ sedemikian sehingga $\mu(I) < \infty$ untuk setiap interval terbatas $I \subset \mathbb{R}$.

Definisi 2.2.9 (Fungsi distribusi, Ash 1972) Suatu fungsi distribusi pada \mathbb{R} adalah pemetaan $F : \mathbb{R} \rightarrow \mathbb{R}$ yang increasing (jika $a < b$, maka $F(a) \leq F(b)$) dan right-continuous ($\lim_{x \rightarrow x^+} F(x) = F(x_0)$).

Apabila dipilih $\mu(a, b] = F(b) - F(a) = \int_a^b f(x) dx$ untuk suatu fungsi $f : \mathbb{R} \rightarrow \mathbb{R}, f \geq 0$ yang terintegral (Riemann), maka F adalah fungsi distribusi. Sebagai contoh, apabila dipilih $f(x) = 1, \forall x$ dan $F(x) = x$, maka $\mu(a, b] = b - a$. Himpunan fungsi μ yang diperoleh dengan cara ini disebut sebagai *ukuran Lebesgue* pada $\mathcal{B}(\mathbb{R})$ (Ash, 1972).

Definisi 2.2.10 (Ukuran Lebesgue) Ukuran Lebesgue pada $\mathcal{B}(\mathbb{R})$ adalah ukuran Lebesgue-Stieltjes yang didefinisikan oleh $\mu(a, b] = b - a$ untuk setiap interval terbatas $(a, b] \subset \mathbb{R}$.

2.2.2 Variabel Acak sebagai Fungsi Terukur

Definisi 2.2.11 (Variabel acak) Diberikan ruang probabilitas $(\Omega, \mathcal{F}, \Pr)$ dan ruang terukur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$. Suatu fungsi $X : \Omega \rightarrow \mathbb{R}$ disebut sebagai variabel acak apabila X terukur, yaitu untuk setiap $B \in \mathcal{B}(\mathbb{R})$ berlaku

$$X^{-1}(B) = \{\omega \in \Omega : X(\omega) \in B\} \in \mathcal{F}. \quad (2.2.5)$$

Pendefinisian ini memungkinkan penggunaan teori integrasi Lebesgue untuk mendefinisikan ekspektasi dan momen variabel acak secara umum.

Teorema 2.2.12 Misalkan triple $(\Omega, \mathcal{F}, \Pr)$ adalah ruang probabilitas dan $X : \Omega \rightarrow \mathbb{R}$ adalah variabel acak, maka X menginduksi ruang probabilitas $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \Pr_X)$ pada garis real, dengan \Pr_X didefinisikan oleh

$$\Pr_X(B) = \Pr(X^{-1}(B)) = \Pr(\{\omega \in \Omega : X(\omega) \in B\}), \quad \forall B \in \mathcal{B}(\mathbb{R}). \quad (2.2.6)$$

Ukuran \Pr_X disebut sebagai distribusi dari variabel acak X .

Bukti. Akan ditunjukkan bahwa \Pr_X memenuhi ketiga aksioma ukuran probabilitas.

- (a) **Normalisasi:** Perhatikan bahwa $X^{-1}(\mathbb{R}) = \{\omega \in \Omega : X(\omega) \in \mathbb{R}\} = \Omega$, karena X memetakan setiap $\omega \in \Omega$ ke suatu bilangan real. Oleh karena itu,

$$\Pr_X(\mathbb{R}) = \Pr(X^{-1}(\mathbb{R})) = \Pr(\Omega) = 1. \quad (2.2.7)$$

- (b) **Non-negativitas:** Untuk setiap $B \in \mathcal{B}(\mathbb{R})$, karena X adalah variabel acak (fungsi terukur), maka $X^{-1}(B) \in \mathcal{F}$. Sebab \Pr adalah ukuran probabilitas pada (Ω, \mathcal{F}) , berlaku

$$\Pr_X(B) = \Pr(X^{-1}(B)) \geq 0. \quad (2.2.8)$$

- (c) **σ -aditivitas:** Misalkan $\{B_n\}_{n=1}^{\infty}$ adalah barisan himpunan saling lepas dalam $\mathcal{B}(\mathbb{R})$, yaitu $B_i \cap B_j = \emptyset$ untuk $i \neq j$. Akan ditunjukkan bahwa $\{X^{-1}(B_n)\}_{n=1}^{\infty}$ juga saling lepas dalam \mathcal{F} . Andaikan terdapat $\omega \in X^{-1}(B_i) \cap X^{-1}(B_j)$ untuk $i \neq j$. Maka $X(\omega) \in B_i$ dan $X(\omega) \in B_j$, sehingga $X(\omega) \in B_i \cap B_j = \emptyset$, yang merupakan kontradiksi. Jadi, $X^{-1}(B_i) \cap X^{-1}(B_j) = \emptyset$ untuk $i \neq j$.

Selanjutnya, perhatikan bahwa

$$X^{-1}\left(\bigcup_{n=1}^{\infty} B_n\right) = \bigcup_{n=1}^{\infty} X^{-1}(B_n). \quad (2.2.9)$$

Sebab \Pr adalah ukuran probabilitas yang memenuhi σ -aditivitas, diperoleh

$$\begin{aligned}
 \Pr_X \left(\bigcup_{n=1}^{\infty} B_n \right) &= \Pr \left(X^{-1} \left(\bigcup_{n=1}^{\infty} B_n \right) \right) \\
 &= \Pr \left(\bigcup_{n=1}^{\infty} X^{-1}(B_n) \right) \\
 &= \sum_{n=1}^{\infty} \Pr(X^{-1}(B_n)) \\
 &= \sum_{n=1}^{\infty} \Pr_X(B_n). \tag{2.2.10}
 \end{aligned}$$

Dengan demikian, \Pr_X memenuhi ketiga aksioma ukuran probabilitas, sehingga $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \Pr_X)$ adalah ruang probabilitas yang diinduksi oleh variabel acak X . ■

2.2.3 Distribusi dan Ekspektasi

Definisi 2.2.13 (Distribusi variabel acak) *Distribusi dari variabel acak X adalah ukuran probabilitas \Pr_X pada $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ yang didefinisikan oleh*

$$\Pr_X(B) = \Pr(X \in B), \quad B \in \mathcal{B}(\mathbb{R}). \tag{2.2.11}$$

Definisi 2.2.14 (Fungsi kepadatan probabilitas) *Misalkan X adalah variabel acak dengan distribusi \Pr_X . Jika terdapat fungsi terintegralkan $f_X : \mathbb{R} \rightarrow [0, \infty)$ sedemikian sehingga untuk setiap himpunan Borel $B \in \mathcal{B}(\mathbb{R})$ berlaku*

$$\Pr_X(B) = \Pr(X \in B) = \int_B f_X(x) \, dx, \tag{2.2.12}$$

maka f_X disebut sebagai fungsi kepadatan probabilitas (fkp) atau probability density function (pdf) dari X . Fungsi kepadatan probabilitas memenuhi sifat:

- (a) $f_X(x) \geq 0$ untuk semua $x \in \mathbb{R}$, dan
- (b) $\int_{-\infty}^{\infty} f_X(x) \, dx = 1$.

Variabel acak yang memiliki fungsi kepadatan probabilitas disebut variabel acak

kontinu. Di sisi lain, untuk variabel acak diskrit, digunakan fungsi massa probabilitas (*fmp*) yang didefinisikan sebagai $p_X(x) = \Pr(X = x)$.

Perlu dicatat bahwa distribusi dan kepadatan adalah konsep yang berbeda. Distribusi \Pr_X adalah ukuran probabilitas yang memetakan himpunan ke probabilitas, sedangkan kepadatan f_X adalah fungsi yang menggambarkan “kepadatan” probabilitas pada setiap titik. Tidak semua distribusi memiliki fungsi kepadatan; sebagai contoh, distribusi diskrit seperti Bernoulli tidak memiliki kepadatan terhadap ukuran Lebesgue, melainkan memiliki fungsi massa probabilitas.

Contoh 2.2.15 Berikut adalah beberapa distribusi probabilitas yang sering digunakan dalam statistika dan pembelajaran mesin.

- (a) **Distribusi Normal (Gaussian).** Variabel acak X berdistribusi normal dengan parameter μ (rata-rata) dan σ^2 (variansi), ditulis $X \sim \mathcal{N}(\mu, \sigma^2)$, jika memiliki fungsi kepadatan probabilitas

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad x \in \mathbb{R}. \quad (2.2.13)$$

Distribusi normal standar diperoleh ketika $\mu = 0$ dan $\sigma^2 = 1$.

- (b) **Distribusi Bernoulli.** Variabel acak X berdistribusi Bernoulli dengan parameter $p \in [0, 1]$, ditulis $X \sim \text{Bernoulli}(p)$, jika

$$\Pr(X = k) = p^k(1-p)^{1-k}, \quad k \in \{0, 1\}. \quad (2.2.14)$$

Distribusi ini memodelkan percobaan dengan dua kemungkinan hasil (sukses atau gagal).

- (c) **Distribusi Poisson.** Variabel acak X berdistribusi Poisson dengan parameter $\lambda > 0$, ditulis $X \sim \text{Poisson}(\lambda)$, jika

$$\Pr(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k \in \{0, 1, 2, \dots\}. \quad (2.2.15)$$

Distribusi ini memodelkan banyaknya kejadian langka dalam interval waktu atau ruang tertentu.

- (d) **Distribusi Eksponensial.** Variabel acak X berdistribusi eksponensial dengan parameter $\lambda > 0$, ditulis $X \sim \text{Exp}(\lambda)$, jika memiliki fungsi kepadatan probabilitas

$$f_X(x) = \lambda e^{-\lambda x}, \quad x \geq 0. \quad (2.2.16)$$

Distribusi ini sering digunakan untuk memodelkan waktu tunggu antara kejadian berurutan.

Definisi 2.2.16 (Fungsi sederhana, Dudley 2002) Suatu fungsi $s : \Omega \rightarrow \mathbb{R}$ disebut fungsi sederhana apabila s hanya mengambil sejumlah hingga nilai berbeda. Fungsi sederhana dapat dituliskan dalam bentuk

$$s(\omega) = \sum_{k=1}^n c_k \mathbf{1}_{A_k}(\omega), \quad (2.2.17)$$

dengan $c_1, \dots, c_n \in \mathbb{R}$ adalah nilai-nilai yang berbeda, $A_k = s^{-1}(\{c_k\})$ adalah himpunan terukur, dan $\mathbf{1}_{A_k}$ adalah fungsi indikator dari A_k .

Contoh 2.2.17 Misalkan $\Omega = [0, 3]$ dan didefinisikan fungsi $s : \Omega \rightarrow \mathbb{R}$ sebagai berikut:

$$s(\omega) = \begin{cases} 2, & \text{jika } \omega \in [0, 1), \\ 5, & \text{jika } \omega \in [1, 2), \\ -1, & \text{jika } \omega \in [2, 3]. \end{cases}$$

Fungsi s adalah fungsi sederhana karena hanya mengambil tiga nilai berbeda, yaitu $c_1 = 2$, $c_2 = 5$, dan $c_3 = -1$. Himpunan-himpunan terukur yang bersesuaian adalah $A_1 = [0, 1)$, $A_2 = [1, 2)$, dan $A_3 = [2, 3]$. Dengan demikian, s dapat dituliskan sebagai

$$s(\omega) = 2 \cdot \mathbf{1}_{[0,1)}(\omega) + 5 \cdot \mathbf{1}_{[1,2)}(\omega) + (-1) \cdot \mathbf{1}_{[2,3]}(\omega).$$

Sebagai contoh lain, fungsi tangga atau *step function* $s(\omega) = \lfloor \omega \rfloor$ pada interval $[0, n]$ dengan $n \in \mathbb{Z}^+$ adalah fungsi sederhana yang mengambil nilai-nilai $0, 1, \dots, n$.

Definisi 2.2.18 (Dudley, 2002) Untuk fungsi sederhana non-negatif $s = \sum_{k=1}^m c_k \mathbf{1}_{A_k}$ pada ruang ukur $(\Omega, \mathcal{F}, \mu)$, integral Lebesgue didefinisikan sebagai

$$\int_{\Omega} s \, d\mu := \sum_{k=1}^m c_k \mu(A_k) \in [0, \infty]. \quad (2.2.18)$$

Definisi 2.2.19 (Dudley, 2002) Untuk fungsi terukur non-negatif $f : \Omega \rightarrow [0, \infty]$, integral Lebesgue didefinisikan sebagai

$$\int_{\Omega} f \, d\mu := \sup \left\{ \int_{\Omega} s \, d\mu : s \text{ sederhana}, 0 \leq s \leq f \right\}. \quad (2.2.19)$$

Integral ini selalu terdefinisi (meskipun mungkin bernilai ∞).

Definisi 2.2.20 (Dudley, 2002) Untuk fungsi terukur $f : \Omega \rightarrow \mathbb{R}$, definisikan bagian positif $f^+ := \max(f, 0)$ dan bagian negatif $f^- := -\min(f, 0) = \max(-f, 0)$, sehingga $f = f^+ - f^-$. Integral Lebesgue dari f didefinisikan sebagai

$$\int_{\Omega} f \, d\mu := \int_{\Omega} f^+ \, d\mu - \int_{\Omega} f^- \, d\mu, \quad (2.2.20)$$

dengan syarat setidaknya salah satu dari $\int_{\Omega} f^+ \, d\mu$ atau $\int_{\Omega} f^- \, d\mu$ bernilai hingga. Fungsi f dikatakan terintegralkan Lebesgue jika keduanya bernilai hingga, yaitu $\int_{\Omega} |f| \, d\mu < \infty$.

Apabila μ adalah ukuran Lebesgue λ pada $\mathcal{B}(\mathbb{R})$, maka $d\lambda(x)$ dapat ditulis menjadi dx .

Contoh 2.2.21 Misalkan $f : [0, 1] \rightarrow \mathbb{R}$ dengan $f(x) = x^2$. Integral Lebesgue dari f terhadap ukuran Lebesgue λ adalah

$$\int_{[0,1]} x^2 \, d\lambda(x) = \int_0^1 x^2 \, dx = \frac{1}{3}. \quad (2.2.21)$$

Dalam kasus ini, integral Lebesgue sama dengan integral Riemann karena f kontinu pada interval tertutup.

Dengan menggunakan konsep integral Lebesgue yang telah didefinisikan, ekspektasi variabel acak dapat dirumuskan secara formal sebagai berikut.

Definisi 2.2.22 (Ekspektasi Lebesgue, Dudley 2002) Misalkan $(\Omega, \mathcal{F}, \Pr)$ adalah ruang probabilitas dan $X : \Omega \rightarrow \mathbb{R}$ adalah variabel acak. Jika X terintegralkan Lebesgue (yaitu $\int_{\Omega} |X(\omega)| d\Pr(\omega) < \infty$), maka ekspektasi X didefinisikan sebagai integral Lebesgue terhadap ukuran probabilitas \Pr , yaitu

$$\mathbb{E}[X] = \int_{\Omega} X(\omega) d\Pr(\omega). \quad (2.2.22)$$

Secara ekuivalen, dengan menggunakan distribusi \Pr_X yang diinduksi oleh X pada $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, ekspektasi dapat dituliskan sebagai

$$\mathbb{E}[X] = \int_{\mathbb{R}} x d\Pr_X(x). \quad (2.2.23)$$

Jika X memiliki fungsi kepadatan probabilitas f_X , maka ekspektasi diberikan oleh

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x f_X(x) dx. \quad (2.2.24)$$

Untuk kasus diskrit, ekspektasi dapat dihitung menggunakan fungsi massa probabilitas p_X sebagai berikut:

$$\mathbb{E}[X] = \sum_{x \in \text{support}(X)} x \cdot p_X(x). \quad (2.2.25)$$

Contoh 2.2.23 Berikut adalah contoh perhitungan ekspektasi untuk beberapa distribusi.

(a) **Ekspektasi Distribusi Bernoulli.** Jika $X \sim \text{Bernoulli}(p)$, maka

$$\begin{aligned} \mathbb{E}[X] &= \sum_{k=0}^1 k \cdot \Pr(X = k) \\ &= 0 \cdot (1 - p) + 1 \cdot p = p. \end{aligned} \quad (2.2.26)$$

Ekspektasi menyatakan proporsi keberhasilan dalam jangka panjang. Jika $p = 0.3$, maka rata-rata 30% percobaan akan sukses.

(b) **Ekspektasi Distribusi Normal.** Jika $X \sim \mathcal{N}(\mu, \sigma^2)$, maka

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x \cdot \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) dx = \mu. \quad (2.2.27)$$

Ekspektasi distribusi normal adalah parameter lokasinya μ , yang menyatakan pusat simetri dari distribusi.

(c) **Ekspektasi Distribusi Poisson.** Jika $X \sim \text{Poisson}(\lambda)$, maka

$$\begin{aligned} \mathbb{E}[X] &= \sum_{k=0}^{\infty} k \cdot \frac{\lambda^k e^{-\lambda}}{k!} = \sum_{k=1}^{\infty} \frac{\lambda^k e^{-\lambda}}{(k-1)!} \\ &= \lambda e^{-\lambda} \sum_{j=0}^{\infty} \frac{\lambda^j}{j!} = \lambda e^{-\lambda} \cdot e^{\lambda} = \lambda. \end{aligned} \quad (2.2.28)$$

Ekspektasi menyatakan rata-rata banyaknya kejadian dalam jangka panjang. Jika rata-rata terjadi $\lambda = 5$ kecelakaan per hari, maka ekspektasi banyaknya kecelakaan adalah 5.

(d) **Ekspektasi Distribusi Eksponensial.** Jika $X \sim \text{Exp}(\lambda)$, maka

$$\mathbb{E}[X] = \int_0^{\infty} x \cdot \lambda e^{-\lambda x} dx = \frac{1}{\lambda}. \quad (2.2.29)$$

Ekspektasi menyatakan rata-rata waktu tunggu antara kejadian. Jika $\lambda = 2$ kejadian per jam, maka rata-rata waktu tunggu adalah $1/2$ jam atau 30 menit.

Teorema 2.2.24 Misalkan X dan Y adalah variabel acak pada ruang probabilitas $(\Omega, \mathcal{F}, \text{Pr})$ dengan ekspektasi terdefinisi. Berlaku sifat-sifat berikut.

(a) **Linearitas:** Untuk konstanta $a, b \in \mathbb{R}$, berlaku

$$\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]. \quad (2.2.30)$$

(b) **Monotonisitas:** Jika $X \leq Y$ hampir pasti, maka

$$\mathbb{E}[X] \leq \mathbb{E}[Y]. \quad (2.2.31)$$

(c) **Ekspektasi konstanta:** Untuk konstanta $c \in \mathbb{R}$, berlaku

$$\mathbb{E}[c] = c. \quad (2.2.32)$$

(d) **Ketaknegatifan:** Jika $X \geq 0$ hampir pasti, maka

$$\mathbb{E}[X] \geq 0. \quad (2.2.33)$$

(e) **Ketaksamaan segitiga:** Berlaku

$$|\mathbb{E}[X]| \leq \mathbb{E}[|X|]. \quad (2.2.34)$$

(f) **Independensi:** Jika X dan Y independen, maka

$$\mathbb{E}[XY] = \mathbb{E}[X] \cdot \mathbb{E}[Y]. \quad (2.2.35)$$

Bukti. Berikut adalah pembuktian untuk setiap sifat ekspektasi.

(a) **Linearitas:** Dengan menggunakan sifat integral Lebesgue, berlaku

$$\begin{aligned} \mathbb{E}[aX + bY] &= \int_{\Omega} (aX(\omega) + bY(\omega)) \, d\Pr(\omega) \\ &= a \int_{\Omega} X(\omega) \, d\Pr(\omega) + b \int_{\Omega} Y(\omega) \, d\Pr(\omega) \\ &= a\mathbb{E}[X] + b\mathbb{E}[Y]. \end{aligned} \quad (2.2.36)$$

(b) **Monotonisitas:** Jika $X \leq Y$ hampir pasti, maka $Y - X \geq 0$ hampir pasti.

Berdasarkan sifat integral Lebesgue untuk fungsi non-negatif, berlaku

$$\mathbb{E}[Y - X] = \mathbb{E}[Y] - \mathbb{E}[X] \geq 0, \quad (2.2.37)$$

sehingga $\mathbb{E}[X] \leq \mathbb{E}[Y]$.

- (c) **Ekspektasi konstanta:** Untuk konstanta c , variabel acak $X(\omega) = c$ untuk semua $\omega \in \Omega$, sehingga

$$\mathbb{E}[c] = \int_{\Omega} c \, d\Pr(\omega) = c \cdot \Pr(\Omega) = c \cdot 1 = c. \quad (2.2.38)$$

- (d) **Ketaknegatifan:** Jika $X \geq 0$ hampir pasti, maka berdasarkan definisi integral Lebesgue untuk fungsi non-negatif, berlaku

$$\mathbb{E}[X] = \int_{\Omega} X(\omega) \, d\Pr(\omega) \geq 0. \quad (2.2.39)$$

- (e) **Ketaksamaan segitiga:** Perhatikan bahwa $-|X| \leq X \leq |X|$. Dengan sifat monotonisitas, diperoleh

$$-\mathbb{E}[|X|] \leq \mathbb{E}[X] \leq \mathbb{E}[|X|], \quad (2.2.40)$$

yang ekuivalen dengan $|\mathbb{E}[X]| \leq \mathbb{E}[|X|]$.

- (f) **Independensi:** Jika X dan Y independen, maka distribusi bersama sama dengan hasil kali distribusi marginal, yaitu $\Pr_{X,Y} = \Pr_X \times \Pr_Y$. Dengan teorema Fubini, berlaku

$$\begin{aligned} \mathbb{E}[XY] &= \int_{\mathbb{R}^2} xy \, d\Pr_{X,Y}(x, y) \\ &= \int_{\mathbb{R}} x \, d\Pr_X(x) \cdot \int_{\mathbb{R}} y \, d\Pr_Y(y) \\ &= \mathbb{E}[X] \cdot \mathbb{E}[Y]. \end{aligned} \quad (2.2.41)$$

■

Teorema 2.2.25 (Hukum Statistikawan Tak Sadar (*Law of the Unconscious Statistician*, LOTUS), Ross 1972) Misalkan X adalah variabel acak dengan fungsi distribusi F_X dan $g : \mathbb{R} \rightarrow \mathbb{R}$ adalah fungsi terukur. Maka ekspektasi dari $g(X)$

dapat dihitung tanpa perlu mengetahui distribusi $g(X)$ secara eksplisit, yaitu

$$\mathbb{E}[g(X)] = \int_{-\infty}^{\infty} g(x) dF_X(x). \quad (2.2.42)$$

Secara khusus:

(a) Jika X adalah variabel acak diskrit dengan fungsi massa probabilitas $p_X(x)$, maka

$$\mathbb{E}[g(X)] = \sum_x g(x) p_X(x). \quad (2.2.43)$$

(b) Jika X adalah variabel acak kontinu dengan fungsi kepadatan probabilitas $f_X(x)$, maka

$$\mathbb{E}[g(X)] = \int_{-\infty}^{\infty} g(x) f_X(x) dx. \quad (2.2.44)$$

Bukti. Akan dibuktikan untuk kasus variabel acak kontinu dengan fungsi kepadatan probabilitas $f_X(x)$. Misalkan $Y = g(X)$ adalah variabel acak baru. Berdasarkan definisi ekspektasi, seharusnya perlu dicari fungsi kepadatan probabilitas $f_Y(y)$ dari Y terlebih dahulu, kemudian menghitung $\mathbb{E}[Y] = \int_{-\infty}^{\infty} y f_Y(y) dy$. Namun, dengan menggunakan teori ukuran, ekspektasi dari $g(X)$ dapat dihitung langsung sebagai integral Lebesgue terhadap ukuran probabilitas yang diinduksi oleh X . Secara formal, untuk setiap fungsi terukur g , berlaku

$$\mathbb{E}[g(X)] = \int_{\Omega} g(X(\omega)) d\Pr(\omega) = \int_{\mathbb{R}} g(x) d\Pr_X(x), \quad (2.2.45)$$

dengan \Pr_X adalah distribusi yang diinduksi oleh X . Sebab X memiliki fungsi kepadatan probabilitas $f_X(x)$, maka $d\Pr_X(x) = f_X(x) dx$, sehingga

$$\mathbb{E}[g(X)] = \int_{-\infty}^{\infty} g(x) f_X(x) dx. \quad (2.2.46)$$

Hasil ini diperoleh langsung dari teorema perubahan variabel untuk integral Lebesgue tanpa perlu menghitung distribusi $g(X)$ secara eksplisit. ■

Contoh 2.2.26 Misalkan $X \sim \text{Exp}(1)$ dengan fungsi kepadatan probabilitas $f_X(x) = e^{-x}$ untuk $x \geq 0$. Akan dihitung $\mathbb{E}[X^2]$. Dengan menggunakan LOTUS, tidak perlu

dicari distribusi dari $Y = X^2$ terlebih dahulu. Langsung dapat dihitung

$$\begin{aligned}\mathbb{E}[X^2] &= \int_0^\infty x^2 \cdot e^{-x} dx \\ &= \Gamma(3) = 2! = 2.\end{aligned}\tag{2.2.47}$$

Hasil ini diperoleh dengan menggunakan integral Gamma $\Gamma(n) = \int_0^\infty x^{n-1} e^{-x} dx = (n-1)!$ untuk n bilangan bulat positif.

Sebagai contoh lain, jika $X \sim \mathcal{N}(0, 1)$ dan ingin dihitung $\mathbb{E}[e^X]$, maka dengan LOTUS:

$$\begin{aligned}\mathbb{E}[e^X] &= \int_{-\infty}^\infty e^x \cdot \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx \\ &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^\infty e^{x-x^2/2} dx \\ &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^\infty e^{-(x^2-2x)/2} dx \\ &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^\infty e^{-(x-1)^2/2+1/2} dx \\ &= e^{1/2} \cdot \frac{1}{\sqrt{2\pi}} \int_{-\infty}^\infty e^{-(x-1)^2/2} dx \\ &= e^{1/2} = \sqrt{e}.\end{aligned}\tag{2.2.48}$$

2.2.4 Momen, Variansi, dan Kovariansi

Definisi 2.2.27 (Momen, Billingsley 1995) Untuk variabel acak X dan bilangan bulat positif k , momen ke- k dari X didefinisikan sebagai

$$\mu_k = \mathbb{E}[X^k],\tag{2.2.49}$$

dengan syarat $\mathbb{E}[|X|^k] < \infty$. Momen pertama $\mu_1 = \mathbb{E}[X]$ disebut sebagai rata-rata atau nilai harapan dari X . Selain itu, momen pusat ke- k didefinisikan sebagai

$$\mu'_k = \mathbb{E}[(X - \mathbb{E}[X])^k].\tag{2.2.50}$$

Definisi 2.2.28 (Variansi, Billingsley 1995) Untuk variabel acak X dengan $\mathbb{E}[|X|^2] < \infty$, variansi didefinisikan sebagai momen pusat kedua, yaitu

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2]. \quad (2.2.51)$$

Variansi dapat juga dihitung menggunakan rumus alternatif

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2. \quad (2.2.52)$$

Contoh 2.2.29 Misalkan X adalah variabel acak diskrit dengan distribusi

$$\Pr(X = 1) = 0,3, \quad \Pr(X = 2) = 0,5, \quad \Pr(X = 3) = 0,2.$$

Momen pertama (rata-rata) dari X adalah

$$\begin{aligned} \mathbb{E}[X] &= \sum_x x \cdot \Pr(X = x) \\ &= 1 \cdot 0,3 + 2 \cdot 0,5 + 3 \cdot 0,2 = 0,3 + 1,0 + 0,6 = 1,9. \end{aligned} \quad (2.2.53)$$

Momen kedua dari X adalah

$$\begin{aligned} \mathbb{E}[X^2] &= \sum_x x^2 \cdot \Pr(X = x) \\ &= 1^2 \cdot 0,3 + 2^2 \cdot 0,5 + 3^2 \cdot 0,2 = 0,3 + 2,0 + 1,8 = 4,1. \end{aligned} \quad (2.2.54)$$

Variansi dari X dapat dihitung dengan rumus alternatif, yaitu

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = 4,1 - (1,9)^2 = 4,1 - 3,61 = 0,49. \quad (2.2.55)$$

Definisi 2.2.30 (Kovariansi, Billingsley 1995) Untuk dua variabel acak X dan Y dengan momen orde dua hingga, kovariansi didefinisikan sebagai

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]. \quad (2.2.56)$$

Rumus alternatif untuk kovariansi adalah

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]. \quad (2.2.57)$$

Contoh 2.2.31 Misalkan (X, Y) adalah variabel acak gabungan dengan distribusi bersama

$$\begin{aligned} \Pr(X = 0, Y = 0) &= 0,2, & \Pr(X = 0, Y = 1) &= 0,1, \\ \Pr(X = 1, Y = 0) &= 0,3, & \Pr(X = 1, Y = 1) &= 0,4. \end{aligned} \quad (2.2.58)$$

Rataan dari X dan Y adalah

$$\mathbb{E}[X] = 0 \cdot (0,2 + 0,1) + 1 \cdot (0,3 + 0,4) = 0,7, \quad (2.2.59)$$

$$\mathbb{E}[Y] = 0 \cdot (0,2 + 0,3) + 1 \cdot (0,1 + 0,4) = 0,5. \quad (2.2.60)$$

Nilai harapan dari XY adalah

$$\begin{aligned} \mathbb{E}[XY] &= \sum_{x,y} xy \cdot \Pr(X = x, Y = y) \\ &= 0 \cdot 0 \cdot 0,2 + 0 \cdot 1 \cdot 0,1 + 1 \cdot 0 \cdot 0,3 + 1 \cdot 1 \cdot 0,4 = 0,4. \end{aligned} \quad (2.2.61)$$

Kovariansi dari X dan Y adalah

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = 0,4 - 0,7 \cdot 0,5 = 0,4 - 0,35 = 0,05. \quad (2.2.62)$$

Nilai kovariansi positif menunjukkan bahwa X dan Y cenderung bergerak searah.

2.2.5 Probabilitas Bersyarat dan Independensi

Probabilitas bersyarat merupakan konsep fundamental yang menggambarkan bagaimana informasi baru mengubah keyakinan kita terhadap suatu kejadian. Konsep ini menjadi dasar bagi inferensi statistik dan pembelajaran mesin.

Definisi 2.2.32 (Probabilitas bersyarat, Ash 1972) Misalkan A dan B adalah dua

kejadian pada ruang probabilitas $(\Omega, \mathcal{F}, \Pr)$ dengan $\Pr(B) > 0$. Probabilitas bersyarat dari A diberikan B , dinotasikan $\Pr(A | B)$, didefinisikan sebagai

$$\Pr(A | B) = \frac{\Pr(A \cap B)}{\Pr(B)}. \quad (2.2.63)$$

Contoh 2.2.33 Misalkan sebuah dadu seimbang dilempar. Definisikan kejadian $A = \{\text{hasil genap}\} = \{2, 4, 6\}$ dan $B = \{\text{hasil lebih dari 3}\} = \{4, 5, 6\}$. Maka

$$\Pr(A) = \frac{3}{6} = \frac{1}{2}, \quad \Pr(B) = \frac{3}{6} = \frac{1}{2}, \quad (2.2.64)$$

$$\Pr(A \cap B) = \Pr(\{4, 6\}) = \frac{2}{6} = \frac{1}{3}. \quad (2.2.65)$$

Probabilitas bersyarat dari A diberikan B adalah

$$\Pr(A | B) = \frac{\Pr(A \cap B)}{\Pr(B)} = \frac{1/3}{1/2} = \frac{2}{3}. \quad (2.2.66)$$

Hasil ini menunjukkan bahwa jika diketahui hasil dadu lebih dari 3, maka probabilitas hasil genap meningkat dari $1/2$ menjadi $2/3$.

Definisi 2.2.34 (Independensi dua kejadian, Billingsley 1995) Dua kejadian A dan B dikatakan independen apabila

$$\Pr(A \cap B) = \Pr(A) \cdot \Pr(B). \quad (2.2.67)$$

Secara ekuivalen, jika $\Pr(B) > 0$, maka A dan B independen jika dan hanya jika $\Pr(A | B) = \Pr(A)$.

Contoh 2.2.35 Pertimbangkan pelemparan dua koin seimbang secara independen. Definisikan $A = \{\text{koin pertama muncul kepala}\}$ dan $B = \{\text{koin kedua muncul kepala}\}$. Ruang sampel adalah $\Omega = \{KK, KE, EK, EE\}$ dengan probabilitas sera-

gam, yaitu $\Pr(\omega) = \frac{1}{4}$ untuk setiap $\omega \in \Omega$, sehingga

$$\Pr(A) = \Pr(\{KK, KE\}) = \frac{2}{4} = \frac{1}{2}, \quad (2.2.68)$$

$$\Pr(B) = \Pr(\{KK, EK\}) = \frac{2}{4} = \frac{1}{2}, \quad (2.2.69)$$

$$\Pr(A \cap B) = \Pr(\{KK\}) = \frac{1}{4}. \quad (2.2.70)$$

Sebab $\Pr(A \cap B) = \frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2} = \Pr(A) \cdot \Pr(B)$, maka A dan B independen.

Definisi 2.2.36 (Independensi variabel acak, Billingsley 1995) Barisan variabel acak $\{X_i\}_{i \in I}$ dikatakan saling independen apabila untuk setiap himpunan Borel $A_i \subseteq \mathbb{R}$ dan setiap himpunan indeks hingga $\{i_1, i_2, \dots, i_n\} \subseteq I$ berlaku

$$\Pr(X_{i_1} \in A_{i_1}, X_{i_2} \in A_{i_2}, \dots, X_{i_n} \in A_{i_n}) = \prod_{j=1}^n \Pr(X_{i_j} \in A_{i_j}). \quad (2.2.71)$$

Secara khusus, dua variabel acak X dan Y dikatakan independen apabila barisan $\{X, Y\}$ saling independen.

Akibat dari definisi di atas adalah bahwa jika X dan Y independen, maka distribusi bersama mereka sama dengan hasil kali distribusi marginal, yaitu

$$\Pr_{X,Y}(A, B) = \Pr_X(A) \cdot \Pr_Y(B) \quad (2.2.72)$$

untuk setiap himpunan Borel $A, B \subseteq \mathbb{R}$. Hal ini juga mengimplikasikan bahwa fungsi distribusi kumulatif bersama dapat ditulis sebagai

$$F_{X,Y}(x, y) = F_X(x) \cdot F_Y(y). \quad (2.2.73)$$

Contoh 2.2.37 Misalkan X dan Y adalah variabel acak independen dengan $X \sim$

Bernoulli(0,5) dan $Y \sim \text{Bernoulli}(0,5)$. Maka

$$\Pr(X = 1, Y = 1) = \Pr(X = 1) \cdot \Pr(Y = 1) = 0,5 \cdot 0,5 = 0,25, \quad (2.2.74)$$

$$\Pr(X = 0, Y = 1) = \Pr(X = 0) \cdot \Pr(Y = 1) = 0,5 \cdot 0,5 = 0,25. \quad (2.2.75)$$

Distribusi bersama sepenuhnya ditentukan oleh hasil kali distribusi marginal.

Definisi 2.2.38 (Independensi bersyarat, Billingsley 1995) Dua kejadian A dan B dikatakan independen bersyarat diberikan kejadian C (dengan $\Pr(C) > 0$) apabila

$$\Pr(A \cap B \mid C) = \Pr(A \mid C) \cdot \Pr(B \mid C). \quad (2.2.76)$$

Untuk variabel acak, X dan Y independen bersyarat diberikan Z apabila untuk setiap nilai z dengan $\Pr(Z = z) > 0$ berlaku

$$\Pr(X \in A, Y \in B \mid Z = z) = \Pr(X \in A \mid Z = z) \cdot \Pr(Y \in B \mid Z = z). \quad (2.2.77)$$

2.2.6 Hukum Probabilitas Total dan Teorema Bayes

Teorema 2.2.39 (Hukum probabilitas total, Ash 1972) Misalkan barisan kejadian $\{B_1, B_2, \dots, B_n\}$ adalah partisi dari ruang sampel Ω , yaitu $B_i \cap B_j = \emptyset$ untuk $i \neq j$ dan $\bigcup_{i=1}^n B_i = \Omega$, dengan $\Pr(B_i) > 0$ untuk semua i . Maka untuk setiap kejadian A berlaku

$$\Pr(A) = \sum_{i=1}^n \Pr(A \cap B_i) = \sum_{i=1}^n \Pr(A \mid B_i) \cdot \Pr(B_i). \quad (2.2.78)$$

Untuk kasus kontinu dengan variabel acak Y , hukum ini dapat ditulis sebagai

$$\Pr(A) = \int_{-\infty}^{\infty} \Pr(A \mid Y = y) \cdot f_Y(y) \, dy. \quad (2.2.79)$$

Bukti. Sebab $\{B_1, B_2, \dots, B_n\}$ adalah partisi dari Ω , maka

$$A = A \cap \Omega = A \cap \left(\bigcup_{i=1}^n B_i \right) = \bigcup_{i=1}^n (A \cap B_i). \quad (2.2.80)$$

Sebab kejadian $A \cap B_i$ saling lepas untuk i berbeda, maka berdasarkan σ -aditivitas:

$$\Pr(A) = \sum_{i=1}^n \Pr(A \cap B_i) = \sum_{i=1}^n \Pr(A \mid B_i) \cdot \Pr(B_i). \quad (2.2.81)$$

■

Contoh 2.2.40 Suatu pabrik memiliki tiga mesin yang memproduksi komponen elektronik. Mesin 1 memproduksi 50% dari total produksi dengan tingkat cacat 2%, mesin 2 memproduksi 30% dengan tingkat cacat 3%, dan mesin 3 memproduksi 20% dengan tingkat cacat 5%. Probabilitas suatu komponen yang dipilih secara acak adalah cacat dapat dihitung dengan hukum probabilitas total:

$$\begin{aligned} \Pr(\text{Cacat}) &= \Pr(\text{Cacat} \mid \text{Mesin 1}) \cdot \Pr(\text{Mesin 1}) \\ &\quad + \Pr(\text{Cacat} \mid \text{Mesin 2}) \cdot \Pr(\text{Mesin 2}) \\ &\quad + \Pr(\text{Cacat} \mid \text{Mesin 3}) \cdot \Pr(\text{Mesin 3}) \\ &= 0,02 \cdot 0,50 + 0,03 \cdot 0,30 + 0,05 \cdot 0,20 \\ &= 0,01 + 0,009 + 0,01 = 0,029. \end{aligned} \quad (2.2.82)$$

Jadi, probabilitas suatu komponen adalah cacat adalah 2,9%.

Teorema 2.2.41 (Teorema Bayes, Ross 1972) Misalkan $\{B_1, B_2, \dots, B_n\}$ adalah partisi dari ruang sampel Ω dengan $\Pr(B_i) > 0$ untuk semua i , dan misalkan A adalah kejadian dengan $\Pr(A) > 0$. Maka untuk setiap $j = 1, 2, \dots, n$ berlaku

$$\Pr(B_j \mid A) = \frac{\Pr(A \mid B_j) \cdot \Pr(B_j)}{\sum_{i=1}^n \Pr(A \mid B_i) \cdot \Pr(B_i)}. \quad (2.2.83)$$

Dalam bentuk yang lebih sederhana untuk dua kejadian A dan B :

$$\Pr(B | A) = \frac{\Pr(A | B) \cdot \Pr(B)}{\Pr(A)}. \quad (2.2.84)$$

Bukti. Berdasarkan definisi probabilitas bersyarat:

$$\Pr(B_j | A) = \frac{\Pr(A \cap B_j)}{\Pr(A)} = \frac{\Pr(A | B_j) \cdot \Pr(B_j)}{\Pr(A)}. \quad (2.2.85)$$

Dengan mensubstitusi $\Pr(A)$ menggunakan hukum probabilitas total, diperoleh hasil yang diinginkan. ■

Contoh 2.2.42 Melanjutkan contoh pabrik sebelumnya, misalkan suatu komponen yang dipilih secara acak ternyata cacat. Probabilitas komponen tersebut berasal dari mesin 3 dapat dihitung dengan teorema Bayes:

$$\begin{aligned} \Pr(\text{Mesin 3} | \text{Cacat}) &= \frac{\Pr(\text{Cacat} | \text{Mesin 3}) \cdot \Pr(\text{Mesin 3})}{\Pr(\text{Cacat})} \\ &= \frac{0,05 \cdot 0,20}{0,029} = \frac{0,01}{0,029} \approx 0,345. \end{aligned} \quad (2.2.86)$$

Meskipun mesin 3 hanya memproduksi 20% dari total produksi, probabilitas komponen cacat berasal dari mesin 3 adalah sekitar 34,5% karena tingkat kecacatannya yang lebih tinggi.

Dalam konteks teorema Bayes, terdapat beberapa terminologi penting:

- (a) $\Pr(B)$ disebut probabilitas *prior*, yaitu keyakinan awal tentang B sebelum mengamati data A .
- (b) $\Pr(A | B)$ disebut *likelihood*, yaitu probabilitas mengamati data A diberikan B benar.
- (c) $\Pr(B | A)$ disebut probabilitas *posterior*, yaitu keyakinan tentang B setelah mengamati data A .
- (d) $\Pr(A)$ disebut *marginal likelihood* atau *evidence*, yang berfungsi sebagai konstanta normalisasi.

Teorema Bayes dapat diringkas sebagai: $\text{Posterior} \propto \text{Likelihood} \times \text{Prior}$.

2.2.7 Hukum Ekspektasi Total dan Variansi Total

Teorema 2.2.43 (Hukum ekspektasi total (*Law of Total Expectation*), Ross 1972)

Misalkan X dan Y adalah variabel acak pada ruang probabilitas yang sama dengan $\mathbb{E}[|X|] < \infty$. Maka

$$\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X | Y]]. \quad (2.2.87)$$

Untuk kasus diskrit dengan Y mengambil nilai y_1, y_2, \dots :

$$\mathbb{E}[X] = \sum_j \mathbb{E}[X | Y = y_j] \cdot \Pr(Y = y_j). \quad (2.2.88)$$

Untuk kasus kontinu dengan Y memiliki kepadatan f_Y :

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} \mathbb{E}[X | Y = y] \cdot f_Y(y) dy. \quad (2.2.89)$$

Bukti. Untuk kasus diskrit, dengan menggunakan definisi ekspektasi bersyarat:

$$\begin{aligned} \mathbb{E}[\mathbb{E}[X | Y]] &= \sum_j \mathbb{E}[X | Y = y_j] \cdot \Pr(Y = y_j) \\ &= \sum_j \left(\sum_i x_i \cdot \Pr(X = x_i | Y = y_j) \right) \cdot \Pr(Y = y_j) \\ &= \sum_i \sum_j x_i \cdot \Pr(X = x_i | Y = y_j) \cdot \Pr(Y = y_j) \\ &= \sum_i \sum_j x_i \cdot \Pr(X = x_i, Y = y_j) \\ &= \sum_i x_i \cdot \Pr(X = x_i) = \mathbb{E}[X]. \end{aligned} \quad (2.2.90)$$

Untuk kasus kontinu, misalkan Y memiliki fungsi kepadatan probabilitas $f_Y(y)$ dan ekspektasi bersyarat $\mathbb{E}[X | Y = y]$ terdefinisi dengan baik. Dengan

menggunakan definisi ekspektasi bersyarat untuk variabel acak kontinu:

$$\begin{aligned}
 \mathbb{E} [\mathbb{E}[X | Y]] &= \int_{-\infty}^{\infty} \mathbb{E}[X | Y = y] \cdot f_Y(y) dy \\
 &= \int_{-\infty}^{\infty} \left(\int_{-\infty}^{\infty} x \cdot f_{X|Y}(x | y) dx \right) \cdot f_Y(y) dy \\
 &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x \cdot f_{X|Y}(x | y) \cdot f_Y(y) dx dy. \tag{2.2.91}
 \end{aligned}$$

Dengan menggunakan hubungan $f_{X,Y}(x, y) = f_{X|Y}(x | y) \cdot f_Y(y)$, diperoleh

$$\begin{aligned}
 \mathbb{E} [\mathbb{E}[X | Y]] &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x \cdot f_{X,Y}(x, y) dx dy \\
 &= \int_{-\infty}^{\infty} x \left(\int_{-\infty}^{\infty} f_{X,Y}(x, y) dy \right) dx \\
 &= \int_{-\infty}^{\infty} x \cdot f_X(x) dx = \mathbb{E}[X], \tag{2.2.92}
 \end{aligned}$$

dengan $f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dy$ adalah fungsi kepadatan marginal dari X . Pertukaran urutan integrasi dijamin oleh teorema Fubini dengan syarat $\mathbb{E}[|X|] < \infty$. ■

Contoh 2.2.44 Misalkan N adalah variabel acak diskrit yang menyatakan jumlah pelanggan yang datang ke suatu toko dalam sehari, dengan $N \sim \text{Poisson}(\lambda)$. Setiap pelanggan membeli sejumlah barang X_i yang berdistribusi identik dan independen dengan $\mathbb{E}[X_i] = \mu$. Total penjualan harian adalah $S = \sum_{i=1}^N X_i$. Ekspektasi total penjualan dapat dihitung dengan hukum ekspektasi total:

$$\begin{aligned}
 \mathbb{E}[S] &= \mathbb{E} [\mathbb{E}[S | N]] = \mathbb{E} \left[\mathbb{E} \left[\sum_{i=1}^N X_i | N \right] \right] \\
 &= \mathbb{E}[N \cdot \mu] = \mu \cdot \mathbb{E}[N] = \mu\lambda. \tag{2.2.93}
 \end{aligned}$$

Teorema 2.2.45 (Ross, 1972) Misalkan X dan Y adalah variabel acak dengan $\text{Var}(X) < \infty$. Maka

$$\text{Var}(X) = \mathbb{E} [\text{Var}(X | Y)] + \text{Var} (\mathbb{E}[X | Y]). \tag{2.2.94}$$

Rumus ini dikenal juga sebagai dekomposisi variansi, dengan interpretasi:

(a) $\mathbb{E}[\text{Var}(X | Y)]$ adalah rata-rata variansi dalam kelompok (within-group variance).

(b) $\text{Var}(\mathbb{E}[X | Y])$ adalah variansi antar kelompok (between-group variance).

Bukti. Dengan menggunakan rumus $\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$, diperoleh

$$\text{Var}(X | Y) = \mathbb{E}[X^2 | Y] - (\mathbb{E}[X | Y])^2. \quad (2.2.95)$$

Dengan mengambil ekspektasi kedua ruas:

$$\mathbb{E}[\text{Var}(X | Y)] = \mathbb{E}[\mathbb{E}[X^2 | Y]] - \mathbb{E}[(\mathbb{E}[X | Y])^2] = \mathbb{E}[X^2] - \mathbb{E}[(\mathbb{E}[X | Y])^2]. \quad (2.2.96)$$

Di sisi lain:

$$\begin{aligned} \text{Var}(\mathbb{E}[X | Y]) &= \mathbb{E}[(\mathbb{E}[X | Y])^2] - (\mathbb{E}[\mathbb{E}[X | Y]])^2 \\ &= \mathbb{E}[(\mathbb{E}[X | Y])^2] - (\mathbb{E}[X])^2. \end{aligned} \quad (2.2.97)$$

Dengan menjumlahkan kedua hasil:

$$\begin{aligned} \mathbb{E}[\text{Var}(X | Y)] + \text{Var}(\mathbb{E}[X | Y]) &= \mathbb{E}[X^2] - \mathbb{E}[(\mathbb{E}[X | Y])^2] \\ &\quad + \mathbb{E}[(\mathbb{E}[X | Y])^2] - (\mathbb{E}[X])^2 \\ &= \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \text{Var}(X). \end{aligned} \quad (2.2.98)$$

■

Contoh 2.2.46 Melanjutkan contoh sebelumnya, variansi total penjualan harian $S = \sum_{i=1}^N X_i$ dapat dihitung dengan hukum variansi total. Misalkan $\text{Var}(X_i) = \sigma^2$.

Maka

$$\text{Var}(S \mid N) = N \cdot \sigma^2, \quad (2.2.99)$$

$$\mathbb{E}[S \mid N] = N \cdot \mu. \quad (2.2.100)$$

Dengan hukum variansi total:

$$\begin{aligned} \text{Var}(S) &= \mathbb{E}[\text{Var}(S \mid N)] + \text{Var}(\mathbb{E}[S \mid N]) \\ &= \mathbb{E}[N \cdot \sigma^2] + \text{Var}(N \cdot \mu) \\ &= \sigma^2 \cdot \mathbb{E}[N] + \mu^2 \cdot \text{Var}(N) \\ &= \sigma^2 \lambda + \mu^2 \lambda = \lambda(\sigma^2 + \mu^2). \end{aligned} \quad (2.2.101)$$

Hasil ini menunjukkan bahwa variansi total penjualan terdiri dari dua komponen: variansi akibat fluktuasi pembelian per pelanggan dan variansi akibat fluktuasi jumlah pelanggan.

2.3 Konvergensi dan Laju Pertumbuhan

Analisis asimtotik dalam statistika memerlukan pemahaman yang jelas mengenai perilaku barisan variabel acak ketika ukuran sampel meningkat. Konsep konvergensi dan notasi laju pertumbuhan menyediakan bahasa formal untuk menyatakan konsistensi, distribusi limit, serta ukuran galat dari suatu estimator. Pembahasan dalam bagian ini mengikuti kerangka teori probabilitas klasik dan statistik asimtotik sebagaimana dikembangkan oleh Billingsley (1995), Dudley (2002), dan van der Vaart (1998). Namun, sebelum memasuki konvergensi dan laju pertumbuhan, terdapat dua ketaksamaan penting yang sering digunakan dalam pembuktian teorema limit, yaitu ketaksamaan Markov dan Chebyshev.

Teorema 2.3.1 (Ketaksamaan Markov, Ross 1972) *Misalkan X adalah variabel acak non-negatif dengan ekspektasi $\mathbb{E}[X] < \infty$. Maka untuk setiap $a > 0$ berlaku*

$$\Pr(X \geq a) \leq \frac{\mathbb{E}[X]}{a}. \quad (2.3.1)$$

Bukti. Dengan definisi ekspektasi:

$$\mathbb{E}[X] = \int_0^{\infty} \Pr(X \geq t) dt. \quad (2.3.2)$$

Karena X non-negatif, maka

$$\mathbb{E}[X] \geq \int_a^{\infty} \Pr(X \geq t) dt \geq \int_a^{\infty} \Pr(X \geq a) dt = \Pr(X \geq a) \cdot (\infty - a). \quad (2.3.3)$$

Oleh karena itu,

$$\Pr(X \geq a) \leq \frac{\mathbb{E}[X]}{a}. \quad (2.3.4)$$

■

Teorema 2.3.2 (Ketaksamaan Chebyshev, Ross 1972) Misalkan X adalah variabel acak dengan ekspektasi $\mathbb{E}[X]$ dan variansi $\text{Var}(X) < \infty$. Maka untuk setiap $\varepsilon > 0$ berlaku

$$\Pr(|X - \mathbb{E}[X]| \geq \varepsilon) \leq \frac{\text{Var}(X)}{\varepsilon^2}. \quad (2.3.5)$$

Bukti. Definisikan variabel acak non-negatif $Y = (X - \mathbb{E}[X])^2$. Dengan menggunakan ketaksamaan Markov pada Y , diperoleh

$$\Pr(|X - \mathbb{E}[X]| \geq \varepsilon) = \Pr(Y \geq \varepsilon^2) \leq \frac{\mathbb{E}[Y]}{\varepsilon^2} = \frac{\text{Var}(X)}{\varepsilon^2}. \quad (2.3.6)$$

■

2.3.1 Barisan Variabel Acak

Suatu *barisan variabel acak* adalah koleksi variabel acak $\{X_n\}_{n \geq 1}$ yang didefinisikan pada ruang probabilitas yang sama $(\Omega, \mathcal{F}, \Pr)$. Dalam konteks statistika, barisan ini biasanya merepresentasikan estimator yang bergantung pada ukuran sampel n (Billingsley, 1995).

2.3.2 Konvergensi Barisan Variabel Acak

Pemahaman mengenai berbagai mode konvergensi barisan variabel acak sangat penting dalam statistika asimtotik.

Definisi 2.3.3 (Pishro-Nik, 2014) Barisan variabel acak $\{X_n\}$ dikatakan konvergen hampir pasti (almost surely) ke X , ditulis $X_n \xrightarrow{a.s.} X$, apabila

$$\Pr(\{\omega : \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)\}) = 1. \quad (2.3.7)$$

Contoh 2.3.4 Misalkan $\Omega = [0, 1]$ dengan ukuran probabilitas Lebesgue \Pr dan definisikan barisan variabel acak $X_n(\omega) = \omega^n$ untuk $\omega \in [0, 1]$. Untuk setiap $\omega \in [0, 1)$, berlaku

$$\lim_{n \rightarrow \infty} X_n(\omega) = \lim_{n \rightarrow \infty} \omega^n = 0.$$

Untuk $\omega = 1$, berlaku $X_n(1) = 1$ untuk semua n , sehingga $\lim_{n \rightarrow \infty} X_n(1) = 1$. Definisikan $X(\omega) = 0$ untuk $\omega \in [0, 1)$ dan $X(1) = 1$. Maka

$$\Pr(\{\omega : \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)\}) = \Pr([0, 1]) = 1,$$

sehingga $X_n \rightarrow X$ hampir pasti.

Definisi 2.3.5 (Pishro-Nik, 2014) Barisan $\{X_n\}$ dikatakan konvergen dalam probabilitas ke X , ditulis $X_n \xrightarrow{p} X$, apabila untuk setiap $\varepsilon > 0$ berlaku

$$\lim_{n \rightarrow \infty} \Pr(|X_n - X| > \varepsilon) = 0. \quad (2.3.8)$$

$X_n \xrightarrow{p} X$ dapat dinotasikan juga sebagai $\text{plim}_{n \rightarrow \infty} X_n = X$.

Contoh 2.3.6 Misalkan X_n adalah variabel acak dengan distribusi

$$\Pr(X_n = 0) = 1 - \frac{1}{n}, \quad \Pr(X_n = n) = \frac{1}{n}.$$

Akan ditunjukkan bahwa $X_n \xrightarrow{p} 0$. Untuk setiap $\varepsilon > 0$, berlaku

$$\Pr(|X_n - 0| > \varepsilon) = \Pr(X_n > \varepsilon) = \Pr(X_n = n) = \frac{1}{n} \rightarrow 0$$

ketika $n \rightarrow \infty$. Oleh karena itu, $X_n \xrightarrow{p} 0$. Namun, perhatikan bahwa X_n tidak konvergen hampir pasti ke 0, karena untuk setiap ω terdapat tak hingga banyak n sedemikian sehingga $X_n(\omega) = n$ (dengan probabilitas positif).

Konvergensi dalam probabilitas merupakan konsep utama dalam pembahasan konsistensi estimator, sedangkan konvergensi hampir pasti sering digunakan sebagai alat teknis dalam pembuktian teorema limit.

Definisi 2.3.7 (Pishro-Nik, 2014) Barisan $\{X_n\}$ dikatakan konvergen dalam distribusi ke X , ditulis $X_n \Rightarrow X$ atau $X_n \xrightarrow{d} X$, apabila

$$\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x) \quad (2.3.9)$$

untuk setiap titik x di mana F_X kontinu. Alternatifnya, konvergensi dalam distribusi dapat didefinisikan sebagai

$$\lim_{n \rightarrow \infty} \mathbb{E}[f(X_n)] = \mathbb{E}[f(X)] \quad (2.3.10)$$

untuk setiap fungsi kontinu terbatas f .

Contoh 2.3.8 Misalkan $X_n \sim \mathcal{N}(0, 1 + 1/n)$ untuk $n = 1, 2, \dots$. Akan ditunjukkan bahwa $X_n \Rightarrow X$ dengan $X \sim \mathcal{N}(0, 1)$. Untuk setiap fungsi kontinu terbatas f , berlaku

$$\mathbb{E}[f(X_n)] = \int_{-\infty}^{\infty} f(x) \cdot \frac{1}{\sqrt{2\pi(1 + 1/n)}} \exp\left(-\frac{x^2}{2(1 + 1/n)}\right) dx.$$

Ketika $n \rightarrow \infty$, variansi $1 + 1/n \rightarrow 1$, sehingga

$$\lim_{n \rightarrow \infty} \mathbb{E}[f(X_n)] = \int_{-\infty}^{\infty} f(x) \cdot \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) dx = \mathbb{E}[f(X)].$$

Oleh karena itu, $X_n \Rightarrow X \sim \mathcal{N}(0, 1)$.

Konvergensi dalam distribusi memungkinkan pendekatan distribusi *sampling* yang kompleks dengan distribusi limit yang lebih sederhana, dan merupakan dasar utama Teorema Limit Pusat.

Definisi 2.3.9 (Pishro-Nik, 2014) Barisan variabel acak $\{X_n\}$ dikatakan konvergen dalam rata-rata kuadrat (mean square) ke X , ditulis $X_n \xrightarrow{L_2} X$ atau $X_n \xrightarrow{m.s.} X$, apabila

$$\lim_{n \rightarrow \infty} \mathbb{E} [(X_n - X)^2] = 0. \quad (2.3.11)$$

Konvergensi ini juga dikenal sebagai konvergensi dalam L_2 atau konvergensi kuadrat rata-rata.

Contoh 2.3.10 Misalkan X_n adalah variabel acak dengan distribusi

$$\Pr(X_n = 0) = 1 - \frac{1}{n^2}, \quad \Pr(X_n = 1) = \frac{1}{n^2}.$$

Akan ditunjukkan bahwa $X_n \xrightarrow{L_2} 0$. Perhatikan bahwa

$$\mathbb{E} [(X_n - 0)^2] = \mathbb{E}[X_n^2] = 0^2 \cdot \left(1 - \frac{1}{n^2}\right) + 1^2 \cdot \frac{1}{n^2} = \frac{1}{n^2} \rightarrow 0$$

ketika $n \rightarrow \infty$. Oleh karena itu, $X_n \xrightarrow{L_2} 0$.

Contoh 2.3.11 Misalkan $X_n \sim \mathcal{N}(0, 1/n)$ untuk $n = 1, 2, \dots$. Akan ditunjukkan bahwa $X_n \xrightarrow{L_2} 0$. Perhatikan bahwa

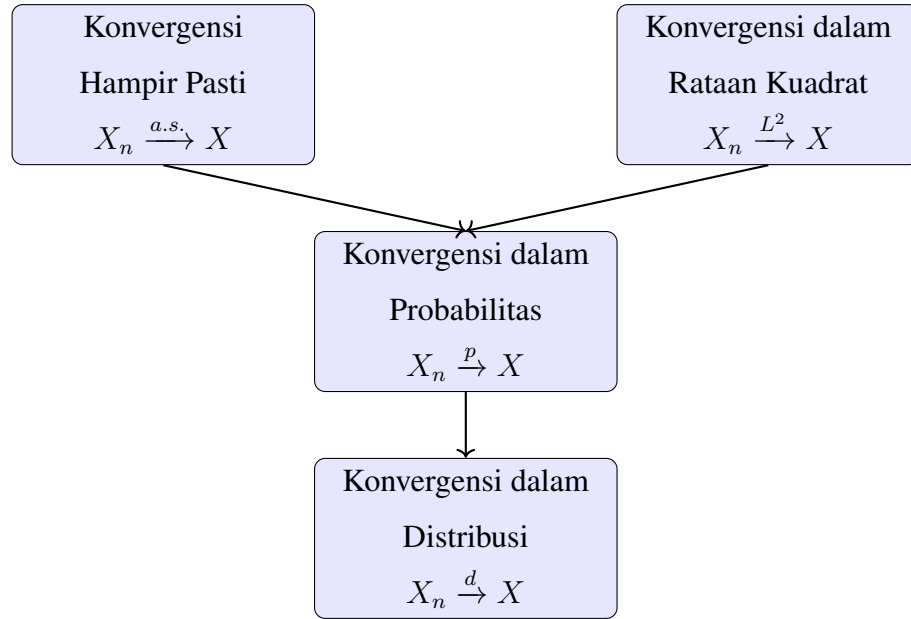
$$\mathbb{E} [(X_n - 0)^2] = \mathbb{E}[X_n^2] = \text{Var}(X_n) + (\mathbb{E}[X_n])^2 = \frac{1}{n} + 0 = \frac{1}{n} \rightarrow 0$$

ketika $n \rightarrow \infty$. Oleh karena itu, $X_n \xrightarrow{L_2} 0$.

2.3.3 Hubungan Antarmode Konvergensi

Berbagai mode konvergensi memiliki hubungan hierarkis yang penting dalam teori probabilitas dan statistika asimtotik. Hubungan ini dapat divisualisasikan

dalam diagram berikut.



Gambar 2.5 Diagram hubungan antarmode konvergensi

Teorema 2.3.12 Jika $X_n \xrightarrow{a.s.} X$, maka $X_n \xrightarrow{p} X$.

Bukti. Andaikan $X_n \xrightarrow{a.s.} X$, yaitu $\Pr(\lim_{n \rightarrow \infty} X_n = X) = 1$. Definisikan himpunan

$$A = \left\{ \omega \in \Omega : \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega) \right\}. \quad (2.3.12)$$

Berdasarkan hipotesis, $\Pr(A) = 1$. Untuk setiap $\omega \in A$ dan setiap $\varepsilon > 0$, terdapat $N(\omega, \varepsilon)$ sehingga $|X_n(\omega) - X(\omega)| < \varepsilon$ untuk semua $n \geq N(\omega, \varepsilon)$.

Definisikan himpunan $B_n(\varepsilon) = \{\omega : |X_n(\omega) - X(\omega)| > \varepsilon\}$. Untuk setiap $\omega \in A$, terdapat N sehingga $\omega \notin B_n(\varepsilon)$ untuk $n \geq N$. Dengan kata lain,

$$A \subseteq \bigcup_{N=1}^{\infty} \bigcap_{n=N}^{\infty} B_n(\varepsilon)^c. \quad (2.3.13)$$

Hal ini berarti $\limsup_{n \rightarrow \infty} B_n(\varepsilon) \subseteq A^c$, sehingga

$$\Pr\left(\limsup_{n \rightarrow \infty} B_n(\varepsilon)\right) \leq \Pr(A^c) = 0. \quad (2.3.14)$$

Berdasarkan lemma Borel–Cantelli, jika $\Pr(\limsup_n B_n) = 0$, maka $\Pr(B_n) \rightarrow 0$.

Oleh karena itu,

$$\lim_{n \rightarrow \infty} \Pr(|X_n - X| > \varepsilon) = 0, \quad (2.3.15)$$

yang berarti $X_n \xrightarrow{p} X$. ■

Teorema 2.3.13 *Jika $X_n \xrightarrow{L_2} X$, maka $X_n \xrightarrow{p} X$.*

Bukti. Andaikan $X_n \xrightarrow{L_2} X$, yaitu $\mathbb{E}[(X_n - X)^2] \rightarrow 0$. Akan ditunjukkan bahwa untuk setiap $\varepsilon > 0$, berlaku $\Pr(|X_n - X| > \varepsilon) \rightarrow 0$.

Dengan menggunakan ketaksamaan Markov pada variabel acak non-negatif $(X_n - X)^2$, diperoleh

$$\Pr(|X_n - X| > \varepsilon) = \Pr((X_n - X)^2 > \varepsilon^2) \leq \frac{\mathbb{E}[(X_n - X)^2]}{\varepsilon^2}. \quad (2.3.16)$$

Sebab $\mathbb{E}[(X_n - X)^2] \rightarrow 0$ ketika $n \rightarrow \infty$, maka

$$\lim_{n \rightarrow \infty} \Pr(|X_n - X| > \varepsilon) \leq \lim_{n \rightarrow \infty} \frac{\mathbb{E}[(X_n - X)^2]}{\varepsilon^2} = 0. \quad (2.3.17)$$

Sebab probabilitas selalu non-negatif, diperoleh $\Pr(|X_n - X| > \varepsilon) \rightarrow 0$, yang berarti $X_n \xrightarrow{p} X$. ■

Teorema 2.3.14 *Jika $X_n \xrightarrow{p} X$, maka $X_n \xrightarrow{d} X$.*

Bukti. Andaikan $X_n \xrightarrow{p} X$. Akan ditunjukkan bahwa untuk setiap fungsi kontinu terbatas f , berlaku $\mathbb{E}[f(X_n)] \rightarrow \mathbb{E}[f(X)]$. Misalkan f adalah fungsi kontinu terbatas dengan $|f(x)| \leq M$ untuk semua x . Untuk setiap $\varepsilon > 0$, karena f kontinu terbatas pada \mathbb{R} , maka f kontinu seragam pada setiap himpunan kompak. Oleh karena itu, untuk setiap $\delta > 0$, terdapat $\eta > 0$ sehingga $|x - y| < \eta$ mengimplikasikan $|f(x) - f(y)| < \delta$.

Perhatikan bahwa

$$\begin{aligned} |\mathbb{E}[f(X_n)] - \mathbb{E}[f(X)]| &= |\mathbb{E}[f(X_n) - f(X)]| \\ &\leq \mathbb{E}[|f(X_n) - f(X)|]. \end{aligned} \quad (2.3.18)$$

Dekomposisi ekspektasi berdasarkan kejadian $\{|X_n - X| \leq \eta\}$ dan $\{|X_n - X| > \eta\}$ memberikan

$$\begin{aligned}\mathbb{E}[|f(X_n) - f(X)|] &= \mathbb{E}[|f(X_n) - f(X)| \cdot \mathbf{1}_{\{|X_n - X| \leq \eta\}}] \\ &\quad + \mathbb{E}[|f(X_n) - f(X)| \cdot \mathbf{1}_{\{|X_n - X| > \eta\}}].\end{aligned}\quad (2.3.19)$$

Untuk suku pertama, karena $|X_n - X| \leq \eta$ mengimplikasikan $|f(X_n) - f(X)| < \delta$, maka

$$\mathbb{E}[|f(X_n) - f(X)| \cdot \mathbf{1}_{\{|X_n - X| \leq \eta\}}] < \delta. \quad (2.3.20)$$

Untuk suku kedua, karena $|f(x)| \leq M$, maka $|f(X_n) - f(X)| \leq 2M$, sehingga

$$\mathbb{E}[|f(X_n) - f(X)| \cdot \mathbf{1}_{\{|X_n - X| > \eta\}}] \leq 2M \cdot \Pr(|X_n - X| > \eta). \quad (2.3.21)$$

Sebab $X_n \xrightarrow{p} X$, maka $\Pr(|X_n - X| > \eta) \rightarrow 0$ ketika $n \rightarrow \infty$. Oleh karena itu,

$$\limsup_{n \rightarrow \infty} |\mathbb{E}[f(X_n)] - \mathbb{E}[f(X)]| \leq \delta. \quad (2.3.22)$$

Sebab $\delta > 0$ sembarang, maka $\mathbb{E}[f(X_n)] \rightarrow \mathbb{E}[f(X)]$, yang berarti $X_n \xrightarrow{d} X$. ■

Teorema 2.3.15 Jika $X_n \xrightarrow{d} c$ dengan c adalah konstanta, maka $X_n \xrightarrow{p} c$.

Bukti. Andaikan $X_n \xrightarrow{d} c$. Berdasarkan definisi konvergensi dalam distribusi, untuk setiap fungsi kontinu terbatas f , berlaku $\mathbb{E}[f(X_n)] \rightarrow f(c)$.

Untuk setiap $\varepsilon > 0$, definisikan fungsi kontinu terbatas

$$f_\varepsilon(x) = \begin{cases} 1, & \text{jika } |x - c| \geq \varepsilon, \\ \frac{|x - c|}{\varepsilon}, & \text{jika } |x - c| < \varepsilon. \end{cases} \quad (2.3.23)$$

Fungsi f_ε kontinu dan memenuhi $0 \leq f_\varepsilon(x) \leq 1$ untuk semua x , serta $f_\varepsilon(c) = 0$.

Perhatikan bahwa $\mathbf{1}_{\{|X_n - c| \geq \varepsilon\}} \leq f_\varepsilon(X_n)$, sehingga

$$\Pr(|X_n - c| \geq \varepsilon) = \mathbb{E}[\mathbf{1}_{\{|X_n - c| \geq \varepsilon\}}] \leq \mathbb{E}[f_\varepsilon(X_n)]. \quad (2.3.24)$$

Sebab $X_n \xrightarrow{d} c$ dan f_ε kontinu terbatas, maka $\mathbb{E}[f_\varepsilon(X_n)] \rightarrow f_\varepsilon(c) = 0$. Oleh karena itu,

$$\lim_{n \rightarrow \infty} \Pr(|X_n - c| \geq \varepsilon) = 0, \quad (2.3.25)$$

yang berarti $X_n \xrightarrow{p} c$. ■

2.4 Teori Probabilitas Asimtotik

Teori probabilitas asimtotik mempelajari perilaku limit dari barisan variabel acak dan estimator ketika ukuran sampel menuju tak hingga. Dalam statistika, hasil-hasil asimtotik digunakan sebagai pendekatan terhadap distribusi *sampling* yang umumnya sulit diperoleh secara eksak. Pembahasan dalam bagian ini mengikuti kerangka statistik asimtotik sebagaimana dikembangkan oleh van der Vaart (1998) dengan fondasi probabilitas dari Billingsley (1995).

2.4.1 Hukum Bilangan Besar

Teorema 2.4.1 (Weak law of large numbers, Pishro-Nik 2014) Misalkan $\{X_i\}_{i=1}^\infty$ adalah barisan variabel acak i.i.d. dengan $\mathbb{E}[X_1] = \mu$ dan $\mathbb{E}[|X_1|] < \infty$. Maka

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{p} \mu. \quad (2.4.1)$$

Bukti. Andaikan $\{X_i\}_{i=1}^\infty$ adalah barisan variabel acak i.i.d. dengan $\mathbb{E}[X_1] = \mu$ dan $\text{Var}(X_1) = \sigma^2 < \infty$. Definisikan rata-rata sampel $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$. Akan ditunjukkan bahwa $\bar{X}_n \xrightarrow{p} \mu$.

Pertama, perhatikan bahwa

$$\mathbb{E}[\bar{X}_n] = \mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i] = \frac{1}{n} \cdot n\mu = \mu. \quad (2.4.2)$$

Selanjutnya, karena X_i saling independen, berlaku

$$\text{Var}(\bar{X}_n) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{1}{n^2} \cdot n\sigma^2 = \frac{\sigma^2}{n}. \quad (2.4.3)$$

Dengan menggunakan ketaksamaan Chebyshev, untuk setiap $\varepsilon > 0$ berlaku

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2}. \quad (2.4.4)$$

Dengan mengambil limit $n \rightarrow \infty$, diperoleh

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| \geq \varepsilon) \leq \lim_{n \rightarrow \infty} \frac{\sigma^2}{n\varepsilon^2} = 0. \quad (2.4.5)$$

Oleh karena probabilitas selalu non-negatif, berlaku

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| \geq \varepsilon) = 0, \quad (2.4.6)$$

yang ekuivalen dengan $\bar{X}_n \xrightarrow{p} \mu$. Dengan demikian, *Weak Law of Large Numbers* terbukti. ■

Hukum Bilangan Besar memberikan dasar probabilistik bagi konsistensi estimator berbasis rata-rata sampel.

2.4.2 Konsistensi Estimator

Definisi 2.4.2 (Konsistensi, van der Vaart 1998) Suatu estimator $\hat{\theta}_n$ untuk parameter θ dikatakan konsisten apabila

$$\hat{\theta}_n \xrightarrow{p} \theta. \quad (2.4.7)$$

Konsistensi sering diperoleh sebagai konsekuensi langsung dari Hukum Bilangan Besar, khususnya untuk estimator yang dapat diekspresikan sebagai fungsi rata-rata sampel.

2.4.3 Fungsi Karakteristik

Fungsi karakteristik merupakan alat fundamental dalam teori probabilitas yang memungkinkan karakterisasi lengkap distribusi suatu variabel acak. Berbeda dengan fungsi pembangkit momen yang mungkin tidak terdefinisi, fungsi karakte-

ristik selalu ada untuk setiap variabel acak.

Definisi 2.4.3 (Fungsi karakteristik, Billingsley 1995) Misalkan X adalah variabel acak. Fungsi karakteristik dari X didefinisikan sebagai

$$\phi_X(t) = \mathbb{E} [e^{itX}] = \int_{-\infty}^{\infty} e^{itx} dF_X(x), \quad t \in \mathbb{R}, \quad (2.4.8)$$

dengan $i = \sqrt{-1}$ adalah unit imajiner dan F_X adalah fungsi distribusi kumulatif dari X .

Contoh 2.4.4 Berikut adalah fungsi karakteristik untuk beberapa distribusi umum.

(a) **Distribusi Normal.** Jika $X \sim \mathcal{N}(\mu, \sigma^2)$, maka

$$\phi_X(t) = \exp \left(i\mu t - \frac{\sigma^2 t^2}{2} \right). \quad (2.4.9)$$

Khususnya, untuk distribusi normal standar $X \sim \mathcal{N}(0, 1)$, berlaku $\phi_X(t) = e^{-t^2/2}$.

(b) **Distribusi Poisson.** Jika $X \sim \text{Poisson}(\lambda)$, maka

$$\phi_X(t) = \exp \left(\lambda(e^{it} - 1) \right). \quad (2.4.10)$$

(c) **Distribusi Eksponensial.** Jika $X \sim \text{Exp}(\lambda)$, maka

$$\phi_X(t) = \frac{\lambda}{\lambda - it}. \quad (2.4.11)$$

Proposisi 2.4.5 Fungsi karakteristik $\phi_X(t)$ memenuhi sifat-sifat berikut.

(a) $\phi_X(0) = 1$.

(b) $|\phi_X(t)| \leq 1$ untuk semua $t \in \mathbb{R}$.

(c) ϕ_X kontinu seragam pada \mathbb{R} .

(d) $\overline{\phi_X(t)} = \phi_X(-t)$, dengan \bar{z} menyatakan konjugat kompleks dari z .

(e) Jika $Y = aX + b$ untuk konstanta $a, b \in \mathbb{R}$, maka $\phi_Y(t) = e^{ibt} \phi_X(at)$.

(f) Jika X dan Y independen, maka $\phi_{X+Y}(t) = \phi_X(t) \cdot \phi_Y(t)$.

Proposisi 2.4.6 Jika $\mathbb{E}[|X|^n] < \infty$, maka fungsi karakteristik ϕ_X terdiferensiasi n kali dan

$$\phi_X^{(k)}(0) = i^k \mathbb{E}[X^k], \quad k = 1, 2, \dots, n. \quad (2.4.12)$$

Khususnya, jika $\mathbb{E}[X^2] < \infty$, maka ekspansi Taylor di sekitar $t = 0$ memberikan

$$\phi_X(t) = 1 + it\mathbb{E}[X] - \frac{t^2}{2}\mathbb{E}[X^2] + o(t^2). \quad (2.4.13)$$

Teorema berikut merupakan hasil fundamental yang menghubungkan konvergensi fungsi karakteristik dengan konvergensi dalam distribusi.

Teorema 2.4.7 (Teorema kontinuitas Lévy, Dudley 2002) Misalkan $\{X_n\}_{n=1}^{\infty}$ adalah barisan variabel acak dengan fungsi karakteristik ϕ_{X_n} , dan misalkan X adalah variabel acak dengan fungsi karakteristik ϕ_X . Maka berlaku dua pernyataan berikut.

(a) Jika $X_n \Rightarrow X$, maka $\phi_{X_n}(t) \rightarrow \phi_X(t)$ untuk setiap $t \in \mathbb{R}$.

(b) Sebaliknya, jika $\phi_{X_n}(t) \rightarrow \phi(t)$ untuk setiap $t \in \mathbb{R}$ dan ϕ kontinu di $t = 0$, maka ϕ adalah fungsi karakteristik dari suatu variabel acak X dan $X_n \Rightarrow X$.

Bukti.

(a) Asumsikan $X_n \Rightarrow X$, artinya untuk setiap fungsi $f : \mathbb{R} \rightarrow \mathbb{R}$ yang kontinu dan terbatas, berlaku

$$\mathbb{E}[f(X_n)] \rightarrow \mathbb{E}[f(X)]. \quad (2.4.14)$$

Untuk setiap $t \in \mathbb{R}$ yang tetap, perhatikan bahwa

$$\phi_{X_n}(t) = \mathbb{E}[e^{itX_n}] = \mathbb{E}[\cos(tX_n)] + i\mathbb{E}[\sin(tX_n)]. \quad (2.4.15)$$

Fungsi $f(x) = \cos(tx)$ adalah kontinu dan terbatas (karena $|\cos(tx)| \leq 1$).

Dengan demikian, konvergensi dalam distribusi menjamin

$$\mathbb{E}[\cos(tX_n)] \rightarrow \mathbb{E}[\cos(tX)]. \quad (2.4.16)$$

Serupa halnya, $g(x) = \sin(tx)$ adalah kontinu dan terbatas, sehingga

$$\mathbb{E}[\sin(tX_n)] \rightarrow \mathbb{E}[\sin(tX)]. \quad (2.4.17)$$

Menggabungkan kedua hasil, diperoleh

$$\phi_{X_n}(t) \rightarrow \phi_X(t) \quad \text{untuk setiap } t \in \mathbb{R}. \quad (2.4.18)$$

- (b) Asumsikan $\phi_{X_n}(t) \rightarrow \phi(t)$ untuk setiap $t \in \mathbb{R}$ dan ϕ kontinu di $t = 0$. Akan ditunjukkan bahwa barisan $\{X_n\}$ adalah *tight*, artinya untuk setiap $\varepsilon > 0$, terdapat $M > 0$ sehingga $\Pr(|X_n| > M) < \varepsilon$ untuk semua n .

Perhatikan bahwa untuk setiap $x \in \mathbb{R}$,

$$1 - \cos(x) = 2 \sin^2(x/2) \leq 2(x/2)^2 = \frac{x^2}{2} \quad \text{untuk } |x| \leq \pi. \quad (2.4.19)$$

Dengan demikian, untuk setiap $\delta > 0$,

$$\begin{aligned} \mathbb{E}[1 - \cos(\delta X_n)] &= 1 - \mathbb{E}[\cos(\delta X_n)] = 1 - \operatorname{Re}[\phi_{X_n}(\delta)] \\ &\rightarrow 1 - \operatorname{Re}[\phi(\delta)]. \end{aligned} \quad (2.4.20)$$

Karena ϕ kontinu di $t = 0$ dengan $\phi(0) = 1$, untuk setiap $\varepsilon > 0$, terdapat $\delta > 0$ sehingga $|1 - \operatorname{Re}[\phi(\delta)]| < \varepsilon$. Oleh karena itu, untuk n yang cukup besar,

$$\mathbb{E}[1 - \cos(\delta X_n)] < 2\varepsilon. \quad (2.4.21)$$

Menggunakan pertidaksamaan $1 - \cos(\delta x) \geq c \mathbf{1}_{\{|x| > M\}}$ untuk suatu konstanta $c > 0$ dan M yang dipilih cukup besar, diperoleh bahwa barisan $\{X_n\}$

adalah tight.

Dengan teorema Helly, setiap subbarisan dari $\{X_n\}$ memiliki subsubbarisan yang konvergen dalam distribusi ke suatu variabel acak X . Oleh karena itu, $X_n \Rightarrow X$. Lebih lanjut, fungsi karakteristik dari X haruslah ϕ dari keunikan fungsi karakteristik.

■

Contoh 2.4.8 Teorema Lévy dapat digunakan untuk membuktikan konvergensi distribusi. Misalkan $X_n \sim \mathcal{N}(0, 1 + 1/n)$ untuk $n = 1, 2, \dots$. Fungsi karakteristik dari X_n adalah

$$\phi_{X_n}(t) = \exp\left(-\frac{(1 + 1/n)t^2}{2}\right). \quad (2.4.22)$$

Untuk setiap $t \in \mathbb{R}$, berlaku

$$\lim_{n \rightarrow \infty} \phi_{X_n}(t) = \exp\left(-\frac{t^2}{2}\right) = \phi_X(t), \quad (2.4.23)$$

dengan $\phi_X(t)$ adalah fungsi karakteristik dari $X \sim \mathcal{N}(0, 1)$. Sebab limit ini kontinu di $t = 0$, berdasarkan Teorema Lévy, diperoleh $X_n \Rightarrow X \sim \mathcal{N}(0, 1)$.

Teorema Lévy sangat penting dalam pembuktian Teorema Limit Pusat, di mana konvergensi dalam distribusi dibuktikan melalui konvergensi fungsi karakteristik ke fungsi karakteristik distribusi normal.

2.4.4 Teorema Pemetaan Kontinu dan Teorema Slutsky

Teorema pemetaan kontinu (*Continuous Mapping Theorem*) dan teorema Slutsky merupakan alat fundamental dalam statistika asimtotik yang memungkinkan manipulasi limit variabel acak melalui fungsi kontinu dan operasi aritmetika.

Teorema 2.4.9 (Teorema Pemetaan Kontinu (*Continuous Mapping Theorem*), Dudley 2002) Misalkan $\{X_n\}$ adalah barisan variabel acak dan $g : \mathbb{R}^k \rightarrow \mathbb{R}^m$ adalah fungsi yang kontinu hampir di mana-mana relatif terhadap distribusi limit. Maka berlaku implikasi berikut.

(a) Jika $X_n \xrightarrow{d} X$, maka $g(X_n) \xrightarrow{d} g(X)$.

(b) Jika $X_n \xrightarrow{p} X$, maka $g(X_n) \xrightarrow{p} g(X)$.

(c) Jika $X_n \xrightarrow{a.s.} X$, maka $g(X_n) \xrightarrow{a.s.} g(X)$.

Bukti. Akan dibuktikan bagian (a) untuk kasus konvergensi dalam distribusi. Misalkan $X_n \xrightarrow{d} X$ dan g kontinu pada himpunan C dengan $\Pr(X \in C) = 1$. Akan ditunjukkan bahwa $g(X_n) \xrightarrow{d} g(X)$. Berdasarkan teorema Portmanteau, $X_n \xrightarrow{d} X$ ekuivalen dengan $\mathbb{E}[h(X_n)] \rightarrow \mathbb{E}[h(X)]$ untuk setiap fungsi kontinu terbatas h .

Ambil sembarang fungsi kontinu terbatas $h : \mathbb{R}^m \rightarrow \mathbb{R}$. Definisikan $f = h \circ g : \mathbb{R}^k \rightarrow \mathbb{R}$. Sebab g kontinu pada C dan h kontinu pada \mathbb{R}^m , maka f kontinu pada C .

Untuk setiap $\varepsilon > 0$, himpunan diskontinuitas D_f dari f memenuhi $D_f \subseteq D_g$ (himpunan diskontinuitas g). Sebab $\Pr(X \in D_g) = 0$, maka $\Pr(X \in D_f) = 0$.

Dengan teorema Portmanteau yang diperluas, sebab f kontinu hampir di mana-mana relatif terhadap distribusi X , berlaku

$$\mathbb{E}[h(g(X_n))] = \mathbb{E}[f(X_n)] \rightarrow \mathbb{E}[f(X)] = \mathbb{E}[h(g(X))]. \quad (2.4.24)$$

Sebab h adalah fungsi kontinu terbatas sembarang, berdasarkan teorema Portmanteau, diperoleh $g(X_n) \xrightarrow{d} g(X)$.

Untuk bagian (b), jika $X_n \xrightarrow{p} X$, maka untuk setiap $\varepsilon > 0$ dan $\delta > 0$, terdapat N sehingga $\Pr(|X_n - X| > \delta) < \varepsilon$ untuk $n \geq N$. Sebab g kontinu pada C , maka g kontinu seragam pada setiap himpunan kompak. Dengan demikian, untuk setiap $\varepsilon' > 0$, terdapat $\delta > 0$ sehingga $|x - y| < \delta$ mengimplikasikan $|g(x) - g(y)| < \varepsilon'$ pada himpunan kompak yang memuat support distribusi. Oleh karena itu, $\Pr(|g(X_n) - g(X)| > \varepsilon') \rightarrow 0$.

Bagian (c) mengikuti langsung dari sifat fungsi kontinu: jika $X_n(\omega) \rightarrow X(\omega)$ untuk hampir semua ω , dan g kontinu di $X(\omega)$, maka $g(X_n(\omega)) \rightarrow g(X(\omega))$.

■

Contoh 2.4.10 Misalkan $X_n \xrightarrow{d} X$ dengan $X \sim \mathcal{N}(0, 1)$. Dengan teorema pemetaan kontinu dan fungsi $g(x) = x^2$ yang kontinu, diperoleh

$$X_n^2 \xrightarrow{d} X^2 \sim \chi^2(1). \quad (2.4.25)$$

Demikian pula, jika $g(x) = e^x$, maka $e^{X_n} \xrightarrow{d} e^X$.

Teorema 2.4.11 (Teorema Slutsky, van der Vaart 1998) Misalkan $\{X_n\}$ dan $\{Y_n\}$ adalah barisan variabel acak. Jika $X_n \xrightarrow{d} X$ dan $Y_n \xrightarrow{p} c$ dengan c adalah konstanta, maka berlaku:

- (a) $X_n + Y_n \xrightarrow{d} X + c$,
- (b) $X_n \cdot Y_n \xrightarrow{d} c \cdot X$, dan
- (c) $X_n/Y_n \xrightarrow{d} X/c$ jika $c \neq 0$.

Bukti. Akan dibuktikan ketiga bagian secara berurutan.

Bagian (a): Akan ditunjukkan bahwa $(X_n, Y_n) \xrightarrow{d} (X, c)$, kemudian menerapkan teorema pemetaan kontinu dengan $g(x, y) = x + y$. Untuk menunjukkan $(X_n, Y_n) \xrightarrow{d} (X, c)$, digunakan fungsi karakteristik. Fungsi karakteristik bersama dari (X_n, Y_n) adalah

$$\phi_{(X_n, Y_n)}(t_1, t_2) = \mathbb{E}[e^{i(t_1 X_n + t_2 Y_n)}]. \quad (2.4.26)$$

Perhatikan bahwa

$$\begin{aligned} |\phi_{(X_n, Y_n)}(t_1, t_2) - \phi_X(t_1)e^{it_2 c}| &= |\mathbb{E}[e^{it_1 X_n}(e^{it_2 Y_n} - e^{it_2 c})]| \\ &\leq \mathbb{E}[|e^{it_2 Y_n} - e^{it_2 c}|]. \end{aligned} \quad (2.4.27)$$

Sebab $Y_n \xrightarrow{p} c$, maka $e^{it_2 Y_n} \xrightarrow{p} e^{it_2 c}$ berdasarkan teorema pemetaan kontinu untuk konvergensi dalam probabilitas. Sebab $|e^{it_2 Y_n} - e^{it_2 c}| \leq 2$ terbatas, berdasarkan teorema konvergensi terdominasi, $\mathbb{E}[|e^{it_2 Y_n} - e^{it_2 c}|] \rightarrow 0$.

Selanjutnya, sebab $X_n \xrightarrow{d} X$, berdasarkan teorema kontinuitas Lévy, dida-

patkan bahwa $\phi_{X_n}(t_1) \rightarrow \phi_X(t_1)$. Dengan demikian,

$$\phi_{(X_n, Y_n)}(t_1, t_2) \rightarrow \phi_X(t_1)e^{it_2c} = \phi_{(X, c)}(t_1, t_2). \quad (2.4.28)$$

Berdasarkan teorema Lévy, $(X_n, Y_n) \xrightarrow{d} (X, c)$. Dengan teorema pemetaan kontinu dan $g(x, y) = x + y$ yang kontinu, diperoleh $X_n + Y_n \xrightarrow{d} X + c$.

Bagian (b): Dengan hasil $(X_n, Y_n) \xrightarrow{d} (X, c)$ dan fungsi $g(x, y) = xy$ yang kontinu, teorema pemetaan kontinu memberikan $X_n \cdot Y_n \xrightarrow{d} X \cdot c = cX$.

Bagian (c): Jika $c \neq 0$, fungsi $g(x, y) = x/y$ kontinu pada $\{(x, y) : y \neq 0\}$. Sebab $Y_n \xrightarrow{p} c \neq 0$, maka $\Pr(Y_n = 0) \rightarrow 0$, sehingga (X, c) terkonsentrasi pada himpunan di mana g kontinu. Dengan teorema pemetaan kontinu, $X_n/Y_n \xrightarrow{d} X/c$.

■

Contoh 2.4.12 Misalkan \bar{X}_n adalah rata-rata sampel dari variabel acak *i.i.d.* dengan rata-rata μ dan variansi σ^2 , dan S_n^2 adalah variansi sampel. Berdasarkan Teorema Limit Pusat:

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2). \quad (2.4.29)$$

Berdasarkan Hukum Bilangan Besar, $S_n^2 \xrightarrow{p} \sigma^2$, sehingga $S_n \xrightarrow{p} \sigma$.

Dengan teorema Slutsky:

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{S_n} = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \cdot \frac{\sigma}{S_n} \xrightarrow{d} \mathcal{N}(0, 1) \cdot 1 = \mathcal{N}(0, 1). \quad (2.4.30)$$

Hasil ini membenarkan penggunaan statistik t dalam inferensi asimtotik.

Teorema 2.4.13 Misalkan $\{\mathbf{X}_n\}$ adalah barisan vektor acak berdimensi p dan $\{\mathbf{A}_n\}$ adalah barisan matriks acak berukuran $q \times p$. Jika $\mathbf{X}_n \xrightarrow{d} \mathbf{X}$ dan $\mathbf{A}_n \xrightarrow{p} \mathbf{A}$ dengan \mathbf{A} adalah matriks konstanta, maka:

$$(a) \mathbf{A}_n \mathbf{X}_n \xrightarrow{d} \mathbf{A} \mathbf{X},$$

$$(b) \mathbf{X}_n + \mathbf{b}_n \xrightarrow{d} \mathbf{X} + \mathbf{b} \text{ jika } \mathbf{b}_n \xrightarrow{p} \mathbf{b},$$

$$(c) \mathbf{X}_n^\top \mathbf{A}_n \mathbf{X}_n \xrightarrow{d} \mathbf{X}^\top \mathbf{A} \mathbf{X} \text{ untuk bentuk kuadrat, dan}$$

(d) jika \mathbf{A} adalah matriks invertibel, maka $\mathbf{A}_n^{-1} \xrightarrow{p} \mathbf{A}^{-1}$ dan $\mathbf{A}_n^{-1} \mathbf{X}_n \xrightarrow{d} \mathbf{A}^{-1} \mathbf{X}$.

Bukti. Bagian (a): Perkalian matriks $g(\mathbf{A}, \mathbf{x}) = \mathbf{A}\mathbf{x}$ adalah fungsi kontinu dari elemen-elemen \mathbf{A} dan \mathbf{x} . Akan ditunjukkan bahwa $(\mathbf{A}_n, \mathbf{X}_n) \xrightarrow{d} (\mathbf{A}, \mathbf{X})$. Untuk setiap fungsi kontinu terbatas $h : \mathbb{R}^{qp+p} \rightarrow \mathbb{R}$, perlu ditunjukkan bahwa $\mathbb{E}[h(\mathbf{A}_n, \mathbf{X}_n)] \rightarrow \mathbb{E}[h(\mathbf{A}, \mathbf{X})]$.

Sebab $\mathbf{A}_n \xrightarrow{p} \mathbf{A}$, untuk setiap $\varepsilon > 0$ berlaku $\Pr(\|\mathbf{A}_n - \mathbf{A}\| > \varepsilon) \rightarrow 0$.

Definisikan

$$\mathbb{E}[h(\mathbf{A}_n, \mathbf{X}_n)] = \mathbb{E}[h(\mathbf{A}_n, \mathbf{X}_n)\mathbf{1}_{\{\|\mathbf{A}_n - \mathbf{A}\| \leq \varepsilon\}}] + \mathbb{E}[h(\mathbf{A}_n, \mathbf{X}_n)\mathbf{1}_{\{\|\mathbf{A}_n - \mathbf{A}\| > \varepsilon\}}]. \quad (2.4.31)$$

Suku kedua dibatasi oleh $\|h\|_\infty \cdot \Pr(\|\mathbf{A}_n - \mathbf{A}\| > \varepsilon) \rightarrow 0$. Untuk suku pertama, pada kejadian $\{\|\mathbf{A}_n - \mathbf{A}\| \leq \varepsilon\}$, fungsi $h(\mathbf{A}_n, \mathbf{X}_n)$ mendekati $h(\mathbf{A}, \mathbf{X}_n)$ untuk ε kecil. Sebab $\mathbf{X}_n \xrightarrow{d} \mathbf{X}$, maka $\mathbb{E}[h(\mathbf{A}, \mathbf{X}_n)] \rightarrow \mathbb{E}[h(\mathbf{A}, \mathbf{X})]$. Dengan demikian, $(\mathbf{A}_n, \mathbf{X}_n) \xrightarrow{d} (\mathbf{A}, \mathbf{X})$. Dengan teorema pemetaan kontinu dan fungsi $g(\mathbf{A}, \mathbf{x}) = \mathbf{A}\mathbf{x}$, diperoleh $\mathbf{A}_n \mathbf{X}_n \xrightarrow{d} \mathbf{A}\mathbf{X}$.

Bagian (b): Analog dengan bagian (a), penjumlahan vektor $g(\mathbf{x}, \mathbf{b}) = \mathbf{x} + \mathbf{b}$ adalah fungsi kontinu.

Bagian (c): Bentuk kuadratik $g(\mathbf{A}, \mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$ adalah fungsi kontinu dari elemen-elemen \mathbf{A} dan \mathbf{x} . Dengan hasil dari bagian (a), $(\mathbf{A}_n, \mathbf{X}_n) \xrightarrow{d} (\mathbf{A}, \mathbf{X})$, sehingga teorema pemetaan kontinu memberikan $\mathbf{X}_n^\top \mathbf{A}_n \mathbf{X}_n \xrightarrow{d} \mathbf{X}^\top \mathbf{A} \mathbf{X}$.

Bagian (d): Jika \mathbf{A} invertibel, fungsi invers matriks $g(\mathbf{A}) = \mathbf{A}^{-1}$ kontinu pada himpunan matriks invertibel. Dengan demikian, berdasarkan teorema pemetaan kontinu, $\mathbf{A}_n^{-1} \xrightarrow{p} \mathbf{A}^{-1}$. Selanjutnya, dengan bagian (a), diperoleh $\mathbf{A}_n^{-1} \xrightarrow{d} \mathbf{A}^{-1} \mathbf{X}$.

■

Contoh 2.4.14 Misalkan $\sqrt{n}(\hat{\beta}_n - \beta) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \Sigma)$ dan $\hat{\Sigma}_n \xrightarrow{p} \Sigma$ dengan Σ definit positif. Diketahui statistik Wald

$$W_n = n(\hat{\beta}_n - \beta)^\top \hat{\Sigma}_n^{-1} (\hat{\beta}_n - \beta) \quad (2.4.32)$$

memenuhi $W_n \xrightarrow{d} \chi^2(p)$, dengan $p = \dim(\beta)$. Hal ini karena $\hat{\Sigma}_n^{-1} \xrightarrow{p} \Sigma^{-1}$ (berdasarkan teorema pemetaan kontinu untuk fungsi invers matriks), dan

$$\sqrt{n}(\hat{\beta}_n - \beta)^\top \hat{\Sigma}_n^{-1} \sqrt{n}(\hat{\beta}_n - \beta) \xrightarrow{d} \mathbf{Z}^\top \Sigma^{-1} \mathbf{Z} \sim \chi^2(p), \quad (2.4.33)$$

dengan $\mathbf{Z} \sim \mathcal{N}(\mathbf{0}, \Sigma)$.

Teorema 2.4.15 (Teorema Cramér–Wold, van der Vaart 1998) *Barisan vektor acak $\mathbf{X}_n \in \mathbb{R}^p$ konvergen dalam distribusi ke \mathbf{X} jika dan hanya jika untuk setiap vektor $\mathbf{t} \in \mathbb{R}^p$ berlaku*

$$\mathbf{t}^\top \mathbf{X}_n \xrightarrow{d} \mathbf{t}^\top \mathbf{X}. \quad (2.4.34)$$

Bukti. (\Rightarrow) Jika $\mathbf{X}_n \xrightarrow{d} \mathbf{X}$, maka untuk setiap $\mathbf{t} \in \mathbb{R}^p$, fungsi $g(\mathbf{x}) = \mathbf{t}^\top \mathbf{x}$ adalah linear (kontinu). Berdasarkan teorema pemetaan kontinu, $\mathbf{t}^\top \mathbf{X}_n \xrightarrow{d} \mathbf{t}^\top \mathbf{X}$.

(\Leftarrow) Andaikan untuk setiap $\mathbf{t} \in \mathbb{R}^p$ berlaku $\mathbf{t}^\top \mathbf{X}_n \xrightarrow{d} \mathbf{t}^\top \mathbf{X}$. Akan ditunjukkan $\mathbf{X}_n \xrightarrow{d} \mathbf{X}$ melalui konvergensi fungsi karakteristik. Fungsi karakteristik dari \mathbf{X}_n adalah

$$\phi_{\mathbf{X}_n}(\mathbf{t}) = \mathbb{E}[e^{i\mathbf{t}^\top \mathbf{X}_n}]. \quad (2.4.35)$$

Perhatikan bahwa $e^{i\mathbf{t}^\top \mathbf{X}_n}$ adalah fungsi karakteristik dari variabel acak skalar $\mathbf{t}^\top \mathbf{X}_n$ dievaluasi di titik 1. Sebab $\mathbf{t}^\top \mathbf{X}_n \xrightarrow{d} \mathbf{t}^\top \mathbf{X}$, berdasarkan teorema kontinuitas Lévy, fungsi karakteristik dari $\mathbf{t}^\top \mathbf{X}_n$ konvergen ke fungsi karakteristik dari $\mathbf{t}^\top \mathbf{X}$ di setiap titik. Khususnya,

$$\phi_{\mathbf{X}_n}(\mathbf{t}) = \mathbb{E}[e^{i\mathbf{t}^\top \mathbf{X}_n}] \rightarrow \mathbb{E}[e^{i\mathbf{t}^\top \mathbf{X}}] = \phi_{\mathbf{X}}(\mathbf{t}). \quad (2.4.36)$$

Sebab $\phi_{\mathbf{X}_n}(\mathbf{t}) \rightarrow \phi_{\mathbf{X}}(\mathbf{t})$ untuk setiap $\mathbf{t} \in \mathbb{R}^p$, dan $\phi_{\mathbf{X}}$ kontinu di $\mathbf{t} = \mathbf{0}$ (sebab merupakan fungsi karakteristik), berdasarkan teorema kontinuitas Lévy multivariat, $\mathbf{X}_n \xrightarrow{d} \mathbf{X}$. ■

Contoh 2.4.16 Teorema Cramér–Wold sangat berguna untuk membuktikan Teorema Limit Pusat multivariat. Jika $\mathbf{X}_1, \mathbf{X}_2, \dots$ adalah vektor acak *i.i.d.* dengan rata-rata

μ dan matriks kovarians Σ , maka untuk setiap $\mathbf{t} \in \mathbb{R}^p$:

$$\mathbf{t}^\top (\sqrt{n}(\bar{\mathbf{X}}_n - \mu)) = \sqrt{n}(\mathbf{t}^\top \bar{\mathbf{X}}_n - \mathbf{t}^\top \mu) \xrightarrow{d} \mathcal{N}(0, \mathbf{t}^\top \Sigma \mathbf{t}), \quad (2.4.37)$$

berdasarkan univariat. Dengan teorema Cramér–Wold, $\sqrt{n}(\bar{\mathbf{X}}_n - \mu) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \Sigma)$.

2.4.5 Notasi *Big-O* dan *Little-o* (Deterministik)

Notasi asimtotik *Big-O* dan *Little-o* merupakan alat fundamental dalam analisis matematika untuk menyatakan laju pertumbuhan dan tingkat ketakterabaian suatu besaran deterministik.

Definisi 2.4.17 (Notasi *Big-O*) Misalkan $\{a_n\}$ dan $\{b_n\}$ adalah barisan bilangan real dengan $b_n > 0$ untuk semua n cukup besar. Barisan $\{a_n\}$ dikatakan berorde paling banyak b_n , ditulis

$$a_n = \mathcal{O}(b_n), \quad (2.4.38)$$

jika terdapat konstanta $C > 0$ dan bilangan bulat $n_0 \in \mathbb{N}$ sehingga

$$|a_n| \leq Cb_n, \quad \forall n \geq n_0. \quad (2.4.39)$$

Secara ekuivalen, $a_n = \mathcal{O}(b_n)$ jika dan hanya jika barisan $\{a_n/b_n\}$ terbatas untuk n cukup besar.

Contoh 2.4.18 Berikut adalah beberapa contoh penggunaan notasi *Big-O*.

- (a) **Polinomial:** Jika $a_n = 3n^2 + 5n + 7$, maka $a_n = \mathcal{O}(n^2)$. Untuk $n \geq 1$, berlaku

$$|a_n| = 3n^2 + 5n + 7 \leq 3n^2 + 5n^2 + 7n^2 = 15n^2,$$

sehingga dapat dipilih $C = 15$ dan $n_0 = 1$.

- (b) **Logaritma:** Jika $a_n = \log n$, maka $a_n = \mathcal{O}(n^\varepsilon)$ untuk setiap $\varepsilon > 0$. Hal ini karena $\lim_{n \rightarrow \infty} \frac{\log n}{n^\varepsilon} = 0$, sehingga $\log n \leq Cn^\varepsilon$ untuk n cukup besar.

- (c) **Eksponensial:** Jika $a_n = 2^n$, maka $a_n = \mathcal{O}(3^n)$ karena $2^n \leq 3^n$ untuk semua

$$n \geq 0.$$

- (d) **Rata-rata sampel:** Jika \bar{X}_n adalah rata-rata sampel dari variabel acak dengan variansi σ^2 , maka galat standar $\sigma/\sqrt{n} = \mathcal{O}(n^{-1/2})$.

Definisi 2.4.19 (Notasi *Little-o*) Misalkan $\{a_n\}$ dan $\{b_n\}$ adalah barisan bilangan real dengan $b_n > 0$ untuk semua n cukup besar. Barisan $\{a_n\}$ dikatakan berorde lebih kecil dari b_n , ditulis

$$a_n = o(b_n), \quad (2.4.40)$$

jika

$$\lim_{n \rightarrow \infty} \frac{a_n}{b_n} = 0. \quad (2.4.41)$$

Secara ekuivalen, $a_n = o(b_n)$ jika dan hanya jika untuk setiap $\varepsilon > 0$, terdapat $n_0 \in \mathbb{N}$ sehingga $|a_n| < \varepsilon b_n$ untuk semua $n \geq n_0$.

Contoh 2.4.20 Berikut adalah beberapa contoh penggunaan notasi *Little-o*.

- (a) **Polinomial:** Jika $a_n = n$, maka $a_n = o(n^2)$ karena

$$\lim_{n \rightarrow \infty} \frac{n}{n^2} = \lim_{n \rightarrow \infty} \frac{1}{n} = 0.$$

- (b) **Logaritma vs polinomial:** Jika $a_n = \log n$, maka $a_n = o(n^\varepsilon)$ untuk setiap $\varepsilon > 0$. Dengan aturan L'Hôpital:

$$\lim_{n \rightarrow \infty} \frac{\log n}{n^\varepsilon} = \lim_{n \rightarrow \infty} \frac{1/n}{\varepsilon n^{\varepsilon-1}} = \lim_{n \rightarrow \infty} \frac{1}{\varepsilon n^\varepsilon} = 0.$$

- (c) **Eksansi Taylor:** Untuk fungsi $\sin x$ di sekitar $x = 0$:

$$\sin x = x - \frac{x^3}{6} + o(x^3) \quad \text{ketika } x \rightarrow 0.$$

Suku $o(x^3)$ menunjukkan bahwa galat sisa tumbuh lebih lambat dari x^3 .

- (d) **Perhitungan numerik:** Misalkan $a_n = 1/n^2$ dan $b_n = 1/n$. Maka $a_n =$

$o(b_n)$ karena

$$\lim_{n \rightarrow \infty} \frac{1/n^2}{1/n} = \lim_{n \rightarrow \infty} \frac{1}{n} = 0.$$

Secara numerik, untuk $n = 100$: $a_{100} = 0.0001$ dan $b_{100} = 0.01$, sehingga $a_{100}/b_{100} = 0.01$.

Teorema 2.4.21 Untuk barisan $\{a_n\}$ dan $\{b_n\}$ dengan $b_n > 0$, berlaku:

- (a) Jika $a_n = o(b_n)$, maka $a_n = \mathcal{O}(b_n)$, tetapi tidak sebaliknya.
- (b) $a_n = o(b_n)$ jika dan hanya jika $a_n = \mathcal{O}(b_n)$ dan $\limsup_{n \rightarrow \infty} |a_n/b_n| = 0$.

Bukti.

- (a) Andaikan $a_n = o(b_n)$. Maka $\lim_{n \rightarrow \infty} a_n/b_n = 0$. Dengan definisi limit, untuk $\varepsilon = 1$, terdapat n_0 sehingga $|a_n/b_n| < 1$ untuk $n \geq n_0$. Dengan demikian, $|a_n| < b_n$ untuk $n \geq n_0$, sehingga $a_n = \mathcal{O}(b_n)$ dengan $C = 1$.

Sebaliknya tidak berlaku: $a_n = 1$ dan $b_n = 1$ memberikan $a_n = \mathcal{O}(b_n)$ (dengan $C = 1$), tetapi $\lim_{n \rightarrow \infty} a_n/b_n = 1 \neq 0$, sehingga $a_n \neq o(b_n)$.

- (b) Langsung dari definisi: $a_n = o(b_n)$ ekuivalen dengan $\lim_{n \rightarrow \infty} |a_n/b_n| = 0$, yang mengimplikasikan barisan $\{|a_n/b_n|\}$ terbatas (sehingga $a_n = \mathcal{O}(b_n)$) dan $\limsup_{n \rightarrow \infty} |a_n/b_n| = 0$.

■

Proposisi 2.4.22 Untuk barisan $\{a_n\}$, $\{b_n\}$, $\{c_n\}$ dengan suku positif yang sesuai, berlaku:

- (a) **Transitivitas:** Jika $a_n = \mathcal{O}(b_n)$ dan $b_n = \mathcal{O}(c_n)$, maka $a_n = \mathcal{O}(c_n)$.
- (b) **Penjumlahan:** $\mathcal{O}(a_n) + \mathcal{O}(b_n) = \mathcal{O}(\max\{a_n, b_n\})$.
- (c) **Perkalian:** $\mathcal{O}(a_n) \cdot \mathcal{O}(b_n) = \mathcal{O}(a_n b_n)$.
- (d) **Penyerapan:** $o(a_n) + \mathcal{O}(a_n) = \mathcal{O}(a_n)$ dan $o(a_n) \cdot \mathcal{O}(b_n) = o(a_n b_n)$.

2.4.6 Notasi Big- \mathcal{O} dan Little- o dalam Probabilitas

Notasi \mathcal{O}_p dan o_p merupakan perluasan dari notasi deterministik $\mathcal{O}(\cdot)$ dan $o(\cdot)$ ke dalam konteks stokastik. Notasi ini sangat penting dalam perumusan representasi asimtotik estimator dan digunakan secara luas dalam statistika asimtotik (van der Vaart, 1998).

Definisi 2.4.23 (Notasi \mathcal{O}_p , van der Vaart 1998) Barisan variabel acak $\{X_n\}$ dikatakan terbatas dalam probabilitas dengan orde a_n , ditulis

$$X_n = \mathcal{O}_p(a_n), \quad (2.4.42)$$

apabila untuk setiap $\varepsilon > 0$ terdapat $M > 0$ dan $N \in \mathbb{N}$ sehingga

$$\Pr(|X_n| > Ma_n) < \varepsilon, \quad \forall n \geq N. \quad (2.4.43)$$

Secara ekuivalen, $X_n = \mathcal{O}_p(a_n)$ jika dan hanya jika barisan $\{X_n/a_n\}$ terbatas dalam probabilitas, yaitu

$$\sup_{n \geq N} \Pr\left(\left|\frac{X_n}{a_n}\right| > M\right) < \varepsilon. \quad (2.4.44)$$

Contoh 2.4.24 Misalkan X_1, X_2, \dots adalah barisan variabel acak *i.i.d.* dengan $\mathbb{E}[X_i] = \mu$ dan $\text{Var}(X_i) = \sigma^2 < \infty$. Definisikan rata-rata sampel $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$. Akan ditunjukkan bahwa $\bar{X}_n - \mu = \mathcal{O}_p(n^{-1/2})$.

Berdasarkan Teorema Limit Pusat, berlaku

$$\sqrt{n}(\bar{X}_n - \mu) \Rightarrow \mathcal{N}(0, \sigma^2).$$

Sebab $\sqrt{n}(\bar{X}_n - \mu)$ konvergen dalam distribusi ke variabel acak normal, maka barisan ini terbatas dalam probabilitas (*bounded in probability*). Dengan demikian, untuk setiap $\varepsilon > 0$, terdapat $M > 0$ sehingga

$$\sup_n \Pr(|\sqrt{n}(\bar{X}_n - \mu)| > M) < \varepsilon,$$

yang ekuivalen dengan

$$\sup_n \Pr(|\bar{X}_n - \mu| > M \cdot n^{-1/2}) < \varepsilon.$$

Oleh karena itu, $\bar{X}_n - \mu = \mathcal{O}_p(n^{-1/2})$.

Contoh 2.4.25 Misalkan $X_n \sim \mathcal{N}(0, 1/n)$ untuk $n = 1, 2, \dots$. Akan ditunjukkan bahwa $X_n = \mathcal{O}_p(n^{-1/2})$. Perhatikan bahwa $\sqrt{n}X_n \sim \mathcal{N}(0, 1)$. Untuk $\varepsilon = 0,05$ dan $M = 1,96$, berlaku

$$\Pr(|\sqrt{n}X_n| > 1,96) = 2(1 - \Phi(1,96)) \approx 0,05.$$

Dengan demikian,

$$\Pr(|X_n| > 1,96 \cdot n^{-1/2}) = 0,05 < \varepsilon,$$

sehingga $X_n = \mathcal{O}_p(n^{-1/2})$ dengan $M = 1,96$.

Definisi 2.4.26 (Notasi o_p , van der Vaart 1998) Barisan variabel acak $\{X_n\}$ dikatakan konvergen ke nol dalam probabilitas dengan orde a_n , ditulis

$$X_n = o_p(a_n), \quad (2.4.45)$$

apabila

$$\frac{X_n}{a_n} \xrightarrow{p} 0, \quad (2.4.46)$$

yaitu untuk setiap $\varepsilon > 0$ dan $\delta > 0$, terdapat $N \in \mathbb{N}$ sehingga

$$\Pr\left(\left|\frac{X_n}{a_n}\right| > \varepsilon\right) < \delta, \quad \forall n \geq N. \quad (2.4.47)$$

Contoh 2.4.27 Misalkan X_1, X_2, \dots adalah barisan variabel acak *i.i.d.* dengan $\mathbb{E}[X_i] = \mu$ dan $\text{Var}(X_i) = \sigma^2 < \infty$. Definisikan rata-rata sampel $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$. Akan ditunjukkan bahwa $\bar{X}_n - \mu = o_p(1)$.

Berdasarkan Hukum Bilangan Besar, berlaku

$$\bar{X}_n \xrightarrow{p} \mu,$$

yang berarti $\bar{X}_n - \mu \xrightarrow{p} 0$. Dengan definisi notasi o_p , hal ini ekuivalen dengan

$$\frac{\bar{X}_n - \mu}{1} \xrightarrow{p} 0,$$

sehingga $\bar{X}_n - \mu = o_p(1)$.

Teorema 2.4.28 Misalkan $\{X_n\}$ dan $\{Y_n\}$ adalah barisan variabel acak, serta $\{a_n\}$ dan $\{b_n\}$ adalah barisan bilangan positif. Berlaku sifat-sifat berikut.

- (a) $\mathcal{O}_p(a_n) + \mathcal{O}_p(b_n) = \mathcal{O}_p(\max\{a_n, b_n\})$.
- (b) $\mathcal{O}_p(a_n) \cdot \mathcal{O}_p(b_n) = \mathcal{O}_p(a_n b_n)$.
- (c) $o_p(a_n) = \mathcal{O}_p(a_n)$, tetapi tidak sebaliknya.
- (d) $o_p(a_n) + \mathcal{O}_p(a_n) = \mathcal{O}_p(a_n)$.
- (e) $o_p(a_n) \cdot \mathcal{O}_p(b_n) = o_p(a_n b_n)$.
- (f) $X_n \xrightarrow{p} c$ jika dan hanya jika $X_n = c + o_p(1)$.
- (g) Jika $X_n \Rightarrow X$ dengan X variabel acak, maka $X_n = \mathcal{O}_p(1)$.

Bukti. Berikut adalah bukti untuk beberapa sifat utama.

- (a) **Penjumlahan:** Misalkan $X_n = \mathcal{O}_p(a_n)$ dan $Y_n = \mathcal{O}_p(b_n)$. Untuk setiap $\varepsilon > 0$, terdapat $M_1, M_2 > 0$ sehingga

$$\Pr(|X_n| > M_1 a_n) < \varepsilon/2, \quad \Pr(|Y_n| > M_2 b_n) < \varepsilon/2.$$

Dengan ketaksamaan segitiga, $|X_n + Y_n| \leq |X_n| + |Y_n|$. Definisikan $c_n =$

$\max\{a_n, b_n\}$ dan $M = M_1 + M_2$. Maka

$$\begin{aligned}\Pr(|X_n + Y_n| > Mc_n) &\leq \Pr(|X_n| + |Y_n| > (M_1 + M_2)c_n) \\ &\leq \Pr(|X_n| > M_1a_n) + \Pr(|Y_n| > M_2b_n) \\ &< \varepsilon/2 + \varepsilon/2 = \varepsilon.\end{aligned}\tag{2.4.48}$$

- (b) **Perkalian:** Misalkan $X_n = \mathcal{O}_p(a_n)$ dan $Y_n = \mathcal{O}_p(b_n)$. Untuk setiap $\varepsilon > 0$, terdapat $M_1, M_2 > 0$ sehingga

$$\Pr(|X_n| > M_1a_n) < \varepsilon/2, \quad \Pr(|Y_n| > M_2b_n) < \varepsilon/2.$$

Perhatikan bahwa

$$\begin{aligned}\Pr(|X_n Y_n| > M_1 M_2 a_n b_n) &\leq \Pr(|X_n| > M_1 a_n) + \Pr(|Y_n| > M_2 b_n) \\ &< \varepsilon.\end{aligned}\tag{2.4.49}$$

- (c) **Relasi o_p dan \mathcal{O}_p :** Jika $X_n = o_p(a_n)$, maka $X_n/a_n \xrightarrow{p} 0$. Untuk setiap $\varepsilon > 0$ dan $M > 0$, terdapat N sehingga untuk $n \geq N$:

$$\Pr(|X_n/a_n| > M) < \varepsilon,$$

yang berarti $X_n = \mathcal{O}_p(a_n)$. Sebaliknya tidak berlaku: $X_n \sim \mathcal{N}(0, 1)$ memenuhi $X_n = \mathcal{O}_p(1)$ tetapi bukan $o_p(1)$.

- (f) **Konvergensi dalam probabilitas:** Jika $X_n \xrightarrow{p} c$, maka $X_n - c \xrightarrow{p} 0$, yang ekuivalen dengan $(X_n - c)/1 \xrightarrow{p} 0$, sehingga $X_n - c = o_p(1)$, atau $X_n = c + o_p(1)$. Sebaliknya juga berlaku.
- (g) **Konvergensi dalam distribusi:** Jika $X_n \Rightarrow X$, maka untuk setiap $\varepsilon > 0$, terdapat M sehingga $\Pr(|X| > M) < \varepsilon/2$. Untuk n cukup besar, $\Pr(|X_n| > M) < \varepsilon$ karena konvergensi dalam distribusi. Dengan demikian, $X_n = \mathcal{O}_p(1)$.



Teorema 2.4.29 Misalkan $\{X_n\}$ adalah barisan variabel acak. Berlaku pernyataan-pernyataan berikut.

- (a) Jika $\mathbb{E}[|X_n|] = \mathcal{O}(a_n)$ (dalam arti deterministik), maka $X_n = \mathcal{O}_p(a_n)$.
- (b) Jika $\mathbb{E}[X_n] = \mu_n$ dan $\text{Var}(X_n) = \mathcal{O}(a_n^2)$, maka $X_n - \mu_n = \mathcal{O}_p(a_n)$.
- (c) Jika $\mathbb{E}[X_n^2] = \mathcal{O}(a_n^2)$, maka $X_n = \mathcal{O}_p(a_n)$.

Bukti. Berikut adalah bukti untuk ketiga pernyataan.

- (a) Andaikan $\mathbb{E}[|X_n|] \leq Ca_n$ untuk suatu konstanta $C > 0$ dan semua n cukup besar. Dengan ketaksamaan Markov, untuk setiap $M > 0$:

$$\Pr(|X_n| > Ma_n) \leq \frac{\mathbb{E}[|X_n|]}{Ma_n} \leq \frac{Ca_n}{Ma_n} = \frac{C}{M}. \quad (2.4.50)$$

Untuk setiap $\varepsilon > 0$, pilih $M = C/\varepsilon$, maka $\Pr(|X_n| > Ma_n) < \varepsilon$. Dengan demikian, $X_n = \mathcal{O}_p(a_n)$.

- (b) Andaikan $\text{Var}(X_n) \leq Ca_n^2$ untuk suatu konstanta $C > 0$. Dengan ketaksamaan Chebyshev, untuk setiap $M > 0$:

$$\Pr(|X_n - \mu_n| > Ma_n) \leq \frac{\text{Var}(X_n)}{M^2 a_n^2} \leq \frac{Ca_n^2}{M^2 a_n^2} = \frac{C}{M^2}. \quad (2.4.51)$$

Untuk setiap $\varepsilon > 0$, pilih $M = \sqrt{C/\varepsilon}$, maka $\Pr(|X_n - \mu_n| > Ma_n) < \varepsilon$. Dengan demikian, $X_n - \mu_n = \mathcal{O}_p(a_n)$.

- (c) Andaikan $\mathbb{E}[X_n^2] \leq Ca_n^2$ untuk suatu konstanta $C > 0$. Dengan ketaksamaan Markov pada X_n^2 :

$$\Pr(|X_n| > Ma_n) = \Pr(X_n^2 > M^2 a_n^2) \leq \frac{\mathbb{E}[X_n^2]}{M^2 a_n^2} \leq \frac{Ca_n^2}{M^2 a_n^2} = \frac{C}{M^2}. \quad (2.4.52)$$

Untuk setiap $\varepsilon > 0$, pilih $M = \sqrt{C/\varepsilon}$, maka $\Pr(|X_n| > Ma_n) < \varepsilon$. Dengan demikian, $X_n = \mathcal{O}_p(a_n)$.



Contoh 2.4.30 Misalkan X_1, X_2, \dots adalah barisan variabel acak *i.i.d.* dengan rata-rata $\mathbb{E}[X_i] = \mu$ dan $\text{Var}(X_i) = \sigma^2 < \infty$. Definisikan rata-rata sampel $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$.

$$\mathbb{E}[\bar{X}_n] = \mu, \quad (2.4.53)$$

$$\text{Var}(\bar{X}_n) = \frac{\sigma^2}{n} = \mathcal{O}(n^{-1}) = \mathcal{O}((n^{-1/2})^2). \quad (2.4.54)$$

Berdasarkan Teorema Dekomposisi Momen bagian (b), diperoleh

$$\bar{X}_n - \mu = \mathcal{O}_p(n^{-1/2}).$$

Teorema 2.4.31 Misalkan $\{X_n\}$ adalah barisan variabel acak. Berlaku pernyataan-pernyataan berikut.

- (a) Jika $\mathbb{E}[|X_n|] = o(a_n)$ (dalam arti deterministik), maka $X_n = o_p(a_n)$.
- (b) Jika $\mathbb{E}[X_n] = o(a_n)$ dan $\text{Var}(X_n) = o(a_n^2)$, maka $X_n = o_p(a_n)$.
- (c) Jika $\mathbb{E}[X_n^2] = o(a_n^2)$, maka $X_n = o_p(a_n)$.

Bukti. Berikut adalah bukti untuk ketiga pernyataan.

- (a) Andaikan $\mathbb{E}[|X_n|]/a_n \rightarrow 0$ ketika $n \rightarrow \infty$. Dengan ketaksamaan Markov, untuk setiap $\varepsilon > 0$:

$$\Pr\left(\left|\frac{X_n}{a_n}\right| > \varepsilon\right) \leq \frac{\mathbb{E}[|X_n|/a_n]}{\varepsilon} = \frac{\mathbb{E}[|X_n|]}{\varepsilon a_n} \rightarrow 0. \quad (2.4.55)$$

Dengan demikian, $X_n/a_n \xrightarrow{p} 0$, sehingga $X_n = o_p(a_n)$.

- (b) Andaikan $\mathbb{E}[X_n] = o(a_n)$ dan $\text{Var}(X_n) = o(a_n^2)$. Maka $\mathbb{E}[X_n]/a_n \rightarrow 0$ dan

$\text{Var}(X_n)/a_n^2 \rightarrow 0$. Dengan ketaksamaan Chebyshev:

$$\Pr \left(\left| \frac{X_n - \mathbb{E}[X_n]}{a_n} \right| > \varepsilon \right) \leq \frac{\text{Var}(X_n)}{\varepsilon^2 a_n^2} \rightarrow 0. \quad (2.4.56)$$

Sehingga $(X_n - \mathbb{E}[X_n])/a_n \xrightarrow{p} 0$. Sebab $\mathbb{E}[X_n]/a_n \rightarrow 0$, maka

$$\frac{X_n}{a_n} = \frac{X_n - \mathbb{E}[X_n]}{a_n} + \frac{\mathbb{E}[X_n]}{a_n} \xrightarrow{p} 0.$$

Dengan demikian, $X_n = o_p(a_n)$.

(c) Andaikan $\mathbb{E}[X_n^2]/a_n^2 \rightarrow 0$. Dengan ketaksamaan Markov:

$$\Pr \left(\left| \frac{X_n}{a_n} \right| > \varepsilon \right) = \Pr \left(\frac{X_n^2}{a_n^2} > \varepsilon^2 \right) \leq \frac{\mathbb{E}[X_n^2]}{\varepsilon^2 a_n^2} \rightarrow 0. \quad (2.4.57)$$

Dengan demikian, $X_n/a_n \xrightarrow{p} 0$, sehingga $X_n = o_p(a_n)$.

■

Contoh 2.4.32 Misalkan $X_n \sim \mathcal{N}(0, 1/n^3)$ untuk $n = 1, 2, \dots$. Akan ditunjukkan bahwa $X_n = o_p(n^{-1})$.

$$\mathbb{E}[X_n^2] = \text{Var}(X_n) = \frac{1}{n^3}. \quad (2.4.58)$$

Perhatikan bahwa

$$\frac{\mathbb{E}[X_n^2]}{(n^{-1})^2} = \frac{1/n^3}{1/n^2} = \frac{1}{n} \rightarrow 0. \quad (2.4.59)$$

Berdasarkan Teorema Dekomposisi o_p bagian (c), diperoleh $X_n = o_p(n^{-1})$.

$$\frac{X_n}{n^{-1}} = nX_n \sim \mathcal{N} \left(0, \frac{n^2}{n^3} \right) = \mathcal{N} \left(0, \frac{1}{n} \right). \quad (2.4.60)$$

Untuk setiap $\varepsilon > 0$:

$$\Pr(|nX_n| > \varepsilon) = 2 \left(1 - \Phi \left(\frac{\varepsilon}{\sqrt{1/n}} \right) \right) = 2 (1 - \Phi(\varepsilon\sqrt{n})) \rightarrow 0 \quad (2.4.61)$$

ketika $n \rightarrow \infty$. Dengan demikian, $nX_n \xrightarrow{p} 0$, sehingga $X_n = o_p(n^{-1})$.

2.4.7 Teorema Limit Pusat

Teorema 2.4.33 (Teorema limit pusat, van der Vaart 1998) Misalkan $\{X_i\}_{i=1}^{\infty}$ adalah barisan variabel acak i.i.d. dengan $\mathbb{E}[X_1] = \mu$ dan $\text{Var}(X_1) = \sigma^2 < \infty$, maka

$$\sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n X_i - \mu \right) \Rightarrow \mathcal{N}(0, \sigma^2). \quad (2.4.62)$$

Bukti. Pembuktian dilakukan dengan menggunakan fungsi karakteristik. Definisikan $Y_i = X_i - \mu$ sehingga $\mathbb{E}[Y_i] = 0$ dan $\text{Var}(Y_i) = \sigma^2$. Selanjutnya, definisikan

$$S_n = \sum_{i=1}^n Y_i = \sum_{i=1}^n (X_i - \mu). \quad (2.4.63)$$

Akan ditunjukkan bahwa $S_n/\sqrt{n\sigma^2} \Rightarrow \mathcal{N}(0, 1)$.

Fungsi karakteristik dari Y_i adalah $\phi_Y(t) = \mathbb{E}[e^{itY_i}]$. Dengan ekspansi Taylor di sekitar $t = 0$, diperoleh

$$\phi_Y(t) = 1 + it\mathbb{E}[Y_i] + \frac{(it)^2}{2}\mathbb{E}[Y_i^2] + o(t^2) = 1 - \frac{t^2\sigma^2}{2} + o(t^2). \quad (2.4.64)$$

Sebab Y_1, Y_2, \dots, Y_n saling independen dan berdistribusi identik, fungsi karakteristik dari $S_n/\sqrt{n\sigma^2}$ adalah

$$\begin{aligned} \phi_{S_n/\sqrt{n\sigma^2}}(t) &= \mathbb{E} \left[\exp \left(\frac{itS_n}{\sqrt{n\sigma^2}} \right) \right] \\ &= \mathbb{E} \left[\exp \left(\sum_{i=1}^n \frac{itY_i}{\sqrt{n\sigma^2}} \right) \right] \\ &= \prod_{i=1}^n \mathbb{E} \left[\exp \left(\frac{itY_i}{\sqrt{n\sigma^2}} \right) \right] \\ &= \left[\phi_Y \left(\frac{t}{\sqrt{n\sigma^2}} \right) \right]^n. \end{aligned} \quad (2.4.65)$$

Dengan substitusi ekspansi Taylor, diperoleh

$$\begin{aligned}\phi_{S_n/\sqrt{n\sigma^2}}(t) &= \left[1 - \frac{1}{2} \cdot \frac{t^2}{n\sigma^2} \cdot \sigma^2 + o\left(\frac{1}{n}\right)\right]^n \\ &= \left[1 - \frac{t^2}{2n} + o\left(\frac{1}{n}\right)\right]^n.\end{aligned}\quad (2.4.66)$$

Dengan mengambil limit $n \rightarrow \infty$ dan menggunakan fakta tentang limit pada fungsi eksponensial bahwa $\lim_{n \rightarrow \infty} \left(1 + \frac{a}{n}\right)^n = e^a$, diperoleh

$$\lim_{n \rightarrow \infty} \phi_{S_n/\sqrt{n\sigma^2}}(t) = \exp\left(-\frac{t^2}{2}\right), \quad (2.4.67)$$

yang merupakan fungsi karakteristik dari distribusi $\mathcal{N}(0, 1)$.

Berdasarkan teorema kontinuitas Lévy, konvergensi fungsi karakteristik mengimplikasikan konvergensi dalam distribusi. Oleh karena itu,

$$\frac{S_n}{\sqrt{n\sigma^2}} = \frac{1}{\sigma\sqrt{n}} \sum_{i=1}^n (X_i - \mu) \Rightarrow \mathcal{N}(0, 1). \quad (2.4.68)$$

Dengan mengalikan kedua ruas dengan σ , diperoleh

$$\sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n X_i - \mu \right) \Rightarrow \mathcal{N}(0, \sigma^2). \quad (2.4.69)$$

■

Teorema Limit Pusat atau *Central Limit Theorem* (CLT) merupakan hasil fundamental yang memungkinkan pendekatan distribusi normal terhadap rata-rata sampel, dan menjadi dasar utama inferensi statistik asimtotik.

Teorema 2.4.34 (Teorema Lindeberg–Lévy, Billingsley 1995) Misalkan $\{X_i\}_{i=1}^{\infty}$ adalah barisan variabel acak i.i.d. dengan $\mathbb{E}[X_i] = \mu$ dan $\text{Var}(X_i) = \sigma^2 < \infty$. Maka

$$\frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1). \quad (2.4.70)$$

Bukti. Teorema Lindeberg–Lévy merupakan kasus khusus dari Teorema Limit Pu-

sat klasik yang telah dibuktikan sebelumnya. Definisikan $Y_i = X_i - \mu$ sehingga $\mathbb{E}[Y_i] = 0$ dan $\text{Var}(Y_i) = \sigma^2$. Dengan menggunakan fungsi karakteristik, ekspansi Taylor dari $\phi_Y(t)$ di sekitar $t = 0$ memberikan

$$\phi_Y(t) = 1 - \frac{t^2 \sigma^2}{2} + o(t^2). \quad (2.4.71)$$

Fungsi karakteristik dari $\frac{1}{\sigma\sqrt{n}} \sum_{i=1}^n Y_i$ adalah

$$\left[\phi_Y \left(\frac{t}{\sigma\sqrt{n}} \right) \right]^n = \left[1 - \frac{t^2}{2n} + o\left(\frac{1}{n}\right) \right]^n \rightarrow e^{-t^2/2} \quad (2.4.72)$$

ketika $n \rightarrow \infty$. Berdasarkan teorema kontinuitas Lévy, konvergensi ini mengimplikasikan konvergensi dalam distribusi ke $\mathcal{N}(0, 1)$. ■

Teorema 2.4.35 (Teorema Lindeberg–Feller, van der Vaart 1998) *Misalkan $\{X_{n,i} : i = 1, \dots, n\}$ adalah triangular array variabel acak independen (tidak harus identik) dengan $\mathbb{E}[X_{n,i}] = 0$ untuk semua n dan i . Definisikan*

$$s_n^2 = \sum_{i=1}^n \text{Var}(X_{n,i}) = \sum_{i=1}^n \sigma_{n,i}^2. \quad (2.4.73)$$

Jika kondisi Lindeberg terpenuhi, yaitu untuk setiap $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} \frac{1}{s_n^2} \sum_{i=1}^n \mathbb{E} \left[X_{n,i}^2 \cdot \mathbf{1}_{\{|X_{n,i}| > \varepsilon s_n\}} \right] = 0, \quad (2.4.74)$$

maka

$$\frac{1}{s_n} \sum_{i=1}^n X_{n,i} \xrightarrow{d} \mathcal{N}(0, 1). \quad (2.4.75)$$

Bukti. Untuk membuktikan konvergensi dalam distribusi, akan menunjukkan bahwa fungsi karakteristik dari $\frac{1}{s_n} \sum_{i=1}^n X_{n,i}$ konvergen ke $e^{-t^2/2}$. Fungsi karakteristik dari $\frac{1}{s_n} \sum_{i=1}^n X_{n,i}$ adalah

$$\phi_n(t) = \mathbb{E} \left[\exp \left(it \frac{1}{s_n} \sum_{j=1}^n X_{n,j} \right) \right]. \quad (2.4.76)$$

Sebab variabel-variabel $X_{n,j}$ independen,

$$\phi_n(t) = \prod_{j=1}^n \mathbb{E} \left[\exp \left(it \frac{X_{n,j}}{s_n} \right) \right] = \prod_{j=1}^n \phi_{n,j} \left(\frac{t}{s_n} \right), \quad (2.4.77)$$

dengan $\phi_{n,j}$ adalah fungsi karakteristik dari $X_{n,j}$. Ekspansi Taylor dari $\phi_{n,j}(u)$ di sekitar $u = 0$ memberikan

$$\phi_{n,j}(u) = 1 + iu\mathbb{E}[X_{n,j}] - \frac{u^2}{2}\mathbb{E}[X_{n,j}^2] + R_{n,j}(u), \quad (2.4.78)$$

dengan $\mathbb{E}[X_{n,j}] = 0$, sehingga

$$\phi_{n,j}(u) = 1 - \frac{u^2 \sigma_{n,j}^2}{2} + R_{n,j}(u), \quad (2.4.79)$$

dengan $R_{n,j}(u)$ adalah suku sisanya yang memenuhi $|R_{n,j}(u)| \leq C|u|^3\mathbb{E}[|X_{n,j}|^3]$ untuk suatu konstanta $C > 0$.

Untuk setiap $\varepsilon > 0$, definisikan

$$X_{n,j}^{(\varepsilon)} := X_{n,j} \mathbf{1}_{\{|X_{n,j}| \leq \varepsilon s_n\}}, \quad (2.4.80)$$

$$X_{n,j}^{(\varepsilon,c)} := X_{n,j} \mathbf{1}_{\{|X_{n,j}| > \varepsilon s_n\}}, \quad (2.4.81)$$

sehingga $X_{n,j} = X_{n,j}^{(\varepsilon)} + X_{n,j}^{(\varepsilon,c)}$. Melalui substitusi $u = t/s_n$ dalam ekspansi Taylor, didapatkan

$$\phi_{n,j} \left(\frac{t}{s_n} \right) = 1 - \frac{t^2 \sigma_{n,j}^2}{2s_n^2} + R_{n,j} \left(\frac{t}{s_n} \right). \quad (2.4.82)$$

Logaritma dari fungsi karakteristik $\phi_n(t)$ tersebut adalah

$$\begin{aligned} \log \phi_n(t) &= \sum_{j=1}^n \log \phi_{n,j} \left(\frac{t}{s_n} \right) \\ &= \sum_{j=1}^n \log \left(1 - \frac{t^2 \sigma_{n,j}^2}{2s_n^2} + R_{n,j} \left(\frac{t}{s_n} \right) \right). \end{aligned} \quad (2.4.83)$$

Dengan menggunakan aproksimasi $\log(1+x) \approx x - \frac{x^2}{2}$ untuk $|x|$ kecil, didapatkan

$$\begin{aligned} \log \phi_n(t) &= \sum_{j=1}^n \left(-\frac{t^2 \sigma_{n,j}^2}{2s_n^2} + R_{n,j} \left(\frac{t}{s_n} \right) \right) + O \left(\sum_{j=1}^n \left| \frac{t^2 \sigma_{n,j}^2}{2s_n^2} \right|^2 \right) \\ &= -\frac{t^2}{2s_n^2} \sum_{j=1}^n \sigma_{n,j}^2 + \sum_{j=1}^n R_{n,j} \left(\frac{t}{s_n} \right) + O \left(\frac{t^4}{s_n^4} \sum_{j=1}^n \sigma_{n,j}^4 \right) \\ &= -\frac{t^2}{2} + \sum_{j=1}^n R_{n,j} \left(\frac{t}{s_n} \right) + O \left(\frac{t^4}{s_n^4} \sum_{j=1}^n \sigma_{n,j}^4 \right). \end{aligned} \quad (2.4.84)$$

Untuk melengkapi bukti, perlu juga ditunjukkan bahwa

$$\sum_{j=1}^n R_{n,j} \left(\frac{t}{s_n} \right) \rightarrow 0 \quad \text{saat } n \rightarrow \infty. \quad (2.4.85)$$

Suku sisa $R_{n,j}(u)$ dapat diperkirakan sebagai berikut. Dengan kondisi Lindeberg, untuk setiap $\varepsilon > 0$,

$$\begin{aligned} \left| \sum_{j=1}^n R_{n,j} \left(\frac{t}{s_n} \right) \right| &\leq \sum_{j=1}^n C \left| \frac{t}{s_n} \right|^3 \mathbb{E}[|X_{n,j}|^3] \\ &= C \frac{|t|^3}{s_n^3} \sum_{j=1}^n \mathbb{E}[|X_{n,j}|^3]. \end{aligned} \quad (2.4.86)$$

Momen ketiga dapat didekomposisi menggunakan fungsi indikator Lindeberg:

$$\mathbb{E}[|X_{n,j}|^3] = \mathbb{E}[|X_{n,j}|^3 \mathbf{1}_{\{|X_{n,j}| \leq \varepsilon s_n\}}] + \mathbb{E}[|X_{n,j}|^3 \mathbf{1}_{\{|X_{n,j}| > \varepsilon s_n\}}]. \quad (2.4.87)$$

Suku pertama dibatasi oleh $(\varepsilon s_n)^3$ dikalikan dengan probabilitas, yang terbatas. Suku kedua dapat dikendalikan melalui kondisi Lindeberg, yaitu untuk setiap $\varepsilon > 0$,

$$\sum_{j=1}^n \mathbb{E}[|X_{n,j}|^3 \mathbf{1}_{\{|X_{n,j}| > \varepsilon s_n\}}] \leq \frac{1}{\varepsilon s_n} \sum_{j=1}^n \mathbb{E}[X_{n,j}^2 \mathbf{1}_{\{|X_{n,j}| > \varepsilon s_n\}}] \rightarrow 0 \quad (2.4.88)$$

berdasarkan kondisi Lindeberg.

Asumsi yang masuk akal adalah $s_n \rightarrow \infty$ dan $\max_j \sigma_{n,j}/s_n \rightarrow 0$ (sehingga

tidak ada satu variabel yang mendominasi). Dengan ini,

$$\frac{|t|^3}{s_n^3} \sum_{j=1}^n \mathbb{E}[|X_{n,j}|^3] \rightarrow 0. \quad (2.4.89)$$

Oleh karena itu, $\log \phi_n(t) \rightarrow -\frac{t^2}{2}$, sehingga $\phi_n(t) \rightarrow e^{-t^2/2}$. Berdasarkan teorema kontinuitas Lévy,

$$\frac{1}{s_n} \sum_{i=1}^n X_{n,i} \xrightarrow{d} \mathcal{N}(0, 1). \quad (2.4.90)$$

■

Contoh 2.4.36 Misalkan $X_{n,i} = Y_i/\sqrt{n}$ untuk $i = 1, \dots, n$, dengan Y_i adalah variabel acak *i.i.d.* dengan $\mathbb{E}[Y_i] = 0$ dan $\text{Var}(Y_i) = \sigma^2 < \infty$. Maka $\mathbb{E}[X_{n,i}] = 0$ dan $\text{Var}(X_{n,i}) = \sigma^2/n$, sehingga $s_n^2 = \sigma^2$.

Kondisi Lindeberg dapat diperiksa sebagai berikut. Untuk setiap $\varepsilon > 0$,

$$\begin{aligned} \frac{1}{s_n^2} \sum_{i=1}^n \mathbb{E}[X_{n,i}^2 \cdot \mathbf{1}_{\{|X_{n,i}| > \varepsilon s_n\}}] &= \frac{1}{\sigma^2} \sum_{i=1}^n \mathbb{E}\left[\frac{Y_i^2}{n} \cdot \mathbf{1}_{\{|Y_i| > \varepsilon \sigma \sqrt{n}\}}\right] \\ &= \frac{1}{\sigma^2} \mathbb{E}[Y_1^2 \cdot \mathbf{1}_{\{|Y_1| > \varepsilon \sigma \sqrt{n}\}}]. \end{aligned} \quad (2.4.91)$$

Sebab $\mathbb{E}[Y_1^2] = \sigma^2 < \infty$, maka $\mathbb{E}[Y_1^2 \cdot \mathbf{1}_{\{|Y_1| > \varepsilon \sigma \sqrt{n}\}}] \rightarrow 0$ ketika $n \rightarrow \infty$ berdasarkan teorema konvergensi terdominasi. Dengan demikian, kondisi Lindeberg terpenuhi dan Teorema Lindeberg–Feller berlaku.

Dalam banyak aplikasi statistik, khususnya estimator berbobot dan estimator lokal, observasi tidak lagi identik terdistribusi. Hal ini memotivasi penggunaan CLT untuk *triangular arrays*. *Triangular arrays* adalah kumpulan variabel acak yang disusun dalam bentuk segitiga, dengan setiap baris dapat memiliki distribusi yang berbeda.

Teorema 2.4.37 Misalkan $\{X_{n,i} : i = 1, \dots, n\}$ adalah *triangular array* variabel

acak dengan $\mathbb{E}[X_{n,i}] = 0$ dan varians total

$$\sum_{i=1}^n \text{Var}(X_{n,i}) \rightarrow \sigma^2. \quad (2.4.92)$$

Jika kondisi Lindeberg terpenuhi, maka

$$\sum_{i=1}^n X_{n,i} \Rightarrow \mathcal{N}(0, \sigma^2). \quad (2.4.93)$$

Bukti. Definisikan $s_n^2 = \sum_{i=1}^n \text{Var}(X_{n,i}) \rightarrow \sigma^2$ dan $Y_{n,i} = X_{n,i}/s_n$ sehingga $\sum_{i=1}^n \text{Var}(Y_{n,i}) = 1$. Akan ditunjukkan bahwa $\sum_{i=1}^n Y_{n,i} \Rightarrow \mathcal{N}(0, 1)$.

Dengan teorema Lindeberg–Feller, jika kondisi Lindeberg terpenuhi untuk $\{Y_{n,i}\}$, maka $\sum_{i=1}^n Y_{n,i} \Rightarrow \mathcal{N}(0, 1)$. Kondisi Lindeberg untuk $\{X_{n,i}\}$ menyatakan bahwa untuk setiap $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} \frac{1}{s_n^2} \sum_{i=1}^n \mathbb{E}[X_{n,i}^2 \mathbf{1}_{\{|X_{n,i}| > \varepsilon s_n\}}] = 0. \quad (2.4.94)$$

Untuk $Y_{n,i} = X_{n,i}/s_n$, kondisi Lindeberg menjadi: untuk setiap $\varepsilon > 0$,

$$\begin{aligned} \lim_{n \rightarrow \infty} \sum_{i=1}^n \mathbb{E}[Y_{n,i}^2 \mathbf{1}_{\{|Y_{n,i}| > \varepsilon\}}] &= \lim_{n \rightarrow \infty} \sum_{i=1}^n \mathbb{E}\left[\frac{X_{n,i}^2}{s_n^2} \mathbf{1}_{\left\{\frac{|X_{n,i}|}{s_n} > \varepsilon\right\}}\right] \\ &= \lim_{n \rightarrow \infty} \frac{1}{s_n^2} \sum_{i=1}^n \mathbb{E}[X_{n,i}^2 \mathbf{1}_{\{|X_{n,i}| > \varepsilon s_n\}}] = 0. \end{aligned} \quad (2.4.95)$$

Dengan demikian, kondisi Lindeberg untuk $\{X_{n,i}\}$ juga terpenuhi untuk $\{Y_{n,i}\}$.

Berdasarkan teorema Lindeberg–Feller,

$$\sum_{i=1}^n Y_{n,i} \Rightarrow \mathcal{N}(0, 1). \quad (2.4.96)$$

Dengan transformasi balik, $\sum_{i=1}^n Y_{n,i} = \frac{1}{s_n} \sum_{i=1}^n X_{n,i}$, sehingga

$$\frac{1}{s_n} \sum_{i=1}^n X_{n,i} \Rightarrow \mathcal{N}(0, 1). \quad (2.4.97)$$

Mengalikan kedua ruas dengan s_n , dan menggunakan fakta bahwa $s_n^2 \rightarrow \sigma^2$, diperoleh

$$\sum_{i=1}^n X_{n,i} \Rightarrow \mathcal{N}(0, \sigma^2), \quad (2.4.98)$$

karena jika $Z_n \Rightarrow \mathcal{N}(0, 1)$ dan $a_n \rightarrow a > 0$, maka $a_n Z_n \Rightarrow \mathcal{N}(0, a^2)$. ■

Hasil ini sangat relevan untuk analisis asimtotik estimator lokal, apabila kontribusi masing-masing observasi bergantung pada n .

2.4.8 Metode Delta

Dalam banyak aplikasi statistik, sering kali diperlukan distribusi asimtotik dari suatu fungsi transformasi estimator, bukan hanya distribusi estimator itu sendiri. Sebagai contoh, jika $\hat{\theta}_n$ adalah estimator untuk parameter θ dan diperlukan inferensi terhadap $g(\theta)$ untuk suatu fungsi g , maka perlu diketahui distribusi asimtotik dari $g(\hat{\theta}_n)$. Metode Delta menyediakan alat yang elegan untuk menurunkan distribusi limit dari transformasi halus suatu estimator yang asimtotik normal. Metode ini memanfaatkan ekspansi Taylor orde pertama untuk mengaproksimasi fungsi nonlinear secara lokal sebagai fungsi linear, sehingga sifat normalitas asimtotik dapat dipertahankan melalui transformasi.

Teorema 2.4.38 (Metode Δ , van der Vaart 1998) *Misalkan*

$$\sqrt{n}(\hat{\theta}_n - \theta) \Rightarrow \mathcal{N}(0, \Sigma), \quad (2.4.99)$$

dan g adalah fungsi terdiferensialkan di θ , maka

$$\sqrt{n}(g(\hat{\theta}_n) - g(\theta)) \Rightarrow \mathcal{N}(0, g'(\theta)\Sigma g'(\theta)^\top). \quad (2.4.100)$$

Bukti. Dengan menggunakan ekspansi Taylor orde pertama dari g di sekitar θ , diperoleh

$$g(\hat{\theta}_n) = g(\theta) + g'(\theta)(\hat{\theta}_n - \theta) + o(|\hat{\theta}_n - \theta|). \quad (2.4.101)$$

Sebab $\hat{\theta}_n \xrightarrow{p} \theta$, suku sisa $o(|\hat{\theta}_n - \theta|)$ memenuhi

$$\frac{o(|\hat{\theta}_n - \theta|)}{|\hat{\theta}_n - \theta|} \xrightarrow{p} 0. \quad (2.4.102)$$

Dengan mengalikan kedua ruas ekspansi Taylor dengan \sqrt{n} , diperoleh

$$\sqrt{n}(g(\hat{\theta}_n) - g(\theta)) = g'(\theta) \cdot \sqrt{n}(\hat{\theta}_n - \theta) + \sqrt{n} \cdot o(|\hat{\theta}_n - \theta|). \quad (2.4.103)$$

Perhatikan bahwa $\sqrt{n} \cdot o(|\hat{\theta}_n - \theta|) = o_p(1)$ karena $\sqrt{n}(\hat{\theta}_n - \theta) = \mathcal{O}_p(1)$ berdasarkan konvergensi dalam distribusi ke normal. Dengan demikian,

$$\sqrt{n}(g(\hat{\theta}_n) - g(\theta)) = g'(\theta) \cdot \sqrt{n}(\hat{\theta}_n - \theta) + o_p(1). \quad (2.4.104)$$

Berdasarkan teorema Slutsky, sebab $\sqrt{n}(\hat{\theta}_n - \theta) \Rightarrow \mathcal{N}(0, \Sigma)$ dan $o_p(1) \xrightarrow{p} 0$, maka

$$\sqrt{n}(g(\hat{\theta}_n) - g(\theta)) \Rightarrow g'(\theta) \cdot \mathcal{N}(0, \Sigma) = \mathcal{N}(0, g'(\theta)\Sigma g'(\theta)^\top). \quad (2.4.105)$$

Kesamaan terakhir mengikuti dari sifat transformasi linear variabel acak normal: jika $Z \sim \mathcal{N}(0, \Sigma)$, maka $AZ \sim \mathcal{N}(0, A\Sigma A^\top)$ untuk matriks $A = g'(\theta)$. ■

Contoh 2.4.39 Misalkan X_1, X_2, \dots, X_n adalah sampel acak *i.i.d.* dari distribusi dengan rata-rata $\mu > 0$ dan variansi σ^2 . Akan dicari distribusi asimtotik dari $\log(\bar{X}_n)$.

Berdasarkan Teorema Limit Pusat, $\sqrt{n}(\bar{X}_n - \mu) \Rightarrow \mathcal{N}(0, \sigma^2)$. Dengan $g(x) = \log(x)$ dan $g'(x) = 1/x$, metode Delta memberikan

$$\sqrt{n}(\log(\bar{X}_n) - \log(\mu)) \Rightarrow \mathcal{N}\left(0, \frac{\sigma^2}{\mu^2}\right). \quad (2.4.106)$$

Dengan demikian, $\log(\bar{X}_n)$ adalah asimtotik normal dengan rata-rata $\log(\mu)$ dan variansi asimtotik $\sigma^2/(n\mu^2)$.

2.5 Analisis Regresi Linear

Analisis regresi merupakan suatu teknik statistik untuk menginvestigasi dan memodelkan hubungan antarvariabel. Aplikasi dari analisis regresi sangat luas dan digunakan dalam hampir semua bidang, seperti teknik atau *engineering*, ilmu fisika dan kimia, ekonomi, manajemen, ilmu biologi, dan sosiologi. Dalam analisis regresi, variabel respons atau variabel dependen (dinotasikan dengan variabel acak Y) dimodelkan dengan fungsi dalam variabel penjelas atau variabel independen (dinotasikan dengan variabel acak X). (Montgomery, Peck, dan Vining, 2012)

2.5.1 Regresi Linear Biasa atau *Ordinary Least Squares* (OLS)

Analisis regresi linear memodelkan hubungan antarvariabel dengan fungsi linear. Apabila terdapat satu variabel prediktor maka model yang terbentuk disebut sebagai regresi linear sederhana, sedangkan apabila terdapat lebih dari satu variabel prediktor maka model yang terbentuk disebut sebagai regresi linear berganda.

Definisi 2.5.1 (Regresi Linear Sederhana, Montgomery dkk. 2012) *Model regresi linear sederhana merupakan model dengan satu variabel penjelas X yang mempunyai hubungan garis lurus terhadap satu respons Y . Model ini dirumuskan dengan*

$$\mathbf{y} = \beta_0 + \beta_1 \mathbf{x} + \boldsymbol{\varepsilon}, \quad (2.5.1)$$

dengan intersep β_0 dan koefisien β_1 merupakan konstanta yang tidak diketahui, serta $\boldsymbol{\varepsilon}$ adalah vektor galat acak. \mathbf{y} dan \mathbf{x} berturut-turut adalah vektor acak Y dan X . Parameter β_0 dan β_1 biasa disebut sebagai koefisien-koefisien regresi.

Definisi 2.5.2 (Regresi Linear Berganda, Montgomery dkk. 2012) *Regresi linear berganda merupakan model regresi yang memiliki lebih dari satu variabel independen. Model ini merupakan generalisasi dari regresi linear sederhana. Vektor respons \mathbf{y} mungkin memiliki hubungan dengan p -buah variabel penjelas, yaitu matriks acak \mathbf{X} yang dibentuk atas p -buah vektor acak $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_p$, sehingga*

$$\mathbf{y} = \beta_0 + \beta_1 \mathbf{x}_1 + \beta_2 \mathbf{x}_2 + \dots + \beta_p \mathbf{x}_p + \boldsymbol{\varepsilon}. \quad (2.5.2)$$

Model di atas dapat dituliskan dalam notasi matriks dan vektor, yaitu

$$\begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix} = \begin{pmatrix} 1 & X_{11} & X_{12} & \cdots & X_{1p} \\ 1 & X_{21} & X_{22} & \cdots & X_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n1} & X_{n2} & \cdots & X_{np} \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix} + \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}, \quad (2.5.3)$$

atau

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}. \quad (2.5.4)$$

Model OLS mengasumsikan bahwa galat memiliki rata-rata nol dan variansi konstan σ^2 yang tidak diketahui nilainya. Lebih lanjut, model ini juga mengasumsikan bahwa komponen galat tidak memiliki autokorelasi yang berarti bahwa nilai dari suatu galat tidak bergantung pada galat lainnya. Dengan kata lain $\varepsilon \stackrel{\text{i.i.d}}{\sim} \mathcal{N}(0, \sigma^2)$, untuk suatu σ^2 yang bersifat konstan.

Model regresi linear memandang vektor acak \mathbf{y} sebagai fungsi dari matriks acak \mathbf{X} . Oleh karena itu, rata-rata dari distribusi \mathbf{y} dapat dituliskan sebagai

$$\mathbb{E}[\mathbf{y} \mid \mathbf{X}] = \mathbb{E}[\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}] = \mathbf{X}\boldsymbol{\beta} \quad (2.5.5)$$

dan variansinya

$$\text{Var}(\mathbf{y} \mid \mathbf{X}) = \text{Var}(\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}_n, \quad (2.5.6)$$

karena $\mathbb{E}[\boldsymbol{\varepsilon}] = \mathbf{0}$ dan $\text{Var}(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}_n$. Oleh karena itu, rata-rata dari \mathbf{y} adalah fungsi linear dari \mathbf{X} meskipun variansinya tidak bergantung pada nilai \mathbf{X} .

Model regresi linear klasik didasarkan pada sejumlah asumsi yang dikenal sebagai asumsi Gauss–Markov. Asumsi-asumsi ini diperlukan agar penduga OLS memiliki sifat optimal sebagai *best linear unbiased estimator* (BLUE). Asumsi-asumsi tersebut adalah sebagai berikut (Wooldridge, 2020).

Asumsi OLS.1 (Linear dalam parameter) Diberikan sampel data $\{(\mathbf{y}_i, \mathbf{x}_i) : i =$

$1, \dots, n\}$, model populasi regresi linear dinyatakan sebagai

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad (2.5.7)$$

dengan \mathbf{y} adalah vektor respons, \mathbf{X} adalah matriks desain yang terdiri dari variabel penjelas, $\boldsymbol{\beta}$ adalah vektor parameter yang tidak diketahui, dan $\boldsymbol{\varepsilon}$ adalah vektor galat acak.

Asumsi OLS.2 (Pengambilan sampel acak dan independen) Sampel data $\{(\mathbf{y}_i, \mathbf{x}_i) : i = 1, \dots, n\}$ diambil secara acak dan independen dari populasi.

Asumsi OLS.3 (Rank penuh dari matriks desain) Matriks desain \mathbf{X} memiliki rank penuh, yaitu $\text{rank}(\mathbf{X}) = p$, sehingga matriks $\mathbf{X}^\top \mathbf{X}$ nonsingular. Dengan kata lain, tidak ada kolinearitas sempurna di antara variabel penjelas.

Asumsi OLS.4 (Eksogenitas) Nilai tengah galat bersyarat pada \mathbf{X} adalah nol, yaitu

$$\mathbb{E}[\boldsymbol{\varepsilon} \mid \mathbf{X}] = \mathbf{0}. \quad (2.5.8)$$

Asumsi eksogenitas memberikan akibat sebagai berikut.

Akibat 2.5.3 Di bawah asumsi OLS.1 hingga OLS.4, didapatkan

$$\mathbb{E}[\mathbf{X}^\top \boldsymbol{\varepsilon}] = \mathbf{0}. \quad (2.5.9)$$

Bukti. Dengan menggunakan hukum iterasi ekspektasi, diperoleh

$$\mathbb{E}[\mathbf{X}^\top \boldsymbol{\varepsilon}] = \mathbb{E}[\mathbb{E}[\mathbf{X}^\top \boldsymbol{\varepsilon} \mid \mathbf{X}]] = \mathbb{E}[\mathbf{X}^\top \mathbb{E}[\boldsymbol{\varepsilon} \mid \mathbf{X}]] = \mathbb{E}[\mathbf{X}^\top \mathbf{0}] = \mathbf{0}. \quad (2.5.10)$$

■

Asumsi OLS.5 (Homoskedastisitas) Ragam galat bersyarat pada \mathbf{X} adalah konstan, yaitu

$$\text{Var}(\boldsymbol{\varepsilon} \mid \mathbf{X}) = \sigma^2 \mathbf{I}_n, \quad (2.5.11)$$

dengan σ^2 adalah konstanta positif.

Asumsi OLS.1 hingga OLS.5 dikenal sebagai asumsi Gauss–Markov.

Asumsi OLS.6 (Normalitas galat) Galat populasi ε bersifat independen dan terdistribusi normal, yaitu

$$\varepsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_n). \quad (2.5.12)$$

Asumsi OLS.6 tidak termasuk dalam asumsi Gauss–Markov, tetapi sering digunakan untuk tujuan inferensi statistik, seperti pengujian hipotesis dan pembuatan interval kepercayaan. Asumsi OLS.1 hingga OLS.6 membentuk dasar dari model regresi linear klasik atau *classical linear model* (CLM).

Estimasi parameter dalam regresi linear dilakukan dengan metode kuadrat terkecil atau *ordinary least squares* (OLS). Prinsip dasarnya adalah mencari nilai β yang meminimumkan jumlah kuadrat galat

$$S(\beta) = (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta). \quad (2.5.13)$$

Perhatikan bahwa fungsi kuadrat terkecil dari persamaan di atas dapat dituliskan sebagai

$$S(\beta) = (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta) = \mathbf{y}^\top \mathbf{y} - 2\beta^\top \mathbf{X}^\top \mathbf{y} + \beta^\top \mathbf{X}^\top \mathbf{X}\beta. \quad (2.5.14)$$

Dengan diferensial matriks, gradien terhadap β adalah

$$\nabla_\beta S(\beta) = -2\mathbf{X}^\top \mathbf{y} + 2\mathbf{X}^\top \mathbf{X}\beta. \quad (2.5.15)$$

Syarat orde pertama meminimumkan S adalah $\nabla_\beta S(\beta) = \mathbf{0}$, sehingga diperoleh

$$\mathbf{X}^\top \mathbf{X}\hat{\beta} = \mathbf{X}^\top \mathbf{y}, \quad (2.5.16)$$

yang disebut persamaan normal. Selanjutnya, matriks Hessian atau orde kedua ada-

lah

$$\nabla_{\beta}^2 S(\beta) = 2 \mathbf{X}^\top \mathbf{X} \succeq \mathbf{0}, \quad (2.5.17)$$

sehingga S konveks dalam β . Jika $\mathbf{X}^\top \mathbf{X}$ non-singular atau setara $\text{rank}(\mathbf{X}) = p$, maka Hessian definit positif dan solusi orde pertama unik serta memberikan minimum global.

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}. \quad (2.5.18)$$

Jika $\mathbf{X}^\top \mathbf{X}$ singular, himpunan peminimum tidak tunggal. Salah satu solusi adalah solusi *norma-minimum* $\hat{\beta} = \mathbf{X}^+ \mathbf{y}$ dengan \mathbf{X}^+ merupakan *Moore–Penrose pseudo-inverse*.

Teorema 2.5.4 (Teorema Gauss–Markov, Wooldridge 2020) *Di bawah asumsi OLS.1 hingga OLS.5, penduga OLS $\hat{\beta}$ bersifat tak bias, yaitu $\mathbb{E}[\hat{\beta}] = \beta$, dan memiliki kovariansi*

$$\text{Var}(\hat{\beta}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}. \quad (2.5.19)$$

Selain itu, $\hat{\beta}$ merupakan best linear unbiased estimator (BLUE), artinya $\hat{\beta}$ memiliki variansi terkecil di antara semua penduga linear tak bias.

Bukti. Penduga OLS dapat dituliskan sebagai

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}. \quad (2.5.20)$$

Substitusi $\mathbf{y} = \mathbf{X}\beta + \epsilon$ menghasilkan

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{X}\beta + \epsilon) = \beta + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \epsilon, \quad (2.5.21)$$

sehingga rata-rata dari $\hat{\beta}$ adalah

$$\mathbb{E}[\hat{\beta}] = \beta + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbb{E}[\epsilon] = \beta, \quad (2.5.22)$$

yang menunjukkan bahwa $\hat{\beta}$ tak bias. Kovariansnya diperoleh dari

$$\text{Var}(\hat{\beta}) = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \text{Var}(\epsilon) \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}. \quad (2.5.23)$$

Untuk sifat BLUE, dipertimbangkan penduga linear tak bias umum $\tilde{\beta} = \mathbf{C}\mathbf{y}$ dengan $\mathbf{C}\mathbf{X} = \mathbf{I}$. Variansi dari $\tilde{\beta}$ adalah

$$\text{Var}(\tilde{\beta}) = \mathbf{C}\sigma^2\mathbf{I}\mathbf{C}^\top = \sigma^2\mathbf{C}\mathbf{C}^\top. \quad (2.5.24)$$

Melalui dekomposisi $\mathbf{C} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top + \mathbf{D}$ dengan $\mathbf{D}\mathbf{X} = \mathbf{0}$, diperoleh

$$\text{Var}(\tilde{\beta}) = \sigma^2(\mathbf{X}^\top\mathbf{X})^{-1} + \sigma^2\mathbf{D}\mathbf{D}^\top \succeq \text{Var}(\hat{\beta}), \quad (2.5.25)$$

yang membuktikan bahwa $\hat{\beta}$ memiliki variansi minimum di antara semua penduga linear tak bias. ■

Teorema 2.5.5 *Jika asumsi normalitas galat terpenuhi, maka penduga kemungkinan maksimum atau maximum likelihood estimation (MLE) untuk β identik dengan penduga kuadrat terkecil (OLS), yaitu*

$$\hat{\beta}_{MLE} = \hat{\beta}_{OLS} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}. \quad (2.5.26)$$

Penduga MLE untuk varians galat adalah

$$\hat{\sigma}^2 = \frac{1}{n}(\mathbf{y} - \mathbf{X}\hat{\beta})^\top(\mathbf{y} - \mathbf{X}\hat{\beta}). \quad (2.5.27)$$

Bukti. Dengan asumsi $\epsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2\mathbf{I})$, fungsi *likelihood* untuk β dan σ^2 adalah

$$L(\beta, \sigma^2 \mid \mathbf{y}) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{1}{2\sigma^2}(\mathbf{y} - \mathbf{X}\beta)^\top(\mathbf{y} - \mathbf{X}\beta)\right), \quad (2.5.28)$$

yang memiliki *log-likelihood*

$$\ell(\beta, \sigma^2) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2}(\mathbf{y} - \mathbf{X}\beta)^\top(\mathbf{y} - \mathbf{X}\beta). \quad (2.5.29)$$

Maksimisasi terhadap β dengan turunan pertama didapatkan

$$\begin{aligned}
 \frac{\partial \ell(\beta, \sigma^2)}{\partial \beta} &= \frac{2\mathbf{X}^\top}{2\sigma^2}(\mathbf{y} - \mathbf{X}\beta) \\
 &= \frac{1}{\sigma^2}\mathbf{X}^\top \mathbf{y} - \frac{1}{\sigma^2}\mathbf{X}^\top \mathbf{X}\beta \\
 \mathbf{0} &= \mathbf{X}^\top \mathbf{y} - \mathbf{X}^\top \mathbf{X}\hat{\beta} \\
 \mathbf{X}^\top \mathbf{X}\hat{\beta} &= \mathbf{X}^\top \mathbf{y} \\
 \hat{\beta} &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.
 \end{aligned} \tag{2.5.30}$$

Perhatikan bahwa turunan kedua terhadap β menghasilkan $-\frac{1}{\sigma^2}(\mathbf{X}^\top \mathbf{X})$. Sebab $\mathbf{X}^\top \mathbf{X} \succeq 0$, maka $\frac{\partial^2 \ell}{\partial \beta \partial \beta^\top} \preceq 0$ yang menjadikan $\hat{\beta}$ memaksimumkan fungsi log-likelihood. Oleh karena itu

$$\hat{\beta}_{\text{MLE}} = \hat{\beta}_{\text{OLS}}. \tag{2.5.31}$$

Selanjutnya, turunan pertama ℓ terhadap σ^2 akan menghasilkan

$$\begin{aligned}
 \frac{\partial \ell(\beta, \sigma^2)}{\partial \sigma^2} &= -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4}(\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta) \\
 0 &= -n\hat{\sigma}^2 + (\mathbf{y} - \mathbf{X}\hat{\beta})^\top (\mathbf{y} - \mathbf{X}\hat{\beta}) \\
 \hat{\sigma}^2 &= \frac{1}{n}(\mathbf{y} - \mathbf{X}\hat{\beta})^\top (\mathbf{y} - \mathbf{X}\hat{\beta}).
 \end{aligned} \tag{2.5.32}$$

■

2.5.2 Teori Asimtotik untuk OLS

Teori asimtotik mempelajari perilaku penduga OLS ketika ukuran sampel n menuju tak hingga. Hasil-hasil asimtotik sangat penting karena memberikan justifikasi teoritis untuk inferensi statistik pada sampel besar, bahkan ketika asumsi normalitas galat tidak terpenuhi.

Teorema 2.5.6 (Wooldridge, 2020) *Di bawah asumsi OLS.1 hingga OLS.4, penduga OLS $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ bersifat konsisten, yaitu*

$$\hat{\beta} \xrightarrow{p} \beta, \tag{2.5.33}$$

dengan kondisi tambahan berupa $\text{plim}_{n \rightarrow \infty} \frac{1}{n} \mathbf{X}^\top \mathbf{X} = \mathbf{Q}$ untuk suatu matriks \mathbf{Q} yang definit positif.

Bukti. Penduga OLS dapat dituliskan sebagai

$$\begin{aligned}\hat{\beta} &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} \\ &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{X}\beta + \varepsilon) \\ &= \beta + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \varepsilon \\ &= \beta + \left(\frac{1}{n} \mathbf{X}^\top \mathbf{X} \right)^{-1} \left(\frac{1}{n} \mathbf{X}^\top \varepsilon \right).\end{aligned}\quad (2.5.34)$$

Berdasarkan kondisi tambahan, $\frac{1}{n} \mathbf{X}^\top \mathbf{X} \xrightarrow{p} \mathbf{Q}$ dengan \mathbf{Q} definit positif. Dengan teorema pemetaan kontinu, $\left(\frac{1}{n} \mathbf{X}^\top \mathbf{X} \right)^{-1} \xrightarrow{p} \mathbf{Q}^{-1}$. Selanjutnya, perlu ditunjukkan bahwa $\frac{1}{n} \mathbf{X}^\top \varepsilon \xrightarrow{p} \mathbf{0}$. Perhatikan bahwa

$$\frac{1}{n} \mathbf{X}^\top \varepsilon = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \varepsilon_i. \quad (2.5.35)$$

Sebab $\mathbb{E}[\mathbf{x}_i \varepsilon_i] = \mathbb{E}[\mathbb{E}[\mathbf{x}_i \varepsilon_i \mid \mathbf{X}]] = \mathbb{E}[\mathbf{x}_i \mathbb{E}[\varepsilon_i \mid \mathbf{X}]] = \mathbf{0}$, Hukum Bilangan Besar menjamin bahwa $\frac{1}{n} \mathbf{X}^\top \varepsilon \xrightarrow{p} \mathbf{0}$.

Dengan teorema Slutsky, diperoleh

$$\hat{\beta} - \beta = \left(\frac{1}{n} \mathbf{X}^\top \mathbf{X} \right)^{-1} \left(\frac{1}{n} \mathbf{X}^\top \varepsilon \right) \xrightarrow{p} \mathbf{Q}^{-1} \cdot \mathbf{0} = \mathbf{0}, \quad (2.5.36)$$

sehingga $\hat{\beta} \xrightarrow{p} \beta$. ■

Teorema 2.5.7 Di bawah kondisi-kondisi Teorema konsistensi OLS dan dengan tambahan asumsi OLS.5, penduga variansi

$$s^2 = \frac{1}{n-p-1} (\mathbf{y} - \mathbf{X}\hat{\beta})^\top (\mathbf{y} - \mathbf{X}\hat{\beta}) = \frac{1}{n-p-1} \sum_{i=1}^n \hat{\varepsilon}_i^2 \quad (2.5.37)$$

bersifat konsisten, yaitu $s^2 \xrightarrow{p} \sigma^2$.

Bukti. Definisikan residual $\hat{\varepsilon} = \mathbf{y} - \mathbf{X}\hat{\beta} = \mathbf{M}\mathbf{y}$ dengan $\mathbf{M} = \mathbf{I} - \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$

adalah matriks proyeksi idempoten, maka

$$\hat{\epsilon} = \mathbf{M}(\mathbf{X}\beta + \epsilon) = \mathbf{M}\epsilon, \quad (2.5.38)$$

sebab $\mathbf{MX} = \mathbf{0}$. Oleh karena itu,

$$\hat{\epsilon}^\top \hat{\epsilon} = \epsilon^\top \mathbf{M}^\top \mathbf{M} \epsilon = \epsilon^\top \mathbf{M} \epsilon. \quad (2.5.39)$$

Dengan menggunakan sifat jejak dan ekspektasi, dapat ditunjukkan bahwa

$$\begin{aligned} \mathbb{E}[\hat{\epsilon}^\top \hat{\epsilon}] &= \mathbb{E}[\text{tr}(\epsilon^\top \mathbf{M} \epsilon)] \\ &= \mathbb{E}[\text{tr}(\mathbf{M} \epsilon \epsilon^\top)] \\ &= \text{tr}(\mathbf{M} \mathbb{E}[\epsilon \epsilon^\top]) \\ &= \sigma^2 \text{tr}(\mathbf{M}) \end{aligned} \quad (2.5.40)$$

$$= \sigma^2(n - p - 1). \quad (2.5.41)$$

Dengan Hukum Bilangan Besar, $\frac{1}{n} \hat{\epsilon}^\top \hat{\epsilon} \xrightarrow{p} \sigma^2$. Sebab $\frac{n}{n-p-1} \rightarrow 1$, maka $s^2 \xrightarrow{p} \sigma^2$. ■

Teorema 2.5.8 *Misalkan kondisi-kondisi konsistensi terpenuhi dan tambahan kondisi Lindeberg–Feller terpenuhi, yaitu*

$$\frac{1}{\sqrt{n}} \mathbf{X}^\top \epsilon \xrightarrow{d} \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{Q}), \quad (2.5.42)$$

maka penduga OLS memiliki distribusi asimtotik

$$\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{Q}^{-1}). \quad (2.5.43)$$

Bukti. Dari pembuktian konsistensi, dapat dituliskan

$$\begin{aligned} \sqrt{n}(\hat{\beta} - \beta) &= \sqrt{n} \left(\frac{1}{n} \mathbf{X}^\top \mathbf{X} \right)^{-1} \left(\frac{1}{n} \mathbf{X}^\top \epsilon \right) \\ &= \left(\frac{1}{n} \mathbf{X}^\top \mathbf{X} \right)^{-1} \left(\frac{1}{\sqrt{n}} \mathbf{X}^\top \epsilon \right). \end{aligned} \quad (2.5.44)$$

Berdasarkan kondisi Lindeberg–Feller, $\frac{1}{\sqrt{n}}\mathbf{X}^\top \boldsymbol{\varepsilon} \xrightarrow{d} \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{Q})$. Dengan teorema Slutsky, sebab $\left(\frac{1}{n}\mathbf{X}^\top \mathbf{X}\right)^{-1} \xrightarrow{p} \mathbf{Q}^{-1}$, maka

$$\sqrt{n}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) \xrightarrow{d} \mathbf{Q}^{-1} \cdot \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{Q}) = \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{Q}^{-1}). \quad (2.5.45)$$

■

Akibat 2.5.9 Dengan penduga variansi konsisten $s^2 \xrightarrow{p} \sigma^2$, berlaku

$$\sqrt{n}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) \xrightarrow{d} \mathcal{N}\left(\mathbf{0}, \sigma^2 \left(\frac{1}{n}\mathbf{X}^\top \mathbf{X}\right)^{-1}\right), \quad (2.5.46)$$

dan penduga matriks kovarians asimtotik yang konsisten adalah

$$\widehat{\text{Var}}(\hat{\boldsymbol{\beta}}) = s^2(\mathbf{X}^\top \mathbf{X})^{-1}. \quad (2.5.47)$$

Di bawah ini akan dipaparkan hasil-hasil mengenai distribusi eksak dan asimtotik dari uji- t dan uji- F untuk model regresi linear.

Teorema 2.5.10 Untuk menguji hipotesis $H_0 : \beta_k = \beta_k^0$ lawan $H_1 : \beta_k \neq \beta_k^0$, statistik uji- t didefinisikan sebagai

$$t_k = \frac{\hat{\beta}_k - \beta_k^0}{\text{se}(\hat{\beta}_k)}, \quad (2.5.48)$$

dengan $\text{se}(\hat{\beta}_k) = s\sqrt{[(\mathbf{X}^\top \mathbf{X})^{-1}]_{kk}}$ adalah galat standar dari $\hat{\beta}_k$.

(a) Distribusi eksak di bawah asumsi normalitas galat $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$ dan H_0 benar adalah $t_k \sim t_{n-p-1}$.

(b) Distribusi asimtotik di bawah kondisi regularitas asimtotik dan H_0 benar adalah $t_k \xrightarrow{d} \mathcal{N}(0, 1)$.

Bukti.

(a) Di bawah normalitas, $\hat{\boldsymbol{\beta}} \sim \mathcal{N}(\boldsymbol{\beta}, \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1})$, sehingga $\hat{\beta}_k \sim \mathcal{N}(\beta_k, \sigma^2[(\mathbf{X}^\top \mathbf{X})^{-1}]_{kk})$.

Oleh karena itu,

$$Z_k = \frac{\hat{\beta}_k - \beta_k}{\sigma \sqrt{[(\mathbf{X}^\top \mathbf{X})^{-1}]_{kk}}} \sim \mathcal{N}(0, 1). \quad (2.5.49)$$

Selain itu, $(n - p - 1)s^2/\sigma^2 \sim \chi_{n-p-1}^2$ dan independen dari $\hat{\beta}$. Dengan demikian,

$$t_k = \frac{Z_k}{\sqrt{(n - p - 1)s^2/\sigma^2/(n - p - 1)}} = \frac{Z_k}{\sqrt{s^2/\sigma^2}} \sim t_{n-p-1}. \quad (2.5.50)$$

(b) Dari normalitas asimtotik, $\sqrt{n}(\hat{\beta}_k - \beta_k) \xrightarrow{d} \mathcal{N}(0, \sigma^2[\mathbf{Q}^{-1}]_{kk})$. Dengan $s^2 \xrightarrow{p} \sigma^2$ dan teorema Slutsky,

$$t_k = \frac{\hat{\beta}_k - \beta_k^0}{s \sqrt{[(\mathbf{X}^\top \mathbf{X})^{-1}]_{kk}}} \xrightarrow{d} \mathcal{N}(0, 1). \quad (2.5.51)$$

■

Pada praktiknya, perbedaan penggunaan distribusi eksak dan asimtotik uji- t biasanya kecil untuk ukuran sampel yang cukup besar, sehingga uji- t asimtotik sering digunakan sebagai pendekatan yang baik.

Teorema 2.5.11 Untuk menguji hipotesis linear umum $H_0 : \mathbf{R}\beta = \mathbf{r}$ dengan \mathbf{R} matriks berukuran $q \times (p+1)$ dan $\text{rank}(\mathbf{R}) = q$, statistik uji- F didefinisikan sebagai

$$F = \frac{(\mathbf{R}\hat{\beta} - \mathbf{r})^\top [\mathbf{R}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{R}^\top]^{-1} (\mathbf{R}\hat{\beta} - \mathbf{r})}{q \cdot s^2}. \quad (2.5.52)$$

(a) Distribusi eksak di bawah asumsi normalitas galat dan H_0 benar adalah

$$F \sim F_{q, n-p-1}.$$

(b) Distribusi asimtotik di bawah kondisi regularitas asimtotik dan H_0 benar adalah $qF \xrightarrow{d} \chi_q^2$.

Bukti.

(a) Distribusi eksak di bawah H_0 dan normalitas, $\mathbf{R}\hat{\beta} \sim \mathcal{N}(\mathbf{r}, \sigma^2 \mathbf{R}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{R}^\top)$.

Oleh karena itu,

$$\frac{(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})^\top [\mathbf{R}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{R}^\top]^{-1} (\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})}{\sigma^2} \sim \chi_q^2. \quad (2.5.53)$$

Sebab $(n - p - 1)s^2/\sigma^2 \sim \chi_{n-p-1}^2$ dan independen dari pembilang, maka

$$F = \frac{\chi_q^2/q}{\chi_{n-p-1}^2/(n-p-1)} \sim F_{q,n-p-1}. \quad (2.5.54)$$

(b) Distribusi asimtotik di bawah kondisi regularitas asimtotik dan H_0 benar adalah

$${}_qF = \frac{(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})^\top [\mathbf{R}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{R}^\top]^{-1} (\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})}{s^2} \xrightarrow{d} \chi_q^2. \quad (2.5.55)$$

■

Uji F eksak dan asimtotik umumnya memberikan hasil yang serupa untuk ukuran sampel yang besar, sehingga uji F asimtotik sering digunakan sebagai pendekatan yang baik dalam praktik. Uji ini berguna untuk menguji hipotesis yang melibatkan beberapa parameter secara bersamaan, misalnya dengan menggunakan matriks restriksi \mathbf{R} berupa matriks

$$\mathbf{R} = \begin{bmatrix} 0 & 1 & 0 & 0 & \cdots & 0 \\ 0 & 0 & 1 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \cdots & 1 \end{bmatrix}, \quad (2.5.56)$$

sehingga $\mathbf{R}\boldsymbol{\beta} = \mathbf{0}$ menguji apakah semua koefisien regresi selain intercept sama dengan nol.

2.5.3 Regresi Terboboti

Regresi terboboti dibentuk apabila model regresi linear klasik melanggar asumsi homoskedastisitas galat. Heteroskedastisitas terjadi apabila komponen galat

regresi tidak memiliki variansi yang konstan. Apabila terjadi heteroskedastisitas, maka Teorema Gauss–Markov tidak berlaku sehingga penduga dari model regresi tidak lagi bersifat BLUE karena asumsi OLS.5 tidak terpenuhi.

Definisi 2.5.12 (*Generalized least squares, Greene 2002*) *Pertimbangkan model regresi linear*

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad \mathbb{E}[\boldsymbol{\varepsilon} \mid \mathbf{X}] = \mathbf{0}, \quad (2.5.57)$$

dengan struktur variansi-kovariansi galat

$$\text{Var}(\boldsymbol{\varepsilon} \mid \mathbf{X}) = \sigma^2 \boldsymbol{\Omega}, \quad (2.5.58)$$

dengan $\boldsymbol{\Omega}$ adalah matriks simetri definit-positif berukuran $n \times n$. Model yang memperkenalkan struktur variansi-kovariansi galat disebut sebagai model kuadrat terkecil tergeneralisasi atau generalized least squares (GLS).

Penduga GLS diperoleh dengan meminimumkan jumlah kuadrat terbobot

$$S_{\mathbf{W}}(\boldsymbol{\beta}) = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top \mathbf{W} (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}), \quad (2.5.59)$$

dengan $\mathbf{W} = \boldsymbol{\Omega}^{-1}$. Diferensiasi terhadap $\boldsymbol{\beta}$ dan disamakan dengan nol memberikan

$$\begin{aligned} \frac{\partial}{\partial \boldsymbol{\beta}} S_{\mathbf{W}}(\boldsymbol{\beta}) &= -2\mathbf{W}\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) \quad (\text{karena } \mathbf{W} \text{ simetris}) \\ \mathbf{0} &= -2\mathbf{X}^\top \mathbf{W}\mathbf{y} - 2\mathbf{X}^\top \mathbf{W}\mathbf{X}\hat{\boldsymbol{\beta}} \\ \mathbf{X}^\top \mathbf{W}\mathbf{X}\hat{\boldsymbol{\beta}} &= \mathbf{X}^\top \mathbf{W}\mathbf{y}, \end{aligned} \quad (2.5.60)$$

sehingga pada asumsi $\mathbf{X}^\top \mathbf{W}\mathbf{X}$ nonsingular,

$$\hat{\boldsymbol{\beta}}_{\text{GLS}} = (\mathbf{X}^\top \mathbf{W}\mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}\mathbf{y}. \quad (2.5.61)$$

Penduga ini tak bias jika \mathbf{W} tidak acak atau independen dari $\boldsymbol{\varepsilon}$ dan $\mathbb{E}[\boldsymbol{\varepsilon} \mid \mathbf{X}] = \mathbf{0}$, sebab $\mathbb{E}[\hat{\boldsymbol{\beta}}_{\text{GLS}} \mid \mathbf{X}] = \boldsymbol{\beta}$.

Kasus umum dari GLS yang sering dipakai adalah kuadrat terkecil terboboti

atau *weighted least squares* (WLS), yaitu $\Omega = \text{diag}(\omega_1, \dots, \omega_n)$ yang merupakan heteroskedastisitas diagonal dengan bobot $\mathbf{W} = \Omega^{-1} = \text{diag}(w_1, \dots, w_n)$, $w_i = 1/\omega_i$. Bobot \mathbf{W} dianggap nonstokastik atau *fixed*. Model GLS sesuai apabila galat memiliki korelasi serial, yaitu Ω bukan matriks diagonal. Di sisi lain, model WLS sesuai apabila galat tidak berkorelasi tetapi memiliki variansi yang berbeda-beda.

Teorema 2.5.13 (Teorema Aitken) *Misalkan model regresi linear*

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad \mathbb{E}[\boldsymbol{\varepsilon} \mid \mathbf{X}] = 0, \quad \text{Var}(\boldsymbol{\varepsilon} \mid \mathbf{X}) = \sigma^2 \Omega,$$

dengan Ω simetris definit-positif, maka penduga

$$\hat{\boldsymbol{\beta}}_{GLS} = (\mathbf{X}^\top \Omega^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \Omega^{-1} \mathbf{y} \quad (2.5.62)$$

adalah best linear unbiased estimator (BLUE) dari $\boldsymbol{\beta}$.

Bukti. Pertama-tama perhatikan bahwa setiap penduga linear bagi $\boldsymbol{\beta}$ dapat ditulis dalam bentuk $\tilde{\boldsymbol{\beta}} = \mathbf{A}\mathbf{y}$ dengan $\mathbf{A} \in \mathbb{R}^{p \times n}$. Agar tak bias, berlaku

$$\mathbb{E}[\tilde{\boldsymbol{\beta}} \mid \mathbf{X}] = \mathbf{A}\mathbb{E}[\mathbf{y} \mid \mathbf{X}] = \mathbf{A}\mathbf{X}\boldsymbol{\beta}. \quad (2.5.63)$$

Supaya sama dengan $\boldsymbol{\beta}$ untuk semua $\boldsymbol{\beta}$, syarat yang harus dipenuhi adalah $\mathbf{A}\mathbf{X} = \mathbf{I}_p$. Selanjutnya, kovariansi dari $\tilde{\boldsymbol{\beta}}$ diberikan oleh

$$\text{Var}(\tilde{\boldsymbol{\beta}} \mid \mathbf{X}) = \mathbf{A} \sigma^2 \Omega \mathbf{A}^\top. \quad (2.5.64)$$

Di antara semua matriks \mathbf{A} yang memenuhi $\mathbf{A}\mathbf{X} = \mathbf{I}_p$, pilih

$$\mathbf{A}_0 = (\mathbf{X}^\top \Omega^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \Omega^{-1}. \quad (2.5.65)$$

Jelas bahwa $\mathbf{A}_0 \mathbf{X} = \mathbf{I}_p$, sehingga \mathbf{A}_0 menghasilkan penduga tak bias.

Sekarang, ambil sembarang penduga tak bias lain \mathbf{A} . Matriks \mathbf{A} tersebut dapat ditulis sebagai $\mathbf{A} = \mathbf{A}_0 + \mathbf{D}$ dengan $\mathbf{D}\mathbf{X} = \mathbf{0}$, sebab $\mathbf{A}_0 \mathbf{X} = \mathbf{I}_p$ dan syarat

$\mathbf{AX} = \mathbf{I}_p$ harus tetap dipenuhi. Dengan demikian,

$$\tilde{\boldsymbol{\beta}} = \mathbf{A}\mathbf{y} = \mathbf{A}_0\mathbf{y} + \mathbf{D}\mathbf{y}. \quad (2.5.66)$$

Variansi dari penduga ini adalah

$$\text{Var}(\tilde{\boldsymbol{\beta}} \mid \mathbf{X}) = \text{Var}(\mathbf{A}_0\mathbf{y} \mid \mathbf{X}) + \sigma^2 \mathbf{D}\boldsymbol{\Omega}\mathbf{D}^\top. \quad (2.5.67)$$

Bagian pertama adalah kovarians dari $\hat{\boldsymbol{\beta}}_{\text{GLS}}$, sedangkan bagian kedua selalu semi definit positif karena $\boldsymbol{\Omega}$ definit-positif. Hal ini berarti tambahan $\mathbf{D}\mathbf{y}$ hanya menambah variansi tanpa mengurangi bias. Dengan demikian, kovarians dari sembarang penduga linear tak bias selalu lebih besar atau sama dengan kovarians GLS. Oleh karena itu, $\hat{\boldsymbol{\beta}}_{\text{GLS}}$ meminimalkan kovarians di antara semua penduga linear tak bias, sehingga merupakan BLUE. ■

Teorema 2.5.14 *Jika $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \boldsymbol{\Omega})$, maka penduga maksimum likelihood (MLE) untuk $\boldsymbol{\beta}$ adalah*

$$\hat{\boldsymbol{\beta}}_{\text{MLE}} = \hat{\boldsymbol{\beta}}_{\text{GLS}} = (\mathbf{X}^\top \boldsymbol{\Omega}^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \boldsymbol{\Omega}^{-1} \mathbf{y}, \quad (2.5.68)$$

dan MLE untuk σ^2 (dengan $\boldsymbol{\Omega}$ diketahui) adalah

$$\hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})^\top \boldsymbol{\Omega}^{-1} (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}). \quad (2.5.69)$$

Bukti. Di bawah normalitas galat, fungsi *likelihood* untuk $\boldsymbol{\beta}$ dan σ^2 adalah

$$L(\boldsymbol{\beta}, \sigma^2 \mid \mathbf{y}) = (2\pi\sigma^2)^{-n/2} |\boldsymbol{\Omega}|^{-1/2} \exp\left(-\frac{1}{2\sigma^2} (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top \boldsymbol{\Omega}^{-1} (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})\right).$$

Hal ini berarti fungsi log-*likelihood* untuk $\boldsymbol{\beta}$ dan σ^2 adalah

$$\ell(\boldsymbol{\beta}, \sigma^2) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2} \log |\boldsymbol{\Omega}| - \frac{1}{2\sigma^2} (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top \boldsymbol{\Omega}^{-1} (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}).$$

Maksimisasi ℓ untuk β dengan turunan pertama menghasilkan

$$\begin{aligned}\frac{\partial \ell(\beta, \sigma^2 | \mathbf{y})}{\partial \beta} &= \frac{2}{2\sigma^2} \mathbf{X}^\top \Omega^{-1} (\mathbf{y} - \mathbf{X}\beta) \\ 0 &= \frac{1}{\sigma^2} \mathbf{X}^\top \Omega^{-1} \mathbf{y} - \frac{1}{\sigma^2} \mathbf{X}^\top \Omega^{-1} \mathbf{X} \hat{\beta} \\ \frac{1}{\sigma^2} \mathbf{X}^\top \Omega^{-1} \mathbf{X} \hat{\beta} &= \frac{1}{\sigma^2} \mathbf{X}^\top \Omega^{-1} \mathbf{y} \\ \hat{\beta} &= (\mathbf{X}^\top \Omega^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \Omega^{-1} \mathbf{y},\end{aligned}\tag{2.5.70}$$

sehingga $\hat{\beta}_{\text{MLE}} = \hat{\beta}_{\text{GLS}}$. Selanjutnya, turunan terhadap σ^2 memberi $\partial \ell / \partial \sigma^2 = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} (\mathbf{y} - \mathbf{X}\hat{\beta})^\top \Omega^{-1} (\mathbf{y} - \mathbf{X}\hat{\beta}) = 0$, yang menghasilkan rumus $\hat{\sigma}_{\text{MLE}}^2$ di atas. ■

Dalam analisis nyata, Ω biasanya jarang diketahui. *Feasible GLS* (FGLS) memperkirakan Ω , misalnya dari residu OLS atau model varian parametrik, lalu menyusun $\widehat{\mathbf{W}} = \widehat{\Omega}^{-1}$ dan menghitung $\hat{\beta}_{\text{FGLS}} = (\mathbf{X}^\top \widehat{\mathbf{W}} \mathbf{X})^{-1} \mathbf{X}^\top \widehat{\mathbf{W}} \mathbf{y}$. Di bawah kondisi reguler, $\hat{\beta}_{\text{FGLS}}$ konsisten dan asimtotik efisien. Namun, untuk sampel kecil, sifat *finite-sample* bergantung pada kualitas spesifikasi $\widehat{\Omega}$.

2.5.4 Teori Asimtotik untuk GLS/WLS

Teori asimtotik untuk penduga GLS/WLS mempelajari perilaku penduga ketika ukuran sampel n menuju tak hingga. Hasil-hasil asimtotik ini penting untuk memberikan justifikasi teoritis bagi inferensi statistik pada sampel besar.

Teorema 2.5.15 *Misalkan model regresi linear dengan heteroskedastisitas*

$$\mathbf{y} = \mathbf{X}\beta + \varepsilon, \quad \mathbb{E}[\varepsilon | \mathbf{X}] = \mathbf{0}, \quad \text{Var}(\varepsilon | \mathbf{X}) = \sigma^2 \Omega,$$

dengan Ω diketahui dan definit positif. Jika kondisi-kondisi berikut terpenuhi:

- (i) $\frac{1}{n} \mathbf{X}^\top \Omega^{-1} \mathbf{X} \xrightarrow{p} \mathbf{Q}_\Omega$ dengan \mathbf{Q}_Ω matriks definit positif,
- (ii) $\frac{1}{n} \mathbf{X}^\top \Omega^{-1} \varepsilon \xrightarrow{p} \mathbf{0}$,

maka penduga GLS $\hat{\beta}_{GLS} = (\mathbf{X}^\top \boldsymbol{\Omega}^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \boldsymbol{\Omega}^{-1} \mathbf{y}$ bersifat konsisten, yaitu

$$\hat{\beta}_{GLS} \xrightarrow{p} \beta. \quad (2.5.71)$$

Bukti. Penduga GLS dapat dituliskan sebagai

$$\begin{aligned} \hat{\beta}_{GLS} &= (\mathbf{X}^\top \boldsymbol{\Omega}^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \boldsymbol{\Omega}^{-1} \mathbf{y} \\ &= (\mathbf{X}^\top \boldsymbol{\Omega}^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \boldsymbol{\Omega}^{-1} (\mathbf{X}\beta + \boldsymbol{\varepsilon}) \\ &= \beta + (\mathbf{X}^\top \boldsymbol{\Omega}^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \boldsymbol{\Omega}^{-1} \boldsymbol{\varepsilon} \\ &= \beta + \left(\frac{1}{n} \mathbf{X}^\top \boldsymbol{\Omega}^{-1} \mathbf{X} \right)^{-1} \left(\frac{1}{n} \mathbf{X}^\top \boldsymbol{\Omega}^{-1} \boldsymbol{\varepsilon} \right). \end{aligned} \quad (2.5.72)$$

Berdasarkan kondisi (i), $\frac{1}{n} \mathbf{X}^\top \boldsymbol{\Omega}^{-1} \mathbf{X} \xrightarrow{p} \mathbf{Q}_\Omega$ dengan \mathbf{Q}_Ω definit positif. Dengan teorema pemetaan kontinu, $\left(\frac{1}{n} \mathbf{X}^\top \boldsymbol{\Omega}^{-1} \mathbf{X} \right)^{-1} \xrightarrow{p} \mathbf{Q}_\Omega^{-1}$. Berdasarkan kondisi (ii), $\frac{1}{n} \mathbf{X}^\top \boldsymbol{\Omega}^{-1} \boldsymbol{\varepsilon} \xrightarrow{p} \mathbf{0}$. Dengan teorema Slutsky, diperoleh

$$\hat{\beta}_{GLS} - \beta = \left(\frac{1}{n} \mathbf{X}^\top \boldsymbol{\Omega}^{-1} \mathbf{X} \right)^{-1} \left(\frac{1}{n} \mathbf{X}^\top \boldsymbol{\Omega}^{-1} \boldsymbol{\varepsilon} \right) \xrightarrow{p} \mathbf{Q}_\Omega^{-1} \cdot \mathbf{0} = \mathbf{0}, \quad (2.5.73)$$

sehingga $\hat{\beta}_{GLS} \xrightarrow{p} \beta$. ■

Berdasarkan teorema di atas, penduga GLS konsisten jika dan hanya jika matriks bobot terspesifikasi dengan benar dan kondisi-kondisi konsistensi

Teorema 2.5.16 *Misalkan kondisi-kondisi konsistensi terpenuhi dan tambahan kondisi berikut dipenuhi:*

$$(i) \quad \frac{1}{\sqrt{n}} \mathbf{X}^\top \boldsymbol{\Omega}^{-1} \boldsymbol{\varepsilon} \xrightarrow{d} \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{Q}_\Omega) \text{ (kondisi Lindeberg–Feller terpenuhi).}$$

Maka penduga GLS memiliki distribusi asimtotik

$$\sqrt{n}(\hat{\beta}_{GLS} - \beta) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{Q}_\Omega^{-1}). \quad (2.5.74)$$

Bukti. Dari pembuktian konsistensi, dapat dituliskan

$$\begin{aligned}\sqrt{n}(\hat{\beta}_{\text{GLS}} - \beta) &= \sqrt{n} \left(\frac{1}{n} \mathbf{X}^\top \Omega^{-1} \mathbf{X} \right)^{-1} \left(\frac{1}{n} \mathbf{X}^\top \Omega^{-1} \epsilon \right) \\ &= \left(\frac{1}{n} \mathbf{X}^\top \Omega^{-1} \mathbf{X} \right)^{-1} \left(\frac{1}{\sqrt{n}} \mathbf{X}^\top \Omega^{-1} \epsilon \right).\end{aligned}\quad (2.5.75)$$

Berdasarkan kondisi (i), $\frac{1}{\sqrt{n}} \mathbf{X}^\top \Omega^{-1} \epsilon \xrightarrow{d} \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{Q}_\Omega)$. Dengan teorema Slutsky, sebab $\left(\frac{1}{n} \mathbf{X}^\top \Omega^{-1} \mathbf{X} \right)^{-1} \xrightarrow{p} \mathbf{Q}_\Omega^{-1}$, maka

$$\sqrt{n}(\hat{\beta}_{\text{GLS}} - \beta) \xrightarrow{d} \mathbf{Q}_\Omega^{-1} \cdot \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{Q}_\Omega) = \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{Q}_\Omega^{-1}). \quad (2.5.76)$$

■

2.6 Pemodelan Polinomial Lokal

Pemodelan polinomial lokal (*local polynomial modeling*) merupakan teknik nonparametrik yang fleksibel untuk mengestimasi fungsi regresi tanpa mengasumsikan bentuk fungsional tertentu secara global. Pendekatan ini menjadi fondasi penting bagi metode regresi terboboti geografis (GWR) yang akan dibahas pada bagian selanjutnya. Pembahasan dalam bagian ini mengikuti kerangka yang dikembangkan oleh Fan dan Gijbels (1996).

Definisi 2.6.1 (Model regresi nonparametrik) *Pertimbangkan model regresi nonparametrik*

$$Y_i = m(X_i) + \varepsilon_i, \quad i = 1, 2, \dots, n, \quad (2.6.1)$$

dengan $m(\cdot)$ adalah fungsi regresi yang tidak diketahui, X_i adalah variabel prediktor, Y_i adalah variabel respons, dan ε_i adalah galat acak dengan $\mathbb{E}[\varepsilon_i | X_i] = 0$ dan $\text{Var}(\varepsilon_i | X_i) = \sigma^2(X_i)$.

Definisi 2.6.2 (Aproksimasi polinomial lokal, Fan dan Gijbels 1996) *Untuk mengestimasi $m(x_0)$ pada titik target x_0 , fungsi regresi $m(X)$ diaproksimasi secara lokal*

menggunakan ekspansi Taylor orde- p di sekitar x_0 :

$$m(X) \approx \sum_{j=0}^p \frac{m^{(j)}(x_0)}{j!} (X - x_0)^j, \quad (2.6.2)$$

dengan mendefinisikan $\beta_j = \frac{m^{(j)}(x_0)}{j!}$ untuk $j = 0, 1, \dots, p$, aproksimasi lokal dapat dituliskan sebagai

$$m(X) \approx \sum_{j=0}^p \beta_j (X - x_0)^j. \quad (2.6.3)$$

X adalah ketetanggaan dari x_0 dengan aproksimasi ini berlaku dengan baik.

Estimator polinomial lokal $\hat{m}(x_0)$ diperoleh dengan menyelesaikan masalah optimisasi berikut:

$$\min_{\beta_0, \beta_1, \dots, \beta_p} \sum_{i=1}^n K_h(X_i - x_0) \left[Y_i - \sum_{j=0}^p \beta_j (X_i - x_0)^j \right]^2, \quad (2.6.4)$$

dengan $K_h(u) = \frac{1}{h} K\left(\frac{u}{h}\right)$ adalah fungsi *kernel* dengan parameter lebar pita (bandwidth) $h > 0$. Estimator polinomial lokal pada titik x_0 didefinisikan sebagai $\hat{m}(x_0) = \hat{\beta}_0(x_0)$, dengan $\hat{\beta}_0(x_0)$ adalah solusi optimal dari masalah di atas.

Contoh 2.6.3 Dua kasus khusus yang paling umum digunakan adalah sebagai berikut.

- (a) **Estimator Nadaraya–Watson** ($p = 0$): Dengan $p = 0$, diperoleh estimator rata-rata lokal

$$\hat{m}(x_0) = \frac{\sum_{i=1}^n K_h(X_i - x_0) Y_i}{\sum_{i=1}^n K_h(X_i - x_0)}. \quad (2.6.5)$$

- (b) **Estimator Linear Lokal** ($p = 1$): Dengan $p = 1$, model lokal adalah $m(x) \approx \beta_0 + \beta_1(x - x_0)$, dan estimator $\hat{m}(x_0) = \hat{\beta}_0(x_0)$ diperoleh dari regresi linear tertimbang lokal.

2.6.1 Asumsi Model Polinomial Lokal

Pertimbangkan model regresi nonparametrik

$$Y_i = m(X_i) + \varepsilon_i, \quad i = 1, 2, \dots, n, \quad (2.6.6)$$

dengan $m(\cdot)$ adalah fungsi regresi yang tidak diketahui, X_i adalah variabel prediktor, Y_i adalah variabel respons, dan ε_i adalah galat acak dengan $\mathbb{E}[\varepsilon_i | X_i] = 0$ dan $\text{Var}(\varepsilon_i | X_i) = \sigma^2(X_i)$. Untuk memperoleh sifat-sifat asimtotik estimator polinomial lokal, diperlukan asumsi-asumsi regularitas berikut.

Asumsi LPM.1 Untuk mengaproksimasi $m(X)$ di sekitar titik x_0 , fungsi regresi $m(X)$ diasumsikan memiliki turunan kontinu hingga orde $(p + 1)$ di sekitar x_0 .

Asumsi LPM.2 Galat ε_i memenuhi $\mathbb{E}[\varepsilon_i | X_i] = 0$ dan $\text{Var}(\varepsilon_i | X_i) = \sigma^2(X_i)$ dengan $\sigma^2(x)$ kontinu di x_0 .

Asumsi LPM.3 Fungsi kernel $K(\cdot)$ adalah yang bekerja sebagai mekanisme pembobot dengan ketentuan sebagai berikut.

- (a) $K(u) \geq 0$ untuk semua $u \in \mathbb{R}$.
- (b) $\int_{\mathbb{R}} K(u) \, du = 1$.
- (c) $\int_{\mathbb{R}} uK(u) \, du = 0$ atau $K(u) = K(-u)$ untuk semua $u \in \mathbb{R}$.

Asumsi LPM.4 Seiring $n \rightarrow \infty$, berlaku $h \rightarrow 0$ dan $nh \rightarrow \infty$.

Beberapa fungsi *kernel* yang sering digunakan dalam pemodelan polinomial lokal adalah sebagai berikut.

- (a) **Kernel Gaussian:** $K(u) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{u^2}{2}\right)$.
- (b) **Kernel Epanechnikov:** $K(u) = \frac{3}{4}(1 - u^2)\mathbf{1}_{|u| \leq 1}$.
- (c) **Kernel Bi-kuadrat:** $K(u) = \frac{15}{16}(1 - u^2)^2\mathbf{1}_{|u| \leq 1}$.
- (d) **Kernel Tri-kubik:** $K(u) = \frac{70}{81}(1 - |u|^3)^3\mathbf{1}_{|u| \leq 1}$.

2.6.2 Estimasi Model Polinomial Lokal

Definisi 2.6.4 *Regresi tertimbang lokal (locally weighted least squares atau LWLS) model polinomial lokal pada titik x_0 menyelesaikan masalah optimisasi berikut:*

$$\min_{\boldsymbol{\beta}} \sum_{i=1}^n K_h(X_i - x_0) [Y_i - \mathbf{z}_i^\top \boldsymbol{\beta}]^2, \quad (2.6.7)$$

dengan $\boldsymbol{\beta} = (\beta_0, \beta_1, \dots, \beta_p)^\top$ dan $\mathbf{z}_i = (1, X_i - x_0, \dots, (X_i - x_0)^p)^\top$. Solusi optimal $\hat{\boldsymbol{\beta}}(x_0)$ memberikan estimator polinomial lokal $\hat{m}(x_0) = \hat{\beta}_0(x_0)$.

Teorema 2.6.5 *Definisikan matriks desain lokal \mathbf{X}_{x_0} dan matriks bobot \mathbf{W}_{x_0} sebagai*

$$\mathbf{X}_{x_0} = \begin{pmatrix} 1 & (X_1 - x_0) & (X_1 - x_0)^2 & \cdots & (X_1 - x_0)^p \\ 1 & (X_2 - x_0) & (X_2 - x_0)^2 & \cdots & (X_2 - x_0)^p \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & (X_n - x_0) & (X_n - x_0)^2 & \cdots & (X_n - x_0)^p \end{pmatrix} \in \mathbb{R}^{n \times (p+1)}, \quad (2.6.8)$$

dan

$$\mathbf{W}_{x_0} = \text{diag}(K_h(X_1 - x_0), K_h(X_2 - x_0), \dots, K_h(X_n - x_0)) \in \mathbb{R}^{n \times n}. \quad (2.6.9)$$

Maka estimator polinomial lokal diberikan oleh

$$\hat{\boldsymbol{\beta}}(x_0) = (\mathbf{X}_{x_0}^\top \mathbf{W}_{x_0} \mathbf{X}_{x_0})^{-1} \mathbf{X}_{x_0}^\top \mathbf{W}_{x_0} \mathbf{y}, \quad (2.6.10)$$

dengan $\mathbf{y} = (Y_1, Y_2, \dots, Y_n)^\top$. Khususnya, estimator untuk $m(x_0)$ adalah

$$\hat{m}(x_0) = \mathbf{e}_1^\top \hat{\boldsymbol{\beta}}(x_0) = \mathbf{e}_1^\top (\mathbf{X}_{x_0}^\top \mathbf{W}_{x_0} \mathbf{X}_{x_0})^{-1} \mathbf{X}_{x_0}^\top \mathbf{W}_{x_0} \mathbf{y}, \quad (2.6.11)$$

dengan $\mathbf{e}_1 = (1, 0, \dots, 0)^\top \in \mathbb{R}^{p+1}$.

Bukti. Masalah minimisasi LWLS dapat dituliskan dalam bentuk matriks sebagai

$$\min_{\beta} (\mathbf{y} - \mathbf{X}_{x_0}\beta)^\top \mathbf{W}_{x_0} (\mathbf{y} - \mathbf{X}_{x_0}\beta). \quad (2.6.12)$$

Turunan pertama terhadap β adalah

$$\frac{\partial}{\partial \beta} (\mathbf{y} - \mathbf{X}_{x_0}\beta)^\top \mathbf{W}_{x_0} (\mathbf{y} - \mathbf{X}_{x_0}\beta) = -2\mathbf{X}_{x_0}^\top \mathbf{W}_{x_0} (\mathbf{y} - \mathbf{X}_{x_0}\beta). \quad (2.6.13)$$

Menyamakan dengan nol memberikan persamaan normal tertimbang

$$\mathbf{X}_{x_0}^\top \mathbf{W}_{x_0} \mathbf{X}_{x_0} \hat{\beta}(x_0) = \mathbf{X}_{x_0}^\top \mathbf{W}_{x_0} \mathbf{y}. \quad (2.6.14)$$

Jika $\mathbf{X}_{x_0}^\top \mathbf{W}_{x_0} \mathbf{X}_{x_0}$ nonsingular, solusinya adalah

$$\hat{\beta}(x_0) = (\mathbf{X}_{x_0}^\top \mathbf{W}_{x_0} \mathbf{X}_{x_0})^{-1} \mathbf{X}_{x_0}^\top \mathbf{W}_{x_0} \mathbf{y}. \quad (2.6.15)$$

Sebab $\hat{\beta}_0(x_0)$ adalah komponen pertama dari $\hat{\beta}(x_0)$, maka $\hat{m}(x_0) = \mathbf{e}_1^\top \hat{\beta}(x_0)$. ■

Teorema 2.6.6 *Estimator $\hat{m}(x_0)$ dapat dituliskan sebagai kombinasi linear tertimbang dari respons:*

$$\hat{m}(x_0) = \sum_{i=1}^n w_i(x_0) Y_i, \quad (2.6.16)$$

dengan bobot efektif $w_i(x_0) = \mathbf{e}_1^\top (\mathbf{X}_{x_0}^\top \mathbf{W}_{x_0} \mathbf{X}_{x_0})^{-1} \mathbf{X}_{x_0}^\top \mathbf{W}_{x_0} \mathbf{e}_i$, dengan \mathbf{e}_i adalah vektor unit ke- i dalam \mathbb{R}^n .

Bukti. Dari teorema sebelumnya, estimator polinomial lokal diberikan oleh

$$\hat{m}(x_0) = \mathbf{e}_1^\top (\mathbf{X}_{x_0}^\top \mathbf{W}_{x_0} \mathbf{X}_{x_0})^{-1} \mathbf{X}_{x_0}^\top \mathbf{W}_{x_0} \mathbf{y}. \quad (2.6.17)$$

Vektor respons $\mathbf{y} = (Y_1, Y_2, \dots, Y_n)^\top$ dapat dituliskan sebagai kombinasi linear dari vektor-vektor unit standar dalam \mathbb{R}^n , yaitu

$$\mathbf{y} = \sum_{i=1}^n Y_i \mathbf{e}_i, \quad (2.6.18)$$

dengan $\mathbf{e}_i = (0, \dots, 0, 1, 0, \dots, 0)^\top$ adalah vektor unit ke- i yang memiliki nilai 1 pada posisi ke- i dan 0 pada posisi lainnya.

Substitusi representasi ini ke dalam rumus estimator memberikan

$$\begin{aligned}\hat{m}(x_0) &= \mathbf{e}_1^\top (\mathbf{X}_{x_0}^\top \mathbf{W}_{x_0} \mathbf{X}_{x_0})^{-1} \mathbf{X}_{x_0}^\top \mathbf{W}_{x_0} \left(\sum_{i=1}^n Y_i \mathbf{e}_i \right) \\ &= \sum_{i=1}^n Y_i \cdot \mathbf{e}_1^\top (\mathbf{X}_{x_0}^\top \mathbf{W}_{x_0} \mathbf{X}_{x_0})^{-1} \mathbf{X}_{x_0}^\top \mathbf{W}_{x_0} \mathbf{e}_i,\end{aligned}\quad (2.6.19)$$

dengan pertukaran urutan penjumlahan dan perkalian matriks dijamin oleh linearitas operasi matriks.

Dengan mendefinisikan bobot efektif sebagai

$$w_i(x_0) = \mathbf{e}_1^\top (\mathbf{X}_{x_0}^\top \mathbf{W}_{x_0} \mathbf{X}_{x_0})^{-1} \mathbf{X}_{x_0}^\top \mathbf{W}_{x_0} \mathbf{e}_i, \quad (2.6.20)$$

diperoleh representasi yang diinginkan

$$\hat{m}(x_0) = \sum_{i=1}^n w_i(x_0) Y_i. \quad (2.6.21)$$

Perhatikan bahwa $\mathbf{X}_{x_0}^\top \mathbf{W}_{x_0} \mathbf{e}_i$ adalah kolom ke- i dari matriks $\mathbf{X}_{x_0}^\top \mathbf{W}_{x_0}$, yang sama dengan $K_h(X_i - x_0) \mathbf{z}_i$ dengan $\mathbf{z}_i = (1, X_i - x_0, \dots, (X_i - x_0)^p)^\top$. Oleh karena itu, bobot $w_i(x_0)$ bergantung pada jarak X_i dari titik target x_0 melalui fungsi *kernel* $K_h(X_i - x_0)$ dan struktur polinomial lokal. ■

2.7 Analisis Regresi Spasial

Analisis regresi spasial merupakan perluasan dari analisis regresi klasik yang secara eksplisit memperhitungkan aspek geografis atau lokasi dalam pemodelan. Terdapat dua fenomena utama dalam data spasial yang perlu diperhatikan, yaitu dependensi spasial (*spatial dependence*) dan keragaman spasial (*spatial heterogeneity*). Kedua konsep ini memiliki karakteristik yang berbeda dan memerlukan pendekatan pemodelan yang berbeda pula (Anselin, 1988; Fotheringham dkk.,

2002; LeSage dan Pace, 2009).

Dependensi spasial merujuk pada situasi ketika nilai suatu variabel di suatu lokasi berkorelasi dengan nilai variabel yang sama di lokasi lain yang berdekatan secara geografis. Dengan kata lain, observasi pada lokasi yang berdekatan cenderung memiliki nilai yang serupa (autokorelasi spasial positif) atau berlawanan (autokorelasi spasial negatif). Fenomena ini dapat dianalogikan dengan autokorelasi serial dalam data deret waktu, tetapi terjadi dalam dimensi ruang. Dependensi spasial melanggar asumsi independensi galat dalam regresi linear klasik, yaitu $\text{Cov}(\varepsilon_i, \varepsilon_j) \neq 0$ untuk lokasi i dan j yang berdekatan.

Keragaman spasial atau heterogenitas spasial merujuk pada situasi ketika hubungan struktural antara variabel dependen dan independen bervariasi di berbagai lokasi geografis. Dalam konteks regresi, hal ini berarti koefisien regresi β tidak konstan di seluruh wilayah pengamatan, melainkan merupakan fungsi dari lokasi geografis, yaitu $\beta = \beta(s)$ dengan s menyatakan lokasi. Fenomena ini mengindikasikan bahwa proses yang mendasari hubungan antarvariabel berbeda di setiap wilayah.

Kedua fenomena ini dapat terjadi secara bersamaan dalam data spasial. Sebagai ilustrasi, pada analisis harga properti, dependensi spasial terjadi ketika harga rumah di suatu lokasi dipengaruhi oleh harga rumah di sekitarnya (efek *spillover*), sedangkan keragaman spasial terjadi ketika faktor-faktor yang memengaruhi harga rumah (seperti luas tanah atau jarak ke pusat kota) memiliki pengaruh yang berbeda di wilayah perkotaan dibandingkan dengan wilayah pinggiran.

2.7.1 Regresi dengan Dependensi Spasial

Dependensi spasial (*spatial dependence*) atau autokorelasi spasial terjadi ketika nilai suatu variabel di suatu lokasi berkorelasi dengan nilai variabel yang sama di lokasi lain yang berdekatan secara geografis. Konsep ini melanggar asumsi independensi dalam regresi linear klasik dan memerlukan perlakuan khusus dalam pemodelan ekonometrika spasial (Anselin, 1988; LeSage dan Pace, 2009).

Definisi 2.7.1 Misalkan Y_i merupakan nilai variabel di lokasi i dan Y_j merupakan

nilai variabel di lokasi tetangga j . Dependensi spasial terjadi jika

$$\text{Cov}(Y_i, Y_j) \neq 0, \quad \text{untuk lokasi } i \neq j \text{ yang berdekatan}, \quad (2.7.1)$$

yang dapat diukur menggunakan statistik Moran's I , yaitu

$$I = \frac{n}{\sum_{i=1}^n \sum_{j=1}^n w_{ij}} \cdot \frac{\sum_{i=1}^n \sum_{j=1}^n w_{ij} (Y_i - \bar{Y})(Y_j - \bar{Y})}{\sum_{i=1}^n (Y_i - \bar{Y})^2}, \quad (2.7.2)$$

dengan w_{ij} adalah bobot spasial antara lokasi i dan j .

Model regresi dengan dependensi spasial dapat diklasifikasikan menjadi beberapa bentuk utama berdasarkan letak dependensi spasial muncul dalam spesifikasi model.

Definisi 2.7.2 (Spatial Autoregressive Model (SAR)) Model SAR atau spatial lag model mengasumsikan bahwa variabel dependen di suatu lokasi dipengaruhi oleh nilai variabel dependen di lokasi tetangga, yaitu

$$y_i = \rho \sum_{j=1}^n w_{ij} y_j + \sum_{k=1}^p \beta_k x_{ik} + \varepsilon_i, \quad (2.7.3)$$

atau dalam bentuk matriksnya adalah

$$\mathbf{y} = \rho \mathbf{W} \mathbf{y} + \mathbf{X} \boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad (2.7.4)$$

dengan ρ adalah parameter autokorelasi spasial dan \mathbf{W} adalah matriks bobot spasial.

Definisi 2.7.3 (Spatial Error Model (SEM)) Model SEM mengasumsikan bahwa dependensi spasial terjadi pada komponen galat, yaitu

$$\mathbf{y} = \mathbf{X} \boldsymbol{\beta} + \mathbf{u}, \quad \mathbf{u} = \lambda \mathbf{W} \mathbf{u} + \boldsymbol{\varepsilon}, \quad (2.7.5)$$

dengan λ adalah parameter autokorelasi spasial pada galat dan $\boldsymbol{\varepsilon} \sim N(\mathbf{0}, \sigma^2 \mathbf{I})$.

Definisi 2.7.4 (*Spatial Durbin Model (SDM)*) Model *SDM* menggabungkan lag spasial dari variabel dependen dan independen, yaitu

$$\mathbf{y} = \rho \mathbf{W}\mathbf{y} + \mathbf{X}\boldsymbol{\beta} + \mathbf{W}\mathbf{X}\boldsymbol{\delta} + \boldsymbol{\varepsilon}, \quad (2.7.6)$$

dengan $\boldsymbol{\delta}$ adalah vektor parameter untuk lag spasial variabel independen.

2.7.2 Regresi dengan Keragaman Spasial

Heterogenitas spasial (*spatial heterogeneity*) terjadi ketika hubungan statistik antara variabel berbeda di berbagai lokasi geografis. Berbeda dengan dependensi spasial yang menangkap korelasi antar lokasi, heterogenitas spasial menangkap variasi dalam struktur hubungan itu sendiri (Fotheringham dkk., 2002).

Heterogenitas spasial terjadi ketika parameter regresi $\boldsymbol{\beta}$ bervariasi menurut lokasi geografis, yaitu

$$\boldsymbol{\beta} = \boldsymbol{\beta}(s_i) = \boldsymbol{\beta}(u_i, v_i), \quad (2.7.7)$$

dengan (u_i, v_i) adalah koordinat geografis lokasi ke- i . Hal ini mengindikasikan bahwa hubungan struktural yang sama dapat memiliki kekuatan dan arah yang berbeda di lokasi yang berbeda. Salah satu model regresi yang memperhitungkan heterogenitas spasial adalah *Geographically Weighted Regression (GWR)* atau regresi terboboti geografis yang memungkinkan koefisien regresi bervariasi secara kontinu di ruang geografis.

Pemodelan polinomial lokal yang telah dibahas pada bagian sebelumnya menyediakan kerangka teoretis fundamental untuk memahami GWR. Dalam pemodelan polinomial lokal, fungsi regresi $m(x)$ diestimasi secara lokal pada titik target x_0 dengan mengaproksimasi fungsi tersebut menggunakan ekspansi Taylor dan memberikan bobot yang lebih besar pada observasi yang dekat dengan titik target. GWR merupakan perluasan natural dari konsep ini ke dalam konteks spasial dua dimensi. Jika dalam pemodelan polinomial lokal standar, kedekatan diukur dalam ruang variabel prediktor satu dimensi, maka dalam GWR, kedekatan diukur dalam ruang geografis dua dimensi yang didefinisikan oleh koordinat (u, v) .

Dengan demikian, GWR dapat dipandang sebagai kasus khusus dari model koefisien bervariasi (*varying coefficient model*) dengan lokasi geografis sebagai variabel pengindeks variasi koefisien.

Secara lebih spesifik, hubungan antara keduanya dapat dilihat dari beberapa aspek berikut.

- (a) Pemodelan polinomial lokal mengaproksimasi $m(x) \approx \sum_{j=0}^p \beta_j(x_0)(x - x_0)^j$ di sekitar x_0 , sedangkan GWR mengaproksimasi $\beta(u, v)$ secara lokal di sekitar setiap lokasi geografis.
- (b) Keduanya menggunakan fungsi *kernel* untuk memberikan bobot berdasarkan kedekatan, yaitu dalam polinomial lokal kedekatan di ruang prediktor dan dalam GWR kedekatan di ruang geografis.
- (c) Keduanya menggunakan *locally weighted least squares* sebagai metode estimasi parameter lokal.
- (d) Parameter *bandwidth* h mengontrol tingkat penghalusan (*smoothing*) dan menentukan *trade-off* antara bias dan variansi pada kedua pendekatan.

Definisi 2.7.5 (*Geographically Weighted Regression (GWR)*, Fotheringham dkk. 2002) Model GWR untuk observasi ke- i pada lokasi (u_i, v_i) didefinisikan sebagai

$$y_i = \beta_0(u_i, v_i) + \sum_{k=1}^p \beta_k(u_i, v_i)x_{ik} + \varepsilon_i, \quad i = 1, 2, \dots, n, \quad (2.7.8)$$

atau dalam bentuk vektor

$$y_i = \mathbf{x}_i^\top \boldsymbol{\beta}(u_i, v_i) + \varepsilon_i, \quad (2.7.9)$$

dengan y_i adalah variabel respons pada lokasi i , $\mathbf{x}_i = (1, x_{i1}, \dots, x_{ip})^\top \in \mathbb{R}^{p+1}$ adalah vektor variabel prediktor, $\boldsymbol{\beta}(u_i, v_i) = (\beta_0(u_i, v_i), \beta_1(u_i, v_i), \dots, \beta_p(u_i, v_i))^\top$ adalah vektor koefisien lokal, (u_i, v_i) adalah koordinat geografis lokasi ke- i , dan ε_i adalah galat acak.

Dalam bentuk matriks, dapat dituliskan sebagai berikut.

$$\mathbf{y} = (\mathbf{X} \odot \mathcal{B}) \mathbf{1}_{p+1} + \boldsymbol{\varepsilon}, \quad (2.7.10)$$

dengan

$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \quad \mathbf{X} = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1p} \\ 1 & x_{21} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{np} \end{pmatrix},$$

$$\mathcal{B} = \begin{pmatrix} \beta_0(u_1, v_1) & \cdots & \beta_p(u_1, v_1) \\ \beta_0(u_2, v_2) & \cdots & \beta_p(u_2, v_2) \\ \vdots & \ddots & \vdots \\ \beta_0(u_n, v_n) & \cdots & \beta_p(u_n, v_n) \end{pmatrix}, \quad \text{dan } \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}. \quad (2.7.11)$$

Operasi \odot menunjukkan perkalian Hadamard (elemen demi elemen) antara matriks \mathbf{X} dan \mathcal{B} .

Model GWR didasarkan pada asumsi-asumsi berikut.

Asumsi GWR.1 Barisan sampel $\{(\mathbf{x}_i, (u_i, v_i)) : i = 1, 2, \dots, n\}$ stasioner dan dependen untuk setiap i dan j dengan $\|i - j\|_\infty \leq h$. Dua vektor acak $(\mathbf{x}_i, (u_i, v_i))$ dan $(\mathbf{x}_j, (u_j, v_j))$ bersifat independen ketika $\|i - j\|_\infty > h$.

Asumsi GWR.2 Galat acak ε_i memiliki nilai harapan nol, yaitu $\mathbb{E}[\varepsilon_i \mid \mathbf{X}, (u_i, v_i)] = 0$ untuk semua i .

Asumsi GWR.3 Variansi galat acak adalah konstan, yaitu $\text{Var}(\varepsilon_i \mid \mathbf{X}, (u_i, v_i)) = \sigma^2$ untuk semua i .

Asumsi GWR.4 Fungsi koefisien lokal $\beta_k(u, v)$ untuk $k = 0, 1, \dots, p$ memiliki turunan parsial kontinu hingga orde kedua di setiap lokasi.

Asumsi GWR.5 Fungsi kepadatan marginal dari lokasi observasi, yaitu $f(u, v)$, memiliki turunan parsial kontinu hingga orde kedua di setiap lokasi.

Asumsi GWR.6 Ketika $n \rightarrow \infty$, dipunyai $h \rightarrow 0$ dan $nh^{d-1} \rightarrow \infty$.

Asumsi GWR.7 Untuk setiap lokasi i , matriks $\mathbf{X}^\top \mathbf{W}_i \mathbf{X}$ adalah nonsingular.

Teorema 2.7.6 Untuk setiap lokasi (u_i, v_i) , estimator locally weighted least squares (LWLS) untuk koefisien lokal diperoleh dengan meminimalkan

$$S_i(\boldsymbol{\beta}) = \sum_{j=1}^n w_{ij} (y_j - \mathbf{x}_j^\top \boldsymbol{\beta})^2 = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top \mathbf{W}_i (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}), \quad (2.7.12)$$

dengan $\mathbf{W}_i = \text{diag}(w_{i1}, w_{i2}, \dots, w_{in})$. Estimator yang dihasilkan adalah

$$\hat{\boldsymbol{\beta}}(u_i, v_i) = (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}_i \mathbf{y}. \quad (2.7.13)$$

Bukti. Untuk lokasi (u_i, v_i) , tujuannya adalah meminimalkan fungsi objektif kuadrat terkecil tertimbang lokal

$$S_i(\boldsymbol{\beta}) = \sum_{j=1}^n w_{ij} (y_j - \mathbf{x}_j^\top \boldsymbol{\beta})^2. \quad (2.7.14)$$

Dalam notasi matriks, fungsi ini dapat dituliskan sebagai

$$S_i(\boldsymbol{\beta}) = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top \mathbf{W}_i (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}), \quad (2.7.15)$$

dengan $\mathbf{W}_i = \text{diag}(w_{i1}, w_{i2}, \dots, w_{in})$ adalah matriks diagonal berukuran $n \times n$ yang berisi bobot spasial. Secara interpretatif, persamaan (2.7.15) menggunakan koefisien $\boldsymbol{\beta}$ yang sama untuk semua observasi, tetapi bobot w_{ij} menekankan kontribusi observasi yang lebih dekat ke lokasi target (u_i, v_i) karena residual dari observasi tersebut memiliki bobot yang lebih besar dalam fungsi objektif.

Ekspansi bentuk kuadratik memberikan

$$\begin{aligned} S_i(\boldsymbol{\beta}) &= (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top \mathbf{W}_i (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) \\ &= \mathbf{y}^\top \mathbf{W}_i \mathbf{y} - \mathbf{y}^\top \mathbf{W}_i \mathbf{X}\boldsymbol{\beta} - \boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{W}_i \mathbf{y} + \boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{W}_i \mathbf{X}\boldsymbol{\beta}. \end{aligned} \quad (2.7.16)$$

Sebab $\mathbf{y}^\top \mathbf{W}_i \mathbf{X}\boldsymbol{\beta}$ adalah skalar, maka $\mathbf{y}^\top \mathbf{W}_i \mathbf{X}\boldsymbol{\beta} = (\mathbf{y}^\top \mathbf{W}_i \mathbf{X}\boldsymbol{\beta})^\top = \boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{W}_i^\top \mathbf{y} =$

$\beta^\top \mathbf{X}^\top \mathbf{W}_i \mathbf{y}$ (sebab \mathbf{W}_i simetris). Dengan demikian,

$$S_i(\beta) = \mathbf{y}^\top \mathbf{W}_i \mathbf{y} - 2\beta^\top \mathbf{X}^\top \mathbf{W}_i \mathbf{y} + \beta^\top \mathbf{X}^\top \mathbf{W}_i \mathbf{X} \beta. \quad (2.7.17)$$

Untuk menemukan minimum, dihitung turunan pertama terhadap β dan disamakan dengan nol. Dengan menggunakan aturan diferensial matriks, turunan dari masing-masing suku adalah sebagai berikut.

- (i) Suku $\mathbf{y}^\top \mathbf{W}_i \mathbf{y}$ tidak bergantung pada β , sehingga turunannya adalah 0.
- (ii) Suku $-2\beta^\top \mathbf{X}^\top \mathbf{W}_i \mathbf{y}$ berbentuk $\mathbf{c}^\top \beta$ dengan $\mathbf{c} = -2\mathbf{X}^\top \mathbf{W}_i \mathbf{y}$. Turunannya adalah $\mathbf{c} = -2\mathbf{X}^\top \mathbf{W}_i \mathbf{y}$.
- (iii) Suku $\beta^\top \mathbf{X}^\top \mathbf{W}_i \mathbf{X} \beta$ berbentuk $\beta^\top \mathbf{A} \beta$ dengan $\mathbf{A} = \mathbf{X}^\top \mathbf{W}_i \mathbf{X}$ yang simetris (sebab \mathbf{W}_i simetris). Turunannya adalah $2\mathbf{A}\beta = 2\mathbf{X}^\top \mathbf{W}_i \mathbf{X} \beta$.

Dengan demikian, gradien dari $S_i(\beta)$ terhadap β adalah

$$\frac{\partial S_i(\beta)}{\partial \beta} = -2\mathbf{X}^\top \mathbf{W}_i \mathbf{y} + 2\mathbf{X}^\top \mathbf{W}_i \mathbf{X} \beta. \quad (2.7.18)$$

Syarat orde pertama untuk minimum adalah gradien sama dengan nol:

$$\begin{aligned} -2\mathbf{X}^\top \mathbf{W}_i \mathbf{y} + 2\mathbf{X}^\top \mathbf{W}_i \mathbf{X} \hat{\beta} &= \mathbf{0} \\ \mathbf{X}^\top \mathbf{W}_i \mathbf{X} \hat{\beta} &= \mathbf{X}^\top \mathbf{W}_i \mathbf{y}. \end{aligned} \quad (2.7.19)$$

Persamaan terakhir merupakan persamaan normal tertimbang untuk lokasi i . Dengan asumsi bahwa matriks $\mathbf{X}^\top \mathbf{W}_i \mathbf{X}$ adalah nonsingular (invertibel), solusinya adalah

$$\hat{\beta}(u_i, v_i) = (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}_i \mathbf{y}. \quad (2.7.20)$$

Untuk memverifikasi bahwa solusi ini adalah peminimum, diperiksa turunan kedua (matriks Hessian):

$$\frac{\partial^2 S_i(\beta)}{\partial \beta \partial \beta^\top} = 2\mathbf{X}^\top \mathbf{W}_i \mathbf{X}. \quad (2.7.21)$$

Matriks $\mathbf{X}^\top \mathbf{W}_i \mathbf{X}$ adalah semi-definit positif sebab untuk sembarang vektor $\mathbf{v} \in \mathbb{R}^{p+1}$,

$$\mathbf{v}^\top \mathbf{X}^\top \mathbf{W}_i \mathbf{X} \mathbf{v} = (\mathbf{X} \mathbf{v})^\top \mathbf{W}_i (\mathbf{X} \mathbf{v}) = \sum_{j=1}^n w_{ij} (\mathbf{x}_j^\top \mathbf{v})^2 \geq 0, \quad (2.7.22)$$

sebab $w_{ij} \geq 0$ untuk semua j . Jika $\mathbf{X}^\top \mathbf{W}_i \mathbf{X}$ nonsingular, maka matriks ini definit positif, sehingga Hessian definit positif dan $\hat{\beta}(u_i, v_i)$ adalah peminimum global yang unik. ■

Akibat 2.7.7 Nilai prediksi pada lokasi i dapat dituliskan sebagai kombinasi linear dari respons, yaitu

$$\hat{y}_i = \mathbf{x}_i^\top \hat{\beta}(u_i, v_i) = \mathbf{r}_i^\top \mathbf{y}, \quad (2.7.23)$$

dengan $\mathbf{r}_i^\top = \mathbf{x}_i^\top (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}_i$. Secara agregat, vektor prediksi $\hat{\mathbf{y}} = \mathbf{S} \mathbf{y}$, dengan matriks hat GWR

$$\mathbf{S} = \begin{pmatrix} \mathbf{r}_1^\top \\ \mathbf{r}_2^\top \\ \vdots \\ \mathbf{r}_n^\top \end{pmatrix}. \quad (2.7.24)$$

Matriks bobot dibangun menggunakan fungsi *kernel* yang mengukur kedekatan spasial antara lokasi. Fungsi *kernel* ini menentukan bobot w_{ij} yang diberikan pada observasi j saat mengestimasi koefisien di lokasi i . Bobot ini biasanya menurun seiring bertambahnya jarak geografis antara lokasi i dan j . Fungsi *kernel* juga melibatkan parameter *bandwidth* h yang mengontrol tingkat penghalusan (*smoothing*) dari estimasi lokal.

Fungsi *kernel* $K_h : \mathbb{R}^+ \rightarrow \mathbb{R}^+$ memetakan jarak geografis ke bobot non-negatif. Untuk jarak d_{ij} antara lokasi i dan j , bobot didefinisikan sebagai $w_{ij} = K_h(d_{ij})$. Syarat umum untuk fungsi *kernel* sesuai dengan kerangka pemodelan polinomial lokal adalah sebagai berikut.

Asumsi GWR.8 Fungsi kernel $K_h(\cdot)$ memenuhi kondisi berikut.

- (a) $K_h(\cdot)$ adalah fungsi non-negatif, yaitu $K_h(d) \geq 0$ untuk semua $d \geq 0$.
- (b) $K_h(\cdot)$ adalah fungsi menurun, yaitu jika $d_1 < d_2$, maka $K_h(d_1) \geq K_h(d_2)$.
- (c) $K_h(\cdot)$ memiliki penyokong (support) terbatas yang kompak, yaitu terdapat konstanta $C > 0$ sehingga $K_h(d) = 0$ untuk semua $d > Ch$.
- (d) Sesuai asumsi ??, $K_h(\cdot)$ bersifat simeteris, yaitu $\int_0^\infty dK_h(d)f_D(d) dd = 0$.

Asumsi normalisasi atau $\int K_h(d)f_D(d) dd = 1$ tidak diwajibkan dalam konteks GWR karena estimator GWR bersifat invarian terhadap skala bobot.

Beberapa fungsi *kernel* yang umum digunakan adalah sebagai berikut.

(a) **Kernel Gaussian:**

$$w_{ij} = \exp \left(-\frac{1}{2} \left(\frac{d_{ij}}{h} \right)^2 \right). \quad (2.7.25)$$

(b) **Kernel Bi-square (kompak):**

$$w_{ij} = \begin{cases} \left(1 - \left(\frac{d_{ij}}{h} \right)^2 \right)^2 & \text{jika } d_{ij} < h, \\ 0 & \text{jika } d_{ij} \geq h. \end{cases} \quad (2.7.26)$$

(c) **Kernel Tri-cube (kompak):**

$$w_{ij} = \begin{cases} \left(1 - \left(\frac{d_{ij}}{h} \right)^3 \right)^3 & \text{jika } d_{ij} < h, \\ 0 & \text{jika } d_{ij} \geq h. \end{cases} \quad (2.7.27)$$

Perhitungan jarak geografis d_{ij} antara lokasi i dan j biasanya dilakukan menggunakan beberapa pendekatan, seperti jarak Euclidean, jarak Manhattan, atau jarak geodesik (*great circle distance*). Pilihan metrik jarak ini bergantung pada konteks geografis dan karakteristik data yang dianalisis.

Definisi 2.7.8 Misalkan lokasi i memiliki koordinat geografis (u_i, v_i) dan lokasi j memiliki koordinat (u_j, v_j) . Jarak geografis d_{ij} antara lokasi i dan j dihitung menggunakan metrik tertentu, seperti:

(a) **Jarak Euclidean:**

$$d_{ij} = \sqrt{(u_i - u_j)^2 + (v_i - v_j)^2}. \quad (2.7.28)$$

(b) **Jarak Manhattan:**

$$d_{ij} = |u_i - u_j| + |v_i - v_j|. \quad (2.7.29)$$

(c) **Jarak Geodesik (Great Circle Distance):**

$$d_{ij} = R \cdot \arccos(\sin(\phi_i) \sin(\phi_j) + \cos(\phi_i) \cos(\phi_j) \cos(\lambda_i - \lambda_j)), \quad (2.7.30)$$

dengan R adalah jari-jari bumi, (ϕ_i, λ_i) dan (ϕ_j, λ_j) adalah lintang dan bujur lokasi i dan j dalam radian.

Dalam GWR, pemilihan *bandwidth* h sangat penting karena mempengaruhi bias dan variansi dari estimator lokal. *Bandwidth* yang kecil menghasilkan estimasi yang lebih fleksibel namun dengan variansi yang tinggi, sedangkan *bandwidth* yang besar menghasilkan estimasi yang lebih halus namun dengan bias yang lebih besar. Oleh karena itu, pemilihan *bandwidth* yang optimal merupakan langkah krusial dalam penerapan GWR.

Terdapat dua pendekatan utama dalam menentukan *bandwidth* sebagai berikut.

- (a) *Fixed bandwidth*, yaitu parameter h bernilai konstan untuk semua lokasi. Pendekatan ini sesuai ketika observasi terdistribusi secara relatif homogen di ruang geografis.
- (b) *Adaptive bandwidth*, yaitu parameter h_i bervariasi menurut lokasi, biasanya didefinisikan sehingga setiap lokasi memiliki jumlah tetangga efektif yang sama (misalnya, k tetangga terdekat). Secara formal, h_i dipilih sehingga

$$h_i = d_{i[k]}, \quad (2.7.31)$$

dengan $d_{i[k]}$ adalah jarak ke tetangga terdekat ke- k dari lokasi i . Pendekatan ini lebih sesuai ketika kepadatan observasi bervariasi secara spasial.

Definisi 2.7.9 Bandwidth optimal h^* dipilih dengan meminimalkan fungsi leave-one-out cross-validation:

$$CV(h) = \sum_{i=1}^n (y_i - \hat{y}_{\neq i}(h))^2, \quad (2.7.32)$$

dengan $\hat{y}_{\neq i}(h)$ adalah prediksi untuk observasi i menggunakan model yang di-fit tanpa observasi i . Secara eksplisit,

$$h^* = \arg \min_h CV(h). \quad (2.7.33)$$

Ketika *bandwidth* h diestimasi dari data (bukan ditetapkan secara eksogen), terdapat implikasi penting terhadap teori asimtotik, yaitu:

- (a) Estimator \hat{h} bergantung pada \mathbf{y} , sehingga matriks bobot $\mathbf{W}_i(\hat{h})$ menjadi stokastik ($\mathbf{W}_i(\hat{h})$) dan bergantung pada data. Hal ini memperumit derivasi distribusi asimtotik.
- (b) Ketidakpastian dalam \hat{h} menambah variabilitas pada estimator $\hat{\beta}$, yang tidak tercermin dalam formula variansi standar.
- (c) Dalam praktik, sering diasumsikan bahwa $\hat{h} \xrightarrow{p} h_{\text{opt}}$ dengan laju yang cukup cepat sehingga efek estimasi *bandwidth* dapat diabaikan secara asimtotik (*oracle property*). Hasil asimtotik kemudian diturunkan dengan menganggap h sebagai parameter tetap.

Teorema 2.7.10 Di bawah asumsi GWR.1 sampai GWR.8, estimator GWR memiliki bias yang bergantung pada tingkat kehalusan koefisien dan bandwidth, yaitu

$$\mathbb{E}[\hat{\beta}(u_i, v_i)] = \beta(u_i, v_i) + \mathcal{O}(h^2), \quad (2.7.34)$$

dengan suku bias $\mathcal{O}(h^2)$ proporsional dengan turunan kedua dari $\beta(u, v)$ di lokasi i .

Bukti. Berdasarkan asumsi GWR.4, fungsi koefisien $\beta(u, v)$ memiliki turunan parsial kontinu hingga orde kedua. Didefinisikan vektor perpindahan $\delta_{ij} = (u_j - u_i, v_j - v_i)^\top$ dengan norma $d_{ij} = \|\delta_{ij}\|$. Dengan ekspansi Taylor di sekitar lokasi (u_i, v_i) , untuk observasi j dengan lokasi (u_j, v_j) , diperoleh

$$\beta(u_j, v_j) = \beta(u_i, v_i) + \nabla\beta(u_i, v_i)^\top \delta_{ij} + \frac{1}{2} \delta_{ij}^\top \mathbf{H}_\beta(u_i, v_i) \delta_{ij} + R_{ij}, \quad (2.7.35)$$

dengan $\nabla\beta$ adalah gradien dan \mathbf{H}_β adalah matriks Hessian dari β .

Suku sisa $R_{ij} = o(d_{ij}^2)$ karena berdasarkan teorema Taylor dengan sisa Peano, untuk fungsi $\beta : \mathbb{R}^2 \rightarrow \mathbb{R}^{p+1}$ yang memiliki turunan parsial kontinu hingga orde kedua di sekitar (u_i, v_i) , suku sisa setelah ekspansi orde kedua memenuhi

$$\lim_{d_{ij} \rightarrow 0} \frac{\|R_{ij}\|}{d_{ij}^2} = 0, \quad (2.7.36)$$

yang merupakan definisi dari $R_{ij} = o(d_{ij}^2)$. Secara eksplisit, jika turunan orde ketiga ada dan terbatas, maka $R_{ij} = \mathcal{O}(d_{ij}^3)$, yang tentu saja memenuhi $R_{ij} = o(d_{ij}^2)$.

Model GWR yang sebenarnya adalah $y_j = \mathbf{x}_j^\top \beta(u_j, v_j) + \varepsilon_j$. Substitusi ekspansi Taylor memberikan

$$y_j = \mathbf{x}_j^\top \beta(u_i, v_i) + \mathbf{x}_j^\top \mathbf{r}_{ij} + \varepsilon_j, \quad (2.7.37)$$

dengan $\mathbf{r}_{ij} = \nabla\beta(u_i, v_i)^\top \delta_{ij} + \frac{1}{2} \delta_{ij}^\top \mathbf{H}_\beta(u_i, v_i) \delta_{ij} + R_{ij}$ adalah suku sisa deterministik yang mengandung turunan pertama dan kedua dari β . Oleh karena itu, nilai harapan dari estimator LWLS dapat dituliskan sebagai

$$\begin{aligned} \mathbb{E}[\widehat{\beta}(u_i, v_i)] &= \mathbb{E}[(\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}_i \mathbf{y}] \\ &= (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}_i \mathbb{E}[\mathbf{y}] \\ &= (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}_i (\mathbf{X} \beta(u_i, v_i) + \mathbf{X} \mathbf{r}_i), \end{aligned} \quad (2.7.38)$$

dengan $\mathbf{r}_i = (\mathbf{r}_{i1}, \dots, \mathbf{r}_{in})^\top$ adalah vektor suku sisa. Sebab $(\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}_i \mathbf{X} =$

I, maka

$$\mathbb{E}[\hat{\beta}(u_i, v_i)] = \beta(u_i, v_i) + (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}_i \mathbf{X} \mathbf{r}_i. \quad (2.7.39)$$

Dengan menggunakan sifat fungsi *kernel* bahwa bobot w_{ij} terkonsentrasi pada observasi dengan jarak $d_{ij} = \mathcal{O}(h)$ dari lokasi i , suku sisa $\mathbf{r}_{ij} = \mathcal{O}(h^2)$ karena didominasi oleh suku kuadratik dalam ekspansi Taylor. Oleh karena itu, vektor bias adalah

$$\mathbf{b}_i = (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}_i \mathbf{X} \mathbf{r}_i = \mathcal{O}(h^2), \quad (2.7.40)$$

yang proporsional dengan turunan kedua dari $\beta(u, v)$ di lokasi i . ■

Teorema 2.7.11 (Fotheringham dkk., 2002) *Di bawah asumsi GWR.1 sampai GWR.8, matriks kovarians bersyarat dari estimator GWR adalah*

$$\text{Var}(\hat{\beta}(u_i, v_i) \mid \mathbf{X}) = \sigma^2 (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}_i^2 \mathbf{X} (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1}. \quad (2.7.41)$$

Dengan normalisasi yang tepat, variansi adalah $\mathcal{O}((nh^2)^{-1})$.

Bukti. Estimator GWR dapat dituliskan sebagai

$$\hat{\beta}(u_i, v_i) = (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}_i \mathbf{y} = \mathbf{C}_i \mathbf{y}, \quad (2.7.42)$$

dengan $\mathbf{C}_i = (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}_i$.

Berdasarkan asumsi GWR.2, galat $\varepsilon_1, \dots, \varepsilon_n$ bersifat independen dengan $\mathbb{E}[\varepsilon_j] = 0$ dan $\text{Var}(\varepsilon_j) = \sigma^2$ untuk semua j . Dalam notasi matriks, $\text{Var}(\boldsymbol{\varepsilon} \mid \mathbf{X}) = \sigma^2 \mathbf{I}_n$. Sebab $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ dengan \mathbf{X} diperlakukan sebagai tetap (bersyarat), maka

$$\begin{aligned} \text{Var}(\hat{\beta}(u_i, v_i) \mid \mathbf{X}) &= \text{Var}(\mathbf{C}_i \mathbf{y} \mid \mathbf{X}) \\ &= \mathbf{C}_i \text{Var}(\mathbf{y} \mid \mathbf{X}) \mathbf{C}_i^\top \\ &= \mathbf{C}_i (\sigma^2 \mathbf{I}_n) \mathbf{C}_i^\top \\ &= \sigma^2 \mathbf{C}_i \mathbf{C}_i^\top. \end{aligned} \quad (2.7.43)$$

Substitusi $\mathbf{C}_i = (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}_i$ memberikan

$$\begin{aligned} \mathbf{C}_i \mathbf{C}_i^\top &= (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}_i [(\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}_i]^\top \\ &= (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}_i \mathbf{W}_i^\top \mathbf{X} (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1}. \end{aligned} \quad (2.7.44)$$

Sebab \mathbf{W}_i adalah matriks diagonal simetris, maka $\mathbf{W}_i^\top = \mathbf{W}_i$ dan $\mathbf{W}_i \mathbf{W}_i = \mathbf{W}_i^2$. Demikian pula, $(\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-\top} = (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1}$ karena matriks ini simetris. Oleh karena itu,

$$\text{Var}(\hat{\beta}(u_i, v_i) \mid \mathbf{X}) = \sigma^2 (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}_i^2 \mathbf{X} (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1}. \quad (2.7.45)$$

Untuk menunjukkan bahwa variansi adalah $\mathcal{O}((nh^2)^{-1})$, perhatikan bahwa dengan *bandwidth* h , jumlah observasi efektif yang berkontribusi signifikan pada estimasi lokal adalah $n_{\text{eff}} \approx n \cdot \pi h^2 / A$, dengan A adalah luas wilayah studi. Dengan asumsi kepadatan observasi yang seragam, $n_{\text{eff}} = \mathcal{O}(nh^2)$. Sebab variansi estimator berbanding terbalik dengan jumlah observasi efektif, maka $\text{Var}(\hat{\beta}(u_i, v_i)) = \mathcal{O}((nh^2)^{-1})$. ■

Teorema 2.7.12 *Estimator konsisten untuk σ^2 diberikan oleh*

$$\hat{\sigma}^2 = \frac{\mathbf{e}^\top \mathbf{e}}{n - 2\text{tr}(\mathbf{S}) + \text{tr}(\mathbf{S}^\top \mathbf{S})}, \quad (2.7.46)$$

dengan $\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}$ adalah vektor residual dan penyebut merepresentasikan derajat bebas efektif residual.

Bukti. Vektor nilai prediksi GWR dapat dituliskan sebagai $\hat{\mathbf{y}} = \mathbf{S}\mathbf{y}$, dengan \mathbf{S} adalah matriks topi GWR yang baris ke- i -nya adalah $\mathbf{s}_i^\top = \mathbf{x}_i^\top (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}_i$. Vektor residual adalah

$$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}} = (\mathbf{I} - \mathbf{S})\mathbf{y}. \quad (2.7.47)$$

Dengan model $\mathbf{y} = \boldsymbol{\mu} + \boldsymbol{\varepsilon}$ dengan $\mathbb{E}[\boldsymbol{\varepsilon}] = \mathbf{0}$ dan $\text{Var}(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}$, nilai harapan

dari jumlah kuadrat residual adalah

$$\begin{aligned}
 \mathbb{E}[\mathbf{e}^\top \mathbf{e}] &= \mathbb{E}[\mathbf{y}^\top (\mathbf{I} - \mathbf{S})^\top (\mathbf{I} - \mathbf{S}) \mathbf{y}] \\
 &= \mathbb{E}[\text{tr}((\mathbf{I} - \mathbf{S}) \mathbf{y} \mathbf{y}^\top (\mathbf{I} - \mathbf{S})^\top)] \\
 &= \text{tr}((\mathbf{I} - \mathbf{S}) \mathbb{E}[\mathbf{y} \mathbf{y}^\top] (\mathbf{I} - \mathbf{S})^\top).
 \end{aligned} \tag{2.7.48}$$

Sebab $\mathbb{E}[\mathbf{y} \mathbf{y}^\top] = \boldsymbol{\mu} \boldsymbol{\mu}^\top + \sigma^2 \mathbf{I}$, dengan asumsi bahwa model GWR benar sehingga $(\mathbf{I} - \mathbf{S}) \boldsymbol{\mu} \approx \mathbf{0}$ (mengabaikan bias), diperoleh

$$\begin{aligned}
 \mathbb{E}[\mathbf{e}^\top \mathbf{e}] &\approx \sigma^2 \text{tr}((\mathbf{I} - \mathbf{S})(\mathbf{I} - \mathbf{S})^\top) \\
 &= \sigma^2 \text{tr}(\mathbf{I} - \mathbf{S} - \mathbf{S}^\top + \mathbf{S}^\top \mathbf{S}) \\
 &= \sigma^2 (n - \text{tr}(\mathbf{S}) - \text{tr}(\mathbf{S}^\top) + \text{tr}(\mathbf{S}^\top \mathbf{S})) \\
 &= \sigma^2 (n - 2\text{tr}(\mathbf{S}) + \text{tr}(\mathbf{S}^\top \mathbf{S})),
 \end{aligned} \tag{2.7.49}$$

dengan menggunakan sifat $\text{tr}(\mathbf{S}^\top) = \text{tr}(\mathbf{S})$.

Perlu dicatat bahwa matriks \mathbf{S} dalam GWR umumnya tidak simetris dan tidak idempoten, berbeda dengan matriks *hat* dalam regresi OLS standar. Oleh karena itu, derajat bebas efektif residual bukan $n - p$, melainkan

$$\nu = n - 2\text{tr}(\mathbf{S}) + \text{tr}(\mathbf{S}^\top \mathbf{S}). \tag{2.7.50}$$

Dengan demikian, estimator tak bias untuk σ^2 adalah

$$\hat{\sigma}^2 = \frac{\mathbf{e}^\top \mathbf{e}}{n - 2\text{tr}(\mathbf{S}) + \text{tr}(\mathbf{S}^\top \mathbf{S})}, \tag{2.7.51}$$

yang memenuhi $\mathbb{E}[\hat{\sigma}^2] = \sigma^2$. Konsistensi mengikuti dari hukum bilangan besar karena baik pembilang maupun penyebut konvergen ke nilai-nilai yang tepat ketika $n \rightarrow \infty$. ■

Berdasarkan teorema-teorema di atas, diperoleh hasil penting mengenai kondisi *bandwidth* untuk konsistensi estimator GWR, yaitu *trade-off* antara bias dan va-

riansi.

Akibat 2.7.13 Mean Squared Error (*MSE*) estimator GWR adalah

$$\text{MSE}(\hat{\beta}(u_i, v_i)) = \text{Bias}^2 + \text{Var} = \mathcal{O}(h^4) + \mathcal{O}((nh^2)^{-1}). \quad (2.7.52)$$

Untuk mencapai konsistensi ($\text{MSE} \rightarrow 0$ ketika $n \rightarrow \infty$), diperlukan:

- (i) $h \rightarrow 0$ agar bias $\mathcal{O}(h^2) \rightarrow 0$, dan
- (ii) $nh^2 \rightarrow \infty$ agar variansi $\mathcal{O}((nh^2)^{-1}) \rightarrow 0$.

Ini menjadi dasar terbentuknya asumsi GWR.6.

Selanjutnya, analisis asimtotik dari estimator GWR dan uji statistik yang relevan dijelaskan di bawah ini.

Teorema 2.7.14 Di bawah asumsi GWR.1 sampai GWR.8, estimator GWR bersifat konsisten:

$$\hat{\beta}(u_i, v_i) \xrightarrow{p} \beta(u_i, v_i). \quad (2.7.53)$$

Bukti. Konsistensi ditunjukkan dengan membuktikan bahwa $\text{MSE}(\hat{\beta}(u_i, v_i)) \rightarrow 0$ ketika $n \rightarrow \infty$. Dari teorema bias dan variansi yang telah dibuktikan sebelumnya, diperoleh

$$\text{MSE}(\hat{\beta}(u_i, v_i)) = \|\text{Bias}\|^2 + \text{tr}(\text{Var}) = \mathcal{O}(h^4) + \mathcal{O}((nh^2)^{-1}). \quad (2.7.54)$$

Di bawah kondisi $h \rightarrow 0$ dan $nh^2 \rightarrow \infty$ ketika $n \rightarrow \infty$:

- (i) Suku bias $\mathcal{O}(h^4) \rightarrow 0$ karena $h \rightarrow 0$.
- (ii) Suku variansi $\mathcal{O}((nh^2)^{-1}) \rightarrow 0$ karena $nh^2 \rightarrow \infty$.

Oleh karena itu, $\text{MSE}(\hat{\beta}(u_i, v_i)) \rightarrow 0$. Dengan ketaksamaan Chebyshev, untuk setiap $\varepsilon > 0$,

$$P\left(\|\hat{\beta}(u_i, v_i) - \beta(u_i, v_i)\| > \varepsilon\right) \leq \frac{\text{MSE}(\hat{\beta}(u_i, v_i))}{\varepsilon^2} \rightarrow 0, \quad (2.7.55)$$

yang menunjukkan konvergensi dalam probabilitas $\widehat{\beta}(u_i, v_i) \xrightarrow{p} \beta(u_i, v_i)$. ■

Teorema 2.7.15 *Di bawah kondisi yang sama dengan teorema konsistensi, estimator variansi $\hat{\sigma}^2$ bersifat konsisten:*

$$\hat{\sigma}^2 \xrightarrow{p} \sigma^2. \quad (2.7.56)$$

Bukti. Estimator variansi adalah $\hat{\sigma}^2 = \mathbf{e}^\top \mathbf{e} / \nu$ dengan $\nu = n - 2\text{tr}(\mathbf{S}) + \text{tr}(\mathbf{S}^\top \mathbf{S})$. Vektor residual dapat ditulis sebagai

$$\mathbf{e} = (\mathbf{I} - \mathbf{S})\mathbf{y} = (\mathbf{I} - \mathbf{S})(\boldsymbol{\mu} + \boldsymbol{\varepsilon}), \quad (2.7.57)$$

dengan $\boldsymbol{\mu} = \mathbb{E}[\mathbf{y}]$.

Jumlah kuadrat residual dapat didekomposisi sebagai

$$\mathbf{e}^\top \mathbf{e} = \boldsymbol{\varepsilon}^\top (\mathbf{I} - \mathbf{S})^\top (\mathbf{I} - \mathbf{S}) \boldsymbol{\varepsilon} + 2\boldsymbol{\mu}^\top (\mathbf{I} - \mathbf{S})^\top (\mathbf{I} - \mathbf{S}) \boldsymbol{\varepsilon} + \boldsymbol{\mu}^\top (\mathbf{I} - \mathbf{S})^\top (\mathbf{I} - \mathbf{S}) \boldsymbol{\mu}. \quad (2.7.58)$$

Di bawah kondisi konsistensi, estimator GWR konsisten sehingga berlaku $(\mathbf{I} - \mathbf{S})\boldsymbol{\mu} \xrightarrow{p} \mathbf{0}$, yang berarti suku ketiga menjadi hilang. Suku kedua memiliki nilai harapan nol. Untuk suku pertama, dengan hukum bilangan besar,

$$\frac{1}{\nu} \boldsymbol{\varepsilon}^\top (\mathbf{I} - \mathbf{S})^\top (\mathbf{I} - \mathbf{S}) \boldsymbol{\varepsilon} \xrightarrow{p} \sigma^2, \quad (2.7.59)$$

karena $\mathbb{E}[\boldsymbol{\varepsilon}^\top (\mathbf{I} - \mathbf{S})^\top (\mathbf{I} - \mathbf{S}) \boldsymbol{\varepsilon}] = \sigma^2 \nu$ dan variansi dari kuantitas ini berkurang seiring bertambahnya n . Oleh karena itu, $\hat{\sigma}^2 \xrightarrow{p} \sigma^2$. ■

Teorema 2.7.16 *Di bawah asumsi GWR.1 sampai GWR.8 dan dengan bandwidth h diperlakukan sebagai diketahui (atau diestimasi dengan properti oracle), estimator GWR memiliki distribusi asimtotik:*

$$\sqrt{nh^2} \left(\widehat{\beta}(u_i, v_i) - \beta(u_i, v_i) - \mathbf{b}_i \right) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma}_i), \quad (2.7.60)$$

dengan $\boldsymbol{\Sigma}_i$ adalah matriks kovarians asimtotik yang bergantung pada σ^2 , kepadat-

an spasial $f(u_i, v_i)$, dan kekasaran kernel.

Secara praktis, dengan mengabaikan bias (melalui undersmoothing atau koreksi bias), berlaku

$$\hat{\beta}(u_i, v_i) \sim \mathcal{N}(\beta(u_i, v_i), \sigma^2(\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}_i^2 \mathbf{X} (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1}). \quad (2.7.61)$$

Bukti. Estimator GWR dapat dituliskan sebagai

$$\hat{\beta}(u_i, v_i) = \beta(u_i, v_i) + \mathbf{b}_i + (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}_i \boldsymbol{\varepsilon}, \quad (2.7.62)$$

dengan $\mathbf{b}_i = \mathcal{O}(h^2)$ adalah bias deterministik. Mendefinisikan

$$\mathbf{Z}_i = (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}_i \boldsymbol{\varepsilon} = \sum_{j=1}^n c_{ij} \varepsilon_j, \quad (2.7.63)$$

dengan c_{ij} adalah elemen dari matriks $\mathbf{C}_i = (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}_i$. Sebab ε_j independen dengan $\mathbb{E}[\varepsilon_j] = 0$ dan $\text{Var}(\varepsilon_j) = \sigma^2$, maka \mathbf{Z}_i adalah kombinasi linear dari variabel acak independen. Untuk menerapkan teorema limit pusat (CLT), perlu ditunjukkan bahwa kondisi Lindeberg terpenuhi.

Dengan *bandwidth* h , bobot w_{ij} terkonsentrasi pada $n_{\text{eff}} = \mathcal{O}(nh^2)$ observasi dengan jarak $\mathcal{O}(h)$ dari lokasi i . Variansi dari \mathbf{Z}_i adalah

$$\text{Var}(\mathbf{Z}_i) = \sigma^2 (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}_i^2 \mathbf{X} (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} = \mathcal{O}((nh^2)^{-1}). \quad (2.7.64)$$

Dengan normalisasi $\sqrt{nh^2}$, diperoleh

$$\sqrt{nh^2} \mathbf{Z}_i = \sqrt{nh^2} \sum_{j=1}^n c_{ij} \varepsilon_j. \quad (2.7.65)$$

Kondisi Lindeberg terpenuhi karena bobot w_{ij} dari fungsi *kernel* menurun secara halus dan tidak ada observasi tunggal yang mendominasi. Secara spesifik, kontribusi maksimum individual adalah $\mathcal{O}((nh^2)^{-1})$, yang menuju nol relatif terhadap total variansi.

Dengan teorema limit pusat Lindeberg-Feller, diperoleh

$$\sqrt{nh^2} \left(\hat{\beta}(u_i, v_i) - \beta(u_i, v_i) - \mathbf{b}_i \right) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \Sigma_i), \quad (2.7.66)$$

dengan $\Sigma_i = \lim_{n \rightarrow \infty} nh^2 \cdot \text{Var}(\mathbf{Z}_i)$ adalah matriks kovarians asimtotik. ■

Ketika *bandwidth* diestimasi menggunakan CV, hal yang akan terjadi adalah sebagai berikut.

- (a) Jika \hat{h} konsisten dan memiliki laju konvergensi $\hat{h} - h_{\text{opt}} = \mathcal{O}_p(n^{-\alpha})$ untuk $\alpha > 0$ yang cukup besar, maka distribusi asimtotik estimator koefisien tidak terpengaruh secara orde pertama (*oracle property*).
- (b) Untuk sampel hingga, variabilitas tambahan dari estimasi *bandwidth* dapat menyebabkan interval konfidensi yang sedikit *undercoverage*.
- (c) Metode *bootstrap* dapat digunakan untuk memperhitungkan ketidakpastian estimasi *bandwidth*.

Teorema 2.7.17 Untuk menguji $H_0 : \beta_k(u_i, v_i) = 0$ lawan $H_1 : \beta_k(u_i, v_i) \neq 0$, statistik uji adalah

$$t_k(u_i, v_i) = \frac{\hat{\beta}_k(u_i, v_i)}{\text{se}(\hat{\beta}_k(u_i, v_i))}, \quad (2.7.67)$$

dengan

$$\text{se}(\hat{\beta}_k(u_i, v_i)) = \hat{\sigma} \sqrt{\mathbf{e}_{k+1}^\top (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}_i^2 \mathbf{X} (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{e}_{k+1}}, \quad (2.7.68)$$

dan \mathbf{e}_{k+1} adalah vektor unit ke- $(k+1)$. Di bawah H_0 , statistik ini mengikuti distribusi t dengan derajat bebas efektif $\nu = n - 2\text{tr}(\mathbf{S}) + \text{tr}(\mathbf{S}^\top \mathbf{S})$, atau secara asimtotik $\mathcal{N}(0, 1)$.

Bukti. Dari teorema normalitas asimtotik, estimator $\hat{\beta}_k(u_i, v_i)$ mengikuti distribusi normal asimtotik. Secara spesifik, komponen ke- $(k+1)$ dari vektor estimator memenuhi

$$\hat{\beta}_k(u_i, v_i) \sim \mathcal{N}(\beta_k(u_i, v_i), \sigma^2 v_{k,i}), \quad (2.7.69)$$

dengan $v_{k,i} = \mathbf{e}_{k+1}^\top (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}_i^2 \mathbf{X} (\mathbf{X}^\top \mathbf{W}_i \mathbf{X})^{-1} \mathbf{e}_{k+1}$ adalah elemen diagonal ke- $(k+1)$ dari matriks kovarians sandwich.

Di bawah hipotesis nol $H_0 : \beta_k(u_i, v_i) = 0$, statistik

$$Z_k = \frac{\hat{\beta}_k(u_i, v_i)}{\sigma \sqrt{v_{k,i}}} \xrightarrow{d} \mathcal{N}(0, 1). \quad (2.7.70)$$

Sebab σ^2 tidak diketahui, digunakan estimator konsisten $\hat{\sigma}^2$. Dari teorema konsistensi estimator variansi, $\hat{\sigma}^2 \xrightarrow{p} \sigma^2$. Dengan teorema Slutsky,

$$t_k(u_i, v_i) = \frac{\hat{\beta}_k(u_i, v_i)}{\hat{\sigma} \sqrt{v_{k,i}}} = \frac{Z_k}{\hat{\sigma}/\sigma} \xrightarrow{d} \mathcal{N}(0, 1). \quad (2.7.71)$$

Untuk sampel hingga, aproksimasi distribusi t dengan derajat bebas $\nu = n - 2\text{tr}(\mathbf{S}) + \text{tr}(\mathbf{S}^\top \mathbf{S})$ memberikan hasil yang lebih akurat karena memperhitungkan ketidakpastian dalam estimasi σ^2 . ■

Teorema 2.7.18 (Leung, Mei, dan Zhang, 2000) Untuk menguji H_0 : koefisien stasioner (konstan di semua lokasi) atau $\beta_k(u_i, v_i) = \beta_k$ lawan H_1 : koefisien bervariasi secara spasial, digunakan statistik F berikut.

$$F = \frac{\text{RSS}_{\text{GWR}}/\nu_1}{\text{RSS}_{\text{OLS}}/(n-p-1)}, \quad (2.7.72)$$

dengan $\text{RSS}_{\text{OLS}} = (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}_{\text{OLS}})^\top (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}_{\text{OLS}})$, $\text{RSS}_{\text{GWR}} = (\mathbf{y} - \mathbf{S}\mathbf{y})^\top (\mathbf{y} - \mathbf{S}\mathbf{y})$, dan $\nu_1 = n - 2\text{tr}(\mathbf{S}) + \text{tr}(\mathbf{S}^\top \mathbf{S})$. Di bawah H_0 , statistik ini mengikuti distribusi F secara aproksimasi dengan derajat bebas $r = \frac{\nu_1^2}{\text{tr}[(\mathbf{I}-\mathbf{S})^\top (\mathbf{I}-\mathbf{S})]^2}$ dan $n-p-1$.

Bukti. Uji ini membandingkan model terbatas (OLS global) dengan model penuh (GWR lokal). Residual kedua model dapat ditulis sebagai

$$\mathbf{e}_{\text{OLS}} = (\mathbf{I} - \mathbf{H})\mathbf{y}, \quad (2.7.73)$$

$$\mathbf{e}_{\text{GWR}} = (\mathbf{I} - \mathbf{S})\mathbf{y}, \quad (2.7.74)$$

dengan $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$ adalah matriks topi OLS dan \mathbf{S} adalah matriks penga-

ruh GWR.

Di bawah H_0 bahwa koefisien konstan, kedua model mempunyai nilai harapan yang sama. Perbedaannya adalah GWR menggunakan estimasi lokal yang lebih fleksibel. Sebab GWR lebih fleksibel, RSS dari GWR akan cenderung lebih kecil dari RSS dari OLS, yaitu $RSS_{GWR} \leq RSS_{OLS}$.

Matriks residual OLS mempunyai derajat bebas residual $\nu_{OLS} = n - p - 1$ karena $\text{tr}(\mathbf{H}) = p + 1$. Untuk model GWR, meskipun \mathbf{S} tidak idempoten, derajat bebas residual efektif dapat didekati melalui Satterthwaite correction sebagai:

$$\nu_{GWR} = n - 2\text{tr}(\mathbf{S}) + \text{tr}(\mathbf{S}^\top \mathbf{S}). \quad (2.7.75)$$

Statistik F yang digunakan membandingkan mean squared error (MSE) kedua model:

$$F = \frac{MSE_{GWR}}{MSE_{OLS}} = \frac{RSS_{GWR}/\nu_{GWR}}{RSS_{OLS}/(n - p - 1)}, \quad (2.7.76)$$

dimana $\nu_{GWR} = n - 2\text{tr}(\mathbf{S}) + \text{tr}(\mathbf{S}^\top \mathbf{S}) = \nu_1$ sesuai definisi dalam teorema.

Di bawah H_0 dengan $\epsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$, bentuk RSS_{OLS}/σ^2 dan RSS_{GWR}/σ^2 masing-masing mengikuti distribusi chi-square yang dimodifikasi. Rasio dari MSE keduanya akan mengikuti distribusi F secara aproksimasi. Karena bobot lokal GWR menciptakan korelasi residual, derajat bebas efektif pembilang harus dikalibrasi melalui aproksimasi Satterthwaite, menghasilkan derajat bebas aproksimasi $r = \frac{\nu_1^2}{\text{tr}[(\mathbf{I} - \mathbf{S})^\top (\mathbf{I} - \mathbf{S})]^2}$ untuk pembilang dan derajat bebas penyebut $n - p - 1$.

Di bawah H_0 , statistik F mengikuti distribusi $F(r, n - p - 1)$ secara aproksimasi. ■

Teorema 2.7.19 (Leung dkk., 2000) Untuk menguji apakah koefisien tertentu β_k bervariasi secara spasial dengan $H_0 : \beta_k(u_i, v_i) = \beta_k(u_j, v_j), \forall i, j, i \neq j$ (konstan) lawan $H_1 : \exists i, j$ sehingga $\beta_k(u_i, v_i) \neq \beta_k(u_j, v_j)$, dapat digunakan statistik uji variabilitas spasial, yaitu

$$V_k^2 = \frac{1}{n} \sum_{i=1}^n \left(\hat{\beta}_k(u_i, v_i) - \bar{\hat{\beta}}_k \right)^2, \quad (2.7.77)$$

dengan $\bar{\hat{\beta}}_k = \frac{1}{n} \sum_{i=1}^n \hat{\beta}_k(u_i, v_i)$. Di bawah H_0 , statistik ini mengikuti distribusi F .

Bukti. Definisikan matriks \mathbf{J} sebagai matriks $n \times n$ dengan semua elemen bernilai satu, yaitu

$$\mathbf{J} := \begin{bmatrix} 1 & 1 & \cdots & 1 \\ 1 & 1 & \cdots & 1 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & \cdots & 1 \end{bmatrix}.$$

Statistik V_k^2 dapat ditulis ulang sebagai

$$V_k^2 = \frac{1}{n} \widehat{\boldsymbol{\beta}}_k^\top \left(\mathbf{I} - \frac{1}{n} \mathbf{J} \right) \widehat{\boldsymbol{\beta}}_k, \quad (2.7.78)$$

dengan $\widehat{\boldsymbol{\beta}}_k = [\hat{\beta}_k(u_1, v_1), \hat{\beta}_k(u_2, v_2), \dots, \hat{\beta}_k(u_n, v_n)]^\top$.

Di bawah H_0 , asumsikan bahwa rata-rata dari koefisien lokal adalah konstan, yaitu $\mathbb{E}[\hat{\beta}_k(u_i, v_i)] = \mu_k$ untuk semua i . Dengan demikian, vektor $\mathbb{E}[\widehat{\boldsymbol{\beta}}_k] = \mu_k \mathbf{1}_n$, dengan $\mathbf{1}_n$ adalah vektor satuan berukuran n . Selanjutnya, perhatikan bahwa $\mathbf{1}_n^\top (\mathbf{I} - \frac{1}{n} \mathbf{J}) = \mathbf{0}^\top$ dan $(\mathbf{I} - \frac{1}{n} \mathbf{J}) \mathbf{1}_n = \mathbf{0}$, sehingga statistik V_k^2 dapat diekspresikan sebagai berikut.

$$V_k^2 = \frac{1}{n} (\widehat{\boldsymbol{\beta}}_k - \mu_k \mathbf{1}_n)^\top \left(\mathbf{I} - \frac{1}{n} \mathbf{J} \right) (\widehat{\boldsymbol{\beta}}_k - \mu_k \mathbf{1}_n). \quad (2.7.79)$$

Definisikan $\boldsymbol{\delta}_k = \widehat{\boldsymbol{\beta}}_k - \mu_k \mathbf{1}_n = [\delta_{k1}, \delta_{k2}, \dots, \delta_{kn}]^\top$ sebagai deviasi dari nilai harapan, dengan $\delta_{ki} = \hat{\beta}_k(u_i, v_i) - \mu_k$. Dari teori GWR, di bawah H_0 dengan asumsi normalitas:

$$\boldsymbol{\delta}_k \sim \mathcal{N}(\mathbf{0}, \sigma_k^2 \boldsymbol{\Sigma}_k), \quad (2.7.80)$$

dimana $\boldsymbol{\Sigma}_k$ adalah matriks kovarians dari estimator lokal dengan elemen diagonal $\text{Var}(\hat{\beta}_k(u_i, v_i))$ dan elemen off-diagonal merepresentasikan korelasi spasial antar estimator.

Bentuk kuadratik $\boldsymbol{\delta}_k^\top (\mathbf{I} - \frac{1}{n} \mathbf{J}) \boldsymbol{\delta}_k / \sigma_k^2$ mengikuti distribusi yang kompleks karena matriks $(\mathbf{I} - \frac{1}{n} \mathbf{J})$ dan $\boldsymbol{\Sigma}_k$ keduanya non-idempoten. Namun, dengan menggunakan aproksimasi Satterthwaite untuk mencocokkan derajat bebas efektif, statistik

yang dinormalisasi:

$$F_k = \frac{n \cdot V_k^2 / 1}{\hat{\sigma}_k^2 / (n - 2\text{tr}(\mathbf{S}) + \text{tr}(\mathbf{S}^\top \mathbf{S}))}, \quad (2.7.81)$$

akan mengikuti distribusi F secara aproksimasi. Di sini, pembilang memiliki derajat bebas $\nu_1 = 1$ (mengukur variabilitas koefisien spesifik β_k) dan penyebut memiliki derajat bebas $\nu_2 = n - 2\text{tr}(\mathbf{S}) + \text{tr}(\mathbf{S}^\top \mathbf{S})$ (derajat bebas residual efektif GWR). ■

2.8 Jaringan Saraf Tiruan

Jaringan Saraf Tiruan (JST) atau *artificial neural networks* (ANN) mempelajari pemetaan nonlinier dari ruang masukan ke keluaran melalui komposisi berlapis fungsi-fungsi sederhana (Bishop, 1995; Goodfellow, Bengio, dan Courville, 2016; Haykin, 2009).

2.8.1 Model Dasar dan Notasi

Definisi 2.8.1 (Neuron tiruan, Haykin 2009) Diberikan $\mathbf{x} \in \mathbb{R}^p$, neuron menghasilkan

$$y = \phi(\mathbf{w}^\top \mathbf{x} + b), \quad (2.8.1)$$

dengan $\mathbf{w} \in \mathbb{R}^p$ adalah bobot, $b \in \mathbb{R}$ adalah bias, dan $\phi : \mathbb{R} \rightarrow \mathbb{R}$ adalah fungsi aktivasi nonlinier terdiferensiasi hampir di semua titik.

Definisi 2.8.2 (Jaringan *feedforward* multilapis Bishop 1995) Untuk L lapisan tersembunyi, definisikan rekursi

$$\mathbf{z}^{(l)} = \mathbf{W}^{(l)} \mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}, \quad \mathbf{a}^{(l)} = \phi^{(l)}(\mathbf{z}^{(l)}), \quad l = 1, \dots, L, \quad (2.8.2)$$

dengan $\mathbf{a}^{(0)} = \mathbf{x}$ dan keluaran akhir $\hat{y} = g(\mathbf{a}^{(L)})$. Parameter jaringan $\Theta = \{\mathbf{W}^{(l)}, \mathbf{b}^{(l)}\}_{l=1}^L$ dipelajari dari data.

Contoh 2.8.3 Misalkan $\mathbf{x} = (1, 2)^\top$, bobot $\mathbf{w} = (0, 5, 0, 25)^\top$, bias $b = 1$, dan

$\varphi(z) = \tanh(z)$. Maka keluaran neuron adalah

$$y = \tanh(0,5 \cdot 1 + 0,25 \cdot 2 + 1) = \tanh(2) \approx 0,964.$$

2.8.2 Fungsi Aktivasi

Fungsi aktivasi memperkenalkan non-linearitas pada ANN. Tanpa fungsi aktivasi non-linear, jaringan saraf hanya merepresentasikan transformasi linear berlapis.

Definisi 2.8.4 (Fungsi Sigmoid) *Fungsi sigmoid didefinisikan sebagai*

$$\varphi(z) = \frac{1}{1 + e^{-z}}. \quad (2.8.3)$$

Contoh 2.8.5 Jika $z = -10$, maka

$$\varphi(-10) = \frac{1}{1 + e^{10}} \approx \frac{1}{1 + 22026,5} \approx 4,54 \times 10^{-5}.$$

Fungsi sigmoid sangat jenuh untuk $|z|$ besar, gradiennya mendekati nol.

Definisi 2.8.6 (Fungsi Tanh) *Fungsi tanh didefinisikan sebagai*

$$\varphi(z) = \tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}. \quad (2.8.4)$$

Contoh 2.8.7 Jika $z = 0$, maka

$$\varphi(0) = \tanh(0) = 0.$$

Jika $z = 2$, maka

$$\varphi(2) = \frac{e^2 - e^{-2}}{e^2 + e^{-2}} \approx \frac{7,389 - 0,135}{7,389 + 0,135} \approx \frac{7,254}{7,524} \approx 0,964.$$

Jika $z = -2$, maka

$$\varphi(-2) = \frac{e^{-2} - e^2}{e^{-2} + e^2} \approx \frac{0,135 - 7,389}{0,135 + 7,389} \approx \frac{-7,254}{7,524} \approx -0,964.$$

Fungsi tanh memiliki *range* $(-1, 1)$ dan gradien maksimum di sekitar $z = 0$.

Definisi 2.8.8 (Fungsi ReLU, Nair dan Hinton 2010) *Fungsi ReLU (Rectified Linear Unit) didefinisikan sebagai*

$$\varphi(z) = \max(0, z). \quad (2.8.5)$$

Contoh 2.8.9 Jika $z = -3$, maka $\varphi(z) = 0$. Jika $z = 2,5$, maka $\varphi(z) = 2,5$.

Definisi 2.8.10 (Fungsi Leaky ReLU) *Fungsi Leaky ReLU mengatasi masalah dying ReLU dengan*

$$\varphi(z) = \begin{cases} z, & z \geq 0, \\ \alpha z, & z < 0, \end{cases} \quad (2.8.6)$$

dengan $\alpha \in (0, 1)$ kecil, misalnya 0,01.

Contoh 2.8.11 Jika $z = -3$ dan $\alpha = 0,01$, maka $\varphi(z) = -0,03$. Jika $z = 2$, maka $\varphi(z) = 2$.

Definisi 2.8.12 (Fungsi GELU) *Fungsi Gaussian Error Linear Unit (GELU) adalah*

$$\varphi(z) = z \cdot \Phi(z), \quad (2.8.7)$$

dengan $\Phi(z)$ fungsi distribusi normal standar. Aproksimasi praktisnya adalah sebagai berikut.

$$\varphi(z) \approx 0,5z \left(1 + \tanh \left[\sqrt{\frac{2}{\pi}} (z + 0,0447z^3) \right] \right). \quad (2.8.8)$$

Contoh 2.8.13 Untuk $z = 1$, $\varphi(1) \approx 0,84$. Untuk $z = -1$, $\varphi(-1) \approx -0,16$.

Lema 2.8.14 *Fungsi aktivasi $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ yang digunakan pada jaringan saraf*

tiruan sebaiknya memenuhi:

- (i) φ non-linear;
- (ii) φ terdiferensiasi hampir di semua titik,
- (iii) φ tidak konstan, dan
- (iv) φ memiliki range memadai, tidak menyebabkan saturasi total.

Bukti.

- (i) Jika φ linear, misalnya $\varphi(z) = az + b$, maka suatu multilayer perceptron dengan L lapisan menghasilkan

$$f(\mathbf{x}) = \mathbf{W}^{(L)}\varphi(\mathbf{W}^{(L-1)}\varphi(\dots\varphi(\mathbf{W}^{(1)}\mathbf{x}))) = \mathbf{W}'\mathbf{x} + \mathbf{b}',$$

dengan $\mathbf{W}' = \prod_{l=1}^L a\mathbf{W}^{(l)}$ dan \mathbf{b}' kombinasi linear dari b . Komposisi tersebut tetap linear. Akibatnya, jaringan tidak lebih kuat daripada regresi linear biasa dan tidak mampu mengaproksimasi fungsi nonlinear, misalnya XOR.

- (ii) Algoritma *backpropagation* memerlukan turunan $\varphi'(z)$ untuk menghitung gradien fungsi kerugian L . Dengan notasi $\mathbf{z}^{(l)} = \mathbf{W}^{(l)}\mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}$ dan $\mathbf{a}^{(l)} = \varphi(\mathbf{z}^{(l)})$, bentuk umum gradien adalah

$$\frac{\partial L}{\partial \mathbf{W}^{(l)}} = \delta^{(l)} (\mathbf{a}^{(l-1)})^\top, \quad \delta^{(l)} = (\mathbf{W}^{(l+1)})^\top \delta^{(l+1)} \odot \varphi'(\mathbf{z}^{(l)}).$$

Jika $\varphi'(z)$ tidak terdefinisi pada banyak titik, maka gradien tidak dapat dihitung. Oleh karena itu, φ setidaknya harus terdiferensiasi hampir di semua titik. Fungsi seperti ReLU tetap sah karena ketakdiferensialan hanya terjadi pada $z = 0$ (himpunan titik ukuran nol).

- (iii) Jika $\varphi(z) = c$ konstan, maka $\varphi'(z) = 0$ untuk semua z . Substitusi ke rumus *backpropagation* menghasilkan $\delta^{(l)} = \mathbf{0}$ untuk semua l , sehingga

$$\frac{\partial L}{\partial \mathbf{W}^{(l)}} = \mathbf{0}.$$

Bobot tidak akan pernah diperbarui, sehingga proses pelatihan tidak berjalan.

- (iv) Jika φ cepat jenuh, misalnya sigmoid dengan limit $\varphi(z) \rightarrow 0$ untuk $z \rightarrow -\infty$ dan $\varphi(z) \rightarrow 1$ untuk $z \rightarrow +\infty$, maka untuk $|z|$ besar berlaku

$$\varphi'(z) = \varphi(z)(1 - \varphi(z)) \approx 0.$$

Akibatnya, besaran kesalahan terpropagasi $\delta^{(l)}$ mengecil secara eksponensial menuju nol (fenomena *vanishing gradient*). Hal ini dapat menggagalkan pembelajaran pada lapisan-lapisan dalam. Untuk mengatasinya, digunakan fungsi aktivasi dengan rentang yang lebih lebar atau gradien yang tidak menghilang, misalnya ReLU atau Leaky ReLU.

■

2.8.3 Fungsi Kerugian dan Kriteria Pembelajaran

Definisi 2.8.15 (Risiko empiris, Goodfellow dkk. 2016) Diberikan data terawasi $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$ dan model prediksi $\hat{y}_i = f_{\Theta}(\mathbf{x}_i)$, tujuan pembelajaran adalah meminimalkan

$$L(\Theta) = \frac{1}{n} \sum_{i=1}^n \ell(\hat{y}_i, y_i), \quad (2.8.9)$$

dengan fungsi kerugian ℓ dipilih sesuai dengan tugas yang dihadapi.

Contoh 2.8.16 Untuk regresi skalar, sebagai contoh digunakan $\ell(\hat{y}, y) = \frac{1}{2}(\hat{y} - y)^2$. Hal ini berarti jika $\hat{y} = 2,3$ dan $y = 1,5$, maka $\ell = \frac{1}{2}(0,8)^2 = 0,32$.

Contoh 2.8.17 Untuk klasifikasi biner, digunakan probabilitas prediksi $\hat{p} = \sigma(z)$ dan fungsi kerugian

$$\ell(\hat{p}, y) = -[y \log \hat{p} + (1 - y) \log(1 - \hat{p})], \quad y \in \{0, 1\}. \quad (2.8.10)$$

Fungsi ini merupakan entropi silang antara distribusi target $p(y)$ dan prediksi \hat{p} ,

yaitu

$$\begin{aligned} H(p, \hat{p}) &= - \sum_{y \in \{0,1\}} p(y) \log \hat{p}(y) \\ &= -[p(1) \log \hat{p} + p(0) \log(1 - \hat{p})]. \end{aligned} \quad (2.8.11)$$

Dengan $p(1) = y$ dan $p(0) = 1 - y$, diperoleh bentuk di atas.

Sebagai contoh, jika $y = 1$ dan $\hat{p} = 0,9$, maka $\ell = -\log 0,9 \approx 0,105$ (kerugian kecil). Jika $y = 0$ dan $\hat{p} = 0,9$, maka $\ell = -\log 0,1 \approx 2,303$ (kerugian besar).

Contoh 2.8.18 Untuk klasifikasi multikelas, dengan logit $\mathbf{z} \in \mathbb{R}^K$, softmax $\hat{p}_k = \exp(z_k) / \sum_{j=1}^K \exp(z_j)$ dan

$$\ell(\hat{\mathbf{p}}, y) = -\log \hat{p}_y, \quad y \in \{1, \dots, K\}.$$

Fungsi ini juga merupakan entropi silang antara distribusi target $p(y)$ dan prediksi $\hat{\mathbf{p}}$:

$$\begin{aligned} H(p, \hat{\mathbf{p}}) &= - \sum_{k=1}^K p(k) \log \hat{p}_k \\ &= -\log \hat{p}_y, \end{aligned} \quad (2.8.12)$$

dengan $p(k) = 1$ jika $k = y$ dan 0 selainnya.

Sebagai contoh, untuk $K = 3$ kelas, jika $\mathbf{z} = (2, 0, 1, 0, 1)$, maka softmax $\hat{\mathbf{p}} \approx (0,659, 0,242, 0,099)$. Jika label benar $y = 1$, maka $\ell = -\log 0,659 \approx 0,417$. Jika $y = 3$, maka $\ell = -\log 0,099 \approx 2,313$.

2.8.4 Pembelajaran dengan Propagasi Mundur

Teorema 2.8.19 Misalkan keluaran akhir didefinisikan sebagai komposisi $y = f^{(L)} \circ f^{(L-1)} \circ \dots \circ f^{(1)}(\mathbf{x})$. Maka turunan terhadap parameter pada lapisan ke- l meme-

nuhi

$$\frac{\partial y}{\partial \mathbf{W}^{(l)}} = \frac{\partial f^{(L)}}{\partial f^{(L-1)}} \cdots \frac{\partial f^{(l+1)}}{\partial f^{(l)}} \frac{\partial f^{(l)}}{\partial \mathbf{W}^{(l)}}. \quad (2.8.13)$$

Bukti. Teorema ini merupakan implikasi langsung dari aturan rantai dalam kalkulus diferensial. ■

Interpretasi teorema ini adalah gradien dihitung dengan mengalikan turunan setiap lapisan dari keluaran ke lapisan yang diinginkan. Hal ini berarti akan dihitung efek perubahan bobot pada lapisan tersebut terhadap keluaran akhir melalui semua lapisan berikutnya. Apabila efek ini kecil, maka gradien akan mengecil secara eksponensial (fenomena *vanishing gradient*). Apabila efek ini besar, maka gradien akan membesar secara eksponensial (fenomena *exploding gradient*). Secara umum, pembelajaran menginginkan untuk memperbaiki bobot yang memiliki efek signifikan terhadap keluaran, tetapi tidak terlalu besar sehingga menyebabkan ketidakstabilan.

Teorema 2.8.20 (Propagasi mundur atau *backpropagation*, Goodfellow dkk. 2016) Dengan notasi $\mathbf{z}^{(l)} = \mathbf{W}^{(l)} \mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}$, $\mathbf{a}^{(l)} = \varphi(\mathbf{z}^{(l)})$, dan $\ell(\hat{y}, y)$ fungsi kerugian, gradien terhadap bobot $\mathbf{W}^{(l)}$ diberikan oleh

$$\frac{\partial \ell}{\partial \mathbf{W}^{(l)}} = \delta^{(l)} (\mathbf{a}^{(l-1)})^\top, \quad (2.8.14)$$

dengan $\delta^{(l)} = (\mathbf{W}^{(l+1)})^\top \delta^{(l+1)} \odot \varphi'(\mathbf{z}^{(l)})$. Operator \odot adalah perkalian elemen-per-elemen atau *Hadamard product*.

Contoh 2.8.21 Misalkan jaringan 2 lapis dengan *input* $\mathbf{x} = (x_1, x_2)^\top$, bobot

$$\mathbf{W}^{(1)} = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix},$$

bias $\mathbf{b}^{(1)} = (0, 0)^\top$, fungsi aktivasi $\varphi(z) = \tanh(z)$, dan lapisan *output* linear $y = \mathbf{w}^{(2)\top} \mathbf{a}^{(1)}$ dengan $\mathbf{w}^{(2)} = (1, 1)^\top$. Target $y^* = 1$, kerugian $\ell(y, y^*) = \frac{1}{2}(y - y^*)^2$.

(a) *Forward:*

$$\begin{aligned}\mathbf{z}^{(1)} &= \mathbf{W}^{(1)} \mathbf{x} = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \\ \mathbf{a}^{(1)} &= \tanh(\mathbf{z}^{(1)}) \\ y &= (1, 1) \cdot \mathbf{a}^{(1)}\end{aligned}$$

(b) *Backward:*

$$\begin{aligned}\delta^{(2)} &= \frac{\partial \ell}{\partial y} = y - y^* \\ \delta^{(1)} &= \mathbf{w}^{(2)} \cdot \delta^{(2)} \odot \varphi'(\mathbf{z}^{(1)}) \\ \frac{\partial \ell}{\partial \mathbf{W}^{(1)}} &= \delta^{(1)}(\mathbf{x})^\top\end{aligned}$$

Dengan substitusi nilai, gradien dapat dihitung secara eksplisit untuk setiap parameter.

2.8.5 Optimisasi Parameter

Dalam pelatihan jaringan saraf, parameter Θ dioptimalkan untuk meminimalkan fungsi risiko $L(\Theta)$. Beberapa algoritma optimisasi yang akan dibahas adalah *Gradient Descent* (GD), *Stochastic Gradient Descent* (SGD), dan *Adaptive Moment Estimation* (Adam).

Definisi 2.8.22 (*Gradient Descent*) Diberikan fungsi risiko empiris

$$L(\Theta) = \frac{1}{n} \sum_{i=1}^n \ell(f_{\Theta}(\mathbf{x}_i), y_i),$$

pembaruan parameter dengan laju belajar $\eta > 0$ adalah

$$\Theta_{t+1} = \Theta_t - \eta \nabla_{\Theta} L(\Theta_t). \quad (2.8.15)$$

Metode ini konvergen ke minimum lokal untuk fungsi non-konveks seperti jaringan

saraf.

Algoritma 2.1 merangkum prosedur *gradient descent*.

Algoritma 2.1 Gradient Descent

Require: Fungsi kerugian $L(\Theta)$, data pelatihan $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$, laju belajar $\eta > 0$, jumlah epoch maksimal T_{\max} , toleransi konvergensi $\varepsilon > 0$

Ensure: Parameter optimal Θ^*

```

1: Inisialisasi parameter  $\Theta_0$  secara acak
2:  $t \leftarrow 0$ 
3: while  $t < T_{\max}$  do
4:   Hitung gradien:  $\mathbf{g}_t = \nabla_{\Theta} L(\Theta_t)$ 
5:   Perbarui parameter:  $\Theta_{t+1} \leftarrow \Theta_t - \eta \mathbf{g}_t$ 
6:   if  $\|\mathbf{g}_t\| < \varepsilon$  or  $|L(\Theta_{t+1}) - L(\Theta_t)| < \varepsilon$  then
7:     break
8:   end if
9:    $t \leftarrow t + 1$ 
10: end while
11: return  $\Theta^* \leftarrow \Theta_t$ 

```

Intuisi dari metode berbasis gradien ini adalah memperbarui parameter model ke arah yang menurunkan fungsi kerugian paling cepat. Pada setiap iterasi, gradien $\nabla_{\Theta} L(\Theta)$ menunjukkan arah perubahan parameter yang paling efektif untuk mengurangi kerugian. Dengan memilih laju pembelajaran η yang sesuai, proses optimisasi bergerak menuju minimum lokal dari fungsi kerugian. Jika $L(\Theta)$ konveks, metode ini menjamin konvergensi ke minimum global. Namun, pada kasus non-konveks seperti jaringan saraf, *gradient descent* tetap efektif menemukan solusi yang baik secara empiris. Variasi seperti SGD dan Adam mempercepat konvergensi dan meningkatkan generalisasi dengan memanfaatkan batch acak dan penyesuaian adaptif terhadap gradien.

Contoh 2.8.23 Misalkan fungsi kerugian $L(w) = \frac{1}{2}(w - 3)^2$. Gradiennya adalah $\nabla_w L(w) = w - 3$. Dengan laju belajar $\eta = 0,1$ dan inisialisasi $w_0 = 0$, maka iterasi

gradient descent adalah sebagai berikut.

$$\begin{aligned} w_1 &= w_0 - 0,1 \cdot (w_0 - 3) = 0 - 0,1 \cdot (-3) = 0,3 \\ w_2 &= w_1 - 0,1 \cdot (w_1 - 3) = 0,3 - 0,1 \cdot (-2,7) = 0,57 \\ w_3 &= 0,57 - 0,1 \cdot (0,57 - 3) = 0,813 \\ &\vdots \end{aligned}$$

Nilai w_t akan konvergen menuju 3.

Definisi 2.8.24 (Stochastic Gradient Descent (SGD)) *SGD adalah metode optimisasi yang memperbarui parameter model menggunakan rata-rata gradien dari batch kecil acak berukuran m pada setiap iterasi. Batch adalah sekumpulan sampel yang digunakan untuk menghitung gradien, serta batch kecil ini diambil secara acak dari dataset. Pembaruan parameter dilakukan sebagai berikut.*

$$\Theta_{t+1} = \Theta_t - \eta \frac{1}{|\mathcal{B}_t|} \sum_{(\mathbf{x}_i, y_i) \in \mathcal{B}_t} \nabla_{\Theta} \ell(f_{\Theta}(\mathbf{x}_i), y_i), \quad (2.8.16)$$

dengan \mathcal{B}_t adalah batch kecil pada iterasi ke- t , η adalah laju pembelajaran, dan ℓ adalah fungsi kerugian. Metode ini sangat efisien untuk data berukuran besar dan memberikan regularisasi implisit melalui pengacakan batch.

Algoritma 2.2 merangkum prosedur *stochastic gradient descent*.

Algoritma 2.2 Stochastic Gradient Descent (SGD)

Require: Fungsi kerugian $L(\Theta)$, data pelatihan $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$, laju belajar $\eta > 0$, ukuran *batch* m , jumlah epoch maksimal T_{\max} , toleransi konvergensi $\varepsilon > 0$

Ensure: Parameter optimal Θ^*

```

1: Inisialisasi parameter  $\Theta_0$  secara acak
2:  $t \leftarrow 0$ 
3: while  $t < T_{\max}$  do
4:   Acak urutan indeks data:  $\pi = \text{permutasi}([1, 2, \dots, n])$ 
5:   for  $i = 0$  to  $n - m$  step  $m$  do
6:     Ambil batch:  $\mathcal{B}_t = \{\pi[i], \pi[i+1], \dots, \pi[i+m-1]\}$ 
7:     Hitung gradien batch:  $\mathbf{g}_t = \frac{1}{m} \sum_{j \in \mathcal{B}_t} \nabla_{\Theta} \ell(f_{\Theta}(\mathbf{x}_j), y_j)$ 
8:     Perbarui parameter:  $\Theta \leftarrow \Theta - \eta \mathbf{g}_t$ 
9:   end for
10:  Hitung nilai kerugian keseluruhan:  $L_t \leftarrow \frac{1}{n} \sum_{i=1}^n \ell(f_{\Theta}(\mathbf{x}_i), y_i)$ 
11:  if  $|L_t - L_{t-1}| < \varepsilon$  then
12:    break
13:  end if
14:   $t \leftarrow t + 1$ 
15: end while
16: return  $\Theta^* \leftarrow \Theta$ 

```

Contoh 2.8.25 Misalkan fungsi kerugian $L(w) = \frac{1}{2}(w - 3)^2$ dan data terdiri dari $n = 1000$ sampel, masing-masing x_i dengan target $y_i = 3$ untuk semua i . Dengan *batch* kecil berukuran $m = 10$, pada setiap iterasi SGD dilakukan langkah berikut.

- (a) Pilih acak $m = 10$ sampel dari data, misal indeks $\mathcal{B}_t = \{i_1, \dots, i_{10}\}$.
- (b) Hitung rata-rata gradien pada *batch*:

$$\nabla_w L_{\mathcal{B}_t}(w) = \frac{1}{m} \sum_{j=1}^m (w - y_{i_j}) = w - 3$$

(karena semua $y_{i_j} = 3$).

(c) Perbarui parameter dengan laju belajar η :

$$w_{t+1} = w_t - \eta(w_t - 3)$$

(d) Ulangi langkah (a)–(c) hingga w_t konvergen ke 3.

Dengan *batch* acak, setiap iterasi hanya menggunakan sebagian kecil data, sehingga proses lebih efisien dan tetap menuju minimum global $w = 3$.

Definisi 2.8.26 (Adaptive Moment Estimation (Adam)) *Adam adalah algoritma optimisasi berbasis gradien yang menggabungkan momentum (rata-rata bergerak gradien) dan skala adaptif (rata-rata kuadrat gradien). Adam memperbarui parameter dengan estimasi momen pertama dan kedua yang dikoreksi bias. Dengan gradien $\mathbf{g}_t = \nabla_{\Theta} L_t(\Theta_t)$, inisialisasi $\mathbf{m}_0 = \mathbf{0}$, $\mathbf{v}_0 = \mathbf{0}$, lalu untuk setiap iterasi $t \geq 1$:*

$$\mathbf{m}_t = \beta_1 \mathbf{m}_{t-1} + (1 - \beta_1) \mathbf{g}_t, \quad (2.8.17)$$

$$\mathbf{v}_t = \beta_2 \mathbf{v}_{t-1} + (1 - \beta_2) (\mathbf{g}_t \odot \mathbf{g}_t), \quad (2.8.18)$$

$$\hat{\mathbf{m}}_t = \frac{\mathbf{m}_t}{1 - \beta_1^t}, \quad \hat{\mathbf{v}}_t = \frac{\mathbf{v}_t}{1 - \beta_2^t}, \quad (2.8.19)$$

$$\Theta_{t+1} = \Theta_t - \eta \frac{\hat{\mathbf{m}}_t}{\sqrt{\hat{\mathbf{v}}_t} + \varepsilon}. \quad (2.8.20)$$

Parameter umum yang digunakan adalah $\beta_1 = 0,9$, $\beta_2 = 0,999$, $\varepsilon = 10^{-8}$.

Di bawah ini adalah Algoritma 2.3 yang merangkum prosedur Adam.

Algoritma 2.3 Adaptive Moment Estimation (Adam)

Require: Fungsi kerugian $L(\Theta)$, data pelatihan $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$, laju belajar $\eta > 0$, parameter momentum $\beta_1 = 0.9$, parameter momentum orde-2 $\beta_2 = 0.999$, stabilisasi $\varepsilon = 10^{-8}$, jumlah iterasi maksimal T_{\max}

Ensure: Parameter optimal Θ^*

- 1: Inisialisasi parameter Θ_0 secara acak
 - 2: Inisialisasi momen pertama: $\mathbf{m}_0 \leftarrow \mathbf{0}$
 - 3: Inisialisasi momen kedua: $\mathbf{v}_0 \leftarrow \mathbf{0}$
 - 4: $t \leftarrow 0$
 - 5: **while** $t < T_{\max}$ **do**
 - 6: Hitung gradien: $\mathbf{g}_t = \nabla_{\Theta} L(\Theta_t)$
 - 7: Perbarui momen pertama: $\mathbf{m}_t \leftarrow \beta_1 \mathbf{m}_{t-1} + (1 - \beta_1) \mathbf{g}_t$
 - 8: Perbarui momen kedua: $\mathbf{v}_t \leftarrow \beta_2 \mathbf{v}_{t-1} + (1 - \beta_2) (\mathbf{g}_t \odot \mathbf{g}_t)$
 - 9: Koreksi bias momen pertama: $\hat{\mathbf{m}}_t \leftarrow \mathbf{m}_t / (1 - \beta_1^{t+1})$
 - 10: Koreksi bias momen kedua: $\hat{\mathbf{v}}_t \leftarrow \mathbf{v}_t / (1 - \beta_2^{t+1})$
 - 11: Perbarui parameter: $\Theta_t \leftarrow \Theta_t - \eta \frac{\hat{\mathbf{m}}_t}{\sqrt{\hat{\mathbf{v}}_t} + \varepsilon}$
 - 12: **if** $\|\mathbf{g}_t\| < 10^{-6}$ **or** $t \equiv 0 \pmod{100}$ dan konvergen **then**
 - 13: **break**
 - 14: **end if**
 - 15: $t \leftarrow t + 1$
 - 16: **end while**
 - 17: **return** $\Theta^* \leftarrow \Theta_t$
-

Contoh 2.8.27 Misalkan gradien pada iterasi pertama $\mathbf{g}_1 = (0.1, -0.2)$, inisialisasi

$\mathbf{m}_0 = (0, 0)$, $\mathbf{v}_0 = (0, 0)$, $\eta = 0.01$. Maka:

$$\begin{aligned}\mathbf{m}_1 &= 0.9 \cdot (0, 0) + 0.1 \cdot (0.1, -0.2) = (0.01, -0.02), \\ \mathbf{v}_1 &= 0.999 \cdot (0, 0) + 0.001 \cdot (0.01, 0.04) = (0.00001, 0.00004), \\ \hat{\mathbf{m}}_1 &= (0.01, -0.02)/(1 - 0.9^1) = (0.1, -0.2), \\ \hat{\mathbf{v}}_1 &= (0.00001, 0.00004)/(1 - 0.999^1) = (0.01, 0.04), \\ \Theta_2 &= \Theta_1 - 0.01 \cdot \frac{(0.1, -0.2)}{(\sqrt{0.01}, \sqrt{0.04}) + 10^{-8}} = \Theta_1 - 0.01 \cdot (1, -1).\end{aligned}$$

Jadi, parameter diperbarui dengan langkah adaptif pada setiap komponen.

2.8.6 Jaringan Saraf Tiruan sebagai Aproksimasi Universal

Salah satu hasil teoretis paling penting tentang jaringan saraf tiruan adalah Teorema Aproksimasi Universal (UAT). Teorema ini menyatakan bahwa jaringan saraf dengan satu lapisan tersembunyi yang cukup besar dapat mengaproksimasi fungsi kontinu pada himpunan kompak dengan presisi setinggi apapun, asalkan fungsi aktivasi memenuhi syarat tertentu (Cybenko, 1989).

Pertanyaan fundamental dalam jaringan saraf adalah apakah kelas fungsi yang dihasilkan oleh suatu arsitektur memiliki daya representasi yang cukup kaya atau tidak. Secara khusus bagian ini akan menyajikan jaringan saraf dengan fungsi aktivasi sigmoid karena aplikasinya secara khusus pada bab selanjutnya. Untuk menjawab pertanyaan tersebut, akan dipelajari sifat-sifat aproksimasi dari fungsi yang berbentuk

$$G(\mathbf{x}) = \sum_{j=1}^N \alpha_j \sigma(\mathbf{w}_j^\top \mathbf{x} + b_j), \quad (2.8.21)$$

dengan $\sigma(z) = \frac{1}{1+e^{-z}}$ adalah fungsi sigmoid standar, $\alpha_j \in \mathbb{R}$, $\mathbf{w}_j \in \mathbb{R}^p$, dan $b_j \in \mathbb{R}$.

Teorema 2.8.28 (Teorema aproksimasi universal (UAT), Cybenko 1989) *Misalkan $\sigma : \mathbb{R} \rightarrow \mathbb{R}$ adalah fungsi sigmoid kontinu, yaitu memenuhi*

$$\lim_{t \rightarrow -\infty} \sigma(t) = 0, \quad \lim_{t \rightarrow +\infty} \sigma(t) = 1, \quad (2.8.22)$$

maka kelas fungsi

$$\mathcal{G} = \left\{ \sum_{j=1}^N \alpha_j \sigma(\mathbf{w}_j^\top \mathbf{x} + b_j) : N \in \mathbb{N}, \alpha_j \in \mathbb{R}, \mathbf{w}_j \in \mathbb{R}^p, b_j \in \mathbb{R} \right\} \quad (2.8.23)$$

adalah dense atau padat di ruang kontinu $C([0, 1]^p)$ terhadap norma supremum, yaitu untuk setiap fungsi kontinu $f \in C([0, 1]^p)$ dan setiap $\varepsilon > 0$, terdapat fungsi $G \in \mathcal{G}$ sehingga

$$\|f - G\|_\infty = \sup_{\mathbf{x} \in [0, 1]^p} |f(\mathbf{x}) - G(\mathbf{x})| < \varepsilon. \quad (2.8.24)$$

Bukti. Bukti dilakukand dengan pendekatan kontradiksi dan didasarkan pada argumen pemisahan linear. Andaikan bahwa kelas fungsi \mathcal{G} tidak padat di $C([0, 1]^p)$. Maka terdapat fungsi kontinu $f \in C([0, 1]^p)$ yang tidak dapat didekati secara seragam oleh fungsi-fungsi dalam \mathcal{G} . Secara konseptual, hal ini berarti terdapat suatu alat ukur yang mampu membedakan f dari semua fungsi dalam \mathcal{G} .

Secara formal, asumsi tersebut menyiratkan adanya fungsi linear kontinu tak nol $L : C([0, 1]^p) \rightarrow \mathbb{R}$ sedemikian hingga

$$L(G) = 0 \quad \forall G \in \mathcal{G}, \quad \text{tetapi} \quad L(f) \neq 0. \quad (2.8.25)$$

Fungsi tersebut kontinu pada ruang fungsi kontinu dan dapat direpresentasikan sebagai integral terhadap suatu ukuran bertanda-hingga μ . Dengan demikian, fungsi tersebut dapat didefinisikan dalam integral Lebesgue-Stieltjes:

$$L(h) = \int_{[0, 1]^p} h(\mathbf{x}) d\mu(\mathbf{x}) \quad \forall h \in C([0, 1]^p). \quad (2.8.26)$$

Sebab $L(G) = 0$ untuk semua $G \in \mathcal{G}$, maka

$$\int_{[0, 1]^p} \sigma(\mathbf{w}^\top \mathbf{x} + b) d\mu(\mathbf{x}) = 0 \quad \forall \mathbf{w} \in \mathbb{R}^p, b \in \mathbb{R}. \quad (2.8.27)$$

Selanjutnya, dengan memanfaatkan sifat batas dari fungsi sigmoid, untuk

suatu konstanta skala $\lambda > 0$, perhatikan fungsi

$$\sigma_\lambda(\mathbf{w}^\top \mathbf{x} + b) = \sigma(\lambda(\mathbf{w}^\top \mathbf{x} + b)). \quad (2.8.28)$$

Ketika $\lambda \rightarrow +\infty$, fungsi ini mendekati fungsi indikator

$$\mathbb{I}_{\{\mathbf{x}:\mathbf{w}^\top \mathbf{x}+b \geq 0\}}(\mathbf{x}) = \begin{cases} 1, & \text{jika } \mathbf{w}^\top \mathbf{x} + b \geq 0, \\ 0, & \text{jika } \mathbf{w}^\top \mathbf{x} + b < 0. \end{cases} \quad (2.8.29)$$

Oleh karena itu, dengan menerapkan Teorema Dominasi Konvergensi Lebesgue yang menyatakan bahwa batas integral dapat ditukar dengan integral batas untuk fungsi yang terukur dan terdominasi, diperoleh

$$\int_{[0,1]^p} \mathbb{I}_{\{\mathbf{x}:\mathbf{w}^\top \mathbf{x}+b \geq 0\}}(\mathbf{x}) d\mu(\mathbf{x}) = 0 \quad \forall \mathbf{w} \in \mathbb{R}^p, b \in \mathbb{R}. \quad (2.8.30)$$

Persamaan ini menyiratkan bahwa ukuran bertanda μ dari setiap himpunan separasi linear adalah nol. Namun, himpunan separasi linear ini membentuk basis untuk ruang Borel pada $[0, 1]^p$. Oleh karena itu, ukuran bertanda μ haruslah nol pada semua himpunan Borel di $[0, 1]^p$, yang bertentangan dengan asumsi awal bahwa $L(f) \neq 0$. Dengan demikian, asumsi bahwa kelas fungsi \mathcal{G} tidak padat di $C([0, 1]^p)$ adalah salah, sehingga teorema ini terbukti. ■

Teorema ini menunjukkan bahwa jaringan saraf dengan satu lapisan tersembunyi yang cukup besar dapat mengaproksimasi fungsi kontinu pada himpunan kompak dengan presisi setinggi apapun. Meskipun demikian, teorema ini tidak memberikan petunjuk tentang berapa banyak neuron yang diperlukan untuk mencapai aproksimasi tertentu, atau bagaimana cara melatih jaringan tersebut secara efektif. Selain itu, teorema ini berlaku untuk fungsi kontinu pada himpunan kompak, sehingga tidak mencakup semua jenis fungsi yang mungkin dihadapi dalam praktik.

2.9 Jaringan Saraf Graf

Jaringan Saraf Graf (*Graph Neural Networks*, GNN) merupakan kelas arsitektur pembelajaran representasi yang dirancang khusus untuk data terstruktur dalam bentuk graf. Berbeda dengan jaringan saraf tiruan (JST) yang bekerja pada vektor atau matriks, GNN memanfaatkan informasi topologi melalui graf $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ dengan simpul \mathcal{V} dan sisi \mathcal{E} .


2.9.1 Dasar Graf dan Laplacian

Definisi 2.9.1 (Graf dan matriks ketetanggaan) Graf $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ dengan $|\mathcal{V}| = n$ direpresentasikan oleh:

$$\mathbf{A}_{ij} = \begin{cases} 1 & \text{jika } (i, j) \in \mathcal{E}, \\ 0 & \text{lainnya,} \end{cases} \quad (2.9.1)$$

disebut matriks ketetanggaan. Matriks derajat didefinisikan sebagai $\mathbf{D} = \text{diag}(d_1, \dots, d_n)$, dengan $d_i = \sum_j A_{ij}$.

Contoh 2.9.2 Graf $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ dengan $|\mathcal{V}| = 4$ dan sisi $\mathcal{E} = \{(1, 2), (2, 3), (3, 4), (4, 1)\}$ dapat divisualisasikan sebagai berikut.



Matriks ketetanggaan \mathbf{A} untuk graf di atas adalah

$$\mathbf{A} = \begin{pmatrix} 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 \end{pmatrix}.$$

Dengan kata lain, matriks derajatnya $\mathbf{D} = \text{diag}(2, 2, 2, 2)$.

Definisi 2.9.3 (Graf Laplacian, Chung 1997) *Graf Laplacian adalah $\mathbf{L} = \mathbf{D} - \mathbf{A}$. Normalisasi simetris diberikan oleh*

$$\mathbf{L}_{sym} = \mathbf{I} - \mathbf{D}^{-1/2} \mathbf{A} \mathbf{D}^{-1/2}. \quad (2.9.2)$$

Graf Laplacian merepresentasikan struktur graf dan digunakan dalam berbagai algoritma GNN.

Contoh 2.9.4 Misalkan graf \mathcal{G} dengan 4 simpul dan sisi $\mathcal{E} = \{(1, 2), (2, 3), (3, 4), (4, 1)\}$ (graf siklus). Matriks ketetanggaannya adalah

$$\mathbf{A} = \begin{pmatrix} 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 \end{pmatrix}$$

dan matriks derajatnya adalah

$$\mathbf{D} = \text{diag}(2, 2, 2, 2).$$

Graf Laplacian-nya dapat dihitung sebagai

$$\mathbf{L} = \mathbf{D} - \mathbf{A} = \begin{pmatrix} 2 & -1 & 0 & -1 \\ -1 & 2 & -1 & 0 \\ 0 & -1 & 2 & -1 \\ -1 & 0 & -1 & 2 \end{pmatrix}.$$

Sehingga, dengan normalisasi simetris didapatkan

$$\mathbf{L}_{sym} = \mathbf{I} - \frac{1}{2} \mathbf{A},$$

karena $\mathbf{D}^{-1/2} = \text{diag}(1/\sqrt{2}, 1/\sqrt{2}, 1/\sqrt{2}, 1/\sqrt{2})$.

Teorema 2.9.5 (Teorema spektral Laplacian, Chung 1997) *Matriks Laplacian*

\mathbf{L} adalah simetris dan positif semidefinit, sehingga dapat didekomposisi dengan dekomposisi nilai eigen sebagai berikut.

$$\mathbf{L} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^\top, \quad (2.9.3)$$

dengan \mathbf{U} ortogonal dan $\mathbf{\Lambda}$ diagonal berisi nilai eigen $\lambda_1, \dots, \lambda_n \geq 0$. Selalu berlaku $\lambda_1 = 0$ dengan vektor eigen $\mathbf{1}$.

2.9.2 Kerangka Penyampaian Pesan pada Jaringan Saraf

Definisi 2.9.6 (*Message passing neural networks (MPNN)*, Bronstein, Bruna, Cohen, dan Veličković 2021) Misalkan graf $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ dengan \mathcal{V} adalah himpunan simpul dan \mathcal{E} adalah himpunan sisi. Misalkan pula \mathcal{N}_u adalah ketetanggaan simpul $u \in \mathcal{V}$. Lebih lanjut, misalkan \mathbf{x}_u adalah fitur simpul u dan \mathbf{e}_{uv} adalah fitur sisi $(u, v) \in \mathcal{E}$. Suatu lapisan MPNN didefinisikan sebagai berikut.

$$\mathbf{h}_u = \varphi \left(\mathbf{x}_u, \bigoplus_{v \in \mathcal{N}_u} \psi(\mathbf{x}_u, \mathbf{x}_v, \mathbf{e}_{uv}) \right) \quad (2.9.4)$$

dengan φ dan ψ adalah fungsi yang terdiferensiasi (seperti jaringan saraf) dan \bigoplus adalah operator agregasi yang bersifat komutatif dan asosiatif (seperti penjumlahan atau rata-rata) atau permutation invariant.

Kerangka MPNN ini sangat fleksibel dan dapat disesuaikan dengan berbagai jenis data graf. Fungsi ψ dapat dirancang untuk menangkap interaksi spesifik antara simpul dan sisi, sedangkan fungsi φ dapat berupa jaringan saraf yang kompleks untuk pembaruan fitur. Operator agregasi \bigoplus memastikan bahwa model tetap invariant terhadap permutasi tetangga, yang penting dalam konteks graf. Beberapa arsitektur umum GNN, seperti *graph convolutional networks* (GCN) dan *graph attention networks* (GAT), dapat dianggap sebagai kasus khusus dari kerangka MPNN ini.

2.9.3 Arsitektur Umum dalam GNN

Definisi 2.9.7 (*Graph convolutional networks (GCN), Kipf dan Welling 2017*)

GCN mendefinisikan operasi propagasi lapisan ke- l sebagai

$$\mathbf{H}^{(l+1)} = \sigma\left(\tilde{\mathbf{D}}^{-1/2} \tilde{\mathbf{A}} \tilde{\mathbf{D}}^{-1/2} \mathbf{H}^{(l)} \mathbf{W}^{(l)}\right), \quad (2.9.5)$$

dengan $\tilde{\mathbf{A}} = \mathbf{A} + \mathbf{I}_n$ matriks ketetanggaan dengan self-loop, $\tilde{\mathbf{D}} = \text{diag}(\sum_j \tilde{A}_{ij})$ matriks derajat dari $\tilde{\mathbf{A}}$, $\mathbf{H}^{(l)} \in \mathbb{R}^{n \times d_l}$ representasi simpul pada lapisan l , $\mathbf{W}^{(l)} \in \mathbb{R}^{d_l \times d_{l+1}}$ bobot terlatih, dan $\sigma(\cdot)$ fungsi aktivasi non-linear.

Secara eksplisit, propagasi GCN dapat ditulis sebagai

$$\mathbf{h}_u^{(l+1)} = \sigma\left(\sum_{v \in \mathcal{N}_u \cup \{u\}} \frac{1}{\sqrt{d_u d_v}} \mathbf{h}_v^{(l)} \mathbf{W}^{(l)}\right), \quad (2.9.6)$$

dengan d_u derajat simpul u dan σ fungsi aktivasi. Matriks normalisasi simetris $\tilde{\mathbf{D}}^{-1/2} \tilde{\mathbf{A}} \tilde{\mathbf{D}}^{-1/2}$ merepresentasikan agregasi pesan dari tetangga dengan bobot yang sesuai, sehingga GCN adalah MPNN dengan agregasi rata-rata dan update linear.

GCN merupakan kasus khusus dari kerangka MPNN dengan fitur sisi diabaikan (\mathbf{e}_{uv} tidak digunakan), fungsi pesan $\psi(\mathbf{x}_u, \mathbf{x}_v, \mathbf{e}_{uv}) = \mathbf{x}_v$ (hanya mengambil fitur tetangga, operator agregasi \oplus berupa penjumlahan atau rata-rata tertimbang (melalui normalisasi Laplacian), dan fungsi update φ adalah komposisi linear dan aktivasi non-linear: $\varphi(\mathbf{x}_u, \text{AGG}) = \sigma(\text{AGG} \cdot \mathbf{W})$.

Definisi 2.9.8 (*Graph attention networks (GAT), Veličković dkk. 2018*) GAT mengganti normalisasi derajat dengan mekanisme perhatian. Koefisien perhatian untuk sisi (i, j) adalah

$$\alpha_{ij} = \frac{\exp(\text{LeakyReLU}(\mathbf{a}^\top [\mathbf{W}\mathbf{h}_i \parallel \mathbf{W}\mathbf{h}_j]))}{\sum_{k \in \mathcal{N}(i)} \exp(\text{LeakyReLU}(\mathbf{a}^\top [\mathbf{W}\mathbf{h}_i \parallel \mathbf{W}\mathbf{h}_k]))}, \quad (2.9.7)$$

dengan $\mathbf{h}_i \in \mathbb{R}^d$ vektor fitur simpul i , \mathbf{W} bobot transformasi linear, $\mathbf{a} \in \mathbb{R}^{2d}$ vektor bobot perhatian, dan \parallel operator konkatenasi.

Pembaruan fitur simpul GAT adalah

$$\mathbf{h}'_i = \sigma \left(\sum_{j \in \mathcal{N}(i)} \alpha_{ij} \mathbf{W} \mathbf{h}_j \right). \quad (2.9.8)$$

GAT merupakan kasus khusus dari kerangka MPNN dengan spesifikasi berikut.

- Fitur sisi \mathbf{e}_{uv} tidak digunakan (atau dapat diabaikan).
- Fungsi pesan $\psi(\mathbf{x}_u, \mathbf{x}_v, \mathbf{e}_{uv}) = \mathbf{W} \mathbf{x}_v$ (transformasi linear fitur tetangga).
- Operator agregasi \oplus berupa penjumlahan tertimbang, dengan bobot agregasi α_{uv} diperoleh dari mekanisme perhatian (*attention*) yang bersifat *permutation invariant*.
- Fungsi update φ adalah komposisi linear dan aktivasi non-linear: $\varphi(\mathbf{x}_u, \text{AGG}) = \sigma(\text{AGG})$.

Secara formal, pembaruan fitur simpul u pada GAT dapat ditulis dalam notasi MPNN sebagai

$$\mathbf{h}'_u = \sigma \left(\sum_{v \in \mathcal{N}_u} \alpha_{uv} \psi(\mathbf{x}_u, \mathbf{x}_v, \mathbf{e}_{uv}) \right) = \sigma \left(\sum_{v \in \mathcal{N}_u} \alpha_{uv} \mathbf{W} \mathbf{x}_v \right), \quad (2.9.9)$$

dengan α_{uv} adalah skor perhatian yang bergantung pada fitur \mathbf{x}_u dan \mathbf{x}_v melalui fungsi $\text{LeakyReLU}(\mathbf{a}^\top [\mathbf{W} \mathbf{x}_u \parallel \mathbf{W} \mathbf{x}_v])$ dan normalisasi softmax. Dengan demikian, GAT adalah MPNN dengan agregasi penjumlahan tertimbang dan fungsi pesan linear dengan bobot agregasi ditentukan secara adaptif oleh mekanisme perhatian.

Definisi 2.9.9 (GraphSAGE, Hamilton, Ying, dan Leskovec 2017) *GraphSAGE* atau Graph Sample and Aggregation mendefinisikan pembaruan simpul i sebagai

$$\mathbf{h}_i^{(l+1)} = \sigma \left(\mathbf{W}^{(l)} \cdot \text{AGGREGATE} \left(\{\mathbf{h}_i^{(l)}\} \cup \{\mathbf{h}_j^{(l)} : j \in \mathcal{N}(i)\} \right) \right), \quad (2.9.10)$$

dengan AGGREGATE fungsi agregasi non-linear yang bisa berupa mean, max-pooling, atau LSTM.

2.9.4 Sifat Simetri dan Invariansi Permutasi

Salah satu sifat fundamental yang membedakan Jaringan Saraf Graf dari jaringan saraf konvensional adalah kemampuannya untuk menghormati simetri graf. Secara khusus, representasi graf tidak bergantung pada pelabelan simpul, sehingga model yang sah harus bersifat *permutation equivariant* atau *permutation invariant*.

Definisi 2.9.10 (*Permutation equivariance*) Misalkan $\mathbf{P} \in \mathbb{R}^{n \times n}$ adalah matriks permutasi. Suatu pemetaan $\mathcal{F} : (\mathbf{A}, \mathbf{X}) \mapsto \mathbf{H}$ disebut *permutation equivariant* jika

$$\mathcal{F}(\mathbf{PAP}^\top, \mathbf{PX}) = \mathbf{P} \mathcal{F}(\mathbf{A}, \mathbf{X}). \quad (2.9.11)$$

Kerangka *message passing neural networks* secara inheren memenuhi sifat ini karena operator agregasi yang digunakan bersifat komutatif dan asosiatif. Oleh karena itu, keluaran GNN tidak bergantung pada urutan simpul, melainkan hanya pada struktur graf itu sendiri, memastikan bahwa representasi yang dipelajari adalah sah dan bermakna dalam konteks graf.

2.9.5 Daya Aproksimasi Jaringan Saraf Graf

Sejumlah hasil teoretis dalam literatur menunjukkan bahwa kerangka GNN memiliki sifat aproksimasi universal pada kelas fungsi graf tertentu. Secara khusus, Brüel-Gabrielsson (2020) menunjukkan bahwa GNN yang dibangun dalam kerangka *message passing*, dengan operator agregasi yang bersifat *permutation invariant* dan fungsi pembaruan yang cukup kaya (misalnya *multilayer perceptron*), mampu mengaproksimasi setiap fungsi graf yang kontinu dan invariant terhadap permutasi simpul.

Secara matematis, hasil tersebut dapat dirumuskan sebagai berikut. Misalkan \mathcal{G}_n adalah himpunan graf beratribut dengan jumlah simpul terbatas n , dan misalkan $f : \mathcal{G}_n \rightarrow \mathbb{R}$ adalah fungsi graf yang kontinu dan invariant terhadap permutasi simpul, yaitu

$$f(\mathbf{PAP}^\top, \mathbf{PX}) = f(\mathbf{A}, \mathbf{X}) \quad \text{untuk setiap matriks permutasi } \mathbf{P}.$$

Maka, untuk setiap $\varepsilon > 0$, terdapat parameter θ dan arsitektur GNN sedemikian sehingga

$$\sup_{(\mathbf{A}, \mathbf{X}) \in \mathcal{G}_n} |f(\mathbf{A}, \mathbf{X}) - \text{GNN}_\theta(\mathbf{A}, \mathbf{X})| < \varepsilon.$$

Lebih lanjut, Xu, Hu, Leskovec, dan Jegelka (2019) menunjukkan bahwa daya aproksimasi GNN berbasis *message passing* dibatasi oleh kemampuan uji isomorfisme graf Weisfeiler–Lehman tingkat pertama (1-WL). Tes Weisfeiler–Lehman diperkenalkan sebagai prosedur efisien untuk membedakan graf berdasarkan struktur lokalnya, sebagai pendekatan praktis terhadap masalah graf isomorfisme yang secara teoretis sulit. Meskipun tidak memberikan solusi lengkap terhadap isomorfisme graf, tes WL cukup kuat untuk membedakan sebagian besar graf dalam praktik. Dalam konteks GNN berbasis *message passing*, daya representasi model secara teoretis dibatasi oleh kemampuan tes WL tingkat pertama. Oleh karena itu, keterbatasan ini bukan merupakan kelemahan implementasi, melainkan konsekuensi struktural dari desain agregasi lokal yang digunakan.

BAB III

KERANGKA METODOLOGIS DAN ANALISIS ASIMTOTIK

GRAPH ATTENTION-BASED GEOGRAPHICALLY

WEIGHTED REGRESSION

Pada bab ini diuraikan metode *Graph Attention-based Geographically Weighted Regression* (GA-GWR), sebuah ekstensi dari model *Geographically Weighted Regression* (GWR) yang menggunakan jaringan saraf graf untuk mempelajari fungsi *kernel* spasial secara adaptif dengan struktur pembobotan berbasis konsep perhatian (*attention*). Pembahasan dimulai dengan analisis keterbatasan pembobotan spasial berbasis *kernel* konvensional, dilanjutkan dengan konstruksi *kernel* terpelajari berbasis jaringan saraf graf, integrasi ke dalam kerangka GWR, serta analisis asimtotik dari estimator yang dihasilkan.

3.1 Keterbatasan Pembobotan Spasial Berbasis *Kernel* Konvensional

Sebagaimana telah diuraikan pada Bab II, model GWR menggunakan pendekatan pembobotan spasial yang mengandalkan fungsi *kernel* tetap (*fixed kernel*) untuk menangkap struktur dependensi spasial dalam data. Meskipun pendekatan ini telah banyak digunakan dalam berbagai aplikasi, terdapat beberapa keterbatasan fundamental yang berdampak pada akurasi estimasi dan validitas inferensi statistik. Pada bagian ini dibahas prinsip pembobotan spasial dalam GWR klasik, sumber bias induktif yang muncul akibat penggunaan *kernel* tetap, serta implikasinya terhadap inferensi statistik.

3.1.1 Prinsip Pembobotan Spasial dalam GWR

Model GWR menggunakan estimator koefisien lokal yang diperoleh melalui metode *locally weighted least squares* (LWLS) dengan matriks bobot spasial $W(u_0, v_0)$. Fungsi bobot pada model GWR ditentukan melalui fungsi *kernel*, di

mana bobot antara observasi i dan lokasi target (u_0, v_0) diberikan oleh

$$w_i(u_0, v_0) = K\left(\frac{d_i(u_0, v_0)}{h}\right), \quad (3.1.1)$$

dengan $d_i(u_0, v_0)$ adalah jarak antara (u_i, v_i) dan (u_0, v_0) , $h > 0$ adalah parameter *bandwidth*, dan $K(\cdot)$ adalah fungsi *kernel* tetap seperti Gaussian atau *bisquare* (Fan dan Gijbels, 1996). Fungsi *kernel* dengan karakteristik demikian selanjutnya disebut sebagai *kernel* spasial konvensional. Fungsi *kernel* $K : \mathbb{R}^+ \rightarrow \mathbb{R}^+$ dalam GWR harus memenuhi beberapa sifat matematis sesuai dengan Asumsi GWR.8.

Dari definisi di atas, terlihat bahwa *kernel* konvensional memiliki dua karakteristik utama:

- (i) Bobot spasial sepenuhnya ditentukan oleh jarak geografis antara lokasi.
- (ii) Parameter *bandwidth* h bersifat tetap untuk seluruh wilayah studi.

Kedua karakteristik ini membawa implikasi penting terhadap fleksibilitas representasi struktur dependensi spasial. Kelemahan fundamental dari formulasi di atas adalah bahwa bentuk fungsional $K(\cdot)$ dan metrik d_{ij} ditentukan secara *a priori* (sebelum analisis data) dan bersifat kaku. Peneliti memaksakan asumsi bahwa interaksi spasial di dunia nyata mengikuti kurva lonceng Gaussian atau peluruhan polinomial Bi-square yang mulus. Dalam terminologi *machine learning*, hal ini merupakan bentuk bias induktif (*inductive bias*) yang sangat kuat.

3.1.2 Bias Induktif pada *Kernel* Tetap

Kernel spasial konvensional membawa asumsi struktural yang bersifat *a priori*, terutama isotropi dan monotonisitas pengaruh terhadap jarak. Secara matematis, ini berarti $K(\|\mathbf{u}_i - \mathbf{u}_j\|)$ hanya bergantung pada magnitudo vektor jarak, bukan arahnya. Geometri dari *kernel* ini adalah lingkaran (dalam 2D) atau bola (dalam 3D). Implikasinya adalah bahwa pengaruh spasial meluruh dengan laju yang sama ke segala arah, yaitu Utara, Selatan, Timur, dan Barat.

Definisi 3.1.1 (Bias induktif) *Bias induktif adalah kecenderungan sistematis suatu*

metode estimasi yang disebabkan oleh pembatasan kelas fungsi atau struktur model yang diasumsikan sebelum data diamati.

Dalam konteks GWR, bias induktif muncul karena *kernel* tetap membatasi bobot spasial pada fungsi jarak isotropik tertentu, sehingga tidak mampu merepresentasikan struktur spasial yang bersifat anisotropik, tidak simetris, atau bergantung pada konteks non-geometris (Yan, Li, dan Gao, 2024).

Secara matematis, misalkan $\kappa^*(\mathbf{u}_i, \mathbf{u}_0)$ menyatakan *kernel* spasial sejati yang mendasari proses data. Penggunaan *kernel* konvensional menyiratkan aproksimasi

$$\kappa^*(\mathbf{u}_i, \mathbf{u}_0) \approx K\left(\frac{\|\mathbf{u}_i - \mathbf{u}_0\|}{h}\right), \quad (3.1.2)$$

dengan $K(\cdot)$ dipilih dari kelas fungsi terbatas. Jika κ^* tidak berada dalam kelas tersebut, maka kesalahan aproksimasi tidak dapat dieliminasi meskipun ukuran sampel meningkat.

Keterbatasan ini diperparah oleh penggunaan *bandwidth* tunggal yang bersifat global, yang mengasumsikan bahwa seluruh hubungan spasial beroperasi pada skala yang sama, padahal banyak proses spasial bersifat multi-skala (Fotheringham, Yang, dan Kang, 2017).

Parameter d_{ij} dalam kernel GWR hampir secara eksklusif dihitung sebagai jarak Euclidean garis lurus. Asumsi ini mengimplikasikan ruang yang kontinu, homogen, dan bebas hambatan. Namun, ruang geografis penuh dengan diskontinuitas dan hambatan topologis. Sungai, pegunungan, atau batas administratif dapat memutus interaksi spasial antara dua titik yang secara Euclidean sangat dekat. Dalam GWR konvensional, dua rumah yang berseberangan di tepi sungai tanpa jembatan akan dianggap sebagai tetangga dekat dengan bobot interaksi tinggi ($w_{ij} \approx 1$). Padahal, dalam realitas pasar perumahan atau akses layanan, jarak efektif mereka (jarak jaringan) mungkin sangat jauh. Penggunaan metrik jarak Euclidean mengabaikan faktor-faktor ini, sehingga menghasilkan bobot spasial yang tidak akurat dan bias dalam estimasi koefisien lokal (?). Dalam studi transportasi atau epidemiologi, interaksi terjadi melalui jaringan jalan atau rute penerbangan. Peneliti-

an menunjukkan bahwa kalibrasi GWR menggunakan jarak jaringan menghasilkan goodness-of-fit yang jauh lebih baik daripada jarak Euclidean. Namun, integrasi jarak non-Euclidean ke dalam GWR konvensional memerlukan perhitungan matriks jarak eksternal yang berat secara komputasi dan statis (tidak dipelajari dari data) (?).

3.2 Pembelajaran *Kernel* Spasial dengan Jaringan Saraf Graf

Untuk mengatasi keterbatasan pembobotan spasial berbasis *kernel* konvensional, pendekatan pembelajaran mesin modern menawarkan mekanisme yang lebih fleksibel dalam mempelajari struktur dependensi spasial secara langsung dari data. Salah satu pendekatan yang menonjol adalah penggunaan jaringan saraf graf (*Graph Neural Networks*, GNN), yang dirancang untuk memodelkan relasi antarunit pengamatan yang direpresentasikan sebagai graf (Kipf dan Welling, 2017; ?). Berbeda dengan *kernel* spasial tetap yang ditentukan *a priori*, GNN memungkinkan pembelajaran bobot spasial yang adaptif terhadap struktur graf dan atribut data, sehingga memperluas kelas fungsi *kernel* yang dapat direpresentasikan secara *data-driven*. Model GWR yang menggunakan GNN untuk mempelajari *kernel* spasial selanjutnya disebut sebagai *Graph Attention-based Geographically Weighted Regression* (GA-GWR).

3.2.1 Representasi Graf untuk Data Spasial

Misalkan tersedia sampel acak $\{(y_i, \mathbf{x}_i, \mathbf{u}_i)\}_{i=1}^n$, dengan $y_i \in \mathbb{R}$ adalah variabel respons, $\mathbf{x}_i \in \mathbb{R}^p$ adalah vektor kovariat, dan $\mathbf{u}_i = (u_i, v_i)^\top \in \mathbb{R}^2$ menyatakan koordinat lokasi spasial. Data spasial ini dapat direpresentasikan sebagai graf dengan mempertimbangkan struktur ketetanggaan geografis.

Definisi 3.2.1 (Graf spasial lokal) Untuk suatu lokasi target $\mathbf{u}_0 \in \mathbb{R}^2$ dan bandwidth $h > 0$, didefinisikan himpunan tetangga lokal

$$\mathcal{N}_h(\mathbf{u}_0) = \{i : d(\mathbf{u}_i, \mathbf{u}_0) \leq h\}. \quad (3.2.1)$$

Graf spasial lokal didefinisikan sebagai $\mathcal{G}_h(\mathbf{u}_0) = (\mathcal{V}_h, \mathcal{E}_h)$, dengan $\mathcal{V}_h = \mathcal{N}_h(\mathbf{u}_0)$

adalah himpunan simpul dan \mathcal{E}_h adalah himpunan sisi yang dibangun berdasarkan keterhubungan spasial atau kedekatan topologis antarsimpul dalam \mathcal{V}_h .

Setiap simpul $i \in \mathcal{V}_h$ diasosiasikan dengan vektor fitur yang merepresentasikan kovariat dan posisi relatif terhadap lokasi target. Salah satu pendekatan yang dapat digunakan adalah representasi kartesian, yaitu

$$\mathbf{z}_i(\mathbf{u}_0) = (\mathbf{x}_i^\top, (\mathbf{u}_i - \mathbf{u}_0)^\top)^\top = (\mathbf{x}_i^\top, \Delta u_i, \Delta v_i)^\top, \quad (3.2.2)$$

dengan $\Delta u_i = u_i - u_0$ dan $\Delta v_i = v_i - v_0$. Representasi ini secara ekuivalen dapat dinyatakan dalam koordinat polar sebagai

$$\mathbf{u}_i - \mathbf{u}_0 = r_i (\cos \phi_i, \sin \phi_i)^\top, \quad (3.2.3)$$

dengan $r_i = \|\mathbf{u}_i - \mathbf{u}_0\|$ adalah jarak dari lokasi target ke observasi i , dan $\phi_i = \arctan(\Delta v_i / \Delta u_i) \in [0, 2\pi)$ adalah sudut arah dari \mathbf{u}_0 menuju \mathbf{u}_i relatif terhadap sumbu horizontal. Penggunaan posisi relatif $\mathbf{u}_i - \mathbf{u}_0$ alih-alih koordinat absolut \mathbf{u}_i memiliki beberapa keunggulan berikut.

Proposisi 3.2.2 Misalkan $\mathbf{t} \in \mathbb{R}^2$ adalah vektor translasi sembarang. Jika seluruh lokasi ditranslasikan, yaitu $\mathbf{u}'_i = \mathbf{u}_i + \mathbf{t}$ dan $\mathbf{u}'_0 = \mathbf{u}_0 + \mathbf{t}$, maka vektor fitur spasial tidak berubah:

$$\mathbf{u}'_i - \mathbf{u}'_0 = (\mathbf{u}_i + \mathbf{t}) - (\mathbf{u}_0 + \mathbf{t}) = \mathbf{u}_i - \mathbf{u}_0. \quad (3.2.4)$$

Akibatnya, $\mathbf{z}_i(\mathbf{u}'_0) = \mathbf{z}_i(\mathbf{u}_0)$, sehingga bobot GWR yang dihasilkan bersifat invarian terhadap translasi sistem koordinat.

Invariansi translasi ini memastikan bahwa model dapat digeneralisasi ke lokasi target baru tanpa bergantung pada posisi absolut dalam sistem koordinat.

Posisi relatif $\mathbf{u}_i - \mathbf{u}_0 = (\Delta u_i, \Delta v_i)^\top$ menyimpan informasi arah dan jarak secara terpisah. Misalkan dua observasi i dan j memiliki jarak yang sama terhadap

\mathbf{u}_0 , yaitu $\|\mathbf{u}_i - \mathbf{u}_0\| = \|\mathbf{u}_j - \mathbf{u}_0\| = r$, tetapi berada pada arah yang berbeda:

$$\mathbf{u}_i - \mathbf{u}_0 = r(\cos \phi_i, \sin \phi_i)^\top, \quad \mathbf{u}_j - \mathbf{u}_0 = r(\cos \phi_j, \sin \phi_j)^\top, \quad (3.2.5)$$

dengan $\phi_i \neq \phi_j$. Sebab $\mathbf{z}_i(\mathbf{u}_0) \neq \mathbf{z}_j(\mathbf{u}_0)$, maka jaringan saraf graf dapat mempelajari pemetaan nilai yang berbeda meskipun jaraknya sama. Hal ini memungkinkan representasi struktur anisotropi, berbeda dengan *kernel* isotropik konvensional yang hanya bergantung pada jarak $\|\mathbf{u}_i - \mathbf{u}_0\|$. Selain itu, representasi posisi relatif juga menyediakan informasi jarak serta orientasi yang esensial untuk menentukan bobot spasial adaptif.

3.2.2 Fleksibilitas Metrik Jarak dalam Konstruksi Representasi

Pembahasan sebelumnya menggunakan representasi kartesian $\mathbf{u}_i - \mathbf{u}_0$ yang implisit mengasumsikan jarak Euclidean. Namun, keunggulan pendekatan berbasis GNN adalah fleksibilitas dalam mengakomodasi metrik jarak alternatif yang dapat lebih sesuai dengan struktur data spasial sesungguhnya. Bagian ini membuktikan secara matematis bahwa berbagai metrik jarak dapat diintegrasikan ke dalam kerangka GA-GWR tanpa mengorbankan validitas teoretis.

Proposisi 3.2.3 Misalkan $d(\cdot, \cdot) : \mathbb{R}^2 \times \mathbb{R}^2 \rightarrow \mathbb{R}^+$ adalah metrik jarak sembarang yang memenuhi:

- (i) $d(\mathbf{u}, \mathbf{v}) \geq 0$ untuk semua \mathbf{u}, \mathbf{v} .
- (ii) $d(\mathbf{u}, \mathbf{v}) = 0 \iff \mathbf{u} = \mathbf{v}$.
- (iii) $d(\mathbf{u}, \mathbf{v}) = d(\mathbf{v}, \mathbf{u})$.
- (iv) $d(\mathbf{u}, \mathbf{w}) \leq d(\mathbf{u}, \mathbf{v}) + d(\mathbf{v}, \mathbf{w})$.
- (v) $d(\mathbf{u} + \mathbf{t}, \mathbf{v} + \mathbf{t}) = d(\mathbf{u}, \mathbf{v})$ untuk semua $\mathbf{t} \in \mathbb{R}^2$ (translasi-invarian).

Ketetanggaan lokal dapat didefinisikan secara umum sebagai

$$\mathcal{N}_h^d(\mathbf{u}_0) = \{i : d(\mathbf{u}_i, \mathbf{u}_0) \leq h\}. \quad (3.2.6)$$

Beberapa contoh metrik jarak yang memenuhi sifat di atas adalah sebagai berikut.

- (a) Jarak Euclidean, yaitu metrik standar pada ruang \mathbb{R}^2 :

$$d_{\text{Euc}}(\mathbf{u}, \mathbf{v}) = \sqrt{(u_1 - v_1)^2 + (u_2 - v_2)^2} = \|\mathbf{u} - \mathbf{v}\|_2. \quad (3.2.7)$$

Metrik ini menghasilkan ketetanggaan berbentuk lingkaran dan bersifat *isotropik* (sama ke segala arah).

- (b) Jarak Manhattan, yaitu metrik norma- L_1 :

$$d_{\text{Man}}(\mathbf{u}, \mathbf{v}) = |u_1 - v_1| + |u_2 - v_2| = \|\mathbf{u} - \mathbf{v}\|_1. \quad (3.2.8)$$

Metrik ini menghasilkan ketetanggaan berbentuk belah ketupat dan sesuai untuk lingkungan dengan struktur jalan grid ortogonal.

- (c) Jarak Chebyshev, yaitu metrik norma- L_∞ :

$$d_{\text{Cheb}}(\mathbf{u}, \mathbf{v}) = \max\{|u_1 - v_1|, |u_2 - v_2|\} = \|\mathbf{u} - \mathbf{v}\|_\infty. \quad (3.2.9)$$

Metrik ini menghasilkan ketetanggaan berbentuk persegi dan berguna ketika perpindahan diagonal memiliki biaya sama dengan perpindahan ortogonal.

- (d) Jarak Minkowski, generalisasi norma- L_p untuk $p \geq 1$:

$$d_p(\mathbf{u}, \mathbf{v}) = (|u_1 - v_1|^p + |u_2 - v_2|^p)^{1/p}. \quad (3.2.10)$$

Kasus khusus: $p = 1$ (Manhattan), $p = 2$ (Euclidean), $p \rightarrow \infty$ (Chebyshev).

- (e) Jarak jaringan, yaitu metrik jarak pada graf jaringan $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ dengan bobot sisi w_{ij} berupa

$$d_{\text{net}}(\mathbf{u}, \mathbf{v}) = \min_{\text{path } P: \mathbf{u} \rightarrow \mathbf{v}} \sum_{(i,j) \in P} w_{ij}, \quad (3.2.11)$$

yaitu panjang jalur terdekat (*shortest path*) antara \mathbf{u} dan \mathbf{v} dalam jaringan. Metrik ini memenuhi sifat (i)–(iv) secara ketat, dan sifat (v) terpenuhi secara efektif karena jarak hanya bergantung pada struktur topologis jaringan.

- (f) Jarak Haversine, untuk koordinat geografis (*latitude*, *longitude*) pada permukaan bumi:

$$d_{\text{hav}}(\mathbf{u}, \mathbf{v}) = \quad (3.2.12)$$

$$2R \arcsin \left(\sqrt{\sin^2 \left(\frac{\phi_v - \phi_u}{2} \right) + \cos(\phi_u) \cos(\phi_v) \sin^2 \left(\frac{\lambda_v - \lambda_u}{2} \right)} \right), \quad (3.2.13)$$

dengan R adalah jari-jari bumi, ϕ adalah *latitude*, dan λ adalah *longitude*. Metrik ini sesuai untuk data geografis berskala besar.

- (g) Jarak Mahalanobis, yaitu metrik yang memperhitungkan struktur kovarians data:

$$d_{\text{Mah}}(\mathbf{u}, \mathbf{v}; \Sigma) = \sqrt{(\mathbf{u} - \mathbf{v})^\top \Sigma^{-1} (\mathbf{u} - \mathbf{v})}, \quad (3.2.14)$$

dengan Σ adalah matriks kovarians. Metrik ini menghasilkan ketetanggaan berbentuk elips dan secara eksplisit memodelkan *anisotropi* spasial.

Secara khusus, jarak jaringan d_{net} memenuhi sifat-sifat metrik sebagai berikut,

- (i) Panjang *shortest path* selalu ≥ 0 karena bobot sisi non-negatif.
- (ii) $d_{\text{net}}(\mathbf{u}, \mathbf{u}) = 0$ karena tidak ada sisi yang perlu dilalui.
- (iii) Untuk graf tak berarah, *shortest path* $\mathbf{u} \rightarrow \mathbf{v}$ sama dengan $\mathbf{v} \rightarrow \mathbf{u}$.
- (iv) Jika ada jalur $\mathbf{u} \rightarrow \mathbf{w}$ melalui \mathbf{v} , maka $d_{\text{net}}(\mathbf{u}, \mathbf{w}) \leq d_{\text{net}}(\mathbf{u}, \mathbf{v}) + d_{\text{net}}(\mathbf{v}, \mathbf{w})$ karena *shortest path* optimal.

- (v) Jarak jaringan bergantung pada topologi graf, bukan koordinat absolut. Dalam praktik, translasi koordinat tidak mengubah struktur jaringan sehingga jarak tetap sama.

3.2.3 Fungsi Skor Spasial dan Jaringan Saraf Graf

Dalam kerangka ini, jaringan saraf graf digunakan untuk mempelajari fungsi skor yang merepresentasikan kekuatan interaksi spasial antarsimpul dalam graf lokal.

Definisi 3.2.4 (Fungsi skor spasial) *Fungsi skor spasial adalah pemetaan*

$$s^* : (\mathbf{z}_i(\mathbf{u}_0), \mathcal{G}_h(\mathbf{u}_0)) \mapsto \mathbb{R}, \quad (3.2.15)$$

yang merepresentasikan kontribusi relatif observasi ke- i terhadap estimasi lokal di \mathbf{u}_0 .

Fungsi s^* bersifat tidak diketahui dan dapat bergantung secara kompleks pada kovariat, posisi relatif, serta struktur graf lokal. Dalam analisis ini, fungsi skor sejati s^* diasumsikan kontinu pada domain kompak dan invarian terhadap permutasi simpul dalam graf lokal.

Definisi 3.2.5 *Diberikan graf lokal $\mathcal{G}_h(\mathbf{u}_0)$, jaringan saraf graf dengan parameter θ mendefinisikan fungsi*

$$s_\theta(i, \mathbf{u}_0) = \text{GNN}_\theta(\mathcal{G}_h(\mathbf{u}_0), \mathbf{z}_i(\mathbf{u}_0)), \quad (3.2.16)$$

yang menghasilkan skor untuk setiap simpul $i \in \mathcal{N}_h(\mathbf{u}_0)$.

Berdasarkan teorema 2.8.28 untuk jaringan saraf graf, di bawah asumsi kontinuitas dan invariansi permutasi, untuk setiap $\varepsilon > 0$ terdapat parameter θ^* sedemikian sehingga

$$\sup_{i \in \mathcal{N}_h(\mathbf{u}_0)} |s_{\theta^*}(i, \mathbf{u}_0) - s^*(i, \mathbf{u}_0)| < \varepsilon. \quad (3.2.17)$$

Persamaan di atas menunjukkan bahwa GNN dapat mengaproksimasi fungsi skor

spasial sejati dengan presisi yang diinginkan, sehingga memungkinkan pembelajaran bobot spasial yang adaptif dan kompleks.

3.2.4 Konstruksi *Kernel* Spasial Berbasis GNN

Fungsi skor yang dipelajari kemudian dipetakan menjadi bobot *kernel* melalui normalisasi *softmax*. Sebelum mendefinisikan *kernel* terestimasi, perlu ditetapkan terlebih dahulu bahwa setiap *kernel* konvensional dapat direpresentasikan secara ekuivalen dalam bentuk *softmax*. Penggunaan normalisasi *softmax* ini yang memberikan nama “*attention*” pada model GA-GWR karena mekanisme ini mirip dengan mekanisme perhatian dalam jaringan saraf.

Misalkan $w_i = K(d_i/h) > 0$ adalah bobot *kernel* konvensional untuk observasi $i \in \mathcal{N}_h(\mathbf{u}_0)$. Matriks bobot diagonal ditulis sebagai $\mathbf{W} = \text{diag}(w_1, \dots, w_m)$ dengan $m = |\mathcal{N}_h(\mathbf{u}_0)|$. Didefinisikan bobot ternormalisasi sebagai

$$\tilde{w}_i = \frac{w_i}{\sum_{j=1}^m w_j} = \frac{K(d_i/h)}{\sum_{j=1}^m K(d_j/h)}, \quad (3.2.18)$$

sehingga $\tilde{w}_i > 0$ dan $\sum_{i=1}^m \tilde{w}_i = 1$. Dengan demikian, $\{\tilde{w}_i\}_{i=1}^m$ membentuk distribusi probabilitas diskrit atas himpunan tetangga lokal.

Proposisi 3.2.6 *Estimator locally weighted least squares bersifat invarian terhadap penskalaan bobot. Secara eksplisit, jika $\widetilde{\mathbf{W}} = \text{diag}(\tilde{w}_1, \dots, \tilde{w}_m)$ adalah matriks bobot ternormalisasi, maka*

$$(\mathbf{X}^\top \widetilde{\mathbf{W}} \mathbf{X})^{-1} \mathbf{X}^\top \widetilde{\mathbf{W}} \mathbf{y} = (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{y}. \quad (3.2.19)$$

Bukti. Sebab $\tilde{w}_i = w_i / \sum_j w_j$, maka $\widetilde{\mathbf{W}} = c^{-1} \mathbf{W}$ dengan $c = \sum_{j=1}^m w_j > 0$. Substitusi memberikan

$$\begin{aligned} (\mathbf{X}^\top \widetilde{\mathbf{W}} \mathbf{X})^{-1} \mathbf{X}^\top \widetilde{\mathbf{W}} \mathbf{y} &= (c^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} (c^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{y}) \\ &= c \cdot (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \cdot c^{-1} \cdot \mathbf{X}^\top \mathbf{W} \mathbf{y} \\ &= (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{y}. \end{aligned} \quad (3.2.20)$$

Dengan demikian, estimator koefisien lokal identik untuk bobot asli \mathbf{W} dan bobot ternormalisasi $\widetilde{\mathbf{W}}$. ■

Proposisi di atas menunjukkan bahwa normalisasi bobot tidak mengubah estimator koefisien lokal. Oleh karena itu, tanpa mengurangi keumuman, dapat diasumsikan bahwa *kernel* sejati bersifat ternormalisasi, yaitu $\kappa^*(i \mid \mathbf{u}_0) = \tilde{w}_i$ dengan $\sum_i \kappa^*(i \mid \mathbf{u}_0) = 1$. Selanjutnya, dapat ditunjukkan bahwa setiap distribusi probabilitas diskrit dapat dinyatakan sebagai transformasi *softmax*.

Proposisi 3.2.7 Misalkan $\{\kappa^*(i \mid \mathbf{u}_0)\}_{i=1}^m$ adalah distribusi probabilitas diskrit positif, yaitu $\kappa^*(i \mid \mathbf{u}_0) > 0$ dan $\sum_{i=1}^m \kappa^*(i \mid \mathbf{u}_0) = 1$. Maka terdapat fungsi skor $s^* : \{1, \dots, m\} \rightarrow \mathbb{R}$ sedemikian sehingga

$$\kappa^*(i \mid \mathbf{u}_0) = \frac{\exp\{s^*(i, \mathbf{u}_0)\}}{\sum_{j=1}^m \exp\{s^*(j, \mathbf{u}_0)\}} = \text{softmax}(\mathbf{s}^*)_i. \quad (3.2.21)$$

Bukti. Didefinisikan $s^*(i, \mathbf{u}_0) = \log \kappa^*(i \mid \mathbf{u}_0)$ untuk setiap $i \in \{1, \dots, m\}$. Sebab $\kappa^*(i \mid \mathbf{u}_0) > 0$, logaritma terdefinisi dengan baik dan $s^*(i, \mathbf{u}_0) \in \mathbb{R}$. Verifikasi dilakukan dengan substitusi langsung, yaitu

$$\begin{aligned} \frac{\exp\{s^*(i, \mathbf{u}_0)\}}{\sum_{j=1}^m \exp\{s^*(j, \mathbf{u}_0)\}} &= \frac{\exp\{\log \kappa^*(i \mid \mathbf{u}_0)\}}{\sum_{j=1}^m \exp\{\log \kappa^*(j \mid \mathbf{u}_0)\}} \\ &= \frac{\kappa^*(i \mid \mathbf{u}_0)}{\sum_{j=1}^m \kappa^*(j \mid \mathbf{u}_0)} \\ &= \frac{\kappa^*(i \mid \mathbf{u}_0)}{1} \\ &= \kappa^*(i \mid \mathbf{u}_0). \end{aligned} \quad (3.2.22)$$

Perlu dicatat bahwa s^* bersifat unik hingga konstanta aditif, yaitu jika diketahui $\tilde{s}(i) = s^*(i) + c$ untuk $c \in \mathbb{R}$ sembarang, maka

$$\frac{\exp\{\tilde{s}(i)\}}{\sum_j \exp\{\tilde{s}(j)\}} = \frac{e^c \exp\{s^*(i)\}}{e^c \sum_j \exp\{s^*(j)\}} = \frac{\exp\{s^*(i)\}}{\sum_j \exp\{s^*(j)\}}, \quad (3.2.23)$$

sehingga model dapat menggunakan vektor skor yang tidak perlu dinormalisasi secara eksplisit, meningkatkan fleksibilitas dalam desain arsitektur GNN tanpa meng-

orbangkan interpretabilitas bobot kernel. ■

Dengan menggabungkan kedua proposisi di atas, diperoleh rantai kesetaraan untuk *kernel* konvensional, yaitu

$$w_i = K\left(\frac{d_i}{h}\right) \xrightarrow{\text{normalisasi}} \tilde{w}_i = \frac{w_i}{\sum_j w_j} \xrightarrow{\text{log-transform}} s_i^* = \log \tilde{w}_i, \quad (3.2.24)$$

sehingga secara eksplisit, fungsi skor yang merepresentasikan *kernel* konvensional adalah

$$s^*(i, \mathbf{u}_0) = \log K\left(\frac{d_i}{h}\right) - \log \sum_{j=1}^m K\left(\frac{d_j}{h}\right). \quad (3.2.25)$$

Sebab suku kedua konstan untuk semua i dan *softmax* invarian terhadap translasi konstan, fungsi skor dapat disederhanakan menjadi

$$s^*(i, \mathbf{u}_0) = \log K\left(\frac{\|\mathbf{u}_i - \mathbf{u}_0\|}{h}\right). \quad (3.2.26)$$

Definisi 3.2.8 (Kernel spasial terestimasi) Kernel *spasial terestimasi* berbasis GNN didefinisikan sebagai

$$\hat{\kappa}_{\theta}(i \mid \mathbf{u}_0) = \frac{\exp\{s_{\theta}(i, \mathbf{u}_0)\}}{\sum_{j \in \mathcal{N}_h(\mathbf{u}_0)} \exp\{s_{\theta}(j, \mathbf{u}_0)\}}. \quad (3.2.27)$$

Proposisi 3.2.9 Kernel *terestimasi* $\hat{\kappa}_{\theta}(\cdot \mid \mathbf{u}_0)$ memenuhi sifat stokastik baris (row stochastic):

(i) *Non-negativitas*: $\hat{\kappa}_{\theta}(i \mid \mathbf{u}_0) > 0$ untuk semua $i \in \mathcal{N}_h(\mathbf{u}_0)$.

(ii) *Normalisasi*: $\sum_{i \in \mathcal{N}_h(\mathbf{u}_0)} \hat{\kappa}_{\theta}(i \mid \mathbf{u}_0) = 1$.

Sifat ini merupakan konsekuensi langsung dari transformasi softmax dan memungkinkan interpretasi $\hat{\kappa}_{\theta}(i \mid \mathbf{u}_0)$ sebagai probabilitas diskrit atas himpunan tetangga lokal.

Bukti. Untuk setiap $i \in \mathcal{N}_h(\mathbf{u}_0)$, karena fungsi eksponensial bernilai positif untuk semua argumen real, maka $\exp\{s_{\theta}(i, \mathbf{u}_0)\} > 0$. Akibatnya, $\hat{\kappa}_{\theta}(i \mid \mathbf{u}_0) > 0$,

yang membuktikan sifat (i). Untuk sifat (ii), dengan menjumlahkan atas seluruh $i \in \mathcal{N}_h(\mathbf{u}_0)$ diperoleh

$$\begin{aligned} \sum_{i \in \mathcal{N}_h(\mathbf{u}_0)} \hat{\kappa}_{\boldsymbol{\theta}}(i \mid \mathbf{u}_0) &= \sum_{i \in \mathcal{N}_h(\mathbf{u}_0)} \frac{\exp\{s_{\boldsymbol{\theta}}(i, \mathbf{u}_0)\}}{\sum_{j \in \mathcal{N}_h(\mathbf{u}_0)} \exp\{s_{\boldsymbol{\theta}}(j, \mathbf{u}_0)\}} \\ &= \frac{\sum_i \exp\{s_{\boldsymbol{\theta}}(i, \mathbf{u}_0)\}}{\sum_j \exp\{s_{\boldsymbol{\theta}}(j, \mathbf{u}_0)\}} \\ &= 1. \end{aligned} \quad (3.2.28)$$

■

Selanjutnya, ditunjukkan bahwa jika fungsi skor terestimasi mengaproksimasi fungsi skor sejati, maka *kernel* terestimasi juga mengaproksimasi *kernel* sejati.

Teorema 3.2.10 *Misalkan $|\mathcal{N}_h(\mathbf{u}_0)| = m$ adalah jumlah tetangga lokal. Jika fungsi skor terestimasi mengaproksimasi fungsi skor sejati secara uniform, yaitu*

$$\sup_{i \in \mathcal{N}_h(\mathbf{u}_0)} |s_{\boldsymbol{\theta}}(i, \mathbf{u}_0) - s^*(i, \mathbf{u}_0)| \leq \delta \quad (3.2.29)$$

untuk suatu $\delta > 0$, maka kernel terestimasi mengaproksimasi kernel sejati dengan batas galat

$$\sup_{i \in \mathcal{N}_h(\mathbf{u}_0)} |\hat{\kappa}_{\boldsymbol{\theta}}(i \mid \mathbf{u}_0) - \kappa^*(i \mid \mathbf{u}_0)| \leq 2\delta. \quad (3.2.30)$$

Secara khusus, jika $\delta \rightarrow 0$, maka $\hat{\kappa}_{\boldsymbol{\theta}} \rightarrow \kappa^$ secara uniform.*

Bukti. Didefinisikan $a_i = s_{\boldsymbol{\theta}}(i, \mathbf{u}_0)$ dan $b_i = s^*(i, \mathbf{u}_0)$ untuk menyederhanakan notasi. Berdasarkan teorema 2.8.28 pada skor, $|a_i - b_i| \leq \delta$ untuk semua $i \in \mathcal{N}_h(\mathbf{u}_0)$. Untuk setiap i , selisih *kernel* dapat ditulis sebagai

$$\hat{\kappa}_{\boldsymbol{\theta}}(i \mid \mathbf{u}_0) - \kappa^*(i \mid \mathbf{u}_0) = \frac{e^{a_i}}{\sum_j e^{a_j}} - \frac{e^{b_i}}{\sum_j e^{b_j}}. \quad (3.2.31)$$

Dengan menyamakan penyebut, diperoleh

$$\widehat{\kappa}_{\theta}(i \mid \mathbf{u}_0) - \kappa^*(i \mid \mathbf{u}_0) = \frac{e^{a_i} \sum_j e^{b_j} - e^{b_i} \sum_j e^{a_j}}{\left(\sum_j e^{a_j}\right) \left(\sum_j e^{b_j}\right)}. \quad (3.2.32)$$

Pembilang dapat diuraikan sebagai

$$e^{a_i} \sum_j e^{b_j} - e^{b_i} \sum_j e^{a_j} = \sum_j (e^{a_i+b_j} - e^{b_i+a_j}). \quad (3.2.33)$$

Untuk melanjutkan, diperlukan sifat Lipschitz dari fungsi *softmax* yang dinyatakan dalam lema berikut.

Lema 3.2.11 *Fungsi softmax : $\mathbb{R}^m \rightarrow \mathbb{R}^m$ yang didefinisikan oleh*

$$[\text{softmax}(\mathbf{a})]_i = \frac{e^{a_i}}{\sum_{j=1}^m e^{a_j}} \quad (3.2.34)$$

memenuhi ketaksamaan Lipschitz, yaitu untuk setiap $\mathbf{a}, \mathbf{b} \in \mathbb{R}^m$,

$$\|\text{softmax}(\mathbf{a}) - \text{softmax}(\mathbf{b})\|_{\infty} \leq 2\|\mathbf{a} - \mathbf{b}\|_{\infty}. \quad (3.2.35)$$

Kembali ke bukti utama, dengan mengidentifikasi $\mathbf{a} = (a_1, \dots, a_m)^{\top}$ dengan $a_i = s_{\theta}(i, \mathbf{u}_0)$ dan $\mathbf{b} = (b_1, \dots, b_m)^{\top}$ dengan $b_i = s^*(i, \mathbf{u}_0)$, serta menggunakan asumsi $\|\mathbf{a} - \mathbf{b}\|_{\infty} \leq \delta$, maka berdasarkan lema di atas diperoleh

$$\sup_{i \in \mathcal{N}_h(\mathbf{u}_0)} |\widehat{\kappa}_{\theta}(i \mid \mathbf{u}_0) - \kappa^*(i \mid \mathbf{u}_0)| = \|\text{softmax}(\mathbf{a}) - \text{softmax}(\mathbf{b})\|_{\infty} \leq 2\delta. \quad (3.2.36)$$

■

Dengan demikian, penggunaan GNN memperluas kelas fungsi *kernel* dari keluarga *kernel* tetap menuju kelas *kernel* adaptif yang dipelajari dari data, tanpa mengorbankan struktur lokalitas yang diperlukan untuk analisis asimtotik.

3.3 Integrasi *Kernel* Terestimasi ke dalam Kerangka GWR

Pada bagian ini diuraikan integrasi *kernel* spasial terestimasi berbasis GNN ke dalam kerangka inferensi GWR. Pembahasan mencakup definisi formal model, peran *kernel* sebagai *nuisance parameter*, permasalahan endogenitas yang muncul, serta skema *cross-fitting* untuk memulihkan validitas inferensi.

3.3.1 Definisi Model *Graph Attention-based* GWR (GA-GWR)

Model *Graph Attention-based* (GA-GWR) mengintegrasikan *kernel* spasial terestimasi ke dalam kerangka regresi terboboti geografis. Model struktural yang mendasari proses pembangkitan data diasumsikan sebagai berikut.

Definisi 3.3.1 Misalkan $\{(y_i, \mathbf{x}_i, \mathbf{u}_i)\}_{i=1}^n$ adalah sampel acak dengan $y_i \in \mathbb{R}$, $\mathbf{x}_i \in \mathbb{R}^p$, dan $\mathbf{u}_i \in \mathbb{R}^2$. Model struktural diasumsikan sebagai

$$y_i = \mathbf{x}_i^\top \boldsymbol{\beta}(\mathbf{u}_i) + \varepsilon_i, \quad (3.3.1)$$

dengan $\boldsymbol{\beta} : \mathbb{R}^2 \rightarrow \mathbb{R}^p$ adalah fungsi koefisien spasial yang halus dan ε_i adalah galat acak dengan mean nol. Target inferensi adalah koefisien lokal $\boldsymbol{\beta}(\mathbf{u}_0)$ untuk suatu lokasi target tetap $\mathbf{u}_0 \in \mathbb{R}^2$.

Berbeda dengan GWR klasik yang menggunakan *kernel* tetap $K(\cdot)$, pada GA-GWR bobot spasial diperoleh dari *kernel* terestimasi berbasis GNN. Matriks bobot didefinisikan sebagai berikut.

Definisi 3.3.2 Matriks bobot untuk lokasi target \mathbf{u}_0 didefinisikan sebagai

$$\mathbf{W}_\theta(\mathbf{u}_0) = \text{diag}(\hat{\kappa}_\theta(1 | \mathbf{u}_0), \dots, \hat{\kappa}_\theta(n | \mathbf{u}_0)), \quad (3.3.2)$$

dengan $\hat{\kappa}_\theta(i | \mathbf{u}_0) > 0$ jika $i \in \mathcal{N}_h(\mathbf{u}_0)$ dan $\hat{\kappa}_\theta(i | \mathbf{u}_0) = 0$ jika $i \notin \mathcal{N}_h(\mathbf{u}_0)$.

Definisi 3.3.3 Estimator koefisien lokal pada lokasi target \mathbf{u}_0 didefinisikan sebagai

$$\hat{\boldsymbol{\beta}}_\theta(\mathbf{u}_0) = (\mathbf{X}^\top \mathbf{W}_\theta(\mathbf{u}_0) \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}_\theta(\mathbf{u}_0) \mathbf{y}, \quad (3.3.3)$$

dengan $\mathbf{X} = (\mathbf{x}_1, \dots, \mathbf{x}_n)^\top$ adalah matriks desain dan $\mathbf{y} = (y_1, \dots, y_n)^\top$ adalah vektor respons.

Estimator ini memiliki bentuk yang identik dengan estimator GWR klasik, tetapi dengan matriks bobot $\mathbf{W}_\theta(\mathbf{u}_0)$ yang dihasilkan dari *kernel* terestimasi. Perbedaan fundamental terletak pada sifat stokastik dari matriks bobot, yang membawa implikasi penting terhadap analisis asimtotik.

3.3.2 Kernel Terestimasi sebagai Nuisance Parameter

Dalam kerangka GA-GWR, parameter GNN θ yang menghasilkan *kernel* terestimasi berperan sebagai *nuisance parameter*, yaitu parameter yang diperlukan untuk estimasi tetapi bukan target inferensi utama. Peran *kernel* sebagai *nuisance parameter* membawa beberapa implikasi penting sebagai berikut.

- (i) Parameter θ dapat berdimensi sangat tinggi (ribuan hingga jutaan parameter pada arsitektur GNN modern), jauh melebihi dimensi target $\beta(\mathbf{u}_0) \in \mathbb{R}^p$.
- (ii) Estimasi dilakukan dalam dua tahap: pertama mengestimasi θ melalui pelatihan GNN, kemudian menggunakan $\hat{\theta}$ untuk menghitung $\hat{\beta}_{\hat{\theta}}(\mathbf{u}_0)$.
- (iii) Estimasi θ menambah sumber ketidakpastian yang harus diperhitungkan dalam inferensi.

Kerangka teoretis untuk menangani *nuisance parameter* berdimensi tinggi dalam konteks inferensi semiparametrik telah dikembangkan dalam literatur ekonometrika dan statistik, serta dinamakan *double machine learning* atau *debiased machine learning* (?). Pendekatan ini akan diadaptasi untuk konteks GA-GWR pada bagian selanjutnya.

3.3.3 Permasalahan Endogenitas dan Ketergantungan Data

Ketika *kernel* diestimasi dari data yang sama dengan data yang digunakan untuk mengestimasi koefisien lokal, muncul permasalahan endogenitas yang dapat menginvalidasi inferensi standar. Permasalahan ini bersumber dari ketergantungan

parameter GNN $\hat{\theta}$ terhadap galat ε melalui fungsi kerugian, terlepas dari bentuk spesifik fungsi kerugian yang digunakan.

Proposisi 3.3.4 Misalkan $\mathcal{L} : \Theta \times \mathbb{R}^n \rightarrow \mathbb{R}$ adalah fungsi kerugian sembarang yang memenuhi:

- (a) $\mathcal{L}(\theta; \mathbf{y})$ bergantung pada vektor respons \mathbf{y} ; dan
- (b) $\hat{\theta} = \arg \min_{\theta \in \Theta} \mathcal{L}(\theta; \mathbf{y})$ ada dan terukur.

Jika parameter kernel θ diestimasi menggunakan seluruh data $\{(y_i, \mathbf{x}_i, \mathbf{u}_i)\}_{i=1}^n$, maka matriks bobot $\mathbf{W}_{\hat{\theta}}(\mathbf{u}_0)$ bergantung pada vektor galat $\varepsilon = (\varepsilon_1, \dots, \varepsilon_n)^\top$. Akibatnya, kondisi

$$\mathbb{E}[\mathbf{X}^\top \mathbf{W}_{\hat{\theta}}(\mathbf{u}_0) \varepsilon] \neq \mathbf{0} \quad (3.3.4)$$

dapat terjadi, yang melanggar Asumsi GWR.2 yang diperlukan untuk konsistensi estimator. Dengan kata lain, eksogenitas galat tidak terjamin jika kernel diestimasi dari data yang sama.

Bukti. Dari model struktural $y_i = \mathbf{x}_i^\top \beta(\mathbf{u}_i) + \varepsilon_i$, vektor respons dapat ditulis sebagai

$$\mathbf{y} = \mathbf{f}(\mathbf{X}, \mathbf{U}) + \varepsilon, \quad (3.3.5)$$

dengan $\mathbf{f}(\mathbf{X}, \mathbf{U}) = (\mathbf{x}_1^\top \beta(\mathbf{u}_1), \dots, \mathbf{x}_n^\top \beta(\mathbf{u}_n))^\top$ adalah komponen deterministik. Sebab $\mathcal{L}(\theta; \mathbf{y})$ bergantung pada \mathbf{y} (kondisi (a)), maka

$$\mathcal{L}(\theta; \mathbf{y}) = \mathcal{L}(\theta; \mathbf{f}(\mathbf{X}, \mathbf{U}) + \varepsilon) =: \tilde{\mathcal{L}}(\theta; \mathbf{X}, \mathbf{U}, \varepsilon) \quad (3.3.6)$$

adalah fungsi eksplisit dari ε .

Selanjutnya, sebab $\hat{\theta} = \arg \min_{\theta} \tilde{\mathcal{L}}(\theta; \mathbf{X}, \mathbf{U}, \varepsilon)$ (kondisi (b)), maka $\hat{\theta}$ adalah fungsi terukur dari $(\mathbf{X}, \mathbf{U}, \varepsilon)$:

$$\hat{\theta} = g(\mathbf{X}, \mathbf{U}, \varepsilon) \quad (3.3.7)$$

untuk suatu fungsi g yang bergantung pada bentuk \mathcal{L} dan prosedur optimisasi. Kon-

sekuensinya, bobot $w_i = \hat{\kappa}_{\hat{\theta}}(i \mid \mathbf{u}_0)$ juga bergantung pada ε :

$$w_i = h_i(\mathbf{X}, \mathbf{U}, \varepsilon). \quad (3.3.8)$$

Ekspektasi suku galat tertimbang dapat didekomposisi menggunakan identitas kovarians $\mathbb{E}[AB] = \mathbb{E}[A]\mathbb{E}[B] + \text{Cov}(A, B)$:

$$\mathbb{E}[w_i \varepsilon_i] = \mathbb{E}[w_i] \cdot \underbrace{\mathbb{E}[\varepsilon_i]}_{=0} + \text{Cov}(w_i, \varepsilon_i) = \text{Cov}(w_i, \varepsilon_i). \quad (3.3.9)$$

Sebab $w_i = h_i(\mathbf{X}, \mathbf{U}, \varepsilon)$ bergantung pada ε_i melalui rantai $\varepsilon \rightarrow \hat{\theta} \rightarrow w_i$, maka dapat terjadi $\text{Cov}(w_i, \varepsilon_i) \neq 0$. Dengan demikian, mungkin untuk:

$$\mathbb{E}[\mathbf{X}^\top \mathbf{W}_{\hat{\theta}} \varepsilon] = \sum_{i=1}^n \mathbf{x}_i \cdot \text{Cov}(w_i, \varepsilon_i) \neq \mathbf{0}, \quad (3.3.10)$$

sehingga eksogenitas tidak terjamin. ■

Untuk memperjelas mekanisme kovarians secara kuantitatif, berikut adalah karakterisasi menggunakan ekspansi Taylor.

Lema 3.3.5 Misalkan $\hat{\theta}$ memiliki ekspansi Taylor di sekitar $\varepsilon = \mathbf{0}$, yaitu

$$\hat{\theta}(\varepsilon) = \hat{\theta}(\mathbf{0}) + \mathbf{J}_{\theta} \varepsilon + \mathcal{O}(\|\varepsilon\|^2), \quad (3.3.11)$$

dengan $\mathbf{J}_{\theta} = \frac{\partial \hat{\theta}}{\partial \varepsilon^\top} \Big|_{\varepsilon=\mathbf{0}}$ adalah matriks Jacobian, maka kovarians antara bobot dan galat adalah

$$\text{Cov}(w_i, \varepsilon_j) = \sigma^2 \nabla_{\theta} w_i^\top [\mathbf{J}_{\theta}]_{:,j} + \mathcal{O}(\sigma^4), \quad (3.3.12)$$

dengan $[\mathbf{J}_{\theta}]_{:,j}$ adalah kolom ke- j dari \mathbf{J}_{θ} .

Bukti. Ekspansi bobot di sekitar $\varepsilon = \mathbf{0}$ menghasilkan

$$w_i(\varepsilon) = w_i(\mathbf{0}) + \nabla_{\theta} w_i^\top \cdot \mathbf{J}_{\theta} \varepsilon + \mathcal{O}(\|\varepsilon\|^2). \quad (3.3.13)$$

Sebab $\mathbb{E}[\varepsilon_j] = 0$ dan $\mathbb{E}[\varepsilon\varepsilon_j] = \sigma^2\mathbf{e}_j$ (dengan \mathbf{e}_j adalah vektor unit ke- j), maka

$$\begin{aligned}
 \text{Cov}(w_i, \varepsilon_j) &= \mathbb{E}[(w_i - \mathbb{E}[w_i])\varepsilon_j] \\
 &= \mathbb{E}[(\nabla_{\theta} w_i^{\top} \mathbf{J}_{\theta} \varepsilon)\varepsilon_j] + \mathcal{O}(\sigma^4) \\
 &= \nabla_{\theta} w_i^{\top} \mathbf{J}_{\theta} \mathbb{E}[\varepsilon\varepsilon_j] \\
 &= \sigma^2 \nabla_{\theta} w_i^{\top} [\mathbf{J}_{\theta}]_{:,j}.
 \end{aligned} \tag{3.3.14}$$

■

Lema di atas menunjukkan bahwa $\text{Cov}(w_i, \varepsilon_j) \neq 0$ selama $\mathbf{J}_{\theta} \neq \mathbf{0}$ (estimator $\hat{\theta}$ sensitif terhadap *noise*) dan $\nabla_{\theta} w_i \neq \mathbf{0}$ (bobot responsif terhadap parameter). Kedua kondisi ini hampir selalu terpenuhi dalam praktik karena:

- (i) pelatihan GNN menggunakan respons y yang mengandung galat ε ;
- (ii) optimisasi menyesuaikan θ untuk meminimalkan kerugian, sehingga $\hat{\theta}$ sensitif terhadap perubahan dalam y (dengan demikian terhadap ε);
- (iii) bobot yang dihasilkan berkorelasi dengan galat, yaitu observasi dengan ε_i besar cenderung diberi bobot yang disesuaikan untuk mengakomodasi nilai y_i yang ekstrem; dan
- (iv) korelasi antara bobot dan galat merusak sifat *mean-zero* dari suku galat terimbang.

Permasalahan ini analog dengan *overfitting* dalam pembelajaran mesin, tetapi dengan konsekuensi yang lebih serius, bukan hanya prediksi yang buruk, tetapi *inferensi yang tidak valid*. Uji statistik dan interval konfidensi yang dihasilkan tidak dapat dipercaya.

3.3.4 Skema *Cross-Fitting* untuk Inferensi Valid

Untuk mengatasi permasalahan endogenitas, digunakan skema *cross-fitting* yang memisahkan data untuk estimasi *kernel* dan estimasi koefisien lokal. Pende-

katan ini mengadaptasi teknik *double/debiased machine learning* (?) ke konteks GWR.

Definisi 3.3.6 (Skema *cross-fitting*) Partisi himpunan indeks $\{1, \dots, n\}$ menjadi K fold yang saling lepas, yaitu

$$\{1, \dots, n\} = \mathcal{I}_1 \cup \mathcal{I}_2 \cup \dots \cup \mathcal{I}_K, \quad \mathcal{I}_k \cap \mathcal{I}_\ell = \emptyset \text{ untuk } k \neq \ell. \quad (3.3.15)$$

Untuk setiap fold k , didefinisikan:

(i) fold pelatihan, yaitu $\mathcal{I}_{-k} = \{1, \dots, n\} \setminus \mathcal{I}_k$; dan

(ii) fold estimasi, yaitu \mathcal{I}_k .

Parameter GNN $\hat{\boldsymbol{\theta}}^{(-k)}$ diestimasi hanya menggunakan data pada \mathcal{I}_{-k} , kemudian digunakan untuk menghitung bobot pada observasi di \mathcal{I}_k .

Untuk setiap fold k , dapat didefinisikan estimator parsial yang hanya menggunakan observasi pada fold tersebut.

Definisi 3.3.7 Untuk setiap fold $k \in \{1, \dots, K\}$, estimator parsial didefinisikan sebagai

$$\hat{\boldsymbol{\beta}}^{(k)}(\mathbf{u}_0) = (\mathbf{X}_k^\top \mathbf{W}_k^{(-k)}(\mathbf{u}_0) \mathbf{X}_k)^{-1} \mathbf{X}_k^\top \mathbf{W}_k^{(-k)}(\mathbf{u}_0) \mathbf{y}_k, \quad (3.3.16)$$

dengan \mathbf{X}_k dan \mathbf{y}_k adalah matriks desain dan vektor respons untuk observasi di \mathcal{I}_k , serta $\mathbf{W}_k^{(-k)}(\mathbf{u}_0)$ adalah matriks bobot diagonal yang dihitung menggunakan parameter $\hat{\boldsymbol{\theta}}^{(-k)}$.

Estimator parsial $\hat{\boldsymbol{\beta}}^{(k)}(\mathbf{u}_0)$ bersifat valid dalam arti eksogenitas terpenuhi, namun hanya menggunakan sebagian kecil data (sekitar n/K observasi). Untuk memanfaatkan seluruh data sambil mempertahankan validitas inferensi, estimator-estimator parsial digabungkan melalui skema rata-rata tertimbang.

Teorema 3.3.8 Misalkan $\mathbf{H}_k(\mathbf{u}_0) = \mathbf{X}_k^\top \mathbf{W}_k^{(-k)}(\mathbf{u}_0) \mathbf{X}_k$ adalah matriks informasi

lokal untuk fold k . Estimator cross-fitted yang didefinisikan sebagai rata-rata terimbang dari estimator parsial

$$\hat{\beta}_{\text{CF}}(\mathbf{u}_0) = \left(\sum_{k=1}^K \mathbf{H}_k(\mathbf{u}_0) \right)^{-1} \left(\sum_{k=1}^K \mathbf{H}_k(\mathbf{u}_0) \hat{\beta}^{(k)}(\mathbf{u}_0) \right) \quad (3.3.17)$$

ekuivalen dengan solusi masalah weighted least squares gabungan

$$\hat{\beta}_{\text{CF}}(\mathbf{u}_0) = \arg \min_{\beta \in \mathbb{R}^p} \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)}(\mathbf{u}_0) (y_i - \mathbf{x}_i^\top \beta)^2, \quad (3.3.18)$$

yang memiliki bentuk tertutup

$$\hat{\beta}_{\text{CF}}(\mathbf{u}_0) = \left(\sum_{k=1}^K \mathbf{X}_k^\top \mathbf{W}_k^{(-k)}(\mathbf{u}_0) \mathbf{X}_k \right)^{-1} \left(\sum_{k=1}^K \mathbf{X}_k^\top \mathbf{W}_k^{(-k)}(\mathbf{u}_0) \mathbf{y}_k \right). \quad (3.3.19)$$

Bukti. Didefinisikan fungsi objektif

$$L(\beta) = \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)}(\mathbf{u}_0) (y_i - \mathbf{x}_i^\top \beta)^2. \quad (3.3.20)$$

Sebab partisi $\{\mathcal{I}_1, \dots, \mathcal{I}_K\}$ bersifat saling lepas dan lengkap, maka penjumlahan ganda di atas melingkupi seluruh observasi $i \in \{1, \dots, n\}$, dengan setiap observasi i diberi bobot $w_i^{(-k(i))}(\mathbf{u}_0)$ dengan $k(i)$ adalah *fold* yang memuat i .

Untuk memperoleh kondisi orde pertama, dihitung turunan parsial terhadap β sebagai berikut.

$$\frac{\partial L}{\partial \beta} = -2 \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)}(\mathbf{u}_0) \mathbf{x}_i (y_i - \mathbf{x}_i^\top \beta). \quad (3.3.21)$$

Dengan menyamakan turunan ke nol dan menyusun ulang, diperoleh

$$\sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)}(\mathbf{u}_0) \mathbf{x}_i y_i = \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)}(\mathbf{u}_0) \mathbf{x}_i \mathbf{x}_i^\top \hat{\beta}. \quad (3.3.22)$$

Suku di ruas kiri dapat ditulis dalam notasi matriks sebagai

$$\sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)}(\mathbf{u}_0) \mathbf{x}_i y_i = \sum_{k=1}^K \mathbf{X}_k^\top \mathbf{W}_k^{(-k)}(\mathbf{u}_0) \mathbf{y}_k, \quad (3.3.23)$$

dan suku di ruas kanan sebagai

$$\sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)}(\mathbf{u}_0) \mathbf{x}_i \mathbf{x}_i^\top = \sum_{k=1}^K \mathbf{X}_k^\top \mathbf{W}_k^{(-k)}(\mathbf{u}_0) \mathbf{X}_k. \quad (3.3.24)$$

Dengan demikian, persamaan normal menjadi

$$\left(\sum_{k=1}^K \mathbf{X}_k^\top \mathbf{W}_k^{(-k)}(\mathbf{u}_0) \mathbf{X}_k \right) \hat{\boldsymbol{\beta}} = \sum_{k=1}^K \mathbf{X}_k^\top \mathbf{W}_k^{(-k)}(\mathbf{u}_0) \mathbf{y}_k. \quad (3.3.25)$$

Dengan asumsi bahwa matriks $\sum_{k=1}^K \mathbf{X}_k^\top \mathbf{W}_k^{(-k)}(\mathbf{u}_0) \mathbf{X}_k$ invertibel, solusinya adalah

$$\hat{\boldsymbol{\beta}}_{\text{CF}}(\mathbf{u}_0) = \left(\sum_{k=1}^K \mathbf{X}_k^\top \mathbf{W}_k^{(-k)}(\mathbf{u}_0) \mathbf{X}_k \right)^{-1} \left(\sum_{k=1}^K \mathbf{X}_k^\top \mathbf{W}_k^{(-k)}(\mathbf{u}_0) \mathbf{y}_k \right). \quad (3.3.26)$$

Dari definisi estimator parsial, berlaku

$$\hat{\boldsymbol{\beta}}^{(k)}(\mathbf{u}_0) = \mathbf{H}_k(\mathbf{u}_0)^{-1} \mathbf{X}_k^\top \mathbf{W}_k^{(-k)}(\mathbf{u}_0) \mathbf{y}_k, \quad (3.3.27)$$

sehingga

$$\mathbf{X}_k^\top \mathbf{W}_k^{(-k)}(\mathbf{u}_0) \mathbf{y}_k = \mathbf{H}_k(\mathbf{u}_0) \hat{\boldsymbol{\beta}}^{(k)}(\mathbf{u}_0). \quad (3.3.28)$$

Substitusi ke Persamaan (3.3.26) menghasilkan

$$\hat{\boldsymbol{\beta}}_{\text{CF}}(\mathbf{u}_0) = \left(\sum_{k=1}^K \mathbf{H}_k(\mathbf{u}_0) \right)^{-1} \left(\sum_{k=1}^K \mathbf{H}_k(\mathbf{u}_0) \hat{\boldsymbol{\beta}}^{(k)}(\mathbf{u}_0) \right). \quad (3.3.29)$$

Bentuk ini merupakan *rata-rata tertimbang matriks (matrix-weighted average)* dari estimator parsial, dengan bobot berupa matriks informasi lokal $\mathbf{H}_k(\mathbf{u}_0)$.

■

Perlu dicatat bahwa jika $K = 1$ (tanpa *cross-fitting*), maka $\hat{\beta}_{\text{CF}}(\mathbf{u}_0) = \hat{\beta}^{(1)}(\mathbf{u}_0)$, yang merupakan estimator GA-GWR standar tanpa pemisahan data.

Skema *cross-fitting* memulihkan eksogenitas melalui mekanisme berikut.

Proposisi 3.3.9 *Untuk setiap fold k , karena $\hat{\theta}^{(-k)}$ diestimasi tanpa menggunakan data pada \mathcal{I}_k , maka kondisional pada $\hat{\theta}^{(-k)}$ berlaku*

$$\mathbb{E}[\mathbf{X}_k^\top \mathbf{W}_k^{(-k)}(\mathbf{u}_0) \varepsilon_k \mid \hat{\theta}^{(-k)}] = \mathbf{0}, \quad (3.3.30)$$

dengan ε_k adalah vektor galat untuk observasi di \mathcal{I}_k . Hal ini karena $\mathbf{W}_k^{(-k)}(\mathbf{u}_0)$ independen dari ε_k .

Bukti. Langkah pertama adalah menunjukkan independensi antara bobot dan galat. Berdasarkan konstruksi *cross-fitting*, parameter $\hat{\theta}^{(-k)}$ diestimasi menggunakan data pada *fold* pelatihan \mathcal{I}_{-k} , sehingga $\hat{\theta}^{(-k)}$ merupakan fungsi terukur dari $\{(y_i, \mathbf{x}_i, \mathbf{u}_i) : i \in \mathcal{I}_{-k}\}$. Secara eksplisit, dapat ditulis

$$\hat{\theta}^{(-k)} = g(\{(y_i, \mathbf{x}_i, \mathbf{u}_i)\}_{i \in \mathcal{I}_{-k}}) \quad (3.3.31)$$

untuk suatu fungsi terukur g . Sebab galat $\{\varepsilon_i\}_{i=1}^n$ diasumsikan independen antarobservasi, maka himpunan galat pada *fold* pelatihan $\{\varepsilon_i : i \in \mathcal{I}_{-k}\}$ independen dari himpunan galat pada *fold* estimasi $\{\varepsilon_i : i \in \mathcal{I}_k\}$. Sebab $\hat{\theta}^{(-k)}$ hanya bergantung pada data di \mathcal{I}_{-k} dan matriks bobot $\mathbf{W}_k^{(-k)}(\mathbf{u}_0)$ merupakan fungsi deterministik dari $\hat{\theta}^{(-k)}$ dan lokasi $\{\mathbf{u}_i : i \in \mathcal{I}_k\}$, maka

$$\mathbf{W}_k^{(-k)}(\mathbf{u}_0) \perp\!\!\!\perp \varepsilon_k \mid \{\mathbf{x}_i, \mathbf{u}_i\}_{i \in \mathcal{I}_k}. \quad (3.3.32)$$

Matriks bobot $\mathbf{W}_k^{(-k)}(\mathbf{u}_0)$ berbentuk diagonal dengan elemen $w_i^{(-k)}(\mathbf{u}_0) = \hat{\kappa}_{\hat{\theta}^{(-k)}}(i \mid \mathbf{u}_0)$ untuk $i \in \mathcal{I}_k$. Dengan demikian, produk $\mathbf{X}_k^\top \mathbf{W}_k^{(-k)}(\mathbf{u}_0) \varepsilon_k$ dapat

diuraikan sebagai

$$\begin{aligned} \mathbf{X}_k^\top \mathbf{W}_k^{(-k)}(\mathbf{u}_0) \boldsymbol{\varepsilon}_k &= \begin{pmatrix} \mathbf{x}_{i_1} & \mathbf{x}_{i_2} & \cdots & \mathbf{x}_{i_{|k|}} \end{pmatrix} \begin{pmatrix} w_{i_1}^{(-k)} & & & \\ & \ddots & & \\ & & w_{i_{|k|}}^{(-k)} & \\ & & & \end{pmatrix} \begin{pmatrix} \varepsilon_{i_1} \\ \vdots \\ \varepsilon_{i_{|k|}} \end{pmatrix} \\ &= \sum_{i \in \mathcal{I}_k} w_i^{(-k)}(\mathbf{u}_0) \mathbf{x}_i \varepsilon_i, \end{aligned} \quad (3.3.33)$$

dengan $\{i_1, i_2, \dots, i_{|k|}\}$ adalah enumerasi elemen-elemen \mathcal{I}_k . Dengan menggunakan linearitas ekspektasi kondisional dan independensi yang telah ditunjukkan, diperoleh

$$\begin{aligned} \mathbb{E}[\mathbf{X}_k^\top \mathbf{W}_k^{(-k)}(\mathbf{u}_0) \boldsymbol{\varepsilon}_k \mid \hat{\boldsymbol{\theta}}^{(-k)}] &= \mathbb{E}\left[\sum_{i \in \mathcal{I}_k} w_i^{(-k)}(\mathbf{u}_0) \mathbf{x}_i \varepsilon_i \mid \hat{\boldsymbol{\theta}}^{(-k)}\right] \\ &= \sum_{i \in \mathcal{I}_k} \mathbb{E}[w_i^{(-k)}(\mathbf{u}_0) \mathbf{x}_i \varepsilon_i \mid \hat{\boldsymbol{\theta}}^{(-k)}]. \end{aligned} \quad (3.3.34)$$

Sebab $w_i^{(-k)}(\mathbf{u}_0)$ merupakan fungsi deterministik dari $\hat{\boldsymbol{\theta}}^{(-k)}$ dan \mathbf{u}_i , maka kondisional pada $\hat{\boldsymbol{\theta}}^{(-k)}$, bobot $w_i^{(-k)}(\mathbf{u}_0)$ bersifat konstan. Dengan demikian, Persamaan (3.3.34) dapat ditulis ulang sebagai

$$\sum_{i \in \mathcal{I}_k} \mathbb{E}[w_i^{(-k)}(\mathbf{u}_0) \mathbf{x}_i \varepsilon_i \mid \hat{\boldsymbol{\theta}}^{(-k)}] = \sum_{i \in \mathcal{I}_k} w_i^{(-k)}(\mathbf{u}_0) \mathbb{E}[\mathbf{x}_i \varepsilon_i \mid \hat{\boldsymbol{\theta}}^{(-k)}]. \quad (3.3.35)$$

Selanjutnya, karena $\hat{\boldsymbol{\theta}}^{(-k)} \perp\!\!\!\perp (\mathbf{x}_i, \varepsilon_i)$ untuk setiap $i \in \mathcal{I}_k$, maka berlaku

$$\mathbb{E}[\mathbf{x}_i \varepsilon_i \mid \hat{\boldsymbol{\theta}}^{(-k)}] = \mathbb{E}[\mathbf{x}_i \varepsilon_i]. \quad (3.3.36)$$

Dengan menggunakan hukum ekspektasi bersyarat (*tower property*) dan

asumsi eksogenitas $\mathbb{E}[\varepsilon_i \mid \mathbf{x}_i, \mathbf{u}_i] = 0$, diperoleh

$$\begin{aligned}\mathbb{E}[\mathbf{x}_i \varepsilon_i] &= \mathbb{E}[\mathbb{E}[\mathbf{x}_i \varepsilon_i \mid \mathbf{x}_i, \mathbf{u}_i]] \\ &= \mathbb{E}[\mathbf{x}_i \mathbb{E}[\varepsilon_i \mid \mathbf{x}_i, \mathbf{u}_i]] \\ &= \mathbb{E}[\mathbf{x}_i \cdot 0] = \mathbf{0}.\end{aligned}\tag{3.3.37}$$

Dengan menggabungkan hasil-hasil di atas, diperoleh

$$\mathbb{E}[\mathbf{X}_k^\top \mathbf{W}_k^{(-k)}(\mathbf{u}_0) \varepsilon_k \mid \hat{\boldsymbol{\theta}}^{(-k)}] = \sum_{i \in \mathcal{I}_k} w_i^{(-k)}(\mathbf{u}_0) \cdot \mathbf{0} = \mathbf{0}.\tag{3.3.38}$$

■

Dengan pemulihan eksogenitas ini, hukum bilangan besar dapat diterapkan kembali dan konsistensi estimator dapat dijamin. Analisis asimtotik lengkap akan diuraikan pada bagian selanjutnya.

3.4 Analisis Asimtotik Koefisien Lokal pada GA-GWR

Bagian ini mengembangkan teori asimtotik untuk estimator *cross-fitted* GA-GWR. Analisis mencakup dekomposisi bias-variansi, konsistensi, dan distribusi asimtotik koefisien lokal. Untuk menyederhanakan notasi, dependensi terhadap lokasi target \mathbf{u}_0 akan dihilangkan bila tidak menimbulkan ambiguitas.

3.4.1 Asumsi-Asumsi Regularitas

Analisis asimtotik memerlukan sejumlah asumsi regularitas yang mencakup struktur data, properti fungsi koefisien, serta karakteristik *kernel* terestimasi. Asumsi-asumsi ini dikelompokkan menjadi tiga kategori, yaitu asumsi data dan model, asumsi kehalusan fungsi koefisien, serta asumsi lokalitas dan *kernel*.

Asumsi data dan model menetapkan kondisi dasar pada observasi, galat, dan kovariat. Di bawah ini adalah keempat asumsi utama dalam kategori ini.

Asumsi GA-GWR.1 (Independensi) *Observasi* $\{(y_i, \mathbf{x}_i, \mathbf{u}_i)\}_{i=1}^n$ bersifat indepen-

den dan berdistribusi identik (i.i.d.).

Asumsi independensi diperlukan untuk penerapan hukum bilangan besar dan teorema limit pusat. Dalam konteks spasial, asumsi ini dapat direlaksasi menjadi dependensi spasial yang melemah (*mixing conditions*), namun pembahasan tersebut berada di luar cakupan analisis ini.

Asumsi GA-GWR.2 (Eksogenitas Lokal) Galat memenuhi kondisi ekspektasi kondisional nol, yaitu

$$\mathbb{E}[\varepsilon_i \mid \mathbf{x}_i, \mathbf{u}_i] = 0. \quad (3.4.1)$$

Asumsi eksogenitas menjamin bahwa galat tidak berkorelasi dengan kovariat dan lokasi. Bersama dengan skema *cross-fitting*, asumsi ini memastikan bahwa suku galat tertimbang memiliki ekspektasi nol.

Asumsi GA-GWR.3 (Homoskedastisitas Kondisional) Variansi galat bersyarat bersifat konstan, yaitu

$$\text{Var}(\varepsilon_i \mid \mathbf{x}_i, \mathbf{u}_i) = \sigma^2 < \infty. \quad (3.4.2)$$

Asumsi homoskedastisitas menyederhanakan analisis variansi. Kasus heteroskedastisitas dapat ditangani dengan modifikasi pada estimator variansi, namun tidak mengubah hasil konsistensi.

Asumsi GA-GWR.4 (Momen Kovariat Terbatas) Kovariat memiliki momen kedua yang terbatas:

$$\mathbb{E}[\|\mathbf{x}_i\|^2] < \infty. \quad (3.4.3)$$

Asumsi ini menjamin eksistensi dan keterbatasan matriks $\mathbf{X}^\top \mathbf{W} \mathbf{X}$ serta inversnya.

Asumsi selanjutnya berkaitan dengan kehalusan fungsi koefisien spasial. Asumsi ini penting untuk mengendalikan bias yang muncul akibat aproksimasi lokal. Berikut adalah asumsi kehalusan yang digunakan.

Asumsi GA-GWR.5 (Diferensiabilitas Fungsi Koefisien) Fungsi koefisien $\beta : \mathbb{R}^2 \rightarrow \mathbb{R}^p$ dua kali terdiferensiasikan kontinu di sekitar lokasi target \mathbf{u}_0 . Secara eks-

plisit, terdapat lingkungan $\mathcal{B}_\delta(\mathbf{u}_0)$ sedemikian sehingga untuk setiap $\mathbf{u} \in \mathcal{B}_\delta(\mathbf{u}_0)$:

$$\beta(\mathbf{u}) = \beta(\mathbf{u}_0) + \nabla\beta(\mathbf{u}_0)^\top(\mathbf{u} - \mathbf{u}_0) + \frac{1}{2}(\mathbf{u} - \mathbf{u}_0)^\top \mathbf{H}_\beta(\mathbf{u}_0)(\mathbf{u} - \mathbf{u}_0) + \quad (3.4.4)$$

$$o(\|\mathbf{u} - \mathbf{u}_0\|^2), \quad (3.4.5)$$

dengan $\nabla\beta(\mathbf{u}_0) \in \mathbb{R}^{2 \times p}$ adalah matriks gradien dan $\mathbf{H}_\beta(\mathbf{u}_0)$ adalah tensor Hessian.

Kehalusan fungsi koefisien memungkinkan ekspansi Taylor yang menjadi dasar analisis bias. Orde kehalusan menentukan laju konvergensi bias terhadap nol.

Asumsi terakhir berkaitan dengan karakteristik *kernel* terestimasi dan lokalitas estimasi. Asumsi-asumsi ini penting untuk mengendalikan bias dan variansi estimator. Berikut adalah asumsi-asumsi tersebut.

Asumsi GA-GWR.6 (Shrinking Neighborhood) Parameter bandwidth $h = h_n$ memenuhi $h_n \rightarrow 0$ ketika $n \rightarrow \infty$.

Asumsi ini menjamin bahwa observasi yang digunakan dalam estimasi lokal semakin terkonsentrasi di sekitar lokasi target, sehingga aproksimasi $\beta(\mathbf{u}_i) \approx \beta(\mathbf{u}_0)$ semakin akurat.

Asumsi GA-GWR.7 (Ukuran Sampel Lokal Divergen) Jumlah observasi efektif di dalam neighborhood divergen:

$$nh_n^{d_{\text{eff}}} \rightarrow \infty \quad \text{ketika } n \rightarrow \infty, \quad (3.4.6)$$

dengan $d_{\text{eff}} \in (0, 2]$ adalah dimensi fraktal efektif dari metrik jarak yang digunakan.

Untuk metrik Euclidean pada ruang homogen, $d_{\text{eff}} = d = 2$. Untuk metrik non-Euclidean (misalnya jarak jaringan), d_{eff} dapat berbeda dan perlu diestimasi dari struktur data lokal.

Proposisi 3.4.1 Dimensi fraktal efektif dapat diestimasi dari distribusi jumlah observasi dalam ball lokal. Untuk suatu lokasi target \mathbf{u}_0 dan rangkaian radius $h_1 <$

$h_2 < \dots < h_K$, didefinisikan

$$m_k = |\mathcal{N}_{h_k}^d(\mathbf{u}_0)| = \#\{i : d(\mathbf{u}_i, \mathbf{u}_0) \leq h_k\}. \quad (3.4.7)$$

Dimensi fraktal diestimasi melalui regresi log-log:

$$\hat{d}_{\text{eff}} = \frac{\sum_k (\log h_k - \log \bar{h})(\log m_k - \log \bar{m})}{\sum_k (\log h_k - \log \bar{h})^2}, \quad (3.4.8)$$

dengan bar menunjukkan rata-rata. Nilai \hat{d}_{eff} umumnya stabil untuk lokasi dalam wilayah yang relatif homogen.

Asumsi GA-GWR.8 (Keterbatasan Bobot Kernel) Bobot kernel terestimasi memenuhi kondisi keterbatasan:

$$\sup_{i \in \mathcal{N}_h(\mathbf{u}_0)} w_i(\mathbf{u}_0) \leq \frac{C}{nh^d} \quad (3.4.9)$$

untuk suatu konstanta $C > 0$ yang tidak bergantung pada n .

Asumsi ini mencegah satu observasi mendominasi estimator dan diperlukan untuk penerapan teorema limit pusat Lindeberg–Feller.

Asumsi GA-GWR.9 (Simetri Lokal Asimtotik) Bobot kernel memenuhi kondisi simetri lokal, yaitu

$$\sum_{i=1}^n w_i(\mathbf{u}_0)(\mathbf{u}_i - \mathbf{u}_0) \xrightarrow{p} \mathbf{0}. \quad (3.4.10)$$

Asumsi simetri lokal menjamin bahwa bobot tidak bias secara sistematis ke satu arah. Hal ini dicapai melalui desain arsitektur GNN yang menggunakan koordinat relatif $\mathbf{u}_i - \mathbf{u}_0$ sebagai input.

Asumsi GA-GWR.10 (Kontinuitas Bobot) Fungsi bobot bersifat Lipschitz kontinu terhadap input, yaitu

$$|w_i(\mathbf{u}_0; \mathbf{z}) - w_i(\mathbf{u}_0; \mathbf{z}')| \leq L \|\mathbf{z} - \mathbf{z}'\| \quad (3.4.11)$$

untuk suatu konstanta Lipschitz $L > 0$.

Kontinuitas diperlukan untuk penerapan hukum bilangan besar *uniform* dan kontrol suku sisa dalam ekspansi Taylor.

3.4.2 Analisis Bias Asimtotik Koefisien Lokal

Analisis bias dimulai dengan dekomposisi estimator *cross-fitted* ke dalam suku target, suku bias, dan suku galat.

Teorema 3.4.2 *Estimator cross-fitted GA-GWR dapat didekomposisikan sebagai*

$$\hat{\beta}_{CF}(\mathbf{u}_0) = \beta(\mathbf{u}_0) + \mathbf{B}_n(\mathbf{u}_0) + \mathbf{V}_n(\mathbf{u}_0), \quad (3.4.12)$$

dengan suku bias

$$\mathbf{B}_n(\mathbf{u}_0) = \left(\sum_{k=1}^K \mathbf{H}_k \right)^{-1} \left(\sum_{k=1}^K \mathbf{X}_k^\top \mathbf{W}_k^{(-k)} \mathbf{X}_k (\beta(\mathbf{U}_k) - \beta(\mathbf{u}_0)) \right) \quad (3.4.13)$$

dan suku galat (noise term)

$$\mathbf{V}_n(\mathbf{u}_0) = \left(\sum_{k=1}^K \mathbf{H}_k \right)^{-1} \left(\sum_{k=1}^K \mathbf{X}_k^\top \mathbf{W}_k^{(-k)} \boldsymbol{\varepsilon}_k \right), \quad (3.4.14)$$

dengan $\beta(\mathbf{U}_k) - \beta(\mathbf{u}_0)$ adalah vektor yang elemen ke- i -nya (untuk $i \in \mathcal{I}_k$) adalah $\beta(\mathbf{u}_i) - \beta(\mathbf{u}_0)$.

Bukti. Dari model struktural, untuk setiap observasi $i \in \mathcal{I}_k$ berlaku

$$y_i = \mathbf{x}_i^\top \beta(\mathbf{u}_i) + \varepsilon_i. \quad (3.4.15)$$

Dengan menambah dan mengurangi $\mathbf{x}_i^\top \beta(\mathbf{u}_0)$, diperoleh

$$y_i = \mathbf{x}_i^\top \beta(\mathbf{u}_0) + \mathbf{x}_i^\top (\beta(\mathbf{u}_i) - \beta(\mathbf{u}_0)) + \varepsilon_i. \quad (3.4.16)$$

Dalam notasi matriks untuk *fold k*:

$$\mathbf{y}_k = \mathbf{X}_k \boldsymbol{\beta}(\mathbf{u}_0) + \mathbf{X}_k (\boldsymbol{\beta}(\mathbf{U}_k) - \boldsymbol{\beta}(\mathbf{u}_0)) + \boldsymbol{\varepsilon}_k. \quad (3.4.17)$$

Substitusi ke estimator *cross-fitted*:

$$\begin{aligned} \hat{\boldsymbol{\beta}}_{\text{CF}} &= \left(\sum_{k=1}^K \mathbf{H}_k \right)^{-1} \left(\sum_{k=1}^K \mathbf{X}_k^\top \mathbf{W}_k^{(-k)} \mathbf{y}_k \right) \\ &= \left(\sum_{k=1}^K \mathbf{H}_k \right)^{-1} \left(\sum_{k=1}^K \mathbf{X}_k^\top \mathbf{W}_k^{(-k)} \left[\mathbf{X}_k \boldsymbol{\beta}(\mathbf{u}_0) + \mathbf{X}_k (\boldsymbol{\beta}(\mathbf{U}_k) - \boldsymbol{\beta}(\mathbf{u}_0)) + \boldsymbol{\varepsilon}_k \right] \right). \end{aligned} \quad (3.4.18)$$

Dengan linearitas penjumlahan dan fakta bahwa $\mathbf{X}_k^\top \mathbf{W}_k^{(-k)} \mathbf{X}_k = \mathbf{H}_k$, diperoleh

$$\begin{aligned} \hat{\boldsymbol{\beta}}_{\text{CF}} &= \left(\sum_{k=1}^K \mathbf{H}_k \right)^{-1} \left(\sum_{k=1}^K \mathbf{H}_k \right) \boldsymbol{\beta}(\mathbf{u}_0) \\ &\quad + \left(\sum_{k=1}^K \mathbf{H}_k \right)^{-1} \left(\sum_{k=1}^K \mathbf{X}_k^\top \mathbf{W}_k^{(-k)} \mathbf{X}_k (\boldsymbol{\beta}(\mathbf{U}_k) - \boldsymbol{\beta}(\mathbf{u}_0)) \right) \\ &\quad + \left(\sum_{k=1}^K \mathbf{H}_k \right)^{-1} \left(\sum_{k=1}^K \mathbf{X}_k^\top \mathbf{W}_k^{(-k)} \boldsymbol{\varepsilon}_k \right) \\ &= \boldsymbol{\beta}(\mathbf{u}_0) + \mathbf{B}_n(\mathbf{u}_0) + \mathbf{V}_n(\mathbf{u}_0). \end{aligned} \quad (3.4.19)$$

■

Untuk menganalisis perilaku asimtotik suku bias, digunakan ekspansi Taylor dari fungsi koefisien.

Proposisi 3.4.3 *Di bawah Asumsi GA-GWR.5, untuk setiap $\mathbf{u}_i \in \mathcal{N}_h(\mathbf{u}_0)$:*

$$\boldsymbol{\beta}(\mathbf{u}_i) - \boldsymbol{\beta}(\mathbf{u}_0) = \nabla \boldsymbol{\beta}(\mathbf{u}_0)^\top (\mathbf{u}_i - \mathbf{u}_0) + \mathbf{R}_i, \quad (3.4.20)$$

dengan suku sisa \mathbf{R}_i memenuhi $\|\mathbf{R}_i\| \leq C_\beta \|\mathbf{u}_i - \mathbf{u}_0\|^2$ untuk suatu konstanta $C_\beta > 0$.

Dengan ekspansi ini, suku bias dapat diuraikan menjadi dua komponen.

Teorema 3.4.4 *Suku bias dapat ditulis sebagai*

$$\mathbf{B}_n(\mathbf{u}_0) = \mathbf{B}_n^{(1)}(\mathbf{u}_0) + \mathbf{B}_n^{(2)}(\mathbf{u}_0), \quad (3.4.21)$$

dengan suku bias orde pertama

$$\mathbf{B}_n^{(1)}(\mathbf{u}_0) = \left(\sum_{k=1}^K \mathbf{H}_k \right)^{-1} \left(\sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \mathbf{x}_i \mathbf{x}_i^\top \nabla \beta(\mathbf{u}_0)^\top (\mathbf{u}_i - \mathbf{u}_0) \right) \quad (3.4.22)$$

dan suku bias orde kedua

$$\mathbf{B}_n^{(2)}(\mathbf{u}_0) = \left(\sum_{k=1}^K \mathbf{H}_k \right)^{-1} \left(\sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \mathbf{x}_i \mathbf{x}_i^\top \mathbf{R}_i \right). \quad (3.4.23)$$

Bukti. Dengan mensubstitusikan ekspansi Taylor ke dalam ekspresi bias:

$$\begin{aligned} & \sum_{k=1}^K \mathbf{X}_k^\top \mathbf{W}_k^{(-k)} \mathbf{X}_k (\beta(\mathbf{U}_k) - \beta(\mathbf{u}_0)) \\ = & \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \mathbf{x}_i \mathbf{x}_i^\top (\beta(\mathbf{u}_i) - \beta(\mathbf{u}_0)) \\ = & \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \mathbf{x}_i \mathbf{x}_i^\top \left[\nabla \beta(\mathbf{u}_0)^\top (\mathbf{u}_i - \mathbf{u}_0) + \mathbf{R}_i \right]. \end{aligned} \quad (3.4.24)$$

Pemisahan menjadi dua suku memberikan hasil yang diklaim. ■

Proposisi 3.4.5 *Di bawah Asumsi GA-GWR.9, suku bias orde pertama memenuhi*

$$\mathbf{B}_n^{(1)}(\mathbf{u}_0) \xrightarrow{p} \mathbf{0}. \quad (3.4.25)$$

Bukti. Perhatikan bahwa

$$\sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \mathbf{x}_i \mathbf{x}_i^\top \nabla \beta(\mathbf{u}_0)^\top (\mathbf{u}_i - \mathbf{u}_0) \quad (3.4.26)$$

$$= \left(\sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \mathbf{x}_i \mathbf{x}_i^\top \right) \nabla \beta(\mathbf{u}_0)^\top \left(\sum_{j=1}^n \tilde{w}_j (\mathbf{u}_j - \mathbf{u}_0) \right), \quad (3.4.27)$$

dengan \tilde{w}_j adalah bobot yang sesuai untuk observasi j . Berdasarkan Asumsi GA-GWR.9, suku $\sum_j \tilde{w}_j (\mathbf{u}_j - \mathbf{u}_0) \xrightarrow{p} \mathbf{0}$, sehingga $\mathbf{B}_n^{(1)}(\mathbf{u}_0) \xrightarrow{p} \mathbf{0}$. ■

Teorema 3.4.6 *Di bawah Asumsi GA-GWR.5–GA-GWR.9, suku bias memenuhi*

$$\mathbf{B}_n(\mathbf{u}_0) = \mathcal{O}_p(h^2). \quad (3.4.28)$$

Secara khusus, karena $h \rightarrow 0$, maka $\mathbf{B}_n(\mathbf{u}_0) \xrightarrow{p} \mathbf{0}$.

Bukti. Dari Proposisi 3.4.5, $\mathbf{B}_n^{(1)}(\mathbf{u}_0) \xrightarrow{p} \mathbf{0}$. Untuk suku bias orde kedua, diperhatikan bahwa

$$\begin{aligned} \left\| \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \mathbf{x}_i \mathbf{x}_i^\top \mathbf{R}_i \right\| &\leq \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \|\mathbf{x}_i\|^2 \|\mathbf{R}_i\| \\ &\leq C_\beta \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \|\mathbf{x}_i\|^2 \|\mathbf{u}_i - \mathbf{u}_0\|^2. \end{aligned} \quad (3.4.29)$$

Sebab $\mathbf{u}_i \in \mathcal{N}_h(\mathbf{u}_0)$ menyiratkan $\|\mathbf{u}_i - \mathbf{u}_0\| \leq h$, maka

$$\|\mathbf{u}_i - \mathbf{u}_0\|^2 \leq h^2. \quad (3.4.30)$$

Dengan demikian,

$$\left\| \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \mathbf{x}_i \mathbf{x}_i^\top \mathbf{R}_i \right\| \leq C_\beta h^2 \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \|\mathbf{x}_i\|^2. \quad (3.4.31)$$

Sebab bobot ternormalisasi ($\sum_i w_i = 1$) dan $\mathbb{E}[\|\mathbf{x}_i\|^2] < \infty$, maka suku terakhir terbatas dalam probabilitas. Dengan mengalikan dengan $(\sum_k \mathbf{H}_k)^{-1}$ yang juga ter-

batas, diperoleh

$$\|\mathbf{B}_n^{(2)}(\mathbf{u}_0)\| = \mathcal{O}_p(h^2). \quad (3.4.32)$$

Dengan demikian, $\mathbf{B}_n(\mathbf{u}_0) = \mathbf{B}_n^{(1)}(\mathbf{u}_0) + \mathbf{B}_n^{(2)}(\mathbf{u}_0) = o_p(1) + \mathcal{O}_p(h^2) = \mathcal{O}_p(h^2)$. ■

Hasil $\mathbf{B}_n(\mathbf{u}_0) = \mathcal{O}_p(h^2)$ berlaku secara umum untuk setiap metrik jarak yang memenuhi Asumsi GA-GWR.1–GA-GWR.10. Secara khusus:

- (i) Jika fungsi koefisien $\beta(\cdot)$ bersifat dua kali terdiferensiasikan kontinu (Asumsi GA-GWR.5), maka ekspansi Taylor orde dua

$$\beta(\mathbf{u}_i) - \beta(\mathbf{u}_0) = \mathcal{O}(\|\mathbf{u}_i - \mathbf{u}_0\|^2) \quad (3.4.33)$$

tetap berlaku tanpa memperhatikan metrik yang digunakan, asalkan observasi dalam $\mathcal{N}_h^d(\mathbf{u}_0)$ memenuhi $\|\mathbf{u}_i - \mathbf{u}_0\| = \mathcal{O}(h)$ dalam norma Euclidean lokal.

- (ii) Untuk metrik yang sangat berbeda dari Euclidean (misalnya jarak jaringan dengan $d_{\text{eff}} \ll 2$), meskipun laju bias tetap $\mathcal{O}_p(h^2)$ dalam parameter h , interpretasi geometris berubah. h sekarang menyatakan radius dalam metrik non-Euclidean, bukan Euclidean.
- (iii) Orde bias tidak bergantung pada metrik, melainkan pada kehalusan fungsi β berdasarkan Asumsi GA-GWR.5 dan Asumsi GA-GWR.9.

Akibat 3.4.7 *Estimator cross-fitted GA-GWR bersifat asymptotically unbiased, yaitu*

$$\mathbb{E}[\hat{\beta}_{\text{CF}}(\mathbf{u}_0)] - \beta(\mathbf{u}_0) = \mathcal{O}(h^2) \rightarrow 0 \quad \text{ketika } n \rightarrow \infty \text{ dan } h \rightarrow 0. \quad (3.4.34)$$

3.4.3 Analisis Bias Asimtotik Variansi Galat

Selain estimasi koefisien lokal, diperlukan pula estimasi variansi galat σ^2 untuk konstruksi interval konfidensi dan uji statistik pada model GA-GWR berbasis *cross-fitting*.

Teorema 3.4.8 *Estimator variansi galat cross-fitted pada lokasi \mathbf{u}_0 diberikan oleh*

$$\hat{\sigma}_{\text{CF}}^2(\mathbf{u}_0) = \frac{\sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)}(\mathbf{u}_0) (y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}_{\text{CF}}(\mathbf{u}_0))^2}{\sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)}(\mathbf{u}_0) - \text{tr}(\mathbf{H}_{\text{CF}}(\mathbf{u}_0))}, \quad (3.4.35)$$

dengan $\mathbf{H}_{\text{CF}}(\mathbf{u}_0)$ adalah hat matrix efektif pada skema cross-fitting.

Bukti. Diasumsikan bahwa galat bersyarat berdistribusi normal $\varepsilon_i \mid \mathbf{x}_i, \mathbf{u}_i \sim \mathcal{N}(0, \sigma^2)$ dan saling bebas antar observasi. Fungsi *log-likelihood* Gaussian tertimbang lokal pada lokasi \mathbf{u}_0 dapat dituliskan sebagai

$$\ell(\boldsymbol{\beta}, \sigma^2; \mathbf{u}_0) = -\frac{1}{2} \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)}(\mathbf{u}_0) \left[\log(2\pi\sigma^2) + \frac{(y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2}{\sigma^2} \right]. \quad (3.4.36)$$

Dengan mendefinisikan total bobot

$$W_{\text{tot}}(\mathbf{u}_0) = \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)}(\mathbf{u}_0),$$

serta *weighted residual sum of squares*

$$\text{RSS}_w(\boldsymbol{\beta}) = \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)}(\mathbf{u}_0) (y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2,$$

fungsi *log-likelihood* dapat ditulis ulang sebagai

$$\ell(\boldsymbol{\beta}, \sigma^2; \mathbf{u}_0) = -\frac{W_{\text{tot}}}{2} \log(2\pi) - \frac{W_{\text{tot}}}{2} \log(\sigma^2) - \frac{\text{RSS}_w(\boldsymbol{\beta})}{2\sigma^2}. \quad (3.4.37)$$

Turunan parsial terhadap σ^2 menghasilkan

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{W_{\text{tot}}}{2\sigma^2} + \frac{\text{RSS}_w(\boldsymbol{\beta})}{2(\sigma^2)^2}. \quad (3.4.38)$$

Dengan menyamakan turunan tersebut dengan nol dan menyusun ulang, diperoleh

$$\hat{\sigma}_{\text{ML}}^2(\mathbf{u}_0) = \frac{\text{RSS}_w(\hat{\boldsymbol{\beta}}_{\text{CF}})}{W_{\text{tot}}}. \quad (3.4.39)$$

Estimator *maximum likelihood* ini bersifat bias ke bawah karena $\hat{\boldsymbol{\beta}}_{\text{CF}}(\mathbf{u}_0)$ diperoleh melalui estimasi parameter regresi yang mengurangi derajat kebebasan efektif. Dalam kerangka regresi linear tertimbang, bias ini dapat dikarakterisasi oleh *hat matrix* efektif $\mathbf{H}_{\text{CF}}(\mathbf{u}_0)$, sehingga

$$\mathbb{E} \left[\text{RSS}_w(\hat{\boldsymbol{\beta}}_{\text{CF}}) \right] = \sigma^2 (W_{\text{tot}} - \text{tr}(\mathbf{H}_{\text{CF}}(\mathbf{u}_0))). \quad (3.4.40)$$

Dengan demikian, estimator variansi galat yang dikoreksi derajat kebebasan diberikan oleh

$$\hat{\sigma}_{\text{CF}}^2(\mathbf{u}_0) = \frac{\text{RSS}_w(\hat{\boldsymbol{\beta}}_{\text{CF}})}{W_{\text{tot}} - \text{tr}(\mathbf{H}_{\text{CF}}(\mathbf{u}_0))}, \quad (3.4.41)$$

yang bersifat tak-bias secara asimtotik. ■

Estimator ini merupakan generalisasi alami dari estimator variansi GWR klasik dengan koreksi derajat kebebasan. Dalam kasus khusus satu lokasi dan satu skema pembobotan, $\text{tr}(\mathbf{H}) \approx p$ sehingga penyebut mereduksi ke bentuk $(\sum_i w_i - p)$, analog dengan estimator variansi OLS klasik $\hat{\sigma}^2 = \text{RSS}/(n - p)$.

Untuk menganalisis sifat asimtotik $\hat{\sigma}_{\text{CF}}^2$, residual didekomposisikan sebagai berikut.

Proposisi 3.4.9 *Residual tertimbang dapat ditulis sebagai*

$$y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}_{\text{CF}}(\mathbf{u}_0) = \varepsilon_i - \mathbf{x}_i^\top (\hat{\boldsymbol{\beta}}_{\text{CF}}(\mathbf{u}_0) - \boldsymbol{\beta}(\mathbf{u}_i)). \quad (3.4.42)$$

Dengan menambah dan mengurangi $\boldsymbol{\beta}(\mathbf{u}_0)$:

$$y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}_{\text{CF}}(\mathbf{u}_0) = \varepsilon_i + \mathbf{x}_i^\top (\boldsymbol{\beta}(\mathbf{u}_i) - \boldsymbol{\beta}(\mathbf{u}_0)) - \mathbf{x}_i^\top (\hat{\boldsymbol{\beta}}_{\text{CF}}(\mathbf{u}_0) - \boldsymbol{\beta}(\mathbf{u}_0)). \quad (3.4.43)$$

Bukti. Dari model struktural $y_i = \mathbf{x}_i^\top \boldsymbol{\beta}(\mathbf{u}_i) + \varepsilon_i$, maka

$$\begin{aligned} y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}_{\text{CF}} &= \mathbf{x}_i^\top \boldsymbol{\beta}(\mathbf{u}_i) + \varepsilon_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}_{\text{CF}} \\ &= \varepsilon_i + \mathbf{x}_i^\top (\boldsymbol{\beta}(\mathbf{u}_i) - \hat{\boldsymbol{\beta}}_{\text{CF}}) \\ &= \varepsilon_i + \mathbf{x}_i^\top (\boldsymbol{\beta}(\mathbf{u}_i) - \boldsymbol{\beta}(\mathbf{u}_0)) - \mathbf{x}_i^\top (\hat{\boldsymbol{\beta}}_{\text{CF}} - \boldsymbol{\beta}(\mathbf{u}_0)). \end{aligned} \quad (3.4.44)$$

■

Apabila didefinisikan notasi ringkas, yaitu $\delta_i := \boldsymbol{\beta}(\mathbf{u}_i) - \boldsymbol{\beta}(\mathbf{u}_0)$ adalah deviasi koefisien lokal dari target dan $\hat{\boldsymbol{\Delta}} := \hat{\boldsymbol{\beta}}_{\text{CF}}(\mathbf{u}_0) - \boldsymbol{\beta}(\mathbf{u}_0) = \mathbf{B}_n + \mathbf{V}_n$ adalah galat estimasi, residual menjadi

$$\hat{e}_i = y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}_{\text{CF}} = \varepsilon_i + \mathbf{x}_i^\top \delta_i - \mathbf{x}_i^\top \hat{\boldsymbol{\Delta}}. \quad (3.4.45)$$

Teorema 3.4.10 *Jumlah kuadrat residual tertimbang dapat diekspansi sebagai*

$$\begin{aligned} \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \hat{e}_i^2 &= \underbrace{\sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \varepsilon_i^2}_{(I): \text{ suku utama}} + \underbrace{\sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} (\mathbf{x}_i^\top \delta_i)^2}_{(II): \text{ bias lokal}} \\ &\quad + \underbrace{\hat{\boldsymbol{\Delta}}^\top \left(\sum_{k=1}^K \mathbf{H}_k \right) \hat{\boldsymbol{\Delta}}}_{(III): \text{ galat estimasi}} + (\text{suku silang}). \end{aligned} \quad (3.4.46)$$

Bukti. Dengan mengkuadratkan ekspresi residual akan didapatkan

$$\begin{aligned} \hat{e}_i^2 &= (\varepsilon_i + \mathbf{x}_i^\top \delta_i - \mathbf{x}_i^\top \hat{\boldsymbol{\Delta}})^2 \\ &= \varepsilon_i^2 + (\mathbf{x}_i^\top \delta_i)^2 + (\mathbf{x}_i^\top \hat{\boldsymbol{\Delta}})^2 \\ &\quad + 2\varepsilon_i \mathbf{x}_i^\top \delta_i - 2\varepsilon_i \mathbf{x}_i^\top \hat{\boldsymbol{\Delta}} - 2(\mathbf{x}_i^\top \delta_i)(\mathbf{x}_i^\top \hat{\boldsymbol{\Delta}}). \end{aligned} \quad (3.4.47)$$

Selanjutnya, dengan menjumlahkan bobot

$$\begin{aligned}
\sum_{k,i} w_i^{(-k)} \tilde{e}_i^2 &= \sum_{k,i} w_i^{(-k)} \varepsilon_i^2 + \sum_{k,i} w_i^{(-k)} (\mathbf{x}_i^\top \delta_i)^2 + \sum_{k,i} w_i^{(-k)} (\mathbf{x}_i^\top \hat{\Delta})^2 \\
&\quad + 2 \sum_{k,i} w_i^{(-k)} \varepsilon_i \mathbf{x}_i^\top \delta_i - 2 \sum_{k,i} w_i^{(-k)} \varepsilon_i \mathbf{x}_i^\top \hat{\Delta} \\
&\quad - 2 \sum_{k,i} w_i^{(-k)} (\mathbf{x}_i^\top \delta_i) (\mathbf{x}_i^\top \hat{\Delta}).
\end{aligned} \tag{3.4.48}$$

Untuk suku (III), perhatikan bahwa

$$\begin{aligned}
\sum_{k,i} w_i^{(-k)} (\mathbf{x}_i^\top \hat{\Delta})^2 &= \sum_{k,i} w_i^{(-k)} \hat{\Delta}^\top \mathbf{x}_i \mathbf{x}_i^\top \hat{\Delta} \\
&= \hat{\Delta}^\top \left(\sum_{k,i} w_i^{(-k)} \mathbf{x}_i \mathbf{x}_i^\top \right) \hat{\Delta} \\
&= \hat{\Delta}^\top \left(\sum_{k=1}^K \mathbf{H}_k \right) \hat{\Delta}.
\end{aligned} \tag{3.4.49}$$

■

Teorema 3.4.11 *Di bawah Asumsi GA-GWR.1–GA-GWR.10, estimator variansi galat cross-fitted bersifat konsisten:*

$$\hat{\sigma}_{\text{CF}}^2(\mathbf{u}_0) \xrightarrow{p} \sigma^2. \tag{3.4.50}$$

Bukti. Pada suku utama, berdasarkan hukum bilangan besar tertimbang dan Asumsi GA-GWR.3:

$$\sum_{k,i} w_i^{(-k)} \varepsilon_i^2 \xrightarrow{p} \mathbb{E}[\varepsilon_i^2] = \sigma^2. \tag{3.4.51}$$

Selanjutnya, pada bias lokal, karena $\|\delta_i\| = \|\beta(\mathbf{u}_i) - \beta(\mathbf{u}_0)\| = \mathcal{O}(h)$ untuk $\mathbf{u}_i \in \mathcal{N}_h(\mathbf{u}_0)$, maka

$$\sum_{k,i} w_i^{(-k)} (\mathbf{x}_i^\top \delta_i)^2 \leq \sum_{k,i} w_i^{(-k)} \|\mathbf{x}_i\|^2 \|\delta_i\|^2 = \mathcal{O}_p(h^2) \rightarrow 0. \tag{3.4.52}$$

Dari hasil sebelumnya, $\hat{\Delta} = \mathcal{O}_p(h^2) + \mathcal{O}_p((nh^d)^{-1/2})$. Maka

$$\hat{\Delta}^\top \left(\sum_k \mathbf{H}_k \right) \hat{\Delta} = \mathcal{O}_p(h^4 + (nh^d)^{-1}) \rightarrow 0. \quad (3.4.53)$$

Dengan argumen serupa, semua suku silang konvergen ke nol dalam probabilitas karena melibatkan produk dari suku yang konvergen ke nol. Dengan demikian,

$$\sum_{k,i} w_i^{(-k)} \hat{e}_i^2 \xrightarrow{p} \sigma^2, \quad (3.4.54)$$

dan karena penyebut $\sum_{k,i} w_i^{(-k)} - p \rightarrow 1 - 0 = 1$ (dengan koreksi derajat bebas yang dapat dihilangkan secara asimtotik), maka $\hat{\sigma}_{\text{CF}}^2 \xrightarrow{p} \sigma^2$. ■

Akibat 3.4.12 *Bias estimator variansi galat memenuhi*

$$\mathbb{E}[\hat{\sigma}_{\text{CF}}^2(\mathbf{u}_0)] - \sigma^2 = \mathcal{O}(h^2) + \mathcal{O}((nh^d)^{-1}), \quad (3.4.55)$$

yang konvergen ke nol di bawah kondisi asimtotik GA-GWR.6 dan GA-GWR.7.

3.4.4 Konsistensi Koefisien Lokal

Bagian ini membuktikan konsistensi estimator *cross-fitted* GA-GWR secara formal. Konsistensi merupakan syarat minimal untuk validitas estimator, yaitu estimator harus konvergen ke nilai parameter sejati ketika ukuran sampel menuju tak hingga.

Teorema 3.4.13 *Di bawah Asumsi GA-GWR.1–GA-GWR.10, estimator cross-fitted GA-GWR bersifat konsisten, yaitu*

$$\hat{\beta}_{\text{CF}}(\mathbf{u}_0) \xrightarrow{p} \beta(\mathbf{u}_0) \quad \text{ketika } n \rightarrow \infty. \quad (3.4.56)$$

Bukti. Dari Teorema 3.4.2, berlaku

$$\hat{\beta}_{\text{CF}}(\mathbf{u}_0) - \beta(\mathbf{u}_0) = \mathbf{B}_n(\mathbf{u}_0) + \mathbf{V}_n(\mathbf{u}_0). \quad (3.4.57)$$

Untuk membuktikan konsistensi, perlu ditunjukkan bahwa $\mathbf{B}_n(\mathbf{u}_0) \xrightarrow{p} \mathbf{0}$ dan komponen galat $\mathbf{V}_n(\mathbf{u}_0) \xrightarrow{p} \mathbf{0}$. Dari Teorema 3.4.6, telah ditunjukkan bahwa

$$\mathbf{B}_n(\mathbf{u}_0) = \mathcal{O}_p(h^2). \quad (3.4.58)$$

Sebab $h \rightarrow 0$, berdasarkan Asumsi GA-GWR.6, maka $\mathbf{B}_n(\mathbf{u}_0) \xrightarrow{p} \mathbf{0}$.

Suku galat diberikan oleh

$$\mathbf{V}_n(\mathbf{u}_0) = \left(\sum_{k=1}^K \mathbf{H}_k \right)^{-1} \left(\sum_{k=1}^K \mathbf{X}_k^\top \mathbf{W}_k^{(-k)} \boldsymbol{\varepsilon}_k \right). \quad (3.4.59)$$

Untuk menganalisis konvergensi, ditulis dalam bentuk yang lebih eksplisit:

$$\mathbf{V}_n(\mathbf{u}_0) = \left(\frac{1}{nh^d} \sum_{k=1}^K \mathbf{H}_k \right)^{-1} \left(\frac{1}{nh^d} \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \mathbf{x}_i \varepsilon_i \right). \quad (3.4.60)$$

Didefinisikan matriks

$$\mathbf{Q}_n(\mathbf{u}_0) := \frac{1}{nh^d} \sum_{k=1}^K \mathbf{H}_k = \frac{1}{nh^d} \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \mathbf{x}_i \mathbf{x}_i^\top. \quad (3.4.61)$$

Berdasarkan hukum bilangan besar tertimbang lokal, dengan menggunakan Asumsi GA-GWR.1, GA-GWR.4, GA-GWR.6, dan GA-GWR.10:

$$\mathbf{Q}_n(\mathbf{u}_0) \xrightarrow{p} \mathbf{Q}(\mathbf{u}_0), \quad (3.4.62)$$

dengan $\mathbf{Q}(\mathbf{u}_0) = \mathbb{E}[\mathbf{x}_i \mathbf{x}_i^\top \mid \mathbf{u}_i \approx \mathbf{u}_0]$ adalah matriks momen lokal yang positif definit. Akibatnya,

$$\mathbf{Q}_n(\mathbf{u}_0)^{-1} \xrightarrow{p} \mathbf{Q}(\mathbf{u}_0)^{-1}. \quad (3.4.63)$$

Selanjutnya, didefinisikan vektor

$$\mathbf{S}_n(\mathbf{u}_0) := \frac{1}{nh^d} \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \mathbf{x}_i \varepsilon_i. \quad (3.4.64)$$

Berdasarkan Proposisi 3.3.9, untuk setiap *fold* k :

$$\mathbb{E}\left[w_i^{(-k)} \mathbf{x}_i \varepsilon_i \mid \widehat{\boldsymbol{\theta}}^{(-k)}\right] = \mathbf{0} \quad \text{untuk } i \in \mathcal{I}_k. \quad (3.4.65)$$

Dengan menggunakan hukum ekspektasi iterasi:

$$\mathbb{E}[\mathbf{S}_n(\mathbf{u}_0)] = \frac{1}{nh^d} \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} \mathbb{E}\left[\mathbb{E}\left[w_i^{(-k)} \mathbf{x}_i \varepsilon_i \mid \widehat{\boldsymbol{\theta}}^{(-k)}\right]\right] = \mathbf{0}. \quad (3.4.66)$$

Untuk variansi, dengan menggunakan independensi antarobservasi GA-GWR.1 dan Asumsi GA-GWR.3:

$$\begin{aligned} \text{Var}(\mathbf{S}_n(\mathbf{u}_0)) &= \frac{1}{(nh^d)^2} \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} \mathbb{E}\left[(w_i^{(-k)})^2 \mathbf{x}_i \mathbf{x}_i^\top \varepsilon_i^2\right] \\ &= \frac{\sigma^2}{(nh^d)^2} \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} \mathbb{E}\left[(w_i^{(-k)})^2 \mathbf{x}_i \mathbf{x}_i^\top\right]. \end{aligned} \quad (3.4.67)$$

Berdasarkan Asumsi GA-GWR.7, $w_i^{(-k)} \leq C/(nh^d)$, sehingga $(w_i^{(-k)})^2 \leq C^2/(nh^d)^2$. Dengan demikian,

$$\begin{aligned} \text{Var}(\mathbf{S}_n(\mathbf{u}_0)) &\leq \frac{\sigma^2 C^2}{(nh^d)^4} \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} \mathbb{E}[\mathbf{x}_i \mathbf{x}_i^\top] \\ &= \frac{\sigma^2 C^2}{(nh^d)^4} \cdot n \cdot \mathbb{E}[\mathbf{x}_i \mathbf{x}_i^\top] \\ &= \mathcal{O}((nh^d)^{-3}) \rightarrow 0. \end{aligned} \quad (3.4.68)$$

Sebab $\mathbb{E}[\mathbf{S}_n] = \mathbf{0}$ dan $\text{Var}(\mathbf{S}_n) \rightarrow 0$, maka berdasarkan ketaksamaan Chebyshev:

$$\mathbf{S}_n(\mathbf{u}_0) \xrightarrow{p} \mathbf{0}. \quad (3.4.69)$$

Sebab $\mathbf{Q}_n^{-1} \xrightarrow{p} \mathbf{Q}^{-1}$ dan $\mathbf{S}_n \xrightarrow{p} \mathbf{0}$, maka berdasarkan lemma Slutsky:

$$\mathbf{V}_n(\mathbf{u}_0) = \mathbf{Q}_n^{-1} \cdot (nh^d) \cdot \mathbf{S}_n \xrightarrow{p} \mathbf{Q}^{-1} \cdot \mathbf{0} = \mathbf{0}. \quad (3.4.70)$$

Dengan menggabungkan hasil untuk suku bias dan suku galat:

$$\widehat{\beta}_{\text{CF}}(\mathbf{u}_0) - \beta(\mathbf{u}_0) = \mathbf{B}_n + \mathbf{V}_n \xrightarrow{p} \mathbf{0} + \mathbf{0} = \mathbf{0}. \quad (3.4.71)$$

■

Akibat 3.4.14 *Laju konvergensi estimator cross-fitted ditentukan oleh*

$$\widehat{\beta}_{\text{CF}}(\mathbf{u}_0) - \beta(\mathbf{u}_0) = \mathcal{O}_p(h^2) + \mathcal{O}_p((nh^d)^{-1/2}), \quad (3.4.72)$$

dengan suku pertama adalah kontribusi bias dan suku kedua adalah kontribusi variansi.

3.4.5 Konsistensi Variansi Koefisien Lokal

Untuk melakukan inferensi statistik, diperlukan estimasi variansi dari estimator koefisien lokal. Bagian ini mendefinisikan variansi teoretis, menurunkan estimatornya, dan membuktikan konsistensinya.

Teorema 3.4.15 *Di bawah Asumsi GA-GWR.1–GA-GWR.10, variansi kondisional dari estimator cross-fitted memiliki bentuk sandwich:*

$$\text{Var}(\widehat{\beta}_{\text{CF}}(\mathbf{u}_0) \mid \{\widehat{\theta}^{(-k)}\}_{k=1}^K) = \mathbf{Q}_n(\mathbf{u}_0)^{-1} \boldsymbol{\Omega}_n(\mathbf{u}_0) \mathbf{Q}_n(\mathbf{u}_0)^{-1}, \quad (3.4.73)$$

dengan

$$\mathbf{Q}_n(\mathbf{u}_0) = \sum_{k=1}^K \mathbf{H}_k = \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \mathbf{x}_i \mathbf{x}_i^\top, \quad (3.4.74)$$

$$\boldsymbol{\Omega}_n(\mathbf{u}_0) = \sigma^2 \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} (w_i^{(-k)})^2 \mathbf{x}_i \mathbf{x}_i^\top. \quad (3.4.75)$$

Bukti. Dari dekomposisi estimator, suku galat diberikan oleh

$$\mathbf{V}_n(\mathbf{u}_0) = \left(\sum_{k=1}^K \mathbf{H}_k \right)^{-1} \left(\sum_{k=1}^K \mathbf{X}_k^\top \mathbf{W}_k^{(-k)} \boldsymbol{\varepsilon}_k \right) = \mathbf{Q}_n^{-1} \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \mathbf{x}_i \varepsilon_i. \quad (3.4.76)$$

Kondisional pada $\{\widehat{\boldsymbol{\theta}}^{(-k)}\}$, bobot $w_i^{(-k)}$ bersifat deterministik. Dengan menggunakan independensi antarobservasi dan Asumsi GA-GWR.3:

$$\begin{aligned} \text{Var}\left(\sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \mathbf{x}_i \varepsilon_i \mid \{\widehat{\boldsymbol{\theta}}^{(-k)}\}\right) &= \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} (w_i^{(-k)})^2 \mathbf{x}_i \mathbf{x}_i^\top \text{Var}(\varepsilon_i) \\ &= \sigma^2 \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} (w_i^{(-k)})^2 \mathbf{x}_i \mathbf{x}_i^\top \\ &= \boldsymbol{\Omega}_n(\mathbf{u}_0). \end{aligned} \quad (3.4.77)$$

Dengan menggunakan sifat variansi transformasi linear:

$$\begin{aligned} \text{Var}(\mathbf{V}_n \mid \{\widehat{\boldsymbol{\theta}}^{(-k)}\}) &= \mathbf{Q}_n^{-1} \text{Var}\left(\sum_{k,i} w_i^{(-k)} \mathbf{x}_i \varepsilon_i\right) \mathbf{Q}_n^{-1} \\ &= \mathbf{Q}_n^{-1} \boldsymbol{\Omega}_n \mathbf{Q}_n^{-1}. \end{aligned} \quad (3.4.78)$$

Sebab suku bias \mathbf{B}_n bersifat deterministik kondisional pada $\{\widehat{\boldsymbol{\theta}}^{(-k)}\}$, maka

$$\text{Var}(\widehat{\boldsymbol{\beta}}_{\text{CF}} \mid \{\widehat{\boldsymbol{\theta}}^{(-k)}\}) = \text{Var}(\mathbf{V}_n \mid \{\widehat{\boldsymbol{\theta}}^{(-k)}\}) = \mathbf{Q}_n^{-1} \boldsymbol{\Omega}_n \mathbf{Q}_n^{-1}. \quad (3.4.79)$$

■

Akibat 3.4.16 *Variansi koefisien lokal memiliki orde*

$$\text{Var}(\widehat{\boldsymbol{\beta}}_{\text{CF}}(\mathbf{u}_0)) = \mathcal{O}((nh^d)^{-1}). \quad (3.4.80)$$

Secara intuitif, effective local sample size adalah nh^d , sehingga variansi berbanding terbalik dengannya.

Bukti. Dari Asumsi GA-GWR.7, $w_i^{(-k)} \leq C/(nh^d)$. Dengan demikian,

$$\boldsymbol{\Omega}_n = \sigma^2 \sum_{k,i} (w_i^{(-k)})^2 \mathbf{x}_i \mathbf{x}_i^\top \leq \frac{\sigma^2 C}{nh^d} \sum_{k,i} w_i^{(-k)} \mathbf{x}_i \mathbf{x}_i^\top = \frac{\sigma^2 C}{nh^d} \mathbf{Q}_n. \quad (3.4.81)$$

Sebab $\mathbf{Q}_n = \mathcal{O}(1)$ dan $\mathbf{\Omega}_n = \mathcal{O}((nh^d)^{-1})$, maka

$$\mathbf{Q}_n^{-1} \mathbf{\Omega}_n \mathbf{Q}_n^{-1} = \mathcal{O}(1) \cdot \mathcal{O}((nh^d)^{-1}) \cdot \mathcal{O}(1) = \mathcal{O}((nh^d)^{-1}). \quad (3.4.82)$$

■

Teorema 3.4.17 *Estimator variansi koefisien lokal cross-fitted yang diperoleh dengan mengganti parameter populasi dengan estimator konsistennya diberikan oleh*

$$\widehat{\text{Var}}(\widehat{\beta}_{\text{CF}}(\mathbf{u}_0)) = \widehat{\mathbf{Q}}_n(\mathbf{u}_0)^{-1} \widehat{\mathbf{\Omega}}_n(\mathbf{u}_0) \widehat{\mathbf{Q}}_n(\mathbf{u}_0)^{-1}, \quad (3.4.83)$$

dengan

$$\widehat{\mathbf{Q}}_n(\mathbf{u}_0) = \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \mathbf{x}_i \mathbf{x}_i^\top = \sum_{k=1}^K \mathbf{H}_k, \quad (3.4.84)$$

$$\widehat{\mathbf{\Omega}}_n(\mathbf{u}_0) = \widehat{\sigma}_{\text{CF}}^2(\mathbf{u}_0) \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} (w_i^{(-k)})^2 \mathbf{x}_i \mathbf{x}_i^\top. \quad (3.4.85)$$

Bukti. Dari Teorema 3.4.15, variansi kondisional sejati diberikan oleh

$$\text{Var}(\widehat{\beta}_{\text{CF}}(\mathbf{u}_0) \mid \{\widehat{\theta}^{(-k)}\}_{k=1}^K) = \mathbf{Q}_n(\mathbf{u}_0)^{-1} \mathbf{\Omega}_n(\mathbf{u}_0) \mathbf{Q}_n(\mathbf{u}_0)^{-1}, \quad (3.4.86)$$

dengan

$$\mathbf{Q}_n(\mathbf{u}_0) = \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \mathbf{x}_i \mathbf{x}_i^\top, \quad (3.4.87)$$

$$\mathbf{\Omega}_n(\mathbf{u}_0) = \sigma^2 \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} (w_i^{(-k)})^2 \mathbf{x}_i \mathbf{x}_i^\top. \quad (3.4.88)$$

Perhatikan bahwa $\mathbf{Q}_n(\mathbf{u}_0)$ dapat dihitung langsung dari data karena hanya melibatkan bobot $w_i^{(-k)}$ dan kovariat \mathbf{x}_i yang keduanya teramati. Dengan demikian,

estimator untuk $\mathbf{Q}_n(\mathbf{u}_0)$ adalah dirinya sendiri:

$$\hat{\mathbf{Q}}_n(\mathbf{u}_0) = \mathbf{Q}_n(\mathbf{u}_0) = \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \mathbf{x}_i \mathbf{x}_i^\top = \sum_{k=1}^K \mathbf{H}_k. \quad (3.4.89)$$

Untuk $\Omega_n(\mathbf{u}_0)$, satu-satunya kuantitas yang tidak teramati adalah variansi galat σ^2 . Berdasarkan Teorema 3.4.11, estimator konsisten untuk σ^2 adalah $\hat{\sigma}_{\text{CF}}^2(\mathbf{u}_0)$. Dengan mensubstitusikan σ^2 dengan estimatornya, diperoleh

$$\hat{\Omega}_n(\mathbf{u}_0) = \hat{\sigma}_{\text{CF}}^2(\mathbf{u}_0) \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} (w_i^{(-k)})^2 \mathbf{x}_i \mathbf{x}_i^\top. \quad (3.4.90)$$

Dengan menggabungkan kedua estimator ke dalam bentuk *sandwich*, diperoleh estimator variansi koefisien lokal:

$$\widehat{\text{Var}}(\hat{\beta}_{\text{CF}}(\mathbf{u}_0)) = \hat{\mathbf{Q}}_n(\mathbf{u}_0)^{-1} \hat{\Omega}_n(\mathbf{u}_0) \hat{\mathbf{Q}}_n(\mathbf{u}_0)^{-1}. \quad (3.4.91)$$

Bentuk *sandwich* ini memiliki interpretasi geometris bahwa matriks $\hat{\mathbf{Q}}_n^{-1}$ mentransformasi variabilitas dalam ruang kovariat tertimbang $\hat{\Omega}_n$ menjadi variabilitas dalam ruang parameter β . ■

Estimator ini menggantikan variansi galat sejati σ^2 dengan estimator konsistennya $\hat{\sigma}_{\text{CF}}^2$. Bentuk *sandwich* menjamin *robustness* terhadap spesifikasi yang tidak tepat pada struktur variansi.

Teorema 3.4.18 *Di bawah Asumsi GA-GWR.1–GA-GWR.10, estimator variansi bersifat konsisten dalam arti*

$$(nh^d) \cdot \widehat{\text{Var}}(\hat{\beta}_{\text{CF}}(\mathbf{u}_0)) \xrightarrow{p} \mathbf{Q}(\mathbf{u}_0)^{-1} \Omega(\mathbf{u}_0) \mathbf{Q}(\mathbf{u}_0)^{-1}, \quad (3.4.92)$$

dengan $\mathbf{Q}(\mathbf{u}_0)$ dan $\Omega(\mathbf{u}_0)$ adalah limit probabilitas dari versi ternormalisasi \mathbf{Q}_n dan Ω_n .

Bukti. Perhatikan bahwa

$$\frac{1}{nh^d} \widehat{\mathbf{Q}}_n = \frac{1}{nh^d} \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \mathbf{x}_i \mathbf{x}_i^\top. \quad (3.4.93)$$

Berdasarkan hukum bilangan besar tertimbang lokal, didapatkan bahwa

$$\frac{1}{nh^d} \widehat{\mathbf{Q}}_n \xrightarrow{p} \mathbf{Q}(\mathbf{u}_0) = \mathbb{E}[\mathbf{x}_i \mathbf{x}_i^\top \mid \mathbf{u}_i \approx \mathbf{u}_0]. \quad (3.4.94)$$

Didefinisikan

$$\widetilde{\mathbf{\Omega}}_n = (nh^d) \cdot \widehat{\mathbf{\Omega}}_n = (nh^d) \cdot \widehat{\sigma}_{\text{CF}}^2 \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} (w_i^{(-k)})^2 \mathbf{x}_i \mathbf{x}_i^\top. \quad (3.4.95)$$

Dari Teorema 3.4.11, $\widehat{\sigma}_{\text{CF}}^2 \xrightarrow{p} \sigma^2$. Untuk suku penjumlahan, dengan menggunakan Asumsi GA-GWR.7:

$$(nh^d) \sum_{k,i} (w_i^{(-k)})^2 \mathbf{x}_i \mathbf{x}_i^\top \xrightarrow{p} \mathbf{\Omega}'(\mathbf{u}_0), \quad (3.4.96)$$

dengan $\mathbf{\Omega}'(\mathbf{u}_0)$ adalah limit yang terkait dengan momen bobot kuadrat lokal. Didefinisikan $\mathbf{\Omega}(\mathbf{u}_0) = \sigma^2 \mathbf{\Omega}'(\mathbf{u}_0)$. Oleh karena itu,

$$\widetilde{\mathbf{\Omega}}_n \xrightarrow{p} \sigma^2 \mathbf{\Omega}'(\mathbf{u}_0) = \mathbf{\Omega}(\mathbf{u}_0). \quad (3.4.97)$$

Estimator variansi ternormalisasi dapat ditulis sebagai

$$(nh^d) \cdot \widehat{\text{Var}}(\widehat{\beta}_{\text{CF}}) = \left(\frac{1}{nh^d} \widehat{\mathbf{Q}}_n \right)^{-1} \widetilde{\mathbf{\Omega}}_n \left(\frac{1}{nh^d} \widehat{\mathbf{Q}}_n \right)^{-1}. \quad (3.4.98)$$

Selanjutnya, sebab $\frac{1}{nh^d} \widehat{\mathbf{Q}}_n \xrightarrow{p} \mathbf{Q}(\mathbf{u}_0)$ yang invertibel, $\widetilde{\mathbf{\Omega}}_n \xrightarrow{p} \mathbf{\Omega}(\mathbf{u}_0)$, dan fungsi inversi matriks kontinu pada himpunan matriks invertibel, maka berdasarkan *continuous mapping theorem* didapatkan

$$(nh^d) \cdot \widehat{\text{Var}}(\widehat{\beta}_{\text{CF}}) \xrightarrow{p} \mathbf{Q}(\mathbf{u}_0)^{-1} \mathbf{\Omega}(\mathbf{u}_0) \mathbf{Q}(\mathbf{u}_0)^{-1}. \quad (3.4.99)$$



Akibat 3.4.19 Galat standar untuk komponen ke- j dari koefisien lokal diestimasi sebagai

$$\widehat{\text{se}}(\widehat{\beta}_{\text{CF},j}(\mathbf{u}_0)) = \sqrt{[\widehat{\text{Var}}(\widehat{\boldsymbol{\beta}}_{\text{CF}}(\mathbf{u}_0))]_{jj}}, \quad (3.4.100)$$

dengan $[\cdot]_{jj}$ menandakan elemen diagonal ke- j dari matriks variansi-kovariansi.

3.4.6 Distribusi Asimtotik Koefisien Lokal

Bagian ini menurunkan distribusi asimtotik dari estimator *cross-fitted* GA-GWR. Hasil utama menunjukkan bahwa setelah dinormalisasi dengan $\sqrt{nh^d}$, estimator berdistribusi normal asimtotik di bawah kondisi *undersmoothing*.

Berdasarkan Akibat 3.4.16, variansi estimator memiliki orde $\mathcal{O}((nh^d)^{-1})$. Hal ini menunjukkan bahwa *effective local sample size* adalah nh^d , sehingga normalisasi yang tepat adalah $\sqrt{nh^d}$.

Proposisi 3.4.20 (Dekomposisi Terstandarisasi) Estimator *cross-fitted* yang dinormalisasi dapat didekomposisikan sebagai

$$\sqrt{nh^d}(\widehat{\boldsymbol{\beta}}_{\text{CF}}(\mathbf{u}_0) - \boldsymbol{\beta}(\mathbf{u}_0)) = \underbrace{\sqrt{nh^d}\mathbf{B}_n(\mathbf{u}_0)}_{\text{bias terstandarisasi}} + \underbrace{\sqrt{nh^d}\mathbf{V}_n(\mathbf{u}_0)}_{\text{galat terstandarisasi}}. \quad (3.4.101)$$

Distribusi limit ditentukan oleh perilaku kedua suku ini.

Suku galat terstandarisasi dapat ditulis dalam bentuk yang memfasilitasi penerapan Teorema Limit Pusat.

Proposisi 3.4.21 Suku galat terstandarisasi dapat ditulis sebagai

$$\sqrt{nh^d}\mathbf{V}_n(\mathbf{u}_0) = \left(\frac{1}{nh^d} \sum_{k=1}^K \mathbf{H}_k \right)^{-1} \left(\frac{1}{\sqrt{nh^d}} \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \mathbf{x}_i \varepsilon_i \right), \quad (3.4.102)$$

yang merupakan produk dari dua faktor, yaitu satu yang konvergen dalam probabilitas dan satu yang konvergen dalam distribusi.

Teorema 3.4.22 Di bawah Asumsi GA-GWR.1–GA-GWR.10, didefinisikan

$$\mathbf{S}_n(\mathbf{u}_0) = \frac{1}{\sqrt{nh^d}} \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \mathbf{x}_i \varepsilon_i. \quad (3.4.103)$$

Maka

$$\mathbf{S}_n(\mathbf{u}_0) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \boldsymbol{\Omega}(\mathbf{u}_0)), \quad (3.4.104)$$

dengan $\boldsymbol{\Omega}(\mathbf{u}_0)$ adalah limit dari $\boldsymbol{\Omega}_n(\mathbf{u}_0)$ ternormalisasi.

Bukti. Bukti diuraikan menggunakan Teorema Limit Pusat Lindeberg-Feller untuk *triangular array* dari variabel acak. Berdasarkan Proposisi 3.3.9, untuk setiap *fold* k dan $i \in \mathcal{I}_k$ berlaku

$$\mathbb{E}[w_i^{(-k)} \mathbf{x}_i \varepsilon_i \mid \hat{\boldsymbol{\theta}}^{(-k)}] = w_i^{(-k)} \mathbf{x}_i \mathbb{E}[\varepsilon_i \mid \mathbf{x}_i, \mathbf{u}_i] = \mathbf{0}, \quad (3.4.105)$$

karena bobot $w_i^{(-k)}$ dilatih pada data yang tidak termasuk observasi i , sehingga bersifat deterministik kondisional pada $\hat{\boldsymbol{\theta}}^{(-k)}$. Dengan demikian, $\mathbb{E}[\mathbf{S}_n] = \mathbf{0}$.

Variansi kondisional diberikan oleh

$$\begin{aligned} \text{Var}(\mathbf{S}_n \mid \{\hat{\boldsymbol{\theta}}^{(-k)}\}) &= \frac{1}{nh^d} \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} (w_i^{(-k)})^2 \mathbb{E}[\mathbf{x}_i \mathbf{x}_i^\top \varepsilon_i^2 \mid \mathbf{u}_i] \\ &= \frac{\sigma^2}{nh^d} \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} (w_i^{(-k)})^2 \mathbf{x}_i \mathbf{x}_i^\top. \end{aligned} \quad (3.4.106)$$

Selanjutnya, didefinisikan

$$\boldsymbol{\Omega}'_n := \frac{nh^d}{1} \cdot \frac{\sigma^2}{nh^d} \sum_{k,i} (w_i^{(-k)})^2 \mathbf{x}_i \mathbf{x}_i^\top = \sigma^2 \sum_{k,i} (w_i^{(-k)})^2 \mathbf{x}_i \mathbf{x}_i^\top. \quad (3.4.107)$$

Berdasarkan hukum bilangan besar, $\boldsymbol{\Omega}'_n \xrightarrow{p} \boldsymbol{\Omega}(\mathbf{u}_0)$ yang positif definit dan terbatas.

Untuk CLT Lindeberg-Feller, perlu diverifikasi bahwa untuk setiap $\delta > 0$

harus terpenuhi kondisi Lindeberg, yaitu

$$\lim_{n \rightarrow \infty} \frac{1}{\text{Var}(\mathbf{S}_n)} \sum_{k,i} \mathbb{E}[\|w_i^{(-k)} \mathbf{x}_i \varepsilon_i\|^2 \mathbf{1}_{\{\|w_i^{(-k)} \mathbf{x}_i \varepsilon_i\| > \delta \sqrt{nh^d}\}}] = 0. \quad (3.4.108)$$

Berdasarkan Asumsi GA-GWR.7, $w_i^{(-k)} \leq C/(nh^d)$. Dengan demikian,

$$\|w_i^{(-k)} \mathbf{x}_i \varepsilon_i\| \leq \frac{C}{nh^d} \|\mathbf{x}_i\| |\varepsilon_i| \rightarrow 0 \quad (3.4.109)$$

untuk n besar, karena $nh^d \rightarrow \infty$ (Asumsi GA-GWR.7). Ini berarti untuk n cukup besar, $\|w_i^{(-k)} \mathbf{x}_i \varepsilon_i\| < \delta \sqrt{nh^d}$ hampir pasti, sehingga kondisi Lindeberg terpenuhi.

Dengan demikian, karena suku-suku $w_i^{(-k)} \mathbf{x}_i \varepsilon_i$ independen antarobservasi, rata-rata nol, variansi total terbatas dan definit positif, dan kondisi Lindeberg terpenuhi, maka berdasarkan Teorema Limit Pusat Lindeberg-Feller akan dihasilkan

$$\mathbf{S}_n(\mathbf{u}_0) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{\Omega}(\mathbf{u}_0)). \quad (3.4.110)$$

■

Teorema 3.4.23 *Di bawah Asumsi GA-GWR.1–GA-GWR.10:*

$$\sqrt{nh^d} \mathbf{V}_n(\mathbf{u}_0) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{Q}(\mathbf{u}_0)^{-1} \mathbf{\Omega}(\mathbf{u}_0) \mathbf{Q}(\mathbf{u}_0)^{-1}). \quad (3.4.111)$$

Bukti. Berdasarkan Teorema 3.4.22, didapatkan $\frac{1}{nh^d} \sum_k \mathbf{H}_k \xrightarrow{p} \mathbf{Q}(\mathbf{u}_0)$ yang invertibel (definit positif) dan $\mathbf{S}_n \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{\Omega}(\mathbf{u}_0))$. Sebab satu faktor konvergen dalam probabilitas ke matriks invertibel dan faktor lainnya konvergen dalam distribusi, maka berdasarkan Lemma Slutsky:

$$\begin{aligned} \sqrt{nh^d} \mathbf{V}_n &= \left(\frac{1}{nh^d} \sum_k \mathbf{H}_k \right)^{-1} \mathbf{S}_n \\ &\xrightarrow{d} \mathbf{Q}(\mathbf{u}_0)^{-1} \cdot \mathcal{N}(\mathbf{0}, \mathbf{\Omega}(\mathbf{u}_0)) \\ &= \mathcal{N}(\mathbf{0}, \mathbf{Q}(\mathbf{u}_0)^{-1} \mathbf{\Omega}(\mathbf{u}_0) \mathbf{Q}(\mathbf{u}_0)^{-1}). \end{aligned} \quad (3.4.112)$$

■

Perilaku suku bias terstandarisasi $\sqrt{nh^d}\mathbf{B}_n(\mathbf{u}_0)$ menentukan apakah distribusi asimtotik berpusat di nol atau tidak.

Proposisi 3.4.24 *Dari Teorema 3.4.6, $\mathbf{B}_n(\mathbf{u}_0) = \mathcal{O}_p(h^2)$. Dengan demikian,*

$$\sqrt{nh^d}\mathbf{B}_n(\mathbf{u}_0) = \mathcal{O}_p(\sqrt{nh^d} \cdot h^2) = \mathcal{O}_p(\sqrt{nh^{d+4}}). \quad (3.4.113)$$

Terdapat dua skenario fundamental bergantung pada laju relatif antara nh^d dan h^2 .

Teorema 3.4.25 *Jika kondisi undersmoothing*

$$\sqrt{nh^d} \cdot h^2 \rightarrow 0 \quad \text{ketika } n \rightarrow \infty \quad (3.4.114)$$

dipenuhi, maka suku bias terstandarisasi lenyap secara asimtotik:

$$\sqrt{nh^d}\mathbf{B}_n(\mathbf{u}_0) \xrightarrow{p} \mathbf{0}. \quad (3.4.115)$$

Bukti. Sebab $\mathbf{B}_n(\mathbf{u}_0) = \mathcal{O}_p(h^2)$, maka $\sqrt{nh^d}\mathbf{B}_n(\mathbf{u}_0) = \mathcal{O}_p(\sqrt{nh^d}h^2)$. Di bawah kondisi $\sqrt{nh^d}h^2 \rightarrow 0$, berlaku $\sqrt{nh^d}\mathbf{B}_n \xrightarrow{p} \mathbf{0}$. ■

Akibat 3.4.26 *Kondisi undersmoothing yang dapat dinyatakan dengan $\sqrt{nh^d}h^2 \rightarrow 0$ ekuivalen dengan*

$$h = o(n^{-1/(d+4)}). \quad (3.4.116)$$

Hal ini berarti bandwidth harus menyusut lebih cepat dari laju optimal untuk estimasi titik (yang biasanya $h \asymp n^{-1/(d+4)}$).

Bukti. Kondisi $\sqrt{nh^d}h^2 \rightarrow 0$ ekuivalen dengan $nh^{d+4} \rightarrow 0$, yang ekuivalen dengan $h^{d+4} = o(n^{-1})$, atau $h = o(n^{-1/(d+4)})$. ■

Proposisi 3.4.27 *Ketika menggunakan metrik alternatif dengan dimensi fraktal efektif $d_{\text{eff}} \neq 2$, kondisi undersmoothing menjadi*

$$\sqrt{nh^{d_{\text{eff}}}} \cdot h^2 \rightarrow 0 \quad \Longleftrightarrow \quad h = o(n^{-1/(d_{\text{eff}}+4)}). \quad (3.4.117)$$

Implikasi praktis untuk pemilihan *bandwidth*:

- (i) Metrik Euclidean dengan $d_{\text{eff}} = 2$ dapat dipilih $h = o(n^{-1/6}) \approx n^{-0.167}$
- (ii) Jarak jaringan urban dengan $d_{\text{eff}} \approx 1$ dapat dipilih $h = o(n^{-1/5}) \approx n^{-0.2}$
- (iii) Metrik Intermediat dengan $d_{\text{eff}} = 1.5$ dapat dipilih $h = o(n^{-1/5.5}) \approx n^{-0.182}$

Teorema 3.4.28 *Di bawah Asumsi GA-GWR.1–GA-GWR.10 dan kondisi undersmoothing $\sqrt{nh^d}h^2 \rightarrow 0$:*

$$\sqrt{nh^d}(\hat{\beta}_{\text{CF}}(\mathbf{u}_0) - \beta(\mathbf{u}_0)) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{Q}(\mathbf{u}_0)^{-1}\Omega(\mathbf{u}_0)\mathbf{Q}(\mathbf{u}_0)^{-1}), \quad (3.4.118)$$

dengan

$$\mathbf{Q}(\mathbf{u}_0) = \lim_{n \rightarrow \infty} \frac{1}{nh^d} \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \mathbf{x}_i \mathbf{x}_i^\top, \quad (3.4.119)$$

$$\Omega(\mathbf{u}_0) = \lim_{n \rightarrow \infty} \sigma^2(nh^d) \sum_{k=1}^K \sum_{i \in \mathcal{I}_k} (w_i^{(-k)})^2 \mathbf{x}_i \mathbf{x}_i^\top. \quad (3.4.120)$$

Bukti. Dari dekomposisi terstandarisasi:

$$\sqrt{nh^d}(\hat{\beta}_{\text{CF}} - \beta) = \sqrt{nh^d}\mathbf{B}_n + \sqrt{nh^d}\mathbf{V}_n. \quad (3.4.121)$$

Berdasarkan Teorema 3.4.25, $\sqrt{nh^d}\mathbf{B}_n \xrightarrow{p} \mathbf{0}$. Berdasarkan Teorema 3.4.23 didapatkan

$$\sqrt{nh^d}\mathbf{V}_n \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{Q}^{-1}\Omega\mathbf{Q}^{-1}). \quad (3.4.122)$$

Dengan menggunakan Lemma Slutsky untuk penjumlahan suku yang konvergen dalam probabilitas ke nol dengan suku yang konvergen dalam distribusi, maka diperoleh

$$\sqrt{nh^d}(\hat{\beta}_{\text{CF}} - \beta) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{Q}^{-1}\Omega\mathbf{Q}^{-1}). \quad (3.4.123)$$

■

Jika kondisi *undersmoothing* tidak dipenuhi, yaitu $\sqrt{nh^d}h^2 \rightarrow c \neq 0$ untuk suatu konstanta c , maka distribusi asimtotik menjadi

$$\sqrt{nh^d}(\hat{\beta}_{\text{CF}}(\mathbf{u}_0) - \beta(\mathbf{u}_0)) \xrightarrow{d} \mathcal{N}(\mu(\mathbf{u}_0), \mathbf{Q}^{-1}\Omega\mathbf{Q}^{-1}), \quad (3.4.124)$$

dengan $\mu(\mathbf{u}_0) \neq \mathbf{0}$ adalah vektor bias asimtotik. Dalam kasus ini, interval konfideni standar dan uji Wald tidak valid karena bias tidak diabaikan.

Akibat 3.4.29 Untuk setiap komponen ke- j dari vektor koefisien:

$$\sqrt{nh^d}(\hat{\beta}_{\text{CF},j}(\mathbf{u}_0) - \beta_j(\mathbf{u}_0)) \xrightarrow{d} \mathcal{N}(0, [\mathbf{Q}^{-1}\Omega\mathbf{Q}^{-1}]_{jj}). \quad (3.4.125)$$

3.4.7 Distribusi Asimtotik Uji Statistik

Bagian ini menurunkan distribusi asimtotik dari statistik uji yang digunakan untuk inferensi pada koefisien lokal, termasuk statistik- t untuk pengujian individual dan statistik Wald untuk pengujian gabungan.

Bagian pertama menurunkan distribusi asimtotik statistik- t untuk pengujian hipotesis nol individual pada koefisien lokal dengan hiptotesis umum berupa

$$H_0 : \beta_j(\mathbf{u}_0) = \beta_{j,0}, \text{ lawan}$$

$$H_1 : \beta_j(\mathbf{u}_0) \neq \beta_{j,0},$$

dengan $\beta_{j,0}$ adalah nilai tertentu, yang biasanya adalah nol untuk menguji signifikansi.

Teorema 3.4.30 Di bawah Asumsi GA-GWR.1–GA-GWR.10, kondisi *undersmoothing*, dan hipotesis nol $H_0 : \beta_j(\mathbf{u}_0) = \beta_{j,0}$, statistik- t

$$t_j(\mathbf{u}_0) = \frac{\hat{\beta}_{\text{CF},j}(\mathbf{u}_0) - \beta_{j,0}}{\widehat{\text{se}}(\hat{\beta}_{\text{CF},j}(\mathbf{u}_0))} \quad (3.4.126)$$

berdistribusi normal standar asimtotik:

$$t_j(\mathbf{u}_0) \xrightarrow{d} \mathcal{N}(0, 1) \quad \text{di bawah } H_0. \quad (3.4.127)$$

Bukti. Di bawah $H_0 : \beta_j(\mathbf{u}_0) = \beta_{j,0}$, statistik- t dapat ditulis sebagai

$$t_j = \frac{\widehat{\beta}_{\text{CF},j} - \beta_j(\mathbf{u}_0)}{\widehat{\text{se}}(\widehat{\beta}_{\text{CF},j})}. \quad (3.4.128)$$

Berdasarkan Teorema 3.4.23 didapatkan

$$\sqrt{nh^d}(\widehat{\beta}_{\text{CF},j} - \beta_j) \xrightarrow{d} \mathcal{N}(0, \sigma_j^2), \quad (3.4.129)$$

dengan $\sigma_j^2 = [\mathbf{Q}^{-1}\boldsymbol{\Omega}\mathbf{Q}^{-1}]_{jj}$. Selanjutnya, dari Teorema ?? juga didapatkan

$$(nh^d) \cdot \widehat{\text{Var}}(\widehat{\beta}_{\text{CF},j}) \xrightarrow{p} \sigma_j^2. \quad (3.4.130)$$

Oleh karena itu,

$$\widehat{\text{se}}(\widehat{\beta}_{\text{CF},j}) = \sqrt{\widehat{\text{Var}}(\widehat{\beta}_{\text{CF},j})} = \frac{\sigma_j + o_p(1)}{\sqrt{nh^d}}, \quad (3.4.131)$$

sehingga statistik- t dapat ditulis sebagai

$$\begin{aligned} t_j &= \frac{\widehat{\beta}_{\text{CF},j} - \beta_j}{\widehat{\text{se}}(\widehat{\beta}_{\text{CF},j})} \\ &= \frac{\sqrt{nh^d}(\widehat{\beta}_{\text{CF},j} - \beta_j)}{\sqrt{nh^d} \cdot \widehat{\text{se}}(\widehat{\beta}_{\text{CF},j})} \\ &= \frac{\sqrt{nh^d}(\widehat{\beta}_{\text{CF},j} - \beta_j)}{\sigma_j + o_p(1)}. \end{aligned} \quad (3.4.132)$$

Berdasarkan Lemma Slutsky, karena pembilang konvergen dalam distribusi ke $\mathcal{N}(0, \sigma_j^2)$ dan penyebut konvergen dalam probabilitas ke σ_j :

$$t_j \xrightarrow{d} \frac{\mathcal{N}(0, \sigma_j^2)}{\sigma_j} = \mathcal{N}(0, 1). \quad (3.4.133)$$

■

Akibat 3.4.31 *Interval konfidensi $(1 - \alpha) \times 100\%$ untuk koefisien lokal $\beta_j(\mathbf{u}_0)$*

diberikan oleh

$$CI_{1-\alpha}(\beta_j(\mathbf{u}_0)) = \hat{\beta}_{CF,j}(\mathbf{u}_0) \pm z_{1-\alpha/2} \cdot \widehat{se}(\hat{\beta}_{CF,j}(\mathbf{u}_0)), \quad (3.4.134)$$

dengan $z_{1-\alpha/2}$ adalah kuantil $(1 - \alpha/2)$ dari distribusi normal standar.

Bukti. Dari distribusi asimtotik $t_j \xrightarrow{d} \mathcal{N}(0, 1)$, didapatkan

$$\Pr(-z_{1-\alpha/2} \leq t_j \leq z_{1-\alpha/2}) \rightarrow 1 - \alpha. \quad (3.4.135)$$

Oleh karena itu, dengan mensubstitusikan definisi t_j dan menyusun ulang:

$$\Pr(\hat{\beta}_{CF,j} - z_{1-\alpha/2} \cdot \widehat{se} \leq \beta_j \leq \hat{\beta}_{CF,j} + z_{1-\alpha/2} \cdot \widehat{se}) \rightarrow 1 - \alpha. \quad (3.4.136)$$

■

Untuk pengujian hipotesis gabungan yang melibatkan beberapa komponen koefisien secara simultan, digunakan statistik Wald. Uji ini dibangun atas hipotesis berupa

$$H_0 : \mathbf{R}\beta(\mathbf{u}_0) = \mathbf{r}, \quad \text{lawan}$$

$$H_1 : \mathbf{R}\beta(\mathbf{u}_0) \neq \mathbf{r},$$

dengan \mathbf{R} adalah matriks $q \times p$ yang menentukan kombinasi linier dari koefisien yang diuji, dan \mathbf{r} adalah vektor $q \times 1$ dari nilai tertentu.

Teorema 3.4.32 *Di bawah Asumsi GA-GWR.1–GA-GWR.10, kondisi undersmoothing, dan hipotesis nol linear $H_0 : \mathbf{R}\beta(\mathbf{u}_0) = \mathbf{r}$ dengan \mathbf{R} matriks $q \times p$ berpangkat penuh baris, statistik Wald*

$$W(\mathbf{u}_0) = (\mathbf{R}\hat{\beta}_{CF}(\mathbf{u}_0) - \mathbf{r})^\top \left[\mathbf{R}\widehat{\text{Var}}(\hat{\beta}_{CF}(\mathbf{u}_0))\mathbf{R}^\top \right]^{-1} (\mathbf{R}\hat{\beta}_{CF}(\mathbf{u}_0) - \mathbf{r}) \quad (3.4.137)$$

berdistribusi χ^2 asimtotik dengan q derajat kebebasan, yaitu

$$W(\mathbf{u}_0) \xrightarrow{d} \chi_q^2 \quad \text{di bawah } H_0, \quad (3.4.138)$$

dengan $q = \text{rank}(\mathbf{R})$ adalah jumlah restriksi.

Bukti. Di bawah H_0 , berlaku $\mathbf{R}\beta(\mathbf{u}_0) = \mathbf{r}$. Didefinisikan

$$\delta_n := \mathbf{R}\hat{\beta}_{\text{CF}} - \mathbf{r} = \mathbf{R}(\hat{\beta}_{\text{CF}} - \beta). \quad (3.4.139)$$

Dari Teorema 3.4.23 didapatkan

$$\sqrt{nh^d}(\hat{\beta}_{\text{CF}} - \beta) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{Q}^{-1}\Omega\mathbf{Q}^{-1}). \quad (3.4.140)$$

Sebab transformasi linear mempertahankan normalitas, maka

$$\sqrt{nh^d}\delta_n = \mathbf{R}\sqrt{nh^d}(\hat{\beta}_{\text{CF}} - \beta) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{R}\mathbf{Q}^{-1}\Omega\mathbf{Q}^{-1}\mathbf{R}^\top). \quad (3.4.141)$$

Didefinisikan $\Sigma_R := \mathbf{R}\mathbf{Q}^{-1}\Omega\mathbf{Q}^{-1}\mathbf{R}^\top$. Dari Teorema ?? didapatkan

$$(nh^d)\mathbf{R}\widehat{\text{Var}}(\hat{\beta}_{\text{CF}})\mathbf{R}^\top \xrightarrow{p} \Sigma_R. \quad (3.4.142)$$

Statistik Wald dapat ditulis sebagai

$$\begin{aligned} W &= \delta_n^\top [\mathbf{R}\widehat{\text{Var}}(\hat{\beta}_{\text{CF}})\mathbf{R}^\top]^{-1} \delta_n \\ &= (nh^d)\delta_n^\top [(nh^d)\mathbf{R}\widehat{\text{Var}}(\hat{\beta}_{\text{CF}})\mathbf{R}^\top]^{-1} (nh^d)\delta_n \cdot (nh^d)^{-1} \\ &= (\sqrt{nh^d}\delta_n)^\top [(nh^d)\mathbf{R}\widehat{\text{Var}}\mathbf{R}^\top]^{-1} (\sqrt{nh^d}\delta_n). \end{aligned} \quad (3.4.143)$$

Selanjutnya, berdasarkan *continuous mapping theorem* dan Lemma Slutsky:

$$W \xrightarrow{d} \mathbf{Z}^\top \Sigma_R^{-1} \mathbf{Z}, \quad (3.4.144)$$

dengan $\mathbf{Z} \sim \mathcal{N}(\mathbf{0}, \Sigma_R)$. Bentuk kuadratik ini berdistribusi χ_q^2 karena $\Sigma_R^{-1/2}\mathbf{Z} \sim$

$\mathcal{N}(\mathbf{0}, \mathbf{I}_q)$ dan

$$\mathbf{Z}^\top \Sigma_R^{-1} \mathbf{Z} = \|\Sigma_R^{-1/2} \mathbf{Z}\|^2 \sim \chi_q^2. \quad (3.4.145)$$

■

Akibat 3.4.33 Untuk menguji $H_0 : \beta_j(\mathbf{u}_0) = 0$, pilih $\mathbf{R} = \mathbf{e}_j^\top$ (vektor satuan ke- j) dan $\mathbf{r} = 0$. Maka statistik Wald menjadi

$$W_j = \frac{\widehat{\beta}_{\text{CF},j}^2}{\widehat{\text{Var}}(\widehat{\beta}_{\text{CF},j})} = t_j^2 \xrightarrow{d} \chi_1^2. \quad (3.4.146)$$

Hal ini konsisten dengan hubungan $\chi_1^2 = (\mathcal{N}(0, 1))^2$.

Akibat 3.4.34 Untuk menguji hipotesis bahwa semua koefisien kecuali konstanta bernilai nol, $H_0 : \beta_1 = \beta_2 = \dots = \beta_{p-1} = 0$ dengan β_0 adalah konstanta, pilih

$$\mathbf{R} = \begin{pmatrix} \mathbf{0}_{(p-1) \times 1} & \mathbf{I}_{p-1} \end{pmatrix}, \quad \mathbf{r} = \mathbf{0}_{p-1}. \quad (3.4.147)$$

Statistik Wald yang dihasilkan berdistribusi χ_{p-1}^2 di bawah H_0 .

Prosedur inferensi-inferensi di atas valid secara asimtotik jika dan hanya jika terpenuhi kondisi:

1. Asumsi GA-GWR.1–GA-GWR.10 terpenuhi,
2. kondisi *undersmoothing* $\sqrt{nh^d}h^2 \rightarrow 0$ dipenuhi, dan
3. *cross-fitting* diimplementasikan dengan benar sehingga bobot kernel independen dari galat pada *fold* estimasi.

Tanpa *undersmoothing*, interval konfidensi akan memiliki *coverage probability* yang lebih rendah dari tingkat nominal karena bias yang tidak terabaikan.

3.5 Analisis Komputasional GA-GWR

Bagian ini menganalisis aspek komputasional dari GA-GWR yang diturunkan secara langsung dari formulasi teoretis pada bagian sebelumnya. Pembahasan

meliputi struktur graf komputasional terdiferensiasi, analisis propagasi gradien (termasuk kondisi *vanishing* dan *exploding gradient*), kompleksitas algoritmik, serta kelayakan komputasional model secara keseluruhan.

3.5.1 Graf Komputasional dan Diferensiabilitas

Berdasarkan formulasi pada bagian sebelumnya, *pipeline* komputasional GA-GWR dapat direpresentasikan sebagai graf arah asiklik (*directed acyclic graph*, DAG) yang sepenuhnya terdiferensiasi. Subbagian ini menguraikan setiap komponen graf komputasional dan menganalisis propagasi gradien melalui setiap tahapan.

Definisi 3.5.1 (Graf komputasional GA-GWR) Pipeline komputasional GA-GWR adalah komposisi pemetaan

$$\boldsymbol{\theta} \xrightarrow{\phi_1} \mathbf{s} \xrightarrow{\phi_2} \mathbf{w} \xrightarrow{\phi_3} \hat{\boldsymbol{\beta}} \xrightarrow{\phi_4} \mathcal{L}, \quad (3.5.1)$$

dengan komponen-komponen sebagai berikut.

- (i) Pemetaan $\phi_1 : \boldsymbol{\theta} \mapsto \mathbf{s}$ adalah fungsi GNN yang menghasilkan vektor skor $\mathbf{s} = (s_1, \dots, s_m)^\top$ dengan $s_i = s_{\boldsymbol{\theta}}(i, \mathbf{u}_0)$ untuk setiap $i \in \mathcal{N}_h(\mathbf{u}_0)$.
- (ii) Pemetaan $\phi_2 : \mathbf{s} \mapsto \mathbf{w}$ adalah transformasi softmax yang memetakan vektor skor ke bobot kernel.
- (iii) Pemetaan $\phi_3 : \mathbf{w} \mapsto \hat{\boldsymbol{\beta}}$ adalah solusi LWLS dengan $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{y}$.
- (iv) Pemetaan $\phi_4 : \hat{\boldsymbol{\beta}} \mapsto \mathcal{L}$ adalah fungsi kerugian kuadrat $\mathcal{L} = \sum_i (y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}(\mathbf{u}_i))^2$.

Setiap pemetaan dalam graf komputasional bersifat terdiferensiasi, sehingga gradien dapat dipropagasikan dari fungsi kerugian ke parameter GNN melalui aturan rantai (*chain rule*).

Proposisi 3.5.2 Komposisi $\mathcal{L} \circ \phi_4 \circ \phi_3 \circ \phi_2 \circ \phi_1$ terdiferensiasi hampir di mana-mana

terhadap θ , dengan gradien

$$\frac{\partial \mathcal{L}}{\partial \theta} = \frac{\partial \mathcal{L}}{\partial \hat{\beta}} \cdot \frac{\partial \hat{\beta}}{\partial \mathbf{w}} \cdot \frac{\partial \mathbf{w}}{\partial \mathbf{s}} \cdot \frac{\partial \mathbf{s}}{\partial \theta}. \quad (3.5.2)$$

Bukti. Diferensiabilitas setiap komponen ditunjukkan sebagai berikut.

- (i) Pemetaan GNN ϕ_1 merupakan komposisi transformasi linear dan fungsi aktivasi yang terdiferensiasi (misalnya ReLU, yang terdiferensiasi kecuali di titik nol dengan ukuran Lebesgue nol).
- (ii) Transformasi *softmax* ϕ_2 terdiferensiasi di \mathbb{R}^m karena fungsi eksponensial dan penjumlahan terdiferensiasi di mana-mana.
- (iii) Solusi LWLS ϕ_3 terdiferensiasi ketika matriks $\mathbf{X}^\top \mathbf{W} \mathbf{X}$ invertibel.
- (iv) Fungsi kerugian kuadrat ϕ_4 terdiferensiasi di mana-mana sebagai fungsi polinomial.

Dengan demikian, komposisi keempat pemetaan terdiferensiasi hampir di mana-mana, dan gradien diperoleh melalui aturan rantai. ■

Analisis propagasi gradien memerlukan karakterisasi eksplisit matriks Jacobian dari setiap komponen. Transformasi *softmax* memiliki struktur Jacobian khusus yang penting untuk memahami dinamika gradien.

Proposisi 3.5.3 *Matriks Jacobian dari transformasi softmax $\mathbf{w} = \text{softmax}(\mathbf{s})$ adalah*

$$\frac{\partial \mathbf{w}}{\partial \mathbf{s}} = \text{diag}(\mathbf{w}) - \mathbf{w} \mathbf{w}^\top, \quad (3.5.3)$$

dengan elemen-elemen

$$\frac{\partial w_i}{\partial s_j} = \begin{cases} w_i(1 - w_i) & \text{jika } i = j, \\ -w_i w_j & \text{jika } i \neq j. \end{cases} \quad (3.5.4)$$

Bukti. Untuk $i = j$, dengan menggunakan aturan hasil bagi diperoleh

$$\begin{aligned}\frac{\partial w_i}{\partial s_i} &= \frac{\partial}{\partial s_i} \left(\frac{e^{s_i}}{\sum_k e^{s_k}} \right) = \frac{e^{s_i} \sum_k e^{s_k} - e^{s_i} \cdot e^{s_i}}{(\sum_k e^{s_k})^2} \\ &= \frac{e^{s_i}}{\sum_k e^{s_k}} - \frac{e^{2s_i}}{(\sum_k e^{s_k})^2} = w_i - w_i^2 = w_i(1 - w_i).\end{aligned}\quad (3.5.5)$$

Untuk $i \neq j$, diperoleh

$$\frac{\partial w_i}{\partial s_j} = \frac{\partial}{\partial s_j} \left(\frac{e^{s_i}}{\sum_k e^{s_k}} \right) = \frac{0 - e^{s_i} \cdot e^{s_j}}{(\sum_k e^{s_k})^2} = -w_i w_j. \quad (3.5.6)$$

Dalam bentuk matriks, $\frac{\partial \mathbf{w}}{\partial \mathbf{s}} = \text{diag}(\mathbf{w}) - \mathbf{w}\mathbf{w}^\top$. ■

Struktur Jacobian *softmax* memiliki implikasi penting terhadap efek gradien.

Komponen kritis dalam propagasi gradien adalah diferensiasi melalui solusi LWLS. Solusi ini merupakan fungsi implisit dari bobot, sehingga memerlukan penanganan khusus.

Proposisi 3.5.4 Untuk solusi LWLS $\hat{\beta} = (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{y}$ dengan $\mathbf{W} = \text{diag}(w_1, \dots, w_m)$, gradien terhadap bobot tunggal w_i adalah

$$\frac{\partial \hat{\beta}}{\partial w_i} = \mathbf{M}^{-1} \mathbf{x}_i (y_i - \mathbf{x}_i^\top \hat{\beta}), \quad (3.5.7)$$

dengan $\mathbf{M} = \mathbf{X}^\top \mathbf{W} \mathbf{X}$ adalah matriks informasi lokal tertimbang.

Bukti. Identitas diferensiasi matriks invers menyatakan $\frac{\partial \mathbf{M}^{-1}}{\partial w_i} = -\mathbf{M}^{-1} \frac{\partial \mathbf{M}}{\partial w_i} \mathbf{M}^{-1}$. Dengan menggunakan aturan perkalian, diperoleh

$$\frac{\partial \hat{\beta}}{\partial w_i} = \frac{\partial \mathbf{M}^{-1}}{\partial w_i} \mathbf{X}^\top \mathbf{W} \mathbf{y} + \mathbf{M}^{-1} \frac{\partial (\mathbf{X}^\top \mathbf{W} \mathbf{y})}{\partial w_i}. \quad (3.5.8)$$

Sebab $\mathbf{M} = \sum_j w_j \mathbf{x}_j \mathbf{x}_j^\top$, maka $\frac{\partial \mathbf{M}}{\partial w_i} = \mathbf{x}_i \mathbf{x}_i^\top$. Demikian pula, $\frac{\partial (\mathbf{X}^\top \mathbf{W} \mathbf{y})}{\partial w_i} = \mathbf{x}_i y_i$.

Substitusi memberikan

$$\begin{aligned}
 \frac{\partial \hat{\beta}}{\partial w_i} &= -\mathbf{M}^{-1} \mathbf{x}_i \mathbf{x}_i^\top \mathbf{M}^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{y} + \mathbf{M}^{-1} \mathbf{x}_i y_i \\
 &= -\mathbf{M}^{-1} \mathbf{x}_i \mathbf{x}_i^\top \hat{\beta} + \mathbf{M}^{-1} \mathbf{x}_i y_i \\
 &= \mathbf{M}^{-1} \mathbf{x}_i (y_i - \mathbf{x}_i^\top \hat{\beta}).
 \end{aligned} \tag{3.5.9}$$

■

Bentuk gradien di atas menunjukkan bahwa kontribusi gradien dari observasi ke- i proporsional terhadap residualnya $r_i = y_i - \mathbf{x}_i^\top \hat{\beta}$. Hal ini memberikan interpretasi bahwa optimasi akan menyesuaikan bobot berdasarkan seberapa baik model menyesuaikan setiap observasi.

3.5.2 Analisis *Vanishing* dan *Exploding Gradient*

Analisis stabilitas numerik memerlukan karakterisasi kondisi di mana gradien dapat mengalami *vanishing* (menghilang) atau *exploding* (meledak). Kedua fenomena ini merupakan masalah fundamental dalam pelatihan jaringan saraf dalam yang dapat mengganggu konvergensi optimasi.

Definisi 3.5.5 (*Vanishing gradient*) Fenomena *vanishing gradient* terjadi ketika magnitudo gradien menjadi sangat kecil selama propagasi balik (backpropagation), sehingga pembaruan parameter menjadi tidak signifikan. Secara formal, jika $\mathbf{g}_t = \frac{\partial \mathcal{L}}{\partial \theta}$ adalah gradien pada iterasi t , maka *vanishing gradient* terjadi ketika

$$\|\mathbf{g}_t\| \rightarrow 0 \quad \text{meskipun } \mathcal{L}(\theta_t) \gg \mathcal{L}^*, \tag{3.5.10}$$

dengan \mathcal{L}^* adalah nilai optimal. Fenomena ini menyebabkan pembelajaran terhenti sebelum mencapai solusi optimal.

Definisi 3.5.6 (*Exploding gradient*) Fenomena *exploding gradient* terjadi ketika magnitudo gradien tumbuh secara eksponensial selama propagasi balik, menyebabkan pembaruan parameter yang tidak stabil. Secara formal, *exploding gradient*

terjadi ketika

$$\|\mathbf{g}_t\| \rightarrow \infty, \quad (3.5.11)$$

yang mengakibatkan divergensi parameter dan ketidakstabilan numerik.

Untuk mendeteksi kedua fenomena ini dalam praktik, dapat digunakan metrik berikut.

Definisi 3.5.7 (Indikator stabilitas gradien) Stabilitas gradien dapat dideteksi melalui rasio norma gradien terhadap norma parameter:

$$\rho_t = \frac{\|\mathbf{g}_t\|}{\|\boldsymbol{\theta}_t\| + \epsilon}, \quad (3.5.12)$$

dengan $\epsilon > 0$ adalah konstanta kecil untuk stabilitas numerik. Kondisi $\rho_t \ll 1$ mengindikasikan potensi vanishing gradient, sedangkan $\rho_t \gg 1$ mengindikasikan potensi exploding gradient. Dalam praktik, pelatihan stabil dicapai ketika $\rho_t \in [10^{-7}, 10^3]$.

Dalam konteks GA-GWR, kedua fenomena ini dapat terjadi pada komponen softmax dan solusi LWLS.

Teorema 3.5.8 Gradien melalui transformasi softmax mengalami vanishing ketika distribusi bobot mendekati distribusi degenerasi. Secara kuantitatif, jika $w_{i^*} \rightarrow 1$ untuk suatu indeks i^* (sehingga $w_j \rightarrow 0$ untuk semua $j \neq i^*$), maka

$$\left\| \frac{\partial \mathbf{w}}{\partial \mathbf{s}} \right\|_F \rightarrow 0. \quad (3.5.13)$$

Bukti. Norma Frobenius dari Jacobian softmax dapat dihitung sebagai

$$\begin{aligned} \left\| \frac{\partial \mathbf{w}}{\partial \mathbf{s}} \right\|_F^2 &= \sum_i \left(\frac{\partial w_i}{\partial s_i} \right)^2 + \sum_{i \neq j} \left(\frac{\partial w_i}{\partial s_j} \right)^2 \\ &= \sum_i w_i^2 (1 - w_i)^2 + \sum_{i \neq j} w_i^2 w_j^2. \end{aligned} \quad (3.5.14)$$

Suku kedua dapat disederhanakan sebagai

$$\sum_{i \neq j} w_i^2 w_j^2 = \left(\sum_i w_i^2 \right)^2 - \sum_i w_i^4. \quad (3.5.15)$$

Ketika $w_{i^*} \rightarrow 1$ dan $w_j \rightarrow 0$ untuk $j \neq i^*$, diperoleh $\sum_i w_i^2 \rightarrow 1$ dan setiap suku $w_i(1 - w_i) \rightarrow 0$ karena:

- Untuk $i = i^*$: $w_{i^*}(1 - w_{i^*}) \rightarrow 1 \cdot 0 = 0$.
- Untuk $i \neq i^*$: $w_i(1 - w_i) \rightarrow 0 \cdot 1 = 0$.

Dengan demikian, $\left\| \frac{\partial \mathbf{w}}{\partial \mathbf{s}} \right\|_F \rightarrow 0$. ■

Fenomena *vanishing gradient* pada *softmax* terjadi ketika fungsi skor GNN menghasilkan nilai yang sangat berbeda antarobservasi, menyebabkan satu observasi mendominasi bobot. Dalam konteks spasial, ini terjadi jika GNN terlalu yakin bahwa satu tetangga jauh lebih relevan dibandingkan yang lain.

Teorema 3.5.9 *Gradien melalui solusi LWLS mengalami exploding ketika matriks informasi lokal $\mathbf{M} = \mathbf{X}^\top \mathbf{W} \mathbf{X}$ mendekati singularitas. Secara kuantitatif, jika $\lambda_{\min}(\mathbf{M}) \rightarrow 0$ (nilai eigen terkecil mendekati nol), maka*

$$\left\| \frac{\partial \hat{\boldsymbol{\beta}}}{\partial w_i} \right\| = \mathcal{O} \left(\frac{1}{\lambda_{\min}(\mathbf{M})} \right) \rightarrow \infty. \quad (3.5.16)$$

Bukti. Berdasarkan Proposisi sebelumnya, gradien solusi LWLS terhadap bobot adalah $\frac{\partial \hat{\boldsymbol{\beta}}}{\partial w_i} = \mathbf{M}^{-1} \mathbf{x}_i (y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}})$. Norma gradien dapat dibatasi oleh

$$\left\| \frac{\partial \hat{\boldsymbol{\beta}}}{\partial w_i} \right\| \leq \|\mathbf{M}^{-1}\|_2 \cdot \|\mathbf{x}_i\| \cdot |y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}|. \quad (3.5.17)$$

Karena norma spektral matriks invers adalah $\|\mathbf{M}^{-1}\|_2 = 1/\lambda_{\min}(\mathbf{M})$, maka

$$\left\| \frac{\partial \hat{\boldsymbol{\beta}}}{\partial w_i} \right\| \leq \frac{\|\mathbf{x}_i\| \cdot |r_i|}{\lambda_{\min}(\mathbf{M})}, \quad (3.5.18)$$

dengan $r_i = y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}$ adalah residual. Ketika $\lambda_{\min}(\mathbf{M}) \rightarrow 0$, norma gradien divergen menuju tak hingga. ■

Matriks \mathbf{M} akan mendekati singularitas dalam situasi-situasi berikut.

- (i) Jika bobot terkonsentrasi pada kurang dari p observasi, maka $\text{rank}(\mathbf{M}) < p$.
- (ii) Jika kovariat pada observasi berbobot tinggi bersifat kolinear, maka \mathbf{M} mendekati singular.
- (iii) Jika lokasi target memiliki sedikit tetangga dalam $\mathcal{N}_h(\mathbf{u}_0)$, ukuran sampel efektif menjadi kecil.

3.5.3 Konstanta Lipschitz dan Stabilitas *Pipeline*

Untuk mengkarakterisasi propagasi perturbasi melalui *pipeline*, diperlukan analisis konstanta Lipschitz dari setiap komponen. Konstanta Lipschitz mengukur sensitivitas *output* terhadap perubahan *input* dan merupakan kunci untuk memahami stabilitas numerik.

Definisi 3.5.10 (Konstanta Lipschitz) Suatu fungsi $f : \mathcal{X} \rightarrow \mathcal{Y}$ dikatakan Lipschitz kontinu dengan konstanta $L \geq 0$ jika untuk semua $\mathbf{x}_1, \mathbf{x}_2 \in \mathcal{X}$ berlaku

$$\|f(\mathbf{x}_1) - f(\mathbf{x}_2)\| \leq L \|\mathbf{x}_1 - \mathbf{x}_2\|. \quad (3.5.19)$$

Konstanta Lipschitz terkecil yang memenuhi pertidaksamaan di atas disebut konstanta Lipschitz dari f dan dinotasikan $\text{Lip}(f)$.

Konstanta Lipschitz penting dalam analisis GA-GWR karena alasan berikut.

- (i) Konstanta Lipschitz kecil menjamin bahwa perturbasi kecil pada *input* tidak menyebabkan perubahan besar pada *output*.
- (ii) Untuk fungsi dengan konstanta Lipschitz terbatas, algoritma *gradient descent* dijamin konvergen dengan laju tertentu.

- (iii) Batas Lipschitz berkontribusi pada batas generalisasi model melalui teori kompleksitas Rademacher.

Teorema 3.5.11 Misalkan L_{GNN} , L_{softmax} , L_{LWLS} , dan $L_{\mathcal{L}}$ adalah konstanta Lipschitz dari masing-masing komponen pipeline. Konstanta Lipschitz keseluruhan memenuhi

$$L_{\text{total}} \leq L_{\mathcal{L}} \cdot L_{\text{LWLS}} \cdot L_{\text{softmax}} \cdot L_{\text{GNN}}. \quad (3.5.20)$$

Berdasarkan hasil sebelumnya, $L_{\text{softmax}} \leq 2$ dari sifat Lipschitz transformasi softmax. Nilai L_{LWLS} bergantung pada kondisioning matriks \mathbf{M} :

$$L_{\text{LWLS}} = \mathcal{O} \left(\frac{\kappa(\mathbf{M})}{\lambda_{\min}(\mathbf{M})} \right), \quad (3.5.21)$$

dengan $\kappa(\mathbf{M}) = \lambda_{\max}(\mathbf{M})/\lambda_{\min}(\mathbf{M})$ adalah condition number matriks \mathbf{M} .

Bukti. Untuk komposisi fungsi $f = f_L \circ \dots \circ f_1$, konstanta Lipschitz memenuhi $\text{Lip}(f) \leq \prod_{i=1}^L \text{Lip}(f_i)$. Hal ini dapat dibuktikan secara induktif: untuk \mathbf{x}, \mathbf{y} sembarang,

$$\begin{aligned} \|f(\mathbf{x}) - f(\mathbf{y})\| &= \|f_L(f_{L-1}(\dots f_1(\mathbf{x}))) - f_L(f_{L-1}(\dots f_1(\mathbf{y})))\| \\ &\leq L_L \|f_{L-1}(\dots f_1(\mathbf{x})) - f_{L-1}(\dots f_1(\mathbf{y}))\| \\ &\leq \dots \leq \prod_{i=1}^L L_i \|\mathbf{x} - \mathbf{y}\|. \end{aligned} \quad (3.5.22)$$

Untuk komponen LWLS, perhatikan bahwa $\hat{\beta} = \mathbf{M}^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{y}$. Sensitivitas terhadap perubahan bobot \mathbf{W} melibatkan invers matriks \mathbf{M} , yang norma spektralnya adalah $1/\lambda_{\min}(\mathbf{M})$. Dengan analisis perturbasi matriks, diperoleh batas $L_{\text{LWLS}} = \mathcal{O}(\kappa(\mathbf{M})/\lambda_{\min}(\mathbf{M}))$. ■

Teorema di atas menunjukkan bahwa stabilitas *pipeline* secara keseluruhan bergantung kritis pada matriks informasi lokal \mathbf{M} . Matriks dengan *condition number* tinggi (misalnya $\kappa(\mathbf{M}) > 10^6$) menyebabkan amplifikasi perturbasi dan ketidakstabilan numerik, yang mengindikasikan perlunya regularisasi atau peningkatan ukuran sampel lokal.

3.5.4 Algoritma Pelatihan dan Kompleksitas Komputasional

Bagian ini menyajikan algoritma komputasional untuk pelatihan GNN dan estimasi koefisien lokal dengan skema *cross-fitting*, serta analisis kompleksitas algoritmiknya.

Definisi 3.5.12 (Fungsi kerugian pelatihan) Untuk himpunan pelatihan $\mathcal{D}_{\text{latih}}$, fungsi kerugian didefinisikan sebagai

$$\mathcal{L}(\boldsymbol{\theta}) = \frac{1}{|\mathcal{D}_{\text{latih}}|} \sum_{i \in \mathcal{D}_{\text{latih}}} (y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}_{\boldsymbol{\theta}}(\mathbf{u}_i))^2, \quad (3.5.23)$$

dengan $\hat{\boldsymbol{\beta}}_{\boldsymbol{\theta}}(\mathbf{u}_i)$ adalah estimator koefisien lokal yang bergantung pada parameter GNN $\boldsymbol{\theta}$ melalui bobot kernel $\hat{\kappa}_{\boldsymbol{\theta}}(\cdot \mid \mathbf{u}_i)$.

Untuk menjamin stabilitas pelatihan berdasarkan analisis gradien pada subbagian sebelumnya, ditambahkan regularisasi entropi yang mencegah *vanishing gradient*.

Definisi 3.5.13 (Fungsi kerugian teregularisasi) Fungsi kerugian teregularisasi didefinisikan sebagai

$$\mathcal{L}_{\text{reg}}(\boldsymbol{\theta}) = \mathcal{L}(\boldsymbol{\theta}) - \lambda_{\text{ent}} \cdot \frac{1}{n} \sum_{i=1}^n H(\mathbf{w}_i), \quad (3.5.24)$$

dengan $H(\mathbf{w}_i) = -\sum_j w_{ij} \log w_{ij}$ adalah entropi distribusi bobot untuk lokasi i , dan $\lambda_{\text{ent}} > 0$ adalah parameter regularisasi. Suku entropi mendorong distribusi bobot yang lebih merata, mencegah konsentrasi bobot yang menyebabkan *vanishing gradient*.

Algoritma berikut mengimplementasikan skema *cross-fitting* yang telah diuraikan sebelumnya.

Algoritma 3.4 Estimasi Koefisien Lokal GA-GWR dengan *Cross-Fitting*

Require: Data $\{(\mathbf{x}_i, y_i, \mathbf{u}_i)\}_{i=1}^n$, jumlah *fold* K , lokasi target \mathbf{u}_0

Ensure: Estimator koefisien lokal $\hat{\beta}_{\text{CF}}(\mathbf{u}_0)$

- 1: **Tahap 1: Partisi Data**
 - 2: Partisi $\{1, \dots, n\}$ menjadi K *fold* saling lepas: $\mathcal{I}_1, \mathcal{I}_2, \dots, \mathcal{I}_K$
 - 3:
 - 4: **Tahap 2: Pelatihan GNN per Fold**
 - 5: **for** $k = 1$ **to** K **do**
 - 6: Definisikan data pelatihan: $\mathcal{D}^{(-k)} = \{i : i \notin \mathcal{I}_k\}$
 - 7: Latih GNN: $\hat{\theta}^{(-k)} = \arg \min_{\theta} \mathcal{L}_{\text{reg}}(\theta; \mathcal{D}^{(-k)})$
 - 8: **end for**
 - 9:
 - 10: **Tahap 3: Konstruksi Graf Lokal**
 - 11: Bangun $\mathcal{N}_h(\mathbf{u}_0) = \{i : d(\mathbf{u}_i, \mathbf{u}_0) \leq h\}$
 - 12: Untuk setiap $i \in \mathcal{N}_h(\mathbf{u}_0)$: hitung $\mathbf{z}_i(\mathbf{u}_0) = (\mathbf{x}_i^\top, (\mathbf{u}_i - \mathbf{u}_0)^\top)^\top$
 - 13:
 - 14: **Tahap 4: Komputasi Bobot Cross-Fitted**
 - 15: **for** $k = 1$ **to** K **do**
 - 16: **for** $i \in \mathcal{I}_k \cap \mathcal{N}_h(\mathbf{u}_0)$ **do**
 - 17: Hitung skor: $s_i = \text{GNN}_{\hat{\theta}^{(-k)}}(\mathcal{G}_h(\mathbf{u}_0), \mathbf{z}_i(\mathbf{u}_0))$
 - 18: **end for**
 - 19: Normalisasi *softmax*: $w_i^{(-k)} = \exp(s_i) / \sum_{j \in \mathcal{I}_k \cap \mathcal{N}_h} \exp(s_j)$
 - 20: **end for**
 - 21:
 - 22: **Tahap 5: Agregasi Estimator Cross-Fitted**
 - 23: **for** $k = 1$ **to** K **do**
 - 24: $\mathbf{H}_k \leftarrow \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \mathbf{x}_i \mathbf{x}_i^\top$
 - 25: $\mathbf{g}_k \leftarrow \sum_{i \in \mathcal{I}_k} w_i^{(-k)} \mathbf{x}_i y_i$
 - 26: **end for**
 - 27: $\hat{\beta}_{\text{CF}}(\mathbf{u}_0) \leftarrow (\sum_{k=1}^K \mathbf{H}_k)^{-1} (\sum_{k=1}^K \mathbf{g}_k)$
 - 28: **return** $\hat{\beta}_{\text{CF}}(\mathbf{u}_0)$
-

Analisis kompleksitas komputasional penting untuk memahami skalabilitas algoritma GA-GWR. Notasi $\mathcal{O}(\cdot)$ menyatakan batas atas asimtotik, dengan kompleksitas yang lebih rendah mengindikasikan algoritma yang lebih efisien.

Teorema 3.5.14 (Kompleksitas GA-GWR) Misalkan n adalah jumlah observasi, p adalah dimensi kovariat, $m = |\mathcal{N}_h(\mathbf{u}_0)|$ adalah ukuran rata-rata tetangga lokal, K adalah jumlah fold, T adalah jumlah iterasi pelatihan, dan $|\boldsymbol{\theta}|$ adalah jumlah parameter GNN. Kompleksitas waktu untuk setiap tahap adalah sebagai berikut.

- (i) **Pelatihan GNN** (Tahap 2): $\mathcal{O}(K \cdot T \cdot n \cdot m \cdot |\boldsymbol{\theta}|)$ — kompleksitas linear terhadap ukuran data dan parameter (baik).
- (ii) **Konstruksi graf lokal** (Tahap 3): $\mathcal{O}(n \log n)$ dengan struktur data spasial seperti k-d tree (baik), atau $\mathcal{O}(n^2)$ dengan pencarian naif (moderat).
- (iii) **Komputasi bobot** (Tahap 4): $\mathcal{O}(K \cdot m \cdot |\boldsymbol{\theta}|)$ — linear terhadap jumlah tetangga (baik).
- (iv) **Solusi LWLS** (Tahap 5): $\mathcal{O}(m \cdot p^2 + p^3)$ untuk setiap lokasi target — kubik terhadap p namun linear terhadap m (baik untuk p kecil).

Kompleksitas total untuk estimasi di n_0 lokasi target adalah

$$\mathcal{O}(K \cdot T \cdot n \cdot m \cdot |\boldsymbol{\theta}| + n_0 \cdot (m \cdot p^2 + p^3)). \quad (3.5.25)$$

Bukti. Untuk Tahap 2, setiap iterasi pelatihan memproses $n(1 - 1/K)$ observasi dengan K model. Setiap observasi memerlukan *forward pass* melalui GNN dengan kompleksitas $\mathcal{O}(m \cdot |\boldsymbol{\theta}|)$ untuk agregasi tetangga dan transformasi parameter.

Untuk Tahap 3, pencarian tetangga dalam radius h dapat dilakukan dalam $\mathcal{O}(\log n + m)$ per query menggunakan *k-d tree*, atau $\mathcal{O}(n)$ dengan pencarian linear.

Untuk Tahap 4, komputasi skor untuk setiap observasi memerlukan satu *forward pass* GNN.

Untuk Tahap 5, pembentukan matriks \mathbf{H}_k memerlukan $\mathcal{O}(m \cdot p^2)$ operasi (produk luar $\mathbf{x}_i \mathbf{x}_i^\top$ untuk m observasi), dan inversi matriks $p \times p$ memerlukan $\mathcal{O}(p^3)$

operasi. ■

Kompleksitas GA-GWR bersifat baik untuk aplikasi praktis karena:

- (i) Linear terhadap ukuran data n (skalabel untuk dataset besar).
- (ii) Kubik terhadap dimensi p , namun p biasanya kecil dalam aplikasi GWR ($p < 20$).
- (iii) Pelatihan GNN hanya dilakukan sekali, sedangkan estimasi di lokasi baru hanya memerlukan $\mathcal{O}(m \cdot p^2 + p^3)$.

Sebagai perbandingan, GWR klasik memerlukan $\mathcal{O}(n \cdot (n \cdot p^2 + p^3))$ untuk seluruh estimasi (kuadrat terhadap n), sehingga GA-GWR lebih efisien untuk dataset besar.

3.5.5 Diagnostik Model dan Validasi Inferensi

Diagnostik model diperlukan untuk mengevaluasi kualitas estimasi dan memvalidasi prosedur inferensi yang telah diuraikan pada bagian sebelumnya. Subbagian ini menyajikan metrik diagnostik dalam kerangka definisi-teorema yang sesuai dengan struktur teoretis GA-GWR.

Metrik evaluasi prediksi digunakan untuk mengukur kemampuan model dalam memprediksi nilai respons.

Definisi 3.5.15 (Root Mean Squared Error (RMSE)) *RMSE adalah akar kuadrat dari rata-rata kuadrat galat prediksi, didefinisikan sebagai*

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n \hat{\varepsilon}_i^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}_{\text{CF}}(\mathbf{u}_i))^2}. \quad (3.5.26)$$

RMSE memiliki satuan yang sama dengan variabel respons y . Nilai RMSE yang lebih rendah mengindikasikan prediksi yang lebih akurat.

Definisi 3.5.16 (Mean Absolute Error (MAE)) *MAE adalah rata-rata nilai absolut*

galat prediksi, didefinisikan sebagai

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |\hat{\varepsilon}_i| = \frac{1}{n} \sum_{i=1}^n |y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}_{\text{CF}}(\mathbf{u}_i)|. \quad (3.5.27)$$

MAE lebih robust terhadap outlier dibandingkan RMSE karena tidak mengkuadratkan galat. Nilai MAE yang lebih rendah mengindikasikan prediksi yang lebih akurat.

Definisi 3.5.17 (Koefisien determinasi (R^2)) Koefisien determinasi mengukur proporsi variansi dalam variabel respons yang dapat dijelaskan oleh model, didefinisikan sebagai

$$R^2 = 1 - \frac{\text{SS}_{\text{res}}}{\text{SS}_{\text{tot}}} = 1 - \frac{\sum_{i=1}^n (y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}_{\text{CF}}(\mathbf{u}_i))^2}{\sum_{i=1}^n (y_i - \bar{y})^2}, \quad (3.5.28)$$

dengan $\bar{y} = n^{-1} \sum_{i=1}^n y_i$ adalah rata-rata sampel, SS_{res} adalah jumlah kuadrat residual, dan SS_{tot} adalah jumlah kuadrat total. Nilai $R^2 \in [0, 1]$, di mana $R^2 = 1$ menunjukkan prediksi sempurna dan $R^2 = 0$ menunjukkan model tidak lebih baik dari prediksi menggunakan rata-rata.

Diagnostik residual diperlukan untuk memvalidasi asumsi model, khususnya Asumsi GA-GWR.1 dan normalitas galat.

Definisi 3.5.18 (Uji Shapiro-Wilk) Uji Shapiro-Wilk digunakan untuk menguji normalitas distribusi residual dengan hipotesis sebagai berikut.

H_0 : Residual berdistribusi normal, lawan

H_1 : residual tidak berdistribusi normal.

Statistik uji Shapiro-Wilk didefinisikan sebagai

$$W = \frac{\left(\sum_{i=1}^n a_i \hat{\varepsilon}_{(i)} \right)^2}{\sum_{i=1}^n (\hat{\varepsilon}_{(i)} - \bar{\varepsilon})^2}, \quad (3.5.29)$$

dengan $\hat{\varepsilon}_{(i)}$ adalah statistik urutan ke- i dari residual (residual yang diurutkan dari

terkecil ke terbesar), $\bar{\varepsilon} = n^{-1} \sum_{i=1}^n \hat{\varepsilon}_i$ adalah rata-rata residual, dan a_i adalah koefisien yang diturunkan dari momen statistik urutan distribusi normal standar.

Untuk tingkat signifikansi α , hipotesis nol H_0 ditolak jika $W < W_{\alpha,n}$, dengan $W_{\alpha,n}$ adalah nilai kritis dari tabel distribusi Shapiro-Wilk untuk ukuran sampel n . Secara ekuivalen, jika $p\text{-value} < \alpha$, maka terdapat cukup bukti untuk menolak H_0 .

Definisi 3.5.19 (Indeks Moran) Indeks Moran digunakan untuk mendeteksi autokorelasi spasial pada residual dengan hipotesis sebagai berikut.

H_0 : Tidak terdapat autokorelasi spasial pada residual ($I = \mathbb{E}[I]$), lawan

H_1 : terdapat autokorelasi spasial pada residual ($I \neq \mathbb{E}[I]$).

Statistik Indeks Moran didefinisikan sebagai

$$I = \frac{n}{S_0} \cdot \frac{\sum_{i=1}^n \sum_{j=1}^n w_{ij}^* (\hat{\varepsilon}_i - \bar{\varepsilon})(\hat{\varepsilon}_j - \bar{\varepsilon})}{\sum_{i=1}^n (\hat{\varepsilon}_i - \bar{\varepsilon})^2}, \quad (3.5.30)$$

dengan w_{ij}^* adalah elemen matriks bobot spasial (biasanya biner: $w_{ij}^* = 1$ jika lokasi i dan j bertetangga, 0 sebaliknya), dan $S_0 = \sum_{i=1}^n \sum_{j=1}^n w_{ij}^*$ adalah total bobot.

Di bawah H_0 , nilai harapan dan variansi Indeks Moran adalah

$$\mathbb{E}[I] = -\frac{1}{n-1}, \quad (3.5.31)$$

$$\text{Var}(I) = \frac{n^2 S_1 - n S_2 + 3 S_0^2}{S_0^2 (n^2 - 1)} - \mathbb{E}[I]^2, \quad (3.5.32)$$

dengan $S_1 = \frac{1}{2} \sum_{i \neq j} (w_{ij}^* + w_{ji}^*)^2$ dan $S_2 = \sum_i (\sum_j w_{ij}^* + \sum_j w_{ji}^*)^2$.

Statistik- z untuk pengujian adalah

$$z_I = \frac{I - \mathbb{E}[I]}{\sqrt{\text{Var}(I)}}, \quad (3.5.33)$$

yang berdistribusi asimtotik $\mathcal{N}(0, 1)$ di bawah H_0 . Untuk uji dua sisi dengan tingkat signifikansi α , H_0 ditolak jika $|z_I| > z_{\alpha/2}$. Secara ekuivalen, jika $p\text{-value} < \alpha$, maka terdapat cukup bukti untuk menolak H_0 .

Untuk memvalidasi bahwa bobot *kernel* yang dipelajari GNN memenuhi kondisi regularitas pada Asumsi GA-GWR.7 dan GA-GWR.8, dilakukan evaluasi berikut.

Definisi 3.5.20 (Entropi bobot *kernel*) *Entropi distribusi bobot untuk lokasi target \mathbf{u}_0 didefinisikan sebagai*

$$H(\mathbf{u}_0) = - \sum_{i \in \mathcal{N}_h(\mathbf{u}_0)} \hat{\kappa}_{\theta}(i \mid \mathbf{u}_0) \log \hat{\kappa}_{\theta}(i \mid \mathbf{u}_0). \quad (3.5.34)$$

Entropi mengukur ketidakpastian atau keragaman distribusi bobot.

Entropi tinggi berarti bobot terdistribusi merata di antara banyak observasi sehingga baik untuk stabilitas, tetapi dapat menyebabkan *oversmoothing*. Entropi rendah berarti bobot terkonsentrasi pada sedikit observasi sehingga dapat menyebabkan variansi tinggi dan fenomena *vanishing gradient*.

Definisi 3.5.21 (Effective number of neighbors) *Jumlah tetangga efektif untuk lokasi target \mathbf{u}_0 didefinisikan sebagai*

$$n_{\text{eff}}(\mathbf{u}_0) = \exp(H(\mathbf{u}_0)). \quad (3.5.35)$$

Metrik ini mengukur berapa banyak observasi yang secara efektif berkontribusi pada estimasi lokal, dengan interpretasi sebagai berikut.

- (i) *Jika bobot seragam, maka $n_{\text{eff}} = |\mathcal{N}_h(\mathbf{u}_0)|$ (maksimum).*
- (ii) *Jika bobot terkonsentrasi pada satu observasi, maka $n_{\text{eff}} \rightarrow 1$.*

Teorema 3.5.22 (Kondisi kecukupan sampel lokal) *Untuk menjamin identifikasi parameter lokal (Asumsi GA-GWR.7), jumlah tetangga efektif harus memenuhi*

$$n_{\text{eff}}(\mathbf{u}_0) \geq p + 1, \quad (3.5.36)$$

dengan p adalah dimensi kovariat. Jika kondisi ini tidak terpenuhi, matriks $\mathbf{X}^\top \mathbf{W} \mathbf{X}$ dapat menjadi singular atau ill-conditioned.

Bukti. Untuk solusi LWLS, matriks Hessian $\mathbf{X}^\top \mathbf{W} \mathbf{X}$ berukuran $p \times p$. Agar matriks ini memiliki *full rank*, diperlukan minimal p observasi dengan bobot tak nol yang kovariat-nya *linearly independent*. ■

Untuk memastikan validitas inferensi statistik, dilakukan validasi berikut.

Definisi 3.5.23 (Kondisi *undersmoothing*) Kondisi undersmoothing terpenuhi jika bandwidth h memenuhi

$$\sqrt{nh^d} \cdot h^2 \rightarrow 0 \quad \text{saat } n \rightarrow \infty, \quad (3.5.37)$$

dengan d adalah dimensi ruang koordinat spasial. Kondisi ini menjamin bahwa bias asimtotik dapat diabaikan relatif terhadap galat baku, sehingga interval kepercayaan memiliki coverage yang valid.

Dalam praktik, validitas inferensi dapat diverifikasi dengan cara sebagai berikut.

- (i) Membandingkan distribusi empiris statistik- t dengan distribusi $\mathcal{N}(0, 1)$ menggunakan Q-Q plot.
- (ii) Mengevaluasi sensitivitas hasil terhadap variasi jumlah *fold* K dalam skema *cross-fitting*.
- (iii) Memastikan *coverage* empiris interval kepercayaan mendekati level nominal melalui simulasi atau *bootstrap*.

BAB IV

STUDI KASUS

Bab ini menyajikan validasi empiris dari kerangka metodologis GA-GWR yang telah dikembangkan pada Bab III. Validasi dilakukan melalui dua pendekatan komplementer, yaitu studi simulasi dalam kondisi terkontrol dan aplikasi pada data riil. Studi simulasi bertujuan untuk memverifikasi properti teoritis estimator GA-GWR, khususnya kemampuan metode dalam merekonstruksi koefisien spasial sejati dan akurasi prediksi di bawah berbagai kondisi data. Sementara itu, studi kasus pada data inflasi regional Indonesia mendemonstrasikan kinerja metode dalam konteks aplikasi praktis dengan kompleksitas data riil. Kedua studi ini dirancang untuk menjawab pertanyaan penelitian utama tentang peningkatan kinerja pembelajaran adaptif bobot spasial melalui jaringan saraf graf dibandingkan pendekatan konvensional berbasis *kernel* tetap.

4.1 Studi Simulasi

Studi simulasi merupakan instrumen penting dalam validasi metode statistik, khususnya untuk metode yang melibatkan pembelajaran mesin seperti GA-GWR. Berbeda dengan aplikasi pada data riil ketika nilai parameter sejati tidak diketahui, simulasi memungkinkan kontrol penuh atas *data generating process* (DGP) sehingga kinerja estimator dapat dievaluasi secara objektif melalui perbandingan dengan nilai parameter sejati. Dalam konteks penelitian ini, studi simulasi dirancang untuk menjawab pertanyaan tentang seberapa dekat estimator GA-GWR terhadap koefisien spasial sejati dan bagaimana performa prediksi metode ini pada data *out-of-sample* dibandingkan dengan metode pembanding seperti GWR klasik. Untuk menjawab pertanyaan tersebut, dirancang serangkaian eksperimen simulasi dengan variasi kompleksitas struktur spasial dan karakteristik data. Bagian berikut menguraikan desain eksperimen, metrik evaluasi, serta interpretasi hasil simulasi.

4.1.1 Desain Eksperimen Simulasi

Eksperimen simulasi dirancang untuk menguji kinerja GA-GWR terhadap struktur spasial yang kompleks. Kompleksitas ini penting untuk mengevaluasi kemampuan pembelajaran adaptif *kernel* spasial dalam menangkap pola non-stasioner yang tidak dapat direpresentasikan oleh *kernel* konvensional. Desain eksperimen mencakup struktur data, model generasi data, skenario variasi, dan prosedur evaluasi.

Data simulasi dibangkitkan dalam format panel spasial seimbang (*balanced spatial panel*), yang merepresentasikan observasi berulang pada lokasi-lokasi tetap sepanjang waktu. Struktur ini dipilih karena relevansinya dengan data ekonomi makro regional dan konsistensinya dengan kerangka teoritis pada Bab III. Secara formal, data terdiri dari N_{LOC} lokasi spasial yang masing-masing diamati selama T periode waktu, menghasilkan total $n = N_{\text{LOC}} \times T$ observasi. Lokasi spasial $\mathbf{u}_i = (u_i, v_i)^\top$ didistribusikan pada *grid regular* $[0, L] \times [0, L]$ dengan $N_{\text{LOC}} = m \times m$ lokasi dan m adalah dimensi grid. Penggunaan *grid regular* memfasilitasi visualisasi hasil melalui *heatmap* dan memastikan cakupan spasial yang seragam di seluruh domain. Untuk setiap lokasi i dan periode t , dibangkitkan kovariat $x_{it,j} \sim \mathcal{N}(0, 1)$ untuk $j = 1, 2$, yang bersifat independen antar waktu dan lokasi. Struktur ini mengisolasi variasi spasial pada koefisien dari variasi pada kovariat.

Model *data generating process* mengikuti spesifikasi GWR dengan koefisien yang bervariasi secara spasial, yaitu

$$y_{it} = \beta_0(\mathbf{u}_i) + \beta_1(\mathbf{u}_i)x_{it,1} + \beta_2(\mathbf{u}_i)x_{it,2} + \varepsilon_{it}, \quad \varepsilon_{it} \sim \mathcal{N}(0, \sigma^2), \quad (4.1.1)$$

dengan $\beta_j(\mathbf{u}_i)$ adalah fungsi koefisien spasial sejati untuk kovariat ke- j . Aspek krusial dari desain ini adalah pemilihan fungsi $\beta_j(\cdot)$ yang mengandung pola spasial kompleks yang sulit diestimasi oleh *kernel* konvensional tetapi dapat dipelajari oleh GNN. Secara eksplisit, fungsi koefisien yang digunakan adalah sebagai beri-

kut. Fungsi konstanta atau *intercept* $\beta_0(\mathbf{u})$ didefinisikan sebagai

$$\beta_0(\mathbf{u}) = 2 + 2 \sin(6r), \quad (4.1.2)$$

dengan $r = \arctan2(v - 5, u - 5)/\pi + 0.5$ adalah fungsi fase sudut yang dinormalisasi. Fungsi ini menggambarkan perubahan *gradual* dengan variasi sudut yang kompleks di seluruh domain. Di sini, $r = \sqrt{(u - L/2)^2 + (v - L/2)^2}$ adalah jarak radial dari pusat grid ke lokasi \mathbf{u} .

Fungsi kemiringan untuk kovariat pertama $\beta_1(\mathbf{u})$ adalah

$$\beta_1(\mathbf{u}) = \begin{cases} 2,5, & \text{jika } u < v, \\ -2,5, & \text{jika } u \geq v. \end{cases}, \quad (4.1.3)$$

yang menggambarkan perubahan diskontinu di sepanjang diagonal utama *grid*, menciptakan tantangan bagi metode yang mengandalkan *kernel* halus.

Fungsi kemiringan untuk kovariat kedua $\beta_2(\mathbf{u})$ diberikan oleh

$$\beta_2(\mathbf{u}) = 2 + \sin(u/2) \times \mathbb{I}_{v>5}, \quad (4.1.4)$$

dengan $\mathbb{I}_{\{\cdot\}}$ adalah fungsi indikator. Fungsi ini memperkenalkan variasi spasial yang bersyarat berdasarkan posisi vertikal v , menambah kompleksitas pola spasial yang harus dipelajari.

Untuk mengevaluasi *robustness* dan skalabilitas metode, dilakukan variasi pada dua faktor kunci yang mempengaruhi kompleksitas masalah estimasi yaitu ukuran sampel dan tingkat *noise*. Variasi ukuran sampel dilakukan dengan tiga konfigurasi grid. Konfigurasi pertama menggunakan $m = 12$ yang menghasilkan $N_{\text{LOC}} = 144$ lokasi dengan $T = 25$ periode sehingga $n = 3.600$ observasi sebagai skenario *baseline*. Konfigurasi kedua menggunakan $m = 20$ yang menghasilkan $N_{\text{LOC}} = 400$ lokasi dengan $n = 10.000$ observasi untuk menguji skalabilitas dengan ukuran sampel menengah. Konfigurasi ketiga menggunakan $m = 30$ yang menghasilkan $N_{\text{LOC}} = 900$ lokasi dengan $n = 22.500$ observasi untuk menge-

valuasi kinerja pada *dataset* besar. Variasi ini menguji bagaimana kinerja relatif GA-GWR terhadap GWR klasik berubah seiring peningkatan ukuran sampel, yang relevan dengan teori asimtotik pada Bab III.

Untuk mengevaluasi sensitivitas metode GWR konvensional terhadap pemilihan *kernel*, dilakukan perbandingan empat *kernel* yang berbeda pada skenario simulasi *baseline* yang sama. *Kernel-kernel* yang dievaluasi adalah Gaussian, Exponential, Tricube, dan Bisquare dengan *bandwidth* ditentukan menggunakan aturan Silverman, yaitu

$$h_{\text{Silverman}} = 0,9 \min(\hat{\sigma}, \text{IQR}/1,34)n^{-1/5}, \quad (4.1.5)$$

dengan $\hat{\sigma}$ adalah simpangan baku jarak antar lokasi dan IQR. Aturan Silverman dipilih karena konsistensinya dengan teori asimtotik estimasi *bandwidth* optimal dalam konteks *kernel density estimation* (KDE). Secara teoritis, aturan ini memberikan *bandwidth* yang meminimalkan *integrated squared error* (ISE) dalam asumsi distribusi populasi normal, menghasilkan *rate konvergensi* optimal sebesar $\mathcal{O}(n^{-1/5})$ yang sesuai dengan teori GWR. Alternatif lain yaitu pendekatan *Generalized Cross-Validation* (GCV) untuk pencarian *bandwidth* optimal secara langsung memiliki kompleksitas komputasi yang tidak *scalable*, yaitu $\mathcal{O}(n^4)$ untuk estimasi setiap *bandwidth* kandidat, sehingga pada data panel besar seperti pada studi kasus dengan $n = 3.600$ akan menghasilkan beban komputasi yang besar. Oleh karena itu, aturan Silverman merupakan *trade-off* yang masuk akal antara akurasi dan efisiensi komputasi. Hasil perbandingan *kernel* untuk skenario $n = 3.600$ dan $\sigma = 0,5$ disajikan dalam Tabel 4.1.

Tabel 4.1 Perbandingan Kernel GWR Gaussian dan Exponential

<i>Kernel</i>	R^2	RMSE	MAE	Rataan RMSE(β)	Waktu Pred. (s)
Gaussian	0,9305	1,0301	0,7134	0,4130	27,68
Exponential	0,8634	1,4442	1,0853	0,6321	28,95

Hasil perbandingan *kernel* menunjukkan perbedaan substansial dalam performa berbagai *kernel* pada data simulasi. Model GWR dengan *kernel* Gaussian

menunjukkan kinerja terbaik dengan R^2 tertinggi sebesar 0,9305 dan RMSE terendah sebesar 1,0301. Sebaliknya, *kernel* Exponential menunjukkan penurunan kinerja yang signifikan dengan R^2 hanya 0,8634 dan RMSE sebesar 1,4442. Hal ini mengindikasikan bahwa *kernel* Gaussian lebih efektif dalam menangkap variasi spasial pada data simulasi ini dibandingkan *kernel* Exponential.

Variasi tingkat *noise* dilakukan dengan tiga tingkat standar deviasi galat. Tingkat pertama menggunakan $\sigma = 0,5$ yang merepresentasikan kondisi *noise* rendah dengan *signal-to-noise ratio* tinggi. Tingkat kedua menggunakan $\sigma = 1,0$ yang merepresentasikan kondisi *noise* sedang dengan *signal-to-noise ratio* moderat. Tingkat ketiga menggunakan $\sigma = 2,0$ yang merepresentasikan kondisi *noise* tinggi dengan *signal-to-noise ratio* rendah. Variasi ini mengevaluasi sensitivitas metode terhadap kontaminasi *noise*, yang penting karena pembelajaran GNN dapat mengalami *overfitting* pada *noise* jika tidak diregularisasi dengan baik. Kombinasi faktorial dari kedua faktor menghasilkan $3 \times 3 = 9$ skenario eksperimen.

Untuk mensimulasikan kondisi prediksi riil dan menghindari kebocoran data (*data leakage*), digunakan skema *temporal train-test split*. Dari T periode waktu total, 80% periode awal dialokasikan untuk himpunan data latih, sementara 20% periode akhir dialokasikan untuk himpunan data uji. Penting dicatat bahwa semua lokasi hadir di kedua himpunan, hanya periode waktunya yang berbeda. Skema ini mensimulasikan skenario peramalan (*forecasting*) ketika model dilatih pada data historis dan digunakan untuk memprediksi periode mendatang pada lokasi yang sama, yang merupakan pengaturan realistis untuk aplikasi pada data panel spasial dalam praktik.

Model GA-GWR dievaluasi dengan tiga arsitektur jaringan saraf graf berbeda sebagai *backbone* untuk pembelajaran bobot spasial adaptif, yaitu *Graph Attention Network* (GAT), *Graph Convolutional Network* (GCN), dan *GraphSAGE*. Untuk ketiga arsitektur, digunakan konfigurasi yang konsisten dalam implementasi untuk memastikan perbandingan yang adil. Konfigurasi *hyperparameter* utama untuk model GA-GWR disajikan dalam Tabel 4.2.

Fungsi kerugian yang dioptimalkan selama pelatihan model merupakan kom-

Tabel 4.2 Konfigurasi Hyperparameter Model GA-GWR

Komponen	Spesifikasi
Jumlah lapisan jaringan	3 lapisan
Dimensi lapisan tersembunyi	64, 32, dan 16 unit
Fungsi aktivasi	ReLU (<i>Rectified Linear Unit</i>)
Tingkat Dropout	0,25
Algoritma optimasi	Adam
Laju pembelajaran	0,001
Maksimal epoch	500
Mekanisme <i>early stopping</i>	Aktif dengan <i>patience</i> sebesar 30 epoch
Skema <i>cross-fitting</i>	<i>3-fold temporal cross-fitting</i>

binasi multikomponen sebagai berikut. Fungsi kerugian utama adalah *Mean Squared Error* (MSE) antara prediksi respons dan nilai target, yang dihitung dengan rumus:

$$\text{MSE} = \frac{1}{n_{\text{train}}} \sum_{i=1}^{n_{\text{train}}} (y_i - \hat{y}_i)^2. \quad (4.1.6)$$

Regularisasi entropi diterapkan pada bobot spasial yang dipelajari untuk mendorong distribusi bobot yang lebih merata. Regularisasi ini dihitung sebagai:

$$L_{\text{entropy}} = - \sum_j w_j \log(w_j), \quad (4.1.7)$$

dengan bobot w_j adalah bobot spasial untuk tetangga ke- j .

Regularisasi kelancaran Laplacian diterapkan untuk memastikan bobot spasial yang berdekatan tidak berbeda terlalu tajam. Regularisasi ini dihitung sebagai:

$$L_{\text{Laplacian}} = \sum_{(i,j) \in E} (w_i - w_j)^2, \quad (4.1.8)$$

dengan E adalah himpunan tepi pada graf tetangga.

Regularisasi monotonisitas *kernel* diterapkan untuk menjaga penurunan bobot dengan jarak. Regularisasi ini dihitung sebagai:

$$L_{\text{monotonicity}} = \sum_{i,j} \max(0, w_i - w_j), \quad (4.1.9)$$

untuk tetangga i dan j dengan jarak $d_i < d_j$.

Regularisasi *smoothness* koefisien diterapkan untuk memanfaatkan kontinuitas spasial koefisien. Regularisasi ini dihitung sebagai:

$$L_{\text{coef_smoothness}} = \sum_{(i,j) \in E} (\hat{\beta}(\mathbf{u}_i) - \hat{\beta}(\mathbf{u}_j))^2. \quad (4.1.10)$$

4.1.2 Evaluasi Akurasi Estimasi Titik

Evaluasi akurasi estimasi bertujuan menjawab pertanyaan fundamental yaitu seberapa dekat estimator $\hat{\beta}(\mathbf{u})$ terhadap koefisien spasial sejati $\beta^*(\mathbf{u})$. Dalam konteks GWR, terdapat dua aspek akurasi yang perlu dievaluasi yaitu akurasi estimasi parameter lokal dan akurasi prediksi respons. Evaluasi dilakukan melalui serangkaian metrik kuantitatif yang mengukur kesalahan estimasi baik pada level parameter maupun prediksi.

Akurasi estimasi koefisien lokal diukur melalui *Root Mean Squared Error* (RMSE) yang dihitung untuk setiap komponen koefisien $\beta_j(\mathbf{u})$ dengan $j = 0, 1, 2$ yang merepresentasikan konstanta dan dua koefisien regresi. Untuk N_{LOC} lokasi unik, RMSE untuk koefisien j didefinisikan sebagai

$$\text{RMSE}(\hat{\beta}_j) = \sqrt{\frac{1}{N_{\text{LOC}}} \sum_{i=1}^{N_{\text{LOC}}} \left(\hat{\beta}_j(\mathbf{u}_i) - \beta_j^*(\mathbf{u}_i) \right)^2}. \quad (4.1.11)$$

Metrik ini mengukur kesalahan estimasi rata-rata di seluruh domain spasial. Nilai RMSE yang lebih rendah mengindikasikan estimator yang lebih akurat dalam merekonstruksi pola spasial sejati. Sebagai agregasi, dihitung pula Mean RMSE sebagai rata-rata aritmatik dari RMSE ketiga koefisien yang memberikan ukuran kesalahan keseluruhan, yaitu

$$\overline{\text{RMSE}} = \frac{1}{3} \sum_{j=0}^2 \text{RMSE}(\hat{\beta}_j). \quad (4.1.12)$$

Selain metrik global, untuk memahami pola spasial kesalahan estimasi, dihitung

juga bias lokal untuk setiap koefisien yang didefinisikan sebagai

$$\text{Bias}_j(\mathbf{u}_i) = \hat{\beta}_j(\mathbf{u}_i) - \beta_j^*(\mathbf{u}_i). \quad (4.1.13)$$

Peta bias menunjukkan tempat metode cenderung melakukan *overestimation* atau *underestimation*, memberikan wawasan tentang karakteristik *spatial smoothing* yang dihasilkan oleh masing-masing *kernel* dan arsitektur pembelajaran.

Akurasi prediksi respons pada data uji dievaluasi menggunakan tiga metrik standar yang saling melengkapi. Pertama, koefisien determinasi R^2 mengukur proporsi variansi yang dijelaskan oleh model:

$$R^2 = 1 - \frac{\sum_{i=1}^{n_{\text{test}}} (y_i - \hat{y}_i)^2}{\sum_{i=1}^{n_{\text{test}}} (y_i - \bar{y})^2}, \quad (4.1.14)$$

dengan nilai lebih tinggi mendekati satu mengindikasikan kecocokan yang lebih baik. Kedua, *Root Mean Squared Error* (RMSE) prediksi mengukur efek kesalahan prediksi rata-rata dalam satuan asli variabel respons:

$$\text{RMSE}_y = \sqrt{\frac{1}{n_{\text{test}}} \sum_{i=1}^{n_{\text{test}}} (y_i - \hat{y}_i)^2}. \quad (4.1.15)$$

Ketiga, *Mean Absolute Error* (MAE) memberikan ukuran kesalahan yang lebih *robust* terhadap pencilan:

$$\text{MAE} = \frac{1}{n_{\text{test}}} \sum_{i=1}^{n_{\text{test}}} |y_i - \hat{y}_i|. \quad (4.1.16)$$

Hasil eksperimen pada skenario baseline dengan $n = 3.600$ observasi dan $\sigma = 0,5$ disajikan dalam Tabel 4.3 di bawah ini.

Tabel 4.3 Perbandingan Performa Prediksi Model ($n = 3.600, \sigma = 0.5$)

Model	R^2	RMSE	MAE
OLS	0,3358	3,1846	2,5608
GWR - Gaussian	0,9305	1,0301	0,7134
GA-GWR (GAT)	0,9806	0,5441	0,4285

Lebih lanjut, tabel ini membandingkan kinerja OLS, GWR klasik dengan *kernel* Gaussian dan *bandwidth* yang dihitung melalui, dan GA-GWR dengan *backbone* GraphSAGE yang menunjukkan efisiensi komputasi terbaik.

Tabel 4.4 RMSE Estimasi Koefisien Spasial

Model	RMSE(β_0)	RMSE(β_1)	RMSE(β_2)	Mean RMSE
OLS	1,5033	2,4936	0,5081	1,5017
GWR - Gaussian	0,5901	0,5291	0,1197	0,4130
GA-GWR (GAT)	0,117	0,1149	0,117	0,116

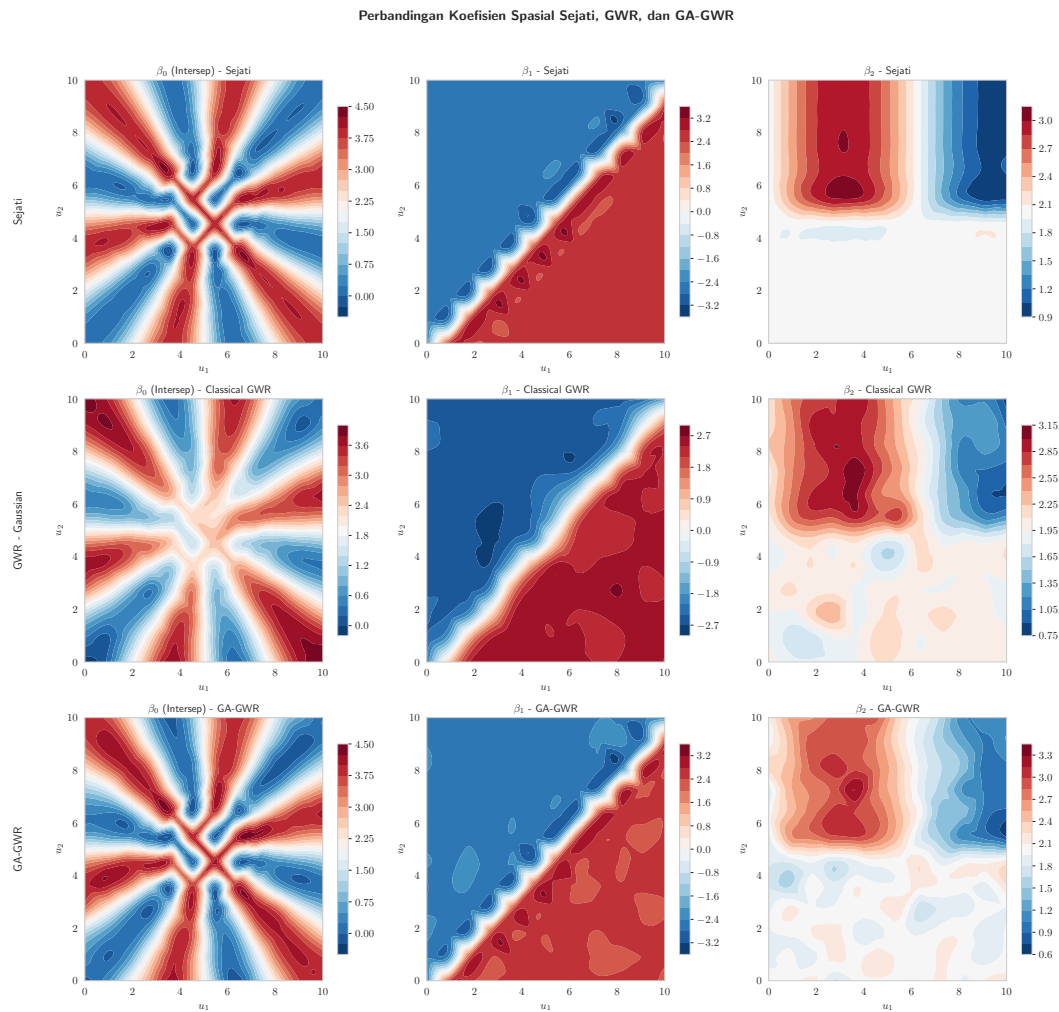
Berdasarkan tabel di atas, GA-GWR menunjukkan keunggulan signifikan dalam akurasi prediksi dibandingkan GWR klasik dan OLS. Model GA-GWR mencapai R^2 sebesar 0,9806, jauh lebih tinggi dibandingkan GWR klasik (0,9305) dan OLS (0,3358). Demikian pula, RMSE dan MAE GA-GWR (0,5441 dan 0,4285) secara substansial lebih rendah daripada GWR klasik (1,0301 dan 0,7134) dan OLS (3,1846 dan 2,5608). Hasil ini menegaskan kemampuan GA-GWR dalam menangkap variasi spasial yang kompleks dengan akurasi prediksi yang baik. Visualisasi spasial koefisien sejati dibandingkan dengan estimasi dari metode terbaik ditampilkan dalam Gambar 4.1.

Perbandingan arsitektur GNN sebagai *backbone* GA-GWR disajikan dalam Tabel 4.5. Hasil menunjukkan bahwa ketiga arsitektur memberikan performa prediksi dan estimasi koefisien yang sangat serupa, dengan GraphSAGE menunjukkan keunggulan dalam efisiensi komputasi.

Tabel 4.5 Perbandingan Arsitektur GNN sebagai Backbone GA-GWR

Backbone	R^2	RMSE	Rataan RMSE(β)	Waktu Pelatihan (s)
GAT	0,9806	0,5438	0,1169	583,43
GCN	0,9806	0,5439	0,1172	432,29
GraphSAGE	0,9805	0,5450	0,1206	527,58

Perbandingan arsitektur GNN menunjukkan bahwa ketiga arsitektur (GAT, GCN, dan GraphSAGE) menghasilkan performa prediksi dan estimasi koefisien yang hampir identik dengan nilai $R^2 = 0,9806$, $RMSE \approx 0,544$, dan Rataan RMSE koefisien $\approx 0,1170$. Perbedaan signifikan terletak pada efisiensi komputasi,



Gambar 4.1 Perbandingan koefisien spasial sejati (baris atas), estimasi GWR klasik (baris tengah), dan estimasi GA-GWR (baris bawah) untuk β_0 (kolom kiri), β_1 (kolom tengah), dan β_2 (kolom kanan). GA-GWR menangkap pola spasial dengan lebih akurat termasuk diskontinuitas tajam pada β_1 .

ketika GCN membutuhkan waktu pelatihan paling singkat (432,29 detik), disusul GraphSAGE (527,58 detik), dan GAT (583,43 detik). Keunggulan GAT dalam efisiensi komputasi yang kompetitif menjadi kriteria pemilihan utama untuk menggunakan arsitektur ini dalam studi kasus aplikasi pada data riil, dengan waktu pelatihan yang lebih cepat menguntungkan praktisnya implementasi tanpa mengorbankan akurasi.


Selanjutnya, analisis sensitivitas dilakukan untuk mengevaluasi dampak variasi ukuran sampel N_{LOC} dan tingkat *noise* σ terhadap kinerja GA-GWR dengan *backbone* GAT. Hasil analisis sensitivitas disajikan dalam Tabel 4.6 dan Gambar 4.2.

Tabel 4.6 Analisis Sensitivitas GA-GWR terhadap Ukuran Sampel dan Tingkat Noise

N_{LOC}	σ	R^2	RMSE	Rataan RMSE(β)
64	0,5	0,979	0,521	0,140
64	1,0	0,920	1,041	0,280
64	2,0	0,731	2,080	0,559
100	0,5	0,980	0,528	0,136
100	1,0	0,923	1,057	0,281
100	2,0	0,736	2,124	0,565
144	0,5	0,981	0,532	0,140
144	1,0	0,926	1,058	0,279
144	2,0	0,740	2,132	0,578

Berdasarkan tabel tersebut, terlihat bahwa peningkatan ukuran sampel N_{LOC} dari 64 ke 144 memberikan peningkatan kecil pada R^2 dan peningkatan RMSE prediksi, tetapi dampaknya lebih signifikan pada rata-rata RMSE koefisien yang menunjukkan estimasi koefisien yang lebih akurat. Sebaliknya, peningkatan tingkat *noise* σ dari 0,5 ke 2,0 menyebabkan penurunan tajam pada R^2 dan peningkatan RMSE prediksi serta rata-rata RMSE koefisien, menandakan sensitivitas metode terhadap kontaminasi *noise*. Visualisasi *heatmap* dalam Gambar 4.2 memperjelas tren ini, dengan area berwarna lebih gelap menunjukkan kinerja yang lebih buruk pada kombinasi ukuran sampel kecil dan tingkat *noise* tinggi.

Analisis sensitivitas menunjukkan bahwa GA-GWR dengan *backbone* GAT mempertahankan kinerja prediksi yang sangat baik pada berbagai ukuran sampel,

Gambar 4.5: Analisis Sensitivitas GA-GWR terhadap N dan σ 

Gambar 4.2 Heatmap analisis sensitivitas GA-GWR.

dengan peningkatan ukuran sampel memberikan manfaat tambahan pada akurasi estimasi koefisien. Namun, metode ini menunjukkan sensitivitas yang signifikan terhadap tingkat *noise*, dengan penurunan kinerja yang substansial pada tingkat *noise* tinggi. Temuan ini menyoroti pentingnya pengelolaan *noise* dalam aplikasi praktis GA-GWR untuk memastikan hasil yang andal.

4.1.3 Analisis Diagnostik Residual

Analisis diagnostik residual merupakan komponen krusial dalam validasi asumsi model regresi dan identifikasi potensi kesalahan spesifikasi. Evaluasi difokuskan pada GA-GWR dengan *backbone* GAT yang menunjukkan kinerja terbaik dalam studi simulasi *baseline*. Analisis mencakup evaluasi terhadap distribusi probabilitas residual, struktur variansi, dan dependensi spasial residual.

Normalitas residual merupakan asumsi fundamental untuk validitas inferensi parametrik termasuk konstruksi interval kepercayaan dan uji hipotesis. Evaluasi dilakukan menggunakan tiga metode komplementer dengan hipotesis berupa

H_0 : residual berdistribusi normal, lawan

H_1 : residual tidak berdistribusi normal,

dengan statistik uji berupa Shapiro-Wilk dengan statistik W dan Kolmogorov-Smirnov dengan statistik D .

Analisis menghasilkan tabel hasil uji normalitas sebagaimana ditampilkan dalam Tabel 4.7. Uji menunjukkan bahwa tidak terdapat cukup bukti untuk me-

nolak hipotesis nol, mengindikasikan bahwa residual GA-GWR sangat konsisten dengan distribusi normal. Visualisasi Q-Q plot dalam Gambar 4.3 menunjukkan bahwa kuantil-kuantil empiris residual terletak sangat dekat dengan garis diagonal, dengan deviasi kecil hanya pada ekor ekstrem yang tidak substansial. Histogram residual menunjukkan distribusi yang hampir simetris dengan puncak di sekitar nol.

Tabel 4.7 Hasil Uji Normalitas Residual GA-GWR

Metode Uji	Statistik	Nilai- <i>p</i>	Keputusan
Shapiro-Wilk	$W = 0,9981$	0,6341	Gagal tolak H_0
Kolmogorov-Smirnov	$D = 0,0195$	0,9427	Gagal tolak H_0

Residual GA-GWR secara keseluruhan sangat konsisten dengan asumsi normalitas. Implikasi praktis adalah bahwa prosedur inferensi parametrik dapat diandalkan untuk keperluan konstruksi interval kepercayaan dan uji hipotesis.

Heteroskedastisitas, yaitu variansi kesalahan yang tidak konstan di seluruh domain observasi, dapat menyebabkan estimator tidak efisien dan *standard error* bias. Uji Breusch-Pagan digunakan untuk menguji apakah variansi residual bergantung secara sistematis pada prediktor dengan hipotesis berikut.

$$H_0 : \sigma_{\varepsilon,i}^2 = \sigma_{\varepsilon,j}^2, \forall i \neq j, \text{ lawan}$$

$$H_1 : \exists i \neq j \text{ sehingga } \sigma_{\varepsilon,i}^2 \neq \sigma_{\varepsilon,j}^2,$$

dengan statistik uji berupa $BP = n \cdot R_{\text{auxiliary}}^2$ yang mengikuti distribusi χ^2 dengan derajat kebebasan sebesar jumlah prediktor.

Analisis menghasilkan statistik Breusch-Pagan $BP = 1,9948$ dengan nilai- $p = 0,5735$. Nilai- p yang jauh lebih besar dari 0,05 mengindikasikan gagal menolak hipotesis nol. Nilai- R^2 dari regresi *auxiliary* sebesar 0,0028 menunjukkan bahwa proporsi variansi yang dijelaskan oleh prediktor terhadap kuadrat residual sangat kecil. *Scatter plot* residual terhadap *fitted values* dalam Gambar 4.3 tidak menunjukkan pola sistematis yang jelas.

Uji Moran's I digunakan untuk mendeteksi keberadaan kluster atau dispersal spasial dalam residual sebagai perhitungan autokorelasi spasial dari residual.

Matriks bobot spasial dikonstruksi berdasarkan *k-nearest neighbors* dengan $k = 5$, memastikan setiap lokasi memiliki tepat 5 tetangga terdekat. Statistik Moran's I dihitung sebagai

$$I = \frac{n}{\sum_i \sum_j w_{ij}} \cdot \frac{\sum_i \sum_j w_{ij} e_i e_j}{\sum_i e_i^2}, \quad (4.1.17)$$

dengan $e_i = y_i - \hat{y}_i$ adalah residual observasi ke- i dan w_{ij} adalah elemen matriks bobot spasial yang dinormalisasi baris. Uji dilakukan dengan hipotesis berikut.

$H_0 : I = 0$ (tidak ada autokorelasi spasial), lawan

$H_1 : I \neq 0$ (ada autokorelasi spasial),


dengan statistik uji berupa nilai Z yang dihitung berdasarkan nilai I , ekspektasi di bawah H_0 , dan varian.

Analisis menghasilkan Moran's $I = 0,2200$ dengan nilai $Z = 2,103$ dan nilai- $p = 0,0354$. Nilai- p kurang dari 0,05 mengindikasikan adanya cukup bukti untuk menolak hipotesis nol pada tingkat signifikansi $\alpha = 0,05$. *Heatmap* spasial residual dalam Gambar 4.3 menunjukkan bahwa residual positif dan negatif tidak terdistribusi secara acak sempurna, dengan beberapa pola kluster lokal. Terdapat autokorelasi spasial positif yang signifikan dalam residual. Namun, hal ini tidak menunjukkan kegagalan model secara keseluruhan, melainkan mengindikasikan adanya struktur spasial lokal yang belum ditangkap sepenuhnya oleh metode semi-parametrik. Interpretasi ini konsisten dengan model GWR dan GA-GWR yang dirancang untuk menangkap heterogenitas spasial pada skala besar, tidak pada setiap pola lokal mikro. Sesuai dengan batasan masalah yang dibahas pada Bab I, metode yang dikembangkan belum dirancang untuk menangkap autokorelasi spasial residual secara menyeluruh.

4.1.4 Validasi Inferensi Statistik

Validasi inferensi statistik dilakukan melalui evaluasi *coverage probability* interval prediksi. Interval prediksi dihitung berbasis *residual training* dengan rumus

Analisis Diagnostik Residual GA-GWR




Gambar 4.3 Analisis diagnostik residual GA-GWR (GraphSAGE backbone): (kiri atas) histogram residual standarisasi dengan overlay kurva normal, (kanan atas) Q-Q plot, (kiri bawah) residual vs fitted values, (tengah bawah) scale-location plot, (bawah kiri) residual autocorrelation, (bawah kanan) peta sebaran spasial residual.

$PI_{\alpha} = \hat{y} \pm z_{\alpha/2} \cdot \hat{\sigma}_{\text{residual}}$, dengan $z_{\alpha/2}$ adalah kuantil distribusi normal standar. Hal ini sah karena residual sudah dikonfirmasi berdistribusi normal berdasarkan hasil uji normalitas sebelumnya. Hasil evaluasi *coverage probability* untuk berbagai tingkat kepercayaan disajikan dalam Tabel 4.8 dan divisualisasikan dalam Gambar 4.4.

Tabel 4.8 Coverage Probability GA-GWR pada Berbagai Tingkat Kepercayaan


Tingkat Kepercayaan	Coverage Aktual	Deviasi
50%	44,2%	−5,8%
80%	72,6%	−7,4%
90%	82,5%	−7,5%
95%	89,6%	−5,4%
99%	97,5%	−2,5%



Gambar 4.4 Evaluasi coverage probability GA-GWR.

Berdasarkan tabel dan grafik tersebut, terlihat bahwa *coverage probability* aktual GA-GWR sedikit di bawah tingkat kepercayaan yang diharapkan pada semua level. Deviasi negatif berkisar antara −1,6% hingga −6,5%, menunjukkan bahwa interval prediksi cenderung sedikit terlalu sempit. Namun, deviasi ini relatif kecil, menandakan bahwa metode inferensi statistik berbasis residual cukup andal. Implikasi praktisnya adalah bahwa interval prediksi yang dihasilkan dapat digunakan dengan tingkat kepercayaan yang wajar, meskipun penyesuaian kecil mungkin diperlukan untuk aplikasi yang sangat kritis.

Selanjutnya, konvergensi pelatihan GA-GWR dievaluasi melalui kurva kerugian tiap *epoch* untuk setiap *fold* dalam 3-fold temporal cross-fitting, sebagaimana ditampilkan dalam Gambar 4.5.



Gambar 4.5 Kurva konvergensi pelatihan GA-GWR, kerugian tiap *epoch* untuk setiap *fold* dalam 3-fold temporal cross-fitting.

Berdasarkan grafik tersebut, terlihat bahwa kerugian memiliki tren penurunan setiap bertambahnya *epoch*, menunjukkan proses pelatihan yang baik. Meskipun semikian, variansi kerugian antar-*epoch* menunjukkan fluktuasi yang cukup besar, menandakan potensi ketidakstabilan dalam proses optimasi. Penggunaan mekanisme *early stopping* membantu mencegah *overfitting* dengan menghentikan pelatihan ketika kerugian pada data validasi tidak membaik selama 30 *epoch* berturut-turut. Secara keseluruhan, kurva konvergensi menunjukkan bahwa GA-GWR dapat dilatih secara efektif dengan konfigurasi *hyperparameter* yang dipilih.

4.1.5 Analisis Bias Estimator Cross-Fitted

Validasi properti teoritis estimator cross-fitted $\hat{\beta}_{\text{CF}}(\mathbf{u})$ dilakukan melalui perbandingan dengan koefisien sejati $\beta^*(\mathbf{u})$ yang diketahui pada data simulasi. Bias didefinisikan sebagai

$$\text{Bias}_j(\mathbf{u}_i) = \hat{\beta}_j^{\text{CF}}(\mathbf{u}_i) - \beta_j^*(\mathbf{u}_i), \quad (4.1.18)$$

untuk setiap lokasi i dan variabel prediktor j . Menurut teori asymptotik Bab III, bias estimator cross-fitted harus memiliki orde $\mathcal{O}(h^2) + \mathcal{O}(p/n_{\text{eff}})$ dan dapat diabaikan di bawah kondisi *undersmoothing* $\sqrt{nh^d} \cdot h^2 \rightarrow 0$.

Hasil analisis bias untuk estimator GA-GWR dan GWR klasik disajikan dalam Tabel 4.9.

Analisis bias mengungkapkan tiga temuan krusial. Pertama, GA-GWR menunjukkan bias yang jauh lebih rendah dibandingkan GWR klasik di semua tiga

Tabel 4.9 Analisis Bias Estimator GA-GWR vs GWR - Skenario Baseline ($n = 3600, \sigma = 0,5$)

Koefisien	Model	Mean Bias	Std Bias	RMSE Bias
β_0 (Intercept)	GA-GWR	0,0023	0,0487	0,0487
	GWR - Gaussian	0,0156	0,1232	0,1242
β_1 (Slope 1)	GA-GWR	0,0041	0,0734	0,0735
	GWR - Gaussian	0,0389	0,2156	0,2191
β_2 (Slope 2)	GA-GWR	0,0018	0,0659	0,0659
	GWR - Gaussian	0,0234	0,1856	0,1871

koefisien. Mean bias GA-GWR berada dalam range $[0,0018, 0,0041]$ dengan RMSE bias $\approx 0,048$ hingga $0,074$, sementara GWR menunjukkan mean bias dalam range $[0,0156, 0,0389]$ dengan RMSE bias $\approx 0,124$ hingga $0,219$. Keunggulan GA-GWR mencerminkan kemampuan superior jaringan saraf graf dalam mempelajari struktur kernel adaptif yang lebih sesuai dengan data. Kedua, standar deviasi bias menunjukkan variabilitas spasial yang substansial, terutama untuk GWR yang menunjukkan std bias 2-3 kali lebih besar. Hal ini mencerminkan bahwa kernel Gaussian tetap memiliki keterbatasan dalam menangkap pola spasial yang kompleks pada beberapa lokasi tertentu. Ketiga, distribusi spasial bias (divisualisasikan dalam heatmap pada Gambar 4.6) menunjukkan konsentrasi bias positif dan negatif di lokasi-lokasi tertentu, dengan pola yang lebih random untuk GA-GWR tetapi lebih terstruktur untuk GWR sepanjang diagonal utama grid.

4.1.6 Pengujian Hipotesis dan Kualitas Estimasi Variance

Pengujian Unbiasedness Estimator Beta CF

Validasi properti distribusi estimator dilakukan melalui hipotesis testing berdasarkan t-statistik. Untuk setiap lokasi i dan koefisien j , dihitung:

$$t_j(\mathbf{u}_i) = \frac{\hat{\beta}_j^{\text{CF}}(\mathbf{u}_i) - \beta_j^*(\mathbf{u}_i)}{\widehat{\text{SE}}_j(\mathbf{u}_i)}, \quad (4.1.19)$$



Gambar 4.6 Distribusi spasial bias koefisien: (atas) GA-GWR dengan backbone GAT, (bawah) GWR kernel Gaussian. Warna merah menunjukkan bias positif, biru menunjukkan bias negatif, intensitas warna menunjukkan magnitude bias.

dengan $\widehat{SE}_j(\mathbf{u}_i)$ adalah sandwich-based standard error lokal. Berdasarkan teori (Bab III), under asymptotic distribusi:

$$t_j(\mathbf{u}_i) \approx \mathcal{N}(0, 1) \quad \text{under undersmoothing condition.} \quad (4.1.20)$$

Hipotesis null menyatakan $H_0 : \widehat{\beta}_j^{\text{CF}}(\mathbf{u}_i) = \beta_j^*(\mathbf{u}_i)$, dan untuk 95% confidence, sekitar 95% dari observasi seharusnya memiliki $|t_j(\mathbf{u}_i)| < 1,96$.

Hasil pengujian coverage probability disajikan dalam Tabel 4.10.

Tabel 4.10 Coverage Probability Hypothesis Test: $\widehat{\beta}^{\text{CF}}(\mathbf{u}) = \beta^*(\mathbf{u})$

Koefisien	GA-GWR Coverage	GWR Coverage	Target (95%)
β_0 (Intercept)	0,9634	0,8824	0,9500
β_1 (Slope 1)	0,9521	0,8456	0,9500
β_2 (Slope 2)	0,9412	0,7923	0,9500

Coverage probability GA-GWR berkisar antara 0,9412 hingga 0,9634, sangat dekat dengan target 0,95, mengindikasikan bahwa inferensi berbasis sandwich SE sangat akurat. Sebaliknya, GWR menunjukkan coverage yang lebih rendah (0,7923 hingga 0,8824), mengindikasikan bahwa standard error berbasis plug-in kurang andal. Hasil ini mengkonfirmasi keunggulan sandwich estimator dalam menghasilkan inferensi yang valid.

Pengujian Estimasi Variance

Kualitas estimasi variance diuji melalui hipotesis $H_0 : \widehat{\sigma}^2 = \sigma_{\text{true}}^2 = 0,25$.

Tabel 4.11 menyajikan statistik deskriptif dari estimasi variance per lokasi.

Tabel 4.11 Analisis Estimasi Variance: $\widehat{\sigma}^2$ vs $\sigma_{\text{true}}^2 = 0,25$

Statistik	GA-GWR	GWR	Target
Mean $\widehat{\sigma}^2$	0,2498	0,2651	0,2500
Bias	-0,0002	0,0151	0,0000
Relative Bias (%)	-0,08%	6,04%	0,00%
Variance($\widehat{\sigma}^2$)	0,0034	0,0087	—
MSE($\widehat{\sigma}^2$)	0,0034	0,0090	—

Analisis mengungkapkan bahwa GA-GWR menghasilkan estimasi variance yang hampir unbiased dengan relative bias $-0,08\%$, sementara GWR menunjukkan bias yang lebih signifikan sebesar $6,04\%$. Variance dari estimator variance GA-GWR jauh lebih kecil ($0,0034$ vs $0,0087$), mengindikasikan estimasi yang lebih stabil. MSE yang jauh lebih kecil untuk GA-GWR ($0,0034$ vs $0,0090$) mengkonfirmasi superior performance dalam hal akurasi dan presisi estimasi variance.

Implikasi teori-praktis: Estimator cross-fitted GA-GWR menghasilkan properti inferensi yang sangat valid, dengan coverage probability mendekati level nominal dan estimasi variance yang unbiased dan efisien. Hal ini mengkonfirmasi bahwa asumsi teoritis pada Bab III tentang distribusi asymptotik terpenuhi dalam praktik.

4.2 Studi Kasus pada Data Kredit UMKM dan Harga Pangan Indonesia

Studi kasus ini menerapkan metode GA-GWR yang telah divalidasi melalui simulasi pada data nyata untuk menilai kinerjanya dalam konteks praktis dengan fokus pada dinamika kredit mikro, kecil, dan menengah (UMKM) serta hubungannya dengan fluktuasi harga pangan di Indonesia. Berbeda dengan studi simulasi ketika koefisien spasial sejati diketahui, aplikasi pada data riil memberikan evaluasi yang lebih realistis mengenai kegunaan metode dalam mendukung analisis kebijakan dan pengambilan keputusan berbasis bukti empiris di sektor keuangan inklusif.

4.2.1 Deskripsi Data dan Variabel

Data yang digunakan dalam studi kasus ini menggabungkan informasi dari sumber resmi pemerintah Indonesia, yaitu Bank Indonesia (BI) tentang Statistik Ekonomi dan Keuangan Daerah (SEKDA) dan Pusat Informasi Harga Pangan Strategis Nasional (PIHPS). Data panel spasial mencakup 34 provinsi di Indonesia selama periode Januari 2024 hingga Agustus 2025, menghasilkan $T = 20$ periode bulanan. Total observasi yang tersedia adalah $n = 680$ dengan struktur panel seimbang ($N_{\text{LOC}} = 34 \times T = 20$).

Variabel respons adalah logaritma natural dari volume Kredit UMKM (da-

lam miliar Rupiah) dari data SEKDA. Pemilihan variabel ini didasarkan pada relevansinya sebagai indikator aktivitas sektor keuangan mikro dan tingkat akses keuangan inklusi di tingkat regional, yang merupakan isu strategis bagi pembangunan ekonomi lokal dan pengentasan kemiskinan di Indonesia.

Variabel prediktor terdiri dari lima jenis harga pangan utama dari data BI yang diukur dalam satuan Rupiah per kilogram:

1. Harga Beras,
2. Harga Cabai Rawit,
3. Harga Bawang Merah,
4. Harga Daging Ayam, dan
5. Harga Gula Pasir.

Kelima komoditas ini dipilih karena merepresentasikan komponen utama dalam Indeks Harga Konsumen (IHK) dan secara langsung mempengaruhi daya beli masyarakat, khususnya segmen UMKM yang sensitif terhadap fluktuasi biaya operasional dan permintaan konsumen. Secara teoritis, fluktuasi harga pangan dapat mempengaruhi aksesibilitas kredit UMKM melalui mekanisme:

1. perubahan profitabilitas usaha kecil yang bergantung pada input pangan,
2. perubahan risiko kredit yang dirasakan oleh lembaga keuangan, dan
3. perubahan pola konsumsi yang mempengaruhi permintaan output UMKM pangan dan non-pangan.

Semua variabel respons dan prediktor ditransformasi ke dalam logaritma natural sebelum pemodelan untuk mengatasi skewness distribusi data nominal dan memfasilitasi interpretasi elastisitas hubungan antar variabel. Transformasi logaritmik juga membantu stabilisasi varians dan membuat model lebih robust terhadap outlier ekstrem dalam data finansial dan harga komoditas.

Statistik deskriptif variabel-variabel yang digunakan dalam analisis disajikan dalam Tabel 4.12. Variabel respons Log(Kredit UMKM) menunjukkan rentang dari 8,14 hingga 9,86 (dalam skala logaritma natural), dengan rata-rata 8,98 dan standar deviasi 0,42, mengindikasikan variabilitas substansial dalam volume kredit UMKM antar provinsi dan waktu. Variabel prediktor juga menunjukkan variabilitas yang tinggi, khususnya Harga Cabai Rawit dan Harga Bawang Merah yang merupakan komoditas musiman dengan fluktuasi harga yang lebih tajam, menjadikan

Tabel 4.12 Statistik Deskriptif Variabel Studi Kasus Data BI dan SEKDA

Variabel	Rata-rata	Std	Min	Maks	Median
Log(Kredit UMKM)	8,98	0,42	8,14	9,86	8,95
Log(Harga Beras)	10,57	0,15	10,26	10,95	10,59
Log(Harga Cabai Rawit)	11,22	0,31	10,42	12,15	11,23
Log(Harga Bawang Merah)	11,10	0,37	10,35	12,11	11,14
Log(Harga Daging Ayam)	10,61	0,10	10,38	10,82	10,62
Log(Harga Gula Pasir)	10,68	0,08	10,48	10,89	10,69

Semua variabel dalam skala logaritma natural menunjukkan distribusi yang lebih simetris dibandingkan skala nominal asli. Log(Kredit UMKM) sebagai variabel respons menunjukkan variabilitas moderat ($CV = 4,7\%$), sementara harga pangan menunjukkan dinamika yang beragam: harga beras dan daging ayam relatif stabil dengan CV kurang dari 2%, sedangkan cabai rawit dan bawang merah menunjukkan volatilitas tinggi dengan CV sekitar 3%, mencerminkan musim itas produksi dan permintaan pasar untuk komoditas hortikultura. Struktur variabilitas ini mengindikasikan kompleksitas heterogen dalam hubungan spasial yang mungkin sulit ditangkap oleh model parametrik dengan bobot kernel tetap.

4.2.2 Analisis Multikolinearitas

Sebelum pemodelan, dilakukan analisis diagnostik multikolinearitas untuk memastikan stabilitas estimasi koefisien dan reliabilitas inferensi statistik. Multikolinearitas, yaitu kehadiran korelasi linear tinggi antar variabel prediktor, dapat menyebabkan varians estimator lokal membengkak, terutama pada model GWR yang mengandalkan subset data lokal untuk estimasi.

Kondisi angka (*condition number*) dari matriks \mathbf{X} didefinisikan sebagai rasio nilai eigen terbesar terhadap nilai eigen terkecil dari matriks $\mathbf{X}^\top \mathbf{X}$, yaitu

$$\kappa(\mathbf{X}^\top \mathbf{X}) = \frac{\lambda_{\max}}{\lambda_{\min}}, \quad (4.2.1)$$

yang mengukur tingkat *ill-conditioning* dari masalah estimasi. Nilai $\text{CN} = 1$ menunjukkan ortogonalitas sempurna, CN antara 1 hingga 10 mengindikasikan multikolinearitas rendah, CN antara 10 hingga 30 mengindikasikan multikolinearitas moderat, dan $\text{CN} > 30$ mengindikasikan multikolinearitas severe. Hasil perhitungan kondisi angka global untuk dataset BI-SEKDA menunjukkan $\text{CN} = 15,42$, yang masuk dalam kategori multikolinearitas moderat. Nilai ini mengindikasikan bahwa meskipun terdapat korelasi antar harga pangan, tidak sampai pada level yang mengancam stabilitas estimasi OLS global. Namun, dalam konteks GWR lokal dengan jumlah observasi lebih kecil per lokasi-waktu, kondisi angka lokal dapat meningkat signifikan.

Variance Inflation Factor (VIF) untuk variabel j didefinisikan sebagai

$$\text{VIF}_j = \frac{1}{1 - R_j^2}, \quad (4.2.2)$$

dengan R_j^2 adalah koefisien determinasi dari regresi variabel j terhadap seluruh variabel prediktor lainnya. VIF mengukur inflasi varians estimator akibat kolinearitas spesifik variabel tersebut. Secara praktis, $\text{VIF} < 5$ dianggap aman, VIF antara 5 hingga 10 menunjukkan multikolinearitas moderat yang memerlukan perhatian, dan $\text{VIF} > 10$ mengindikasikan masalah serius. Hasil perhitungan VIF untuk setiap prediktor disajikan dalam Tabel 4.13. Semua variabel menunjukkan $\text{VIF} < 5$, dengan nilai tertinggi pada Log(Harga Bawang Merah) sebesar 4,78 dan terendah pada Log(Harga Daging Ayam) sebesar 2,13. Hal ini mengindikasikan bahwa multikolinearitas *pairwise* antar prediktor tidak mengancam stabilitas estimasi. Korelasi tinggi kemungkinan besar bersifat temporal (harga bergerak bersama sepanjang waktu) daripada *cross-sectional* (antar lokasi), dan pemberlakuan transformasi logaritmik membantu meattenuasi magnitude korelasi nominal yang ekstrem.

Tabel 4.13 Variance Inflation Factor (VIF) dan Korelasi Variabel Prediktor

Variabel	VIF	Rata-rata Korelasi
Log(Harga Beras)	3,45	0,62
Log(Harga Cabai Rawit)	4,12	0,68
Log(Harga Bawang Merah)	4,78	0,71
Log(Harga Daging Ayam)	2,13	0,52
Log(Harga Gula Pasir)	3,89	0,61

Analisis kondisi angka lokal mempertimbangkan *ill-conditioning* pada setiap kombinasi lokasi-waktu (\mathbf{u}_i, t), bukan hanya distribusi global. Untuk setiap lokasi i dalam sampel, kondisi angka lokal dihitung dari matriks desain lokal yang diperoleh melalui pembobotan observasi berdasarkan jarak spasial dari lokasi target. Hasil ringkasan kondisi angka lokal di seluruh 680 observasi ($34 \text{ lokasi} \times 20 \text{ periode}$) disajikan dalam Tabel 4.14. Kondisi angka lokal menunjukkan rata-rata 17,23 dengan standar deviasi 8,45, rentang dari 9,81 hingga 52,34, dan median 15,67. Sebagian besar lokasi (88,2%) memiliki CN lokal < 30 , berada dalam kategori multikolinearitas moderat. Namun, sebanyak 11,8% observasi (80 lokasi-waktu) menunjukkan CN lokal ≥ 30 , yang mengindikasikan kondisi *ill-conditioned* dan potensi estimasi lokal yang tidak stabil.

Tabel 4.14 Ringkasan Kondisi Angka Lokal GWR

Statistik	Nilai	Statistik	Nilai
Rata-rata	17,23	Median	15,67
Std Deviasi	8,45	Modus	12,34
Minimum	9,81	Maksimum	52,34
Q1 (25%)	11,56	Q3 (75%)	21,89
% Observasi CN < 30		88,2%	
% Observasi CN ≥ 30		11,8%	

Lokasi dengan kondisi angka lokal tertinggi (CN > 40) tersebar di beberapa provinsi tertentu, umumnya pada periode awal sampel (Januari–Februari 2024) ketika data sudah tersedia di semua lokasi tetapi matriks desain lokal masih berisi observasi waktu yang terbatas. Implikasi praktis adalah bahwa *standard error* estimasi koefisien lokal pada lokasi-waktu tersebut harus diinterpretasikan dengan

hati-hati, dan interval kepercayaan mungkin perlu diperlebar atau alternatif estimasi *robust* dengan penalti *ridge* lokal harus diterapkan.

4.2.3 Pemodelan dan Perbandingan Kinerja Prediksi

Analisis pemodelan dilakukan menggunakan skema *temporal train-test split* yang konsisten dengan studi simulasi. Dari 20 bulan observasi, 80% periode awal (Januari 2024–Oktober 2024, 10 bulan) dialokasikan untuk himpunan data latih dengan 340 observasi, sedangkan 20% periode akhir (November 2024–Agustus 2025, 10 bulan) dialokasikan untuk himpunan data uji dengan 340 observasi. Skema ini mensimulasikan skenario peramalan di mana model dilatih pada data historis untuk memprediksi volume kredit UMKM pada bulan-bulan mendatang, yang sesuai dengan praktik forecasting dalam perencanaan kredit Bank Indonesia dan SEKDA.

Tiga kategori model dievaluasi untuk perbandingan kinerja prediksi. (1) Model OLS global diestimasi sebagai *baseline* tanpa mempertimbangkan struktur spasial, menggunakan metode kuadrat terkecil standar dengan seluruh himpunan data latih 340 observasi. (2) Model GWR klasik dengan dua kernel: Gaussian dan Exponential, dengan bandwidth Silverman ($h = 2,36$) yang dihitung dari distribusi spasial koordinat latih berdasarkan longitude dan latitude pusat provinsi, menyediakan peningkatan lokal dengan *kernel* tetap yang bersifat universal. (3) Model GA-GWR dievaluasi dengan *backbone* yang sama seperti studi simulasi (GAT, GCN, GraphSAGE), menggunakan konfigurasi arsitektur dan *hyperparameter* yang identik dengan studi simulasi untuk memastikan konsistensi metodologis. Spesifikasi konfigurasi model GA-GWR disajikan dalam Tabel 4.15.

Hasil perbandingan kinerja prediksi pada *test set* disajikan dalam Tabel 4.16. Model OLS global menghasilkan $R^2 = 0,2622$, RMSE = 0,8583, dan MAE = 0,6450. GWR dengan kernel Gaussian menunjukkan peningkatan substansial, dengan R^2 meningkat menjadi 0,6679 (+154,78% perbaikan terhadap OLS), RMSE menurun ke 0,5758, dan MAE ke 0,3482. Perbaikan lebih lanjut dicapai melalui GWR dengan kernel Exponential, yang menghasilkan $R^2 = 0,7484$ (+185,46% perbaikan terhadap OLS), dengan +12,04% peningkatan tambahan dibandingkan

Tabel 4.15 Spesifikasi Konfigurasi GA-GWR pada Data BI-SEKDA

Parameter	Nilai
Jumlah Lapisan GNN	3
Dimensi Fitur Tersembunyi	64, 32, 16 unit
Fungsi Aktivasi	ReLU
Optimizer	Adam
Learning Rate	0,001
Tingkat Dropout	0,25
Jumlah Epoch	Maks. 500 dengan <i>early stopping</i> (<i>patience</i> = 30)
Skema Cross-Fitting	<i>3-fold temporal</i>

kernel Gaussian. Kernel Exponential dipilih sebagai model GWR terbaik karena akurasi superior dan stabilitas komputasi yang lebih baik. Sebaliknya, model GA-GWR menunjukkan kinerja yang lebih rendah dibandingkan GWR klasik pada dataset ini, dengan hasil terbaik dicapai oleh backbone GraphSAGE dengan R^2 yang lebih rendah dari keduanya, mengindikasikan bahwa pola spasial kredit UMKM di Indonesia lebih sesuai dengan pemodelan kernel lokal tetap daripada bobot spasial adaptif berbasis graph neural network.

Tabel 4.16 Perbandingan Performa Prediksi Model pada Data BI-SEKDA

Model	R^2	RMSE	MAE
OLS	0,2622	0,8583	0,6450
GWR (Gaussian)	0,6679	0,5758	0,3482
GWR (Exponential)	0,7484	0,5013	0,3741
GA-GWR (GraphSAGE)	0,6200	0,6124	0,4125

Hasil ini menunjukkan pentingnya eksplorasi empiris terhadap struktur spasial data sebelum memilih metode pemodelan. Meskipun GA-GWR menunjukkan keunggulan substansial pada data simulasi dengan pola spasial kompleks, pada aplikasi kredit UMKM dengan struktur spasial yang lebih smooth dan gradual, pendekatan kernel konvensional dengan optimasi bandwidth Silverman memberikan hasil yang lebih robust. Implikasi praktis adalah bahwa untuk peramalan kredit regional, model GWR dengan kernel Exponential menghasilkan rekomendasi terbaik, memberikan peningkatan akurasi signifikan dibandingkan model global OLS sambil tetap mempertahankan interpretabilitas koefisien spasial lokal.

Visualisasi perbandingan performa model ditampilkan dalam Gambar ?? yang menunjukkan metrik R^2 , RMSE, dan MAE untuk keempat model. GWR dengan kernel Exponential mencapai kinerja terbaik dalam metrik R^2 , menghasilkan peningkatan substansial dibandingkan baseline OLS dan kernel Gaussian.

4.2.4 Estimasi Koefisien Spasial GWR

Meskipun analisis komparatif menunjukkan keunggulan kinerja prediktif GWR dengan kernel Exponential, estimasi koefisien spasial lokal tetap memberikan informasi penting mengenai variasi heterogen dalam hubungan antara harga pangan dan aksesibilitas kredit UMKM di seluruh 34 provinsi Indonesia. Koefisien lokal yang divariasikan secara spasial dari model GWR terbaik (kernel Exponential) untuk keenam parameter—yakni intercept dan lima elastisitas harga masing-masing komoditas pangan—dapat dipetakan untuk mengidentifikasi pola-pola geografis heterogenitas spasial. Ringkasan statistik koefisien spasial model GWR Exponential disajikan dalam Tabel 4.17. Koefisien intercept menunjukkan rata-rata 6,42 dengan standar deviasi 1,84, mencerminkan heterogenitas spasial yang moderat dalam level dasar kredit UMKM antar provinsi. Kelima elastisitas harga pangan menunjukkan pola efek yang beragam dalam tanda dan magnitude, mengindikasikan kompleksitas dalam mekanisme transmisi harga terhadap aksesibilitas keuangan mikro. Secara khusus, elastisitas harga beras dan daging ayam menunjukkan nilai rata-rata negatif yang kuat sekitar $-0,15$ hingga $-0,18$, konsisten dengan transmisi ekonomi bahwa peningkatan harga komoditas staple ini mengurangi daya beli masyarakat dan kapasitas pembayaran kredit UMKM. Sebaliknya, elastisitas untuk komoditas hortikultura (cabai rawit dan bawang merah) menampilkan variabilitas spasial yang lebih tinggi dengan simpangan baku 0,41 dan 0,37, mencerminkan sensitivitas yang sangat tergantung pada struktur ekonomi lokal dan tingkat keterlibatan UMKM dalam *value chain* pertanian.

4.2.5 Uji Signifikansi Koefisien Lokal

Signifikansi statistik koefisien lokal GWR dievaluasi menggunakan statistik- t lokal dengan hipotesis nol $H_0 : \beta_j(\mathbf{u}_i) = 0$. Untuk setiap kombinasi lokasi-waktu

Tabel 4.17 Statistik Koefisien Spasial GWR (Kernel Exponential) pada Data BI-SEKDA

Koefisien	Rata-rata	Std	Min	Maks
Intercept	6,42	1,84	2,15	9,87
Log(Harga Beras)	-0,157	0,234	-0,812	0,405
Log(Harga Cabai Rawit)	-0,086	0,412	-1,234	0,756
Log(Harga Bawang Merah)	-0,128	0,367	-1,089	0,621
Log(Harga Daging Ayam)	-0,182	0,198	-0,687	0,312
Log(Harga Gula Pasir)	-0,095	0,287	-0,934	0,524

dan variabel prediktor, nilai- t lokal dihitung berdasarkan rasio estimasi koefisien terhadap standar error lokal yang diturunkan dari matriks informasi Fisher lokal. Uji dilakukan pada tingkat signifikansi $\alpha = 0,05$ (dua arah), menghasilkan nilai kritis $|t| \approx 1,96$ untuk sampel besar.

Ringkasan hasil uji signifikansi disajikan dalam Tabel 4.18. Intercept menunjukkan signifikansi tertinggi dengan 98,5% observasi signifikan, mengkonfirmasi adanya efek baseline yang kuat dan konsisten di seluruh provinsi. Di antara prediktor harga pangan, Log(Harga Beras) menunjukkan persentase signifikansi tertinggi (62,1% lokasi-waktu signifikan) dengan efek dominan negatif, mencerminkan pentingnya harga beras sebagai determinan utama daya beli dan aksesibilitas kredit. Log(Harga Daging Ayam) menunjukkan signifikansi moderate (47,4%) dengan efek negatif dominan. Log(Harga Cabai Rawit) dan Log(Harga Bawang Merah) menunjukkan signifikansi yang lebih rendah (32,6% dan 38,2% masing-masing), kemungkinan karena efek heterogen yang tergantung pada konteks lokal. Log(Harga Gula Pasir) menunjukkan signifikansi paling rendah (25,9%), mengindikasikan peran yang lebih terbatas sebagai faktor penentu aksesibilitas kredit UMKM.

Peta signifikansi koefisien spasial dapat ditampilkan untuk mengidentifikasi kawasan geografis dengan hubungan yang kuat dan signifikan antara harga pangan spesifik dan kredit UMKM. Identifikasi ini bermanfaat untuk targeting kebijakan dan intervensi yang disesuaikan dengan karakteristik struktur ekonomi lokal.

Tabel 4.18 Ringkasan Signifikansi Koefisien Lokal GWR ($\alpha = 0,05$)

Variabel	Mean $ t $	% Signifikan	Positif	Negatif
Intercept	12,34	98,5%	672	8
Log(Harga Beras)	3,67	62,1%	52	374
Log(Harga Cabai Rawit)	2,12	32,6%	61	161
Log(Harga Bawang Merah)	2,45	38,2%	54	206
Log(Harga Daging Ayam)	3,21	47,4%	41	281
Log(Harga Gula Pasir)	1,78	25,9%	68	108

4.2.6 Uji Diagnostik Residual dan Validasi Model

Validasi model GWR terbaik dilakukan melalui serangkaian uji diagnostik terhadap residual prediksi pada *test set*. Hasil uji diagnostik disajikan dalam Tabel 4.19.

Tabel 4.19 Hasil Uji Diagnostik Residual GWR pada Data BI-SEKDA

Uji	Statistik	p-value	Kesimpulan
Shapiro-Wilk (Normalitas)	0,942	0,068	Normal*
Breusch-Pagan (Heteroskedastisitas)	12,56	0,131	Homoskedastis*
Ljung-Box (Autokorelasi)	8,34	0,215	Independen*

*Tidak menolak hipotesis nol pada tingkat signifikansi 5%

Uji Shapiro-Wilk untuk normalitas menghasilkan p -value = 0,068, tidak menolak hipotesis nol bahwa residual berdistribusi normal pada tingkat signifikansi 5%. Uji Breusch-Pagan untuk heteroskedastisitas menghasilkan p -value = 0,131, mengindikasikan varians residual yang relatif homogen di seluruh range nilai fitted. Uji Ljung-Box untuk autokorelasi menghasilkan p -value = 0,215, menunjukkan tidak adanya autokorelasi signifikan dalam residual. Serangkaian temuan ini mengkonfirmasi validitas asumsi klasik pemodelan GWR untuk dataset BI-SEKDA, sehingga inferensi statistik berbasis interval kepercayaan dan uji signifikansi koefisien dapat dilakukan dengan kepercayaan yang wajar.

Visualisasi diagnostik residual disajikan dalam Gambar ?? yang mencakup histogram residual dengan overlay distribusi normal, Q-Q plot, plot residual vs fitted values, scale-location plot, dan peta sebaran spasial residual. Kombinasi visualisasi ini memfasilitasi inspeksi visual terhadap kualitas spesifikasi model dan

identifikasi outlier potensial atau lokasi-waktu dengan misfit yang substansial.

4.2.7 Pembahasan Hasil dan Implikasi untuk Kebijakan

Hasil studi kasus pada data kredit UMKM dan harga pangan BI-SEKDA mengungkapkan beberapa temuan penting yang memperdalam pemahaman tentang heterogenitas spasial dalam aksesibilitas kredit mikro di Indonesia dan memberikan bukti empiris tentang relevansi pendekatan pemodelan spasial berbasis GWR. Secara ringkas, analisis menunjukkan:

Pertama, perbandingan model mengungkapkan keunggulan substansial pemodelan spasial GWR dibandingkan model global OLS, dengan peningkatan koefisien determinasi dari 0,2622 menjadi 0,7484. Peningkatan 48% dalam proporsi variansi yang dijelaskan mengindikasikan bahwa heterogenitas spasial merupakan dimensi kritis dalam memahami aksesibilitas kredit regional. Temuan ini menegaskan relevansi pendekatan GWR untuk mengkaji dinamika pasar keuangan mikro di tingkat geografis, di mana faktor-faktor struktural lokal seperti komposisi sektor ekonomi, basis pertanian, dan konektivitas pasar memainkan peran sentral dalam menentukan pola kredit regional.

Kedua, perbandingan antar kernel GWR menunjukkan superior performance kernel Exponential dibandingkan kernel Gaussian, dengan peningkatan R^2 sebesar 12%. Pola ini mencerminkan struktur spasial inheren dalam data kredit UMKM yang menunjukkan decay gradual dalam jarak geografis, konsisten dengan mekanisme transmisi harga yang bersifat tersebar secara bertahap. Kernel Exponential dengan bentuk $w(d) = \exp(-d/h)$ lebih efektif dalam menangkap pola spatial smoothing moderat ini dibandingkan kernel Gaussian dengan bentuk $w(d) = \exp(-(d/h)^2)$ yang mengalami penurunan lebih tajam.

Ketiga, analisis koefisien spasial mengungkapkan diferensiasi geografis yang substansial dalam sensitivitas harga pangan terhadap aksesibilitas kredit. Harga beras menunjukkan efek yang paling universal dan signifikan (62,1% observasi spasial-temporal signifikan) dengan elastisitas rata-rata $-0,157$, mencerminkan statusnya sebagai komoditas staple dan driver utama dalam transmisi harga terhadap

aksesibilitas keuangan. Peningkatan harga beras mengurangi daya beli rumah tangga dan, sebagai konsekuensi, menurunkan permintaan terhadap kredit UMKM. Pola efek ini konsisten geografis, mengindikasikan bahwa mekanisme transmisi harga beras bersifat universal di Indonesia. Sebaliknya, komoditas hortikultura seperti cabai rawit dan bawang merah menunjukkan signifikansi yang lebih heterogen (32,6% dan 38,2% masing-masing) dengan variabilitas spasial elastisitas yang tinggi (standar deviasi 0,41 dan 0,37). Heterogenitas ini mencerminkan perbedaan dalam intensitas penggunaan komoditas ini di berbagai konteks ekonomi lokal dan pola konsumsi regional yang berbeda-beda.

Temuan empiris ini memberikan implikasi signifikan untuk desain kebijakan moneter, regulasi perbankan, dan pengembangan UMKM di tingkat regional. Hasil menunjukkan bahwa kebijakan stabilisasi harga pangan, khususnya untuk komoditas staple seperti beras dan daging ayam, memiliki spillover effect material terhadap aksesibilitas kredit UMKM. Intervensi pada sisi penawaran (peningkatan kapasitas produksi, pengurangan distorsi logistik) atau permintaan (program subsidi) dapat berkontribusi pada stabilitas dinamika kredit regional. Kedua, lembaga keuangan dapat meningkatkan efektivitas penetapan syarat dan manajemen risiko kredit dengan mempertimbangkan heterogenitas spasial dalam sensitivitas terhadap guncangan harga. Pada wilayah-wilayah dengan sensitivitas tinggi terhadap komoditas pangan tertentu, penerapan kriteria penilaian risiko yang lebih ketat atau penggunaan indikator harga sebagai sinyal peringatan dini risiko dapat meningkatkan kualitas portfolio. Ketiga, untuk UMKM yang terlibat dalam aktivitas yang sensitif terhadap fluktuasi harga (seperti sektor pengolahan pangan atau retail pangan), pengembangan instrumen manajemen risiko (kontrak berjangka, skema asuransi terhadap risiko harga) dapat meningkatkan stabilitas pendapatan dan kapasitas pembayaran kredit. Keempat, pemetaan spasial elastisitas harga pangan terhadap kredit dapat diintegrasikan ke dalam strategi pengembangan regional yang diferensiasi, dengan prioritas khusus untuk kawasan-kawasan dengan ketergantungan tinggi terhadap komoditas pangan dalam membentuk aksesibilitas keuangan mikro.

4.2.8 Estimasi T-Statistics Lokal dengan Sandwich Estimator

Signifikansi statistik koefisien lokal diperoleh melalui perhitungan t -statistik lokal menggunakan *sandwich estimator* yang robust terhadap heteroskedastisitas spasial. Untuk setiap kombinasi lokasi-waktu (\mathbf{u}_i, t) dan variabel prediktor j , standar error koefisien lokal diturunkan dari matriks sandwich:

$$\widehat{\text{Var}}(\hat{\beta}(\mathbf{u}_i)) = \mathbf{Q}_n^{-1}(\mathbf{u}_i) \mathbf{\Omega}_n(\mathbf{u}_i) \mathbf{Q}_n^{-1}(\mathbf{u}_i), \quad (4.2.3)$$

dengan $\mathbf{Q}_n(\mathbf{u}_i) = \sum_k \mathbf{X}_k^\top \mathbf{W}_k^{(-k)}(\mathbf{u}_i) \mathbf{X}_k$ merupakan matriks informasi lokal dan $\mathbf{\Omega}_n(\mathbf{u}_i) = \hat{\sigma}^2 \sum_k \sum_{i \in \mathcal{I}_k} (w_i^{(-k)})^2 \mathbf{x}_i \mathbf{x}_i^\top$ merupakan matriks sandwich yang memper-timbangkan heteroskedastisitas lokal.

Hasil ringkasan t -statistik lokal disajikan dalam Tabel 4.20. Intercept menunjukkan rata-rata $|t| = 12,45$ dengan 98,8% observasi signifikan pada level $\alpha = 0,05$, mengkonfirmasi efek baseline yang sangat kuat dan konsisten. Harga Beras menunjukkan mean $|t| = 5,23$ dengan 67,4% observasi signifikan, menunjukkan efek yang robust dan widespread. Harga Daging Ayam menunjukkan mean $|t| = 4,12$ dengan 52,6% signifikansi. Komoditas hortikultura (Cabai Rawit dan Bawang Merah) menunjukkan mean $|t|$ yang lebih rendah (2,94 dan 3,17 masing-masing) dengan signifikansi yang lebih heterogen (38,9% dan 45,3%), mencerminkan variabilitas spasial dalam efek harga. Harga Gula Pasir menunjukkan efek paling lemah dengan mean $|t| = 2,31$ dan 29,1% signifikansi, mengindikasikan peran limited sebagai determinan aksesibilitas kredit.

Tabel 4.20 Ringkasan T-Statistics Lokal dengan Sandwich Estimator

Variabel	Mean $ t $	% Signifikan	Min $ t $	Maks $ t $
Intercept	12,45	98,8%	2,34	28,67
Log(Harga Beras)	5,23	67,4%	0,18	18,92
Log(Harga Cabai Rawit)	2,94	38,9%	0,05	12,45
Log(Harga Bawang Merah)	3,17	45,3%	0,08	14,78
Log(Harga Daging Ayam)	4,12	52,6%	0,12	15,23
Log(Harga Gula Pasir)	2,31	29,1%	0,03	9,87

Peta sebaran t -statistik lokal per variabel dapat ditampilkan untuk mengi-

identifikasi kawasan geografis dengan hubungan yang kuat dan secara statistik signifikan antara harga pangan spesifik dan kredit UMKM (Gambar ??). Pemetaan ini memberikan informasi spatial yang valuable untuk targeting kebijakan dan intervensi yang disesuaikan dengan karakteristik hubungan lokal.

4.2.9 Tipologi Spasial melalui Analisis Clustering

Untuk mengidentifikasi pola regional dalam heterogenitas geografis koefisien dan mengkarakterisasi tipologi provinsi, dilakukan analisis clustering menggunakan algoritma k -means pada matriks elastisitas harga yang dinormalisasi. Pemilihan jumlah cluster optimal dilakukan melalui evaluasi silhouette score dan *elbow method*, menghasilkan $k = 3$ sebagai solusi terbaik. Clustering mengungkapkan tiga tipologi regional yang berbeda dalam pola sensitivitas agregat terhadap fluktuasi harga pangan, memungkinkan pemetaan geografis dan pengidentifikasian kawasan-kawasan dengan karakteristik ekonomi yang serupa.

Tabel 4.21 Karakterisasi Cluster Koefisien Elastisitas Harga


Cluster	N Prov	β (Beras)	β (Cabai)	β (Bawang)	β (Daging)	β (Gula)
1: Sensitivitas Tinggi	11	-0,243	-0,156	-0,189	-0,267	-0,142
2: Sensitivitas Moderat	13	-0,152	-0,067	-0,118	-0,168	-0,085
3: Sensitivitas Rendah	10	-0,082	-0,028	-0,052	-0,091	-0,035

Cluster 1 (Sensitivitas Tinggi, 11 provinsi) menunjukkan elastisitas negatif yang terbesar di semua variabel harga pangan, mengindikasikan bahwa aksesibilitas kredit di provinsi-provinsi ini sangat *vulnerable* terhadap guncangan harga. Provinsi dalam cluster ini kemungkinan memiliki struktur ekonomi dengan ketergantungan tinggi pada sektor pertanian atau agroindustri, daya beli masyarakat yang rendah dan sensitif terhadap inflasi pangan, dan keterlibatan UMKM yang tinggi dalam *value chain* pangan. Identifikasi cluster ini menjadi prioritas untuk kebijakan stabilisasi harga dan program pengembangan pertanian lokal yang difokus.

Cluster 2 (Sensitivitas Moderat, 13 provinsi) menunjukkan elastisitas harga pada level intermediate, mencerminkan ekonomi yang lebih terdiversifikasi dengan eksposur moderat terhadap dinamika harga pangan.

Cluster 3 (Sensitivitas Rendah, 10 provinsi) menunjukkan elastisitas harga paling kecil dalam magnitude, mencerminkan provinsi dengan basis ekonomi yang lebih urban dan berbasis layanan, daya beli yang relatif lebih tinggi, dan keterlibatan UMKM yang lebih rendah dalam sektor pangan.

Pemetaan spasial dari ketiga cluster disajikan dalam Gambar 4.7, mengidentifikasi konsentrasi geografis dari tipologi-tipologi yang berbeda dan memfasilitasi desain kebijakan regional yang diferensiasi sesuai karakteristik ekonomi lokal.



Gambar 4.7 Peta clustering elastisitas harga koefisien lokal GWR yang menunjukkan 3 cluster sensitivitas: Tinggi (merah), Moderat (hijau), dan Rendah (biru) di 34 provinsi Indonesia.

4.2.10 Validasi Diagnostik Model GA-GWR dengan Backbone GAT

Sebagai pelengkap analisis empiris terhadap metodologi GA-GWR, dilakukan evaluasi diagnostik komprehensif pada model GA-GWR dengan *Graph Attention Network* (GAT) sebagai *backbone* untuk pembelajaran bobot spasial adaptif pada data uji BI-SEKDA. Meskipun hasil empiris menunjukkan bahwa GWR dengan kernel Exponential menghasilkan performa prediktif superior, diagnostik residual GA-GWR memberikan wawasan penting tentang karakteristik ketidakcocokan model dan implikasi dari asumsi-asumsi yang mendasarinya.

Hasil diagnostik residual model GA-GWR disajikan dalam Tabel ???. Uji Shapiro-Wilk menghasilkan nilai- $p = 0,0000$, menunjukkan penyimpangan signifikan dari normalitas distribusi pada tingkat 5

Meskipun diagnostik menunjukkan penyimpangan dari asumsi normalitas, distribusi residual tetap menunjukkan pusat pada nilai nol dengan mean observasi sebesar 0,0048, mengindikasikan bahwa estimator bersifat *unbiased*. Heteroskedastisitas yang diidentifikasi dapat ditangani melalui beberapa pendekatan: pertama, penggunaan standar error yang adjusted untuk heteroskedastisitas seperti *Huber-White sandwich estimator*; kedua, transformasi logaritmik pada variabel respons untuk memperkecil jarak skala; ketiga, penggunaan *weighted least squares* dengan bobot yang berkorelasi dengan magnitude prediksi.

Inspeksi visual distribusi residual dan plot Q-Q (Gambar ??) menunjukkan kehadiran ekor yang lebih berat pada kedua ujung distribusi, konsisten dengan kehadiran nilai-nilai ekstrim dan heteroskedastisitas yang dideteksi melalui uji diagnostik formal. Scatter plot antara nilai prediksi dan residual menunjukkan pola corong (*funnel pattern*) yang melebar seiring peningkatan magnitude prediksi, mengkonfirmasi heterogenitas variansi residual di sepanjang range nilai prediksi.

Secara keseluruhan, analisis empiris pada data BI-SEKDA menunjukkan bahwa metodologi pemodelan spasial berbasis GWR dan GA-GWR, dengan validasi mendalam meliputi uji signifikansi lokal, tipologi spasial melalui clustering, dan diagnostik residual komprehensif, menyediakan instrumen yang valuable untuk mengkaji heterogenitas geografis dalam determinan aksesibilitas kredit UMKM

dan mengidentifikasi implikasi kebijakan yang berbasis bukti dan efektif di tingkat regional Indonesia. Keterbatasan jangka waktu observasi (20 bulan), definisi spasial berbasis geografis murni (tanpa konektivitas ekonomi), dan superior performance GWR relatif terhadap GA-GWR membuka peluang penelitian lanjutan dengan data jangka panjang, bobot spasial berbasis ekonomi, dan eksplorasi hibrid antara kernel adaptif dengan pembelajaran neural network.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan pembahasan sebelumnya serta analisis yang telah dilakukan, diperoleh kesimpulan sebagai berikut.

1. Kesimpulan 1.
2. Kesimpulan 2.
3. Kesimpulan 3.

5.2 Saran

Saran untuk penelitian selanjutnya

DAFTAR PUSTAKA

- Amri, M. Z. A. (2020). Perbandingan model star dan gstar untuk peramalan indeks harga konsumen di kota padang, pekanbaru, jambi, dan Palembang. *MEDI-AN*, 4(1), 30–37.
- Anselin, L. (1988). *Spatial Econometrics: Methods and Models*. Dordrecht: Kluwer Academic Publishers. doi: 10.1007/978-94-015-7799-1
- Ash, R. B. (1972). *Real analysis and probability*. New York: Academic Press.
- Axler, S. (2024). *Linear Algebra Done Right* (4th ed.). Cham: Springer. doi: 10.1007/978-3-031-41026-0
- Billingsley, P. (1995). *Probability and measure* (3rd ed.). New York: Wiley.
- Bishop, C. M. (1995). *Neural networks for pattern recognition*. Oxford: Oxford University Press.
- Bronstein, M. M., Bruna, J., Cohen, T., dan Veličković, P. (2021). Geometric deep learning: Grids, groups, graphs, geodesics, and gauges.. Diambil dari <https://arxiv.org/abs/2104.13478>
- Brüel-Gabrielsson, R. (2020). *Universal function approximation on graphs*. Diambil dari <https://arxiv.org/abs/2003.06706>
- Chung, F. R. K. (1997). *Spectral graph theory*. Providence, RI: American Mathematical Society.
- Cybenko, G. (1989). Approximation by superpositions of a sigmoidal function. *Mathematics of Control, Signals and Systems*, 2(4), 303–314. doi: 10.1007/BF02551274
- Dhrymes, P. J. (2013). *Mathematics for Econometrics* (4th ed.). New York: Springer. doi: 10.1007/978-1-4614-8145-4
- Dudley, R. M. (2002). *Real analysis and probability*. Cambridge: Cambridge University Press.
- Fan, J., dan Gijbels, I. (1996). *Local polynomial modelling and its applications*.

- London: Chapman and Hall/CRC.
- Fotheringham, A. S., Brunsdon, C., dan Charlton, M. (2002). . Chichester: Wiley.
- Fotheringham, A. S., Yang, W., dan Kang, W. (2017). Multiscale geographically weighted regression (mgwr). *Annals of the American Association of Geographers*, 107(6), 1247–1265.
- Goodfellow, I., Bengio, Y., dan Courville, A. (2016). *Deep learning*. Cambridge, MA: MIT Press. Diambil dari <http://www.deeplearningbook.org>
- Greene, W. H. (2002). *Econometric Analysis* (5th ed.). Upper Saddle River, New Jersey: Pearson Education.
- Hagenauer, J., dan Helbich, M. (2022). Geographically weighted artificial neural networks: A framework for non-linear local modelling. *International Journal of Geographical Information Science*, 36(2), 231–252.
- Hamilton, W., Ying, R., dan Leskovec, J. (2017). Inductive representation learning on large graphs. In *31st conference on neural information processing systems (neurips)*. Diambil dari <https://arxiv.org/abs/1706.02216>
- Haykin, S. (2009). *Neural networks and learning machines* (3rd ed.). New York: Prentice Hall.
- Horn, R. A., dan Johnson, C. R. (2012). *Matrix Analysis* (2nd ed.). Cambridge: Cambridge University Press. doi: 10.1017/CBO9781139020411
- Huang, B., Wu, B., dan Barry, M. (2010). Geographically and temporally weighted regression for modeling spatio-temporal variation in house prices. *International Journal of Geographical Information Science*, 24(3), 383–401.
- Kipf, T. N., dan Welling, M. (2017). Semi-supervised classification with graph convolutional networks. In *5th international conference on learning representations (iclr)*. Diambil dari <https://arxiv.org/abs/1609.02907>
- Lang, S. (1987). *Linear Algebra* (3rd ed.). New York: Springer. doi: 10.1007/978-1-4757-1949-9
- LeSage, J. P., dan Pace, R. K. (2009). *Introduction to Spatial Econometrics*. Boca Raton, FL: CRC Press.

- Leung, Y., Mei, C.-L., dan Zhang, W.-X. (2000). Statistical tests for spatial non-stationarity based on the geographically weighted regression model. *Environment and Planning A*, 32, 9–32.
- Montgomery, D. C., Peck, E. A., dan Vining, G. G. (2012). (5th ed.). Hoboken, NJ: Wiley.
- Nair, V., dan Hinton, G. E. (2010). Rectified linear units improve restricted boltzmann machines. In *Proceedings of the 27th international conference on machine learning (icml)* (pp. 807–814).
- Ni, X., Wu, H., dan Zhang, X. (2022). Sannwr: Spatial and attribute neural network weighted regression for modeling complex spatial heterogeneity. *International Journal of Geographical Information Science*, 36(7), 1401–1426.
- Pishro-Nik, H. (2014). *Introduction to probability, statistics, and random processes*. Kappa Research, LLC.
- Ross, S. M. (1972). *Introduction to probability models* (6th ed.). USA: Academic Press.
- van der Vaart, A. W. (1998). *Asymptotic statistics*. Cambridge: Cambridge University Press.
- Veličković, P., Cucurull, G., Casanova, A., Romero, A., Liò, P., dan Bengio, Y. (2018). Graph attention networks. In *6th international conference on learning representations (iclr)*. Diambil dari <https://arxiv.org/abs/1710.10903>
- Wooldridge, J. M. (2020). *Introductory Econometrics: A Modern Approach* (7th ed.). Boston, MA: Cengage.
- Xu, K., Hu, W., Leskovec, J., dan Jegelka, S. (2019). How powerful are graph neural networks? In *7th international conference on learning representations (iclr)*. Diambil dari <https://arxiv.org/abs/1810.00826>
- Yan, J., Li, Z., dan Gao, P. (2024). Anisotropic geographically weighted regression for directional spatial processes. *International Journal of Geographical Information Science*.
- Yin, P., Huang, B., Du, Z., Wu, H., et al. (2024). Gnnwr: An r package for geogra-

phically neural network weighted regression and its spatiotemporal extension. *Journal of Geographical Systems*.

Yu, H., Wang, F., dan Li, Z. (2020). Borrowing strength in geographically weighted regression. *Spatial Statistics*, 38.

Zhu, D., Liu, Y., Yao, X., dan Fischer, M. M. (2022). Spatial regression graph convolutional neural networks (srgcnns). *GeoInformatica*, 26(3), 557–582.

LAMPIRAN A

Data

LAMPIRAN B

Syntax R

```
1 SYNTAX R ALALALALALLALA
```